

Entwicklung probabilistischer Modelle zur Abbildung unsicherer Randbedingungen in der Gebäudesimulation

Development of Probabilistic Models for the Representation of Uncertain Boundary Conditions in Building Performance Simulation

Wissenschaftliche Arbeit zur Erlangung des Grades

Master of Science

an der TUM School of Engineering and Design der Technischen Universität München.

Studiengang M.Sc. Ressourceneffizientes und Nachhaltiges Bauen

Betreut von
Laura Franke, M.Sc.
Prof. Dipl. Ing. Thomas Auer

Lehrstuhl für Gebäudetechnologie und klimagerechtes Bauen

Eingereicht von
Roman Ficht
Knollerstraße 3
80802 München

Eingereicht am München, den 15.07.2022

Anhang I

Erklärung

Ich versichere hiermit, dass ich die von mir eingereichte Abschlussarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

München, 15.07.2022, Unterschrift

Inhaltsverzeichnis

Kurzzusammenfassung	III
Abstract.....	IV
Glossar	V
Abkürzungsverzeichnis.....	VII
Symbolverzeichnis	VIII
1 Unsichere Randbedingungen in der Gebäudesimulation	1
1.1 Problemstellung	1
1.2 Hypothese und Forschungsfrage	4
1.3 Umfang und Aufbau der Arbeit.....	4
2 Probabilistische Verfahren in der Gebäudesimulation.....	5
2.1 Grundlagen der Gebäudesimulation	5
2.2 Probabilistische Modelle zur Beschreibung des Nutzungsverhaltens.....	6
2.3 Statistische Grundlagen	9
3 Methode und Workflow	14
3.1 Datenanalyse	14
3.2 Modellierung	15
3.3 Simulation.....	19
4 Auswertung der Messdaten	21
4.1 Aufbereitung der Daten.....	21
4.2 Auswertung der Messdaten	35
5 Entwicklung probabilistischer Steuerungsmodelle	55
5.1 Empirische Analyse der Fensteröffnung	55
5.2 Monte-Carlo-Simulation	59
5.3 Logistische Regression.....	62
5.4 Ergebnisse.....	70
6 Einordnung der Ergebnisse	77
7 Ausblick	81
Literaturverzeichnis	82
Abbildungsverzeichnis	91
Tabellenverzeichnis	92

Anhang A	Messkonzept	93
A.1	Sensorverzeichnis	93
A.2	Sensorplan	94
Anhang B	Zusätzliche Auswertungen des Datensatzes	97
B.1	Missing Data	98
B.2	Übersicht der Messungen in einer Wohnung	107
B.3	Übersicht Wetterdaten	108
B.4	Beispiel der verwendeten adaptiven Komfortgraphen	109
B.5	Clustering der Heizkörperaktivierung zur Ermittlung von Heiztagen	110
B.6	Clustering des Anwesenheitssignals zur Ermittlung von länger Nichtnutzung..	113
Anhang C	Simulation	114
C.1	Bauweisen	114
C.2	Materialien	115
C.3	Wandaufbauten	116
C.4	Wetterdatensatz	117
Anhang D	Digitaler Anhang	118

Kurzzusammenfassung

Der *Performance Gap* in der Gebäudesimulation kann unterschiedliche Ursachen haben. Neben unerwarteten externen Einflüssen oder Fehler in der Gebäudetechnik kann Heterogenität im Nutzungsverhalten der Nutzer:innen dazu führen, dass die simulierten energetischen und thermischen Parameter nicht mit den tatsächlich gemessenen Werten übereinstimmen. Diese Heterogenität wird durch die immer komplexere Gebäudetechnik verstärkt. Tatsächlich werden in der Gebäudesimulation deterministische Werte als Eingangsparameter genutzt. Im Rahmen dieser Arbeit wird untersucht, ob stochastische Modelle dazu geeignet sein können, das Nutzungsverhalten in der Gebäudesimulation abzubilden. Dazu werden *in situ* Messdaten aus dem Forschungsprojekt *Einfach Bauen* genutzt, um das Nutzungsverhalten unabhängig von der Gebäudetechnik statistisch zu beschreiben.

Zunächst werden die gesammelten Daten aufbereitet und im Rahmen einer deskriptiven statistischen Auswertung im Hinblick auf den thermischen Komfort und des Nutzungsverhaltens ausgewertet. Davon ausgehend werden probabilistische Modelle entwickelt, die dann in einem parametrischen Simulationsprogramm erprobt werden.

Im Kontext der Datenaufbereitung werden dabei aus mehreren beobachteten Parametern Indikatoren für das Heizverhalten und die Anwesenheit in den beobachteten Wohnungen erstellt. Das Lüftungsverhalten wurde durch eine empirische Analyse und die Integration probabilistischer Steuerungsmodelle in eine thermisch dynamische Gebäudesimulation evaluiert. Dabei hat sich gezeigt, dass sich das Lüftungsverhalten nur schwer über äußere Randbedingungen wie die CO_2 -Konzentration oder über die Raum- bzw. Außenlufttemperatur beschreiben lässt. Vielmehr scheint, dass sich das Lüftungsverhalten vor allem nach dem Tagesablauf der Nutzer:innen richtet.

Abstract

The *performance gap* in the building performance simulation can have different causes. In addition to unexpected external influences or errors in the HVAC system, heterogeneity in the user's behavior can lead to the simulated energy and thermal parameters not matching the in situ measured values. This heterogeneity is exacerbated by increasingly complex building technology. In fact, deterministic values are used as input parameters in building simulation. In the context of this work, it is investigated whether stochastic models can be used to represent the utilization behavior in the building performance simulation. For this purpose, in situ measurement data from the research project *Einfach Bauen* is used to statistically describe the utilization behavior independently of the building technology.

First, the collected data is processed and evaluated in the context of a descriptive statistical evaluation with regard to thermal comfort and user behavior. Based on this, probabilistic models are developed, which are then tested in a parametric simulation program.

In the context of data preprocessing, indicators for heating behavior and occupancy in the observed apartments are derived from several observed parameters. The ventilation behavior was analyzed empirically, and probabilistic control models were integrated into a thermal dynamic building simulation. This showed that ventilation behavior is difficult to describe by external boundary conditions such as CO_2 -concentration or by room or outdoor air temperature. Rather, it seems that the ventilation behavior is mainly determined by the daily routine of the users.

Glossar

adaptives Komfortmodell nach DIN EN 16798-1:2022

Standardwerte für zulässige Innentemperaturen für Gebäude ohne maschinelle Kühlanlagen. Im Rahmen dieser Arbeit wird hier die Komfortkategorie II verwendet. Dieses Modell ist erst ab einer mittleren Außenlufttemperatur von $>10^{\circ}\text{C}$ definiert und damit nur für den Sommerfall relevant. 1, 34, 43, 87

adaptives Komfortmodell nach DIN EN 16798-1:2022 - NA

Empfohlene operative Raumtemperaturen für Räume, in denen die Nutzer:innen ihre Bekleidung anpassen können. Um die Komfortkategorie KAT II einzuhalten, dürfen die Komforttemperaturen für nicht mehr als 1 % der Nutzungszeit mehr als 2 K außerhalb des Komfortbandes liegen. Dieses Modell ist vorwiegend für den Winterfall relevant. 1, 34, 43, 72, 87

diskrete Variable

Eine Variable ist diskret, wenn sie endliche oder unendlichzählbare Ausprägungen annehmen kann (z.B. Anzahl der Fensteröffnungen). 1, 12

hx-Diagramm

Ermöglicht die Darstellung und Ermittlung von Zustandsänderungen feuchter Luft durch Veränderungen der Lufttemperatur und Feuchte. Es wird die abs. Feuchte gegen die Raumlufttemperatur aufgetragen. Über dargestellte Isobaren, lassen sich die rel. Luftfeuchten ablesen. Die Darstellung in dieser Arbeit erfolgt in Form von Histogrammen, d.h. anhand der Stärke der Färbung im Diagramm kann abgelesen werden, wie viele Messpunkte in diesem Bereich liegen. Der Komfortbereich wird nach DIN 15251:2012 definiert. 1

kategorische Variable

Eine Variable ist kategorisch, wenn sie sich einer endlichen Anzahl an Gruppen zuordnen lässt (z.B. Jahreszeit). 1

KMeans Algorithmus

Clustering-Algorithmus, welcher n Beobachtungen in k Gruppen teilt. Das Gruppenzugehörigkeitskriterium ist hierbei das arithmetische Mittel (mean) bzw. die Varianz. 1, 36, 48

Prädiktor

Auch unabhängige Variable ist eine Variable, die genutzt wird um eine andere vorherzusagen. 1

Referenzwohnung

Als Referenzappartments dienen im die unbewohnten Einzimmerappartement im 2.OG jeden Hauses. 1, 22

robust

Beschreibung für einen Gegenstand, der durch seine widerstandsfähig und strapazierfähig auch in der Nutzung zugänglich ist. 1, 3

Sensitivität und Spezifität

Sensitivität beschreibt die Genauigkeit eines statistischen Tests im Hinblick auf die Wahrscheinlichkeit einen wahren (korrekt) positiven Test zu ermitteln (bezeichnet als $1 - \beta$) während die Spezifität die Genauigkeit im Hinblick auf die Wahrscheinlichkeit einen wahren (korrekt) falschen Tests bezeichnet ($1 - \alpha$).^{1, 17}

sichere Randbedingung

Eine Randbedingung die sich im Laufe der Simulation nicht verändert, oder die vorab als unveränderlich festgelegt werden kann.^{1, 2}

stetige Variable

Eine Variable ist stetig, wenn sie unzählbare Anzahl an Ausprägungen annehmen kann. Die Wahrscheinlichkeit des Auftretens jedes einzelnen Werts geht gegen Null (z.B. Temperatur).^{1, 12}

unsichere Randbedingung

Eine Randbedingung die sich im Laufe der Simulation nicht verändert, oder die vorab als unveränderlich festgelegt werden kann.^{1, 2}

Variance Inflation Factor (VIF)

Der Faktor der Varianz, der in einer Regression mit mehreren Prädikatoren durch die Korrelation dieser erklärt wird (Multikollinearität)^{1, 18, 64, 65}

Abkürzungsverzeichnis

A

Abk. Abkürzungen

arth. Mittel arithmetische Mittel

B

B Bad

Bez. Bezeichnung

C

CDF Verteilungsfunktion

D

DWD Deutscher Wetterdienst

F

F Flur

H

HoY Hour of Year

I

IQR Interquartilsabstand

K

K Küche

L

LB Leichtbeton

M

MC-Simulaton Monte-Carlo-Simulation

MH Massivholz

MW Mauerwerk

N

N Wohnung Nord

NA nationaler Anhang

neg. negativ

O

O Referenzwohnung Ost

P

PDF Dichtefunktion

PG Performance Gap

pos. positiv

R

ref. referenz

S

S Wohnung Süd

SWK Schlafen, Wohnen und Kochen

SZ Schlafzimmer

T

TGA technische Gebäudeausrüstung

TRY Testreferenzjahr

U

ÜTGS Übertemperaturgradstunden

UTGS Untertemperaturgradstunden

U-Wert Wärmedurchgangskoeffizient

W

WZ Wohnzimmer

Symbolverzeichnis

Bezeichnung	Beschreibung	Symbol
ACR	Luftwechselrate	1/h
\bar{x}	arithmetisches Mittel	-
μ	Erwartungswert	-
g_{abs}	absolute Luftfeuchte	g/kg
HK_{IO}	Heizkörperstatus	-
\vee	Logisches <i>oder</i>	-
\wedge	Logisches <i>und</i>	-
MRT	Mittlere Strahlungstemperatur	°C
rH, rH_{amb}	relative Luftfeuchte	%
σ	Standardabweichung	-
T_{air}, T_{amb}	(Raum-)Lufttemperatur	°C
T_{HK}	Oberflächentemperatur des Heizkörpers	°C
T_{op}	operative Raumtemperatur	°C
$T_{set,est.}$	angenommene Thermostateinstellung des Heizkörpers	°C
T_{SK}	Schwarzkugeltemperatur	°C

1. Unsichere Randbedingungen in der Gebäudesimulation

Gebäude sind für ca. 35 % des gesamten Endenergieverbrauchs in Deutschland verantwortlich (Deutsche Energie-Agentur GmbH, 2021). Zur Erreichung der Pariser Klimaziele ist es unerlässlich, diesen Anteil zu reduzieren. Im Zuge dessen ist es wichtig, bereits in der Planung möglichst akkurate Vorhersagen über den zu erwartenden Energiebedarf eines Gebäudes treffen zu können. Nur so lassen sich präzise Einsparmaßnahmen treffen. Heute tritt dabei oft ein als Performance Gap (PG) bezeichnetes Problem auf. Dabei handelt es sich um Abweichungen zwischen den in der Planung berechneten Parametern und den in der Realität erzielten Größen. Häufig wird dabei der Energieverbrauch unterschätzt (Ioannou & Itard, 2015). Die Gründe dafür können vielfältiger Natur sein. Häufig handelt es sich technische Fehlfunktionen, unerwartete Wetterereignisse oder das Nutzungsverhalten des Gebäudes (Shi et al., 2019).

Die Verbrauchswerte von Gebäuden werden heute häufig durch thermisch dynamischer Gebäudesimulation ermittelt. Diese bieten gegenüber den herkömmlich verwendeten statischen Verfahren des Bundesministerium für Wohnen, Stadtentwicklung und Bauwesen (2020), dass sie wesentlich genauer arbeiten können. Dabei arbeiten sie dennoch häufig mit deterministischen Größen, Erfahrungs- oder Mittelwerten. Dies führt oft dazu, der Energieverbrauch eines Gebäudes unterschätzt wird. Insbesondere in Anbetracht immer komplexer werdender Gebäudeausstattungen liegen die Berechnungen unter zu Hilfenahme dieser statischen Größen oft weit daneben (Macdonald, 2002).

Im Rahmen dieser Arbeit soll anhand von Messdaten aus dem Forschungsprojekt *Einfach Bauen* untersucht werden, wie das Verhalten der Nutzer:Innen realitätsnäher in einer Gebäudesimulation abgebildet werden kann. Dazu werden in einem ersten Schritt die gewonnenen Daten aufbereitet. Im nächsten Schritt erfolgt im Rahmen einer deskriptiven statistische Auswertung eine Beschreibung des thermischen Komforts und des beobachteten Nutzungsverhaltens. Davon ausgehend sollen probabilistische Modelle entwickelt werden, die dann in einer angepassten Simulationsumgebung simuliert werden.

1.1. Problemstellung

Thermisch dynamische Gebäudesimulationen (in dieser Arbeit kurz: Gebäudesimulationen) sind ein wichtiges Planungstool zur Ermittlung des Energieverbrauchs und des zu erwartenden thermischen Komforts eines geplanten Gebäudes. Im Vergleich zu statischen Bilanzverfahren wie z. B. dem Monatsbilanzverfahren nach GEG (Bundesministerium für Wohnen, Stadtentwicklung und Bauwesen, 2020) haben thermisch dynamische Verfahren den Vorteil auch kurzzeitige Effekte auf das Raumklima abzubilden. Dadurch lassen sich insbesondere

bezogen auf den thermischen Komfort präzisere Aussagen treffen.

Gebäudesimulation

Gebäudesimulationsprogramme arbeiten i. d. R. deterministisch. Das bedeutet, jede durchgeführte Simulation stellt eine Momentaufnahme unter den gegebenen Parameter dar. Jede erneute Berechnung mit den gleichen Eingangsgrößen führt zum selben Ergebnis.

Wichtige Parameter sind dabei die Geometrie, die Baukonstruktion, die technische Gebäudeausstattung technische Gebäudeausrüstung (TGA), das Wetter sowie die Art der Nutzung.

Parameter wie die Geometrie, die Baukonstruktion oder Materialeigenschaften werden i. d. R. einmal festgelegt und ändern sich im Laufe der Lebensdauer eines Gebäudes i. d. R. nicht. Im Rahmen dieser Arbeit werden diese Parameter als sichere Randbedingung bezeichnet. Andere Parameter wie das Wetter oder die Art der Nutzung können nicht einfach a priori festgelegt werden. Sie können während der Nutzungszeit eines Gebäudes z. T. stark schwanken und müssen daher in der Gebäudesimulation approximiert werden. Zur Festlegung dieser – im weiteren Verlauf der Arbeit unsichere Randbedingung genannten Größen gibt es verschiedene Herangehensweisen.

Das Wetter wird bspw. über die sogenannten Testreferenzjahre (TRY) abgebildet. Diese werden vom Deutschen Wetterdienst (DWD) bereitgestellt und sollen dabei einen typischen Witterungsverlauf in Form von mittleren Werten dar (Deutscher Wetterdienst, n. d.). Parameter, die sich während der Simulation ändern können, oder die prognostiziert werden müssen werden. Während sich das Wetter noch relativ gut prognostizieren lässt, ist das Nutzungsverhalten eines Gebäudes nur bedingt Vorhersagbar. Hier muss in der Regel auf Erfahrungs- oder Normwerte Normwerken wie z. B. der *SIA 2024, 2021*, der *DIN V 18599-1, 2018* oder der *ANSI/ASHRAE Standard 55, 2010* verwendet. Diese arbeiten oft mit Mittelwerten und Faktoren und haben das Ziel im Mittel ein möglichst repräsentatives Ergebnis zu erzielen, liefern damit allerdings immer nur ein Ergebnis für ein mögliches unter vielen Szenarien (Maderspacher, 2017). Insbesondere bei Gebäuden mit einem hohen energetischen Standard sind die Ergebnisse von Gebäudesimulationen unter diesen standardisierten Parametern jedoch oft nicht realitätsnah (Ioannou & Itard, 2015). Die Betrachtung von Modellunsicherheiten bekommt daher in der Forschung zur Gebäudesimulation immer mehr Aufmerksamkeit (Burhenne et al., 14–2011).

Performance Gap

Die beschriebenen Modellunsicherheiten tragen ihren Teil zum eingangs erwähnten Performance Gap (PG) bei. Unter dem PG versteht man klassischerweise die Diskrepanz zwischen der in der Planung berechneten Energieverbrauchs und dem in der Realität tatsächlich auftretenden Energieverbrauchs eines Gebäudes (de Wilde, 2014). Dabei kann dieses Konzept ebenso auf den thermischen Komfort, den ökologischen Fußabdruck oder andere Parameter von Gebäuden übertragen werden (Shi et al., 2019). Nach Mojic et al. (2018) lässt sich der

PG in vier Ursachengruppen unterteilen:

- Der *Ambient-Gap* beschreibt Faktoren die durch Abweichungen der Umgebungsbedingungen verursacht werden,
- der *User-Gap* beschreibt die Abweichungen, die durch unvorhergesehenes Nutzungsverhalten verursacht wird,
- Der *Norm-Gap* beschreibt Abweichungen die durch falsche Annahmen in den Normwerken verursacht werden und
- der *Technical-Gap* beschreibt alle Faktoren die durch Fehler in der Gebäudetechnik oder Bauausführung begründet liegen.

Während es bei Sichtung der Literatur weitgehend Konsens zu sein scheint, dass der PG existiert, so ist die exakte Ursachenforschung und dessen Quantifizierung immer noch Gegenstand der Forschung (Shi et al., 2019).

Mojic et al. (2018) bezeichnen in ihrer Arbeit z. B. den *Technical Gap* als "Performance Gap im eigentlichen Sinne". Dieser Annahme folgen auch Forschungsprojekte wie *Robuste, Nutzerfreundliche Und Kostengünstige TGA in Gebäuden* (T. Auer et al., 2021) oder *Einfach Bauen I* (Nagler et al., 2018). Beide versuchen durch robustere Bauweisen und oder TGA weniger Fehlfunktionen und Ausfälle zu provozieren, um dadurch die *Technical-Gap* zu verkleinern.

Beschreibung des Forschungsprojekts

Im Rahmen des Projektes *Einfach Bauen I* wurde bereits in der Planung versucht dem PG entgegenzuwirken. Dazu wurde in einer parametrischen Gebäudesimulation eine Raumkonfiguration in Dimension, Materialität und Ausstattung definiert, welche eine möglichst geringe Anfälligkeit für Fehlverhalten der Nutzer:Innen oder Fehlfunktionen der TGA aufweist.

Dabei wird vor allem auf sogenannte *Low Tech*-Lösungen gesetzt. Das bedeutet, die Häuser haben z. B. besonders wenig störungsanfällige Anlagentechnik, einfache – von den Nutzer:innen kontrollierbare Heizkörper und simple Grundrisse.

Um eine möglichst *robuste* Bauweise zu finden, wurden dabei in über 2000 Simulationen alle kombinatorisch möglichen Raumdimensionen simuliert, um eine optimale Raumkonfiguration zu finden. Anschließend wurden einzelne Fehlverhaltens- oder Ausfallszenarien wie z. B. dauerhaft lüftende Nutzer:Innen oder eine defekte Verschattung simuliert. Dieses Verfahren ist an das mathematische Konzept der robusten Optimierung (Rhein, 2014) angelehnt. Es soll eine Konfiguration bestimmt werden, die rechnerisch vielleicht nicht das optimale Ergebnis liefert, jedoch in der Praxis weniger anfällig gegen unvorhersehbare Ereignisse, wodurch der PG reduziert werden soll (Nagler et al., 2018).

Aus der entwickelten Raumkonfiguration entstanden drei Entwürfe in unterschiedlichen Bau-

weisen die im Ortsteil Mietraching des bayerischen Bad Aibling als Forschungshäuser errichtet werden konnten. Um die Funktionalität und Praktikabilität der Entwürfe – in Hinblick auf den Energieverbrauch und thermischen Komfort zu evaluieren wurden vor Ort Langzeitmessungen des Raum- und Umweltklimas durchgeführt.

1.2. Hypothese und Forschungsfrage

Im Rahmen dieser Arbeit wird eine Methode entwickelt, die Daten die im Forschungsprojekt *Einfach Bauen* gewonnen wurden aufzubereiten und auszuwerten. Anhand der gewonnenen Erkenntnisse sollen Möglichkeiten aufgezeigt werden, wie unsichere Randbedingungen in der Gebäudesimulation durch probabilistische Methoden so abgebildet werden können, dass man daraus das Ausmaß des PG abschätzen kann. Daraus leiten sich die folgenden Forschungsfragen ab:

1. Lassen sich über empirische Analysen Erkenntnisse bzgl. des Nutzungsverhaltens von Wohngebäuden erzielen?
2. Können aus diesen Erkenntnissen Modelle abgeleitet werden, die unsichere Randbedingungen in der so Gebäudesimulation abbilden können?
3. Kann mithilfe der hergeleiteten Modelle die Modellunsicherheit abgeschätzt werden?

1.3. Umfang und Aufbau der Arbeit

Bei der Beantwortung der dargelegten Forschungsfragen liegt in dieser Arbeit der Schwerpunkt auf der Auswertung der Nutzungsdaten und der Implementation der Ergebnisse in eine thermisch dynamische Gebäudesimulation. Dabei wird hauptsächlich das Lüftungsverhalten untersucht, da hier im Rahmen des Forschungsprojektes eine solide Datengrundlage entstanden ist. Andere Parameter, wie z. B. das Heizverhalten kann anhand der Messdaten nur indirekt abgebildet werden und eignet sich daher zur Modellierung nur bedingt. Außerdem sind die Messungen des Energieverbrauchs (Wärme und Strom) der Gebäude erst wesentlich später, als die des Raumklimas gestartet. Dadurch ist hier die Datengrundlage zum aktuellen Zeitpunkt noch nicht ausreichend. Das Thema Wetter wird in dieser Arbeit auch nur peripher betrachtet. Selbstverständlich sind alle gewonnenen Erkenntnisse vom Klima während der Beobachtung beeinflusst. Es findet jedoch keine Extrapolation der Modelle auf andere Klimazonen oder im Hinblick auf zukünftige Klimaveränderungen statt. Die zu entwickelten Verfahren, sollen jedoch methodisch z. B. auch auf die unsichere Randbedingung Wetter angewendet werden können.

2. Probabilistische Verfahren in der Gebäudesimulation

Gebäudesimulationen können mit der Hilfe von einer Fülle an verschiedenen Tools durchgeführt werden. Wichtige Vertreter sind dabei *IDA ICE*, *EnergyPlus* und *TRNSYS*. Während *IDA ICE* und *TRNSYS* kommerzielle Software sind, handelt es sich bei *EnergyPlus* um ein Open-Source-Projekt. Dennoch bieten alle diese drei Softwarepakete einen vergleichbaren Umfang an Funktionen an und erlauben erfahrenen Nutzer:innen das Erstellen von selbst definierten Programmteilen und Berechnungen (Gaetani et al., 2016).

Das Paket *TRNSYS* kann über das Open Source Plugin für Grasshopper *TRNLizard* in die 3D-Modellierungssoftware *Rhinoceros3D* integriert werden. Dabei dient *TRNLizard* als sogenannter Wrapper um Inputdateien für die thermisch dynamische Simulationsengine *TRNSYS* in Grasshopper zu erzeugen. Dies ermöglicht es, die Gebäudesimulation in eine parametrische Gebäudemodellierung zu integrieren. Durch die flexibel gestaltete Python-Schnittstelle können darüber hinaus erfahrene Nutzer:innen eigene Komponenten und Berechnungen in die Simulation integrieren (Frenzel & Hiller, 2014).

2.1. Grundlagen der Gebäudesimulation

Dennoch arbeiten alle diese Programme in der Regel deterministisch, d.h. die Simulationen folgen festen Regeln und Eingangsparametern. Dabei gibt es zwei wesentliche Steuerungsmechanismen: Hysteresen und Schedules.

Exemplarisch wird hier die voreingestellte Hysterese zur Steuerung der Fensterlüftung von *TRNLizard* vorgestellt. Diese wird über den TRNSYS-Type168 *Natural Ventilation* abgebildet. Dieser kombiniert zwei Hysteresen: Die erste aktiviert die Komponente. Dabei wird eine obere und eine untere Grenze für die Raumlufttemperatur festgelegt. Liegt die Raumlufttemperatur über der oberen Grenze ist die Komponente aktiviert, liegt die Temperatur unter der unteren Grenze wird die Komponente deaktiviert. Der zweite Mechanismus steuert nun den eigentlichen Lüftungsvorgang. Dieser wird in Gang gesetzt, wenn die Differenz zwischen Außen- und Raumluft einen oberen Grenzwert überschreitet. Unterschreitet diese Differenz die untere Grenze, wird die Lüftung wieder beendet. Die voreingestellten Werte können Tabelle 2.1 entnommen werden.

Zusätzlich zur Hysterese kann noch ein Schedule, der Anwesenheit im Raum induziert, hinterlegt werden. Schedules sind vordefinierte Zeitreihen, die einem bestimmten Intervall, z.B. für jede Stunde eines Tages oder jeden Monat eines Jahres, einen Faktor zuweisen. Dabei kann zwischen binären [0,1] und proportionalen Signalen [0 bis 1] unterschieden. Binäre Schedules können beispielsweise als Steuerungssignal, proportionale Schedules als

Tabelle 2.1 Parameter der Hysteresen zur Steuerung der natürlichen Lüftung. Voreinstellung des Templates von Frenzel (2019)

Kriterium		Wert	Einheit
Raumlufttemperatur	obere Grenze	25,0	°C
	untere Grenze	22,0	°C
Temperaturdifferenz (Außen, Innen)	obere Grenze	1,5	K
	untere Grenze	0,0	K

Gewichtungsfaktoren verwendet werden.

Diese Steuerungsmethoden setzen voraus, dass feste Regeln oder Werte zur Beschreibung eines Parameters bekannt sind. Da dies oft nicht der Fall ist, werden in der Praxis Erfahrungswerte verwendet oder Annahmen getroffen.

Diese Annahmen bilden jedoch oft nur eine Teilmenge aller möglichen Lösungen ab und lassen nicht immer einen Schluss auf die Gesamtmenge zu. Dadurch entstehen sogenannte Modellunsicherheiten.

2.2. Probabilistische Modelle zur Beschreibung des Nutzungsverhaltens

Eine Möglichkeit um Modellunsicherheiten zu quantifizieren, ohne dabei alle möglichen Lösungen ausrechnen zu müssen, ist die Beschreibung der Unsicherheiten über sogenannte probabilistische Modelle. Probabilistische Modelle (von latein. *probabilis* = glaublich, wahrscheinlich) bilden einen bestimmten Teil der Realität mit Hilfe mathematische Zusammenhänge in Form von Wahrscheinlichkeiten ab. Diese Zusammenhänge können durch Daten, die z.B. durch Beobachtungen oder Messungen, gewonnen werden, etabliert werden (Hájek, 2019).

Im Bereich der Gebäudesimulation finden diese Modelle noch relativ wenig Anwendung. Problematisch ist dabei stets die Datengrundlage, welche erst durch Messungen oder Beobachtungen hergestellt werden muss. Die meisten Studien zu probabilistischen Modellen betreffen das Nutzungsverhalten in Gebäuden (Gaetani et al., 2016).

Wie bereits in den beiden vorangegangenen Abschnitten beschrieben, spielt das Nutzungsverhalten bei der Gebäudesimulation eine entscheidende Rolle. Nicht nur ist es schwer in Form deterministischer Größen zu beschreiben, es trägt auch in nicht unerheblichem Umfang zum Performance Gap bei (Shi et al., 2019). Andersen et al. (2007) haben in Simulationen herausgefunden, dass das Nutzungsverhalten den Energieverbrauch eines Gebäudes um bis

zu 300 % beeinflussen kann.

Zu den wichtigsten Faktoren des Nutzungsverhaltens gehören dabei nach Gaetani et al. (2016) die Anwesenheit, die Steuerung des Lichtes und der Verschattung, die Handhabung der Klimaanlage sowie die Nutzung der Heizung oder die Öffnung der Fenster.

Es gibt unterschiedliche Ansätze, wie das Nutzungsverhalten in mathematische Modelle formuliert werden kann. Carlucci et al. (2020) führen eine breite Literaturanalyse durch und dabei in Bezug auf das Nutzungsverhalten als häufigsten Methoden logistische Regressions (auch: Logit Model), Markov-Ketten und Neurale-Netzwerke ermittelt. Dabei basieren die meisten der gefundenen Modelle (67 %) auf gesammelten Messdaten, gefolgt von 15 % Simulationsdaten, sowie Umfragen und andere. Durchgeführt wurden die Untersuchungen zu 45 % in Bürogebäuden und zu 33 % in Wohngebäuden.

Exemplarisch sei hier die Studie von Andersen et al. (2013) genannt. Diese haben im Jahr 2008 Messungen des Nutzungsverhaltens durchgeführt und diese Messungen mit Befragungen der Nutzer:innen kombiniert. Anhand der erhobenen Daten stellen sie mithilfe eines Logit-Models mehrere Modelle zur Beschreibung des Fensteröffnungs- und schließungsverhaltens auf. Dabei wird festgestellt, dass in ihren Modellen die CO_2 -Konzentration den größten Einfluss auf die Fensteröffnung und die Außenlufttemperatur den größten Einfluss auf die Fensterschließung haben.

Eine ähnliche Studie wurde von Calì et al. (2016) durchgeführt. Hier wurden in Deutschland mehrere Wohnungen über einen Zeitraum von über einem Jahr vermessen und schließlich anhand einer logistischen Regression herausgefunden, dass die Treiber der Fensteröffnung die Tageszeit und die CO_2 -Konzentration sind. Für die Treiber der Fensterschließung wurden die mittlere Außenlufttemperatur gefolgt von der Tageszeit ermittelt.

Bei der Sichtung der Literatur ließ sich kein eindeutiges Bild identifizieren, welche Faktoren schlussendlich wirklich maßgebend für die Interaktion der Nutzer:innen mit den Fenstern ist. Außerdem gab es nur wenige Studien, die diese Modelle auch in eine Simulationsumgebung überführt und als Steuerungssignal verwendet haben. Da die logistische Regression für jeden Zeitschritt parallel zur Simulation stattfinden muss, ist diese Methode mit einem größeren Rechen- und Implementierungsaufwand verbunden (Gaetani et al., 2016).

Neben der logistischen Regression ist auch die Monte-Carlo-Simulation (MC-Simulaton) eine häufig verwendete probabilistische Methode. Bei der MC-Simulaton werden die Eingangsgrößen einer Simulation zufällig aus einer Verteilung bestimmt. Bei wiederholter Durchführung lässt sich so ebenfalls eine gute Abbildung einer Grundgesamtheit erzielen (Burhenne, 2013). Auch im Forschungsprojekt *Robuste, Nutzerfreundliche Und Kostengünstige TGA in Gebäuden*, sowie in den Arbeiten von Meier (2020) und Schmidt, 2016 konnten mithilfe von MC-Simulaton unsichere Randbedingungen erfolgreich abgebildet werden. Die MC-

Simulaton lässt sich wesentlich einfacher in den Workflow einer Gebäudesimulation integrieren, da sie größtenteils vor der Simulation durchgeführt werden kann. Das Durchführen der MC-Simulaton schränkt jedoch die Einsatzszenarien stark ein.

Hong et al. (2018) haben eine intensive Literaturrecherche zur Implementation von (probabilistischen) Modellen zur Abbildung des Nutzungsverhaltens in die Gebäudesimulation durchgeführt. Dabei haben sie vier wesentliche Methoden ermitteln können:

1. Bei der *direkten Eingabe oder Steuerung* werden vordefinierte deterministische Signale oder Szenarien, die vor der Simulation berechnet wurden (meist aus Messungen oder Erfahrungswerten), verwendet.
2. *Eingebaute Nutzungsmodelle* sind vordefinierte Modelle, die in einigen Simulationssoftwares enthalten sind.
3. Die Nutzung von *benutzerdefinierte Funktionen* erlaubt es einfache mathematische Beziehungen über Gleichungen zu implementieren und dadurch ein Steuerungssignal abzuleiten.
4. Bei einer *Paralell Simulation* (Simultan-Simulation) wird das Nutzungsverhalten parallel zur Gebäudesimulation mit einer externen Simulation oder einem Algorythmus bestimmt und wird simultan an die Gebäudesimulation übergeben.

Dabei nimmt die Komplexität der Implementation von 1 bis 4 zu. Zudem stellen Hong et al. (2018) fest, dass bei der Anwendung von probabilistischen Verfahren am häufigsten die *Parallel Simulation* verwendet wird. Gelegentlich werden auch *eingebaute Nutzungsmodelle* verwendet, während *benutzerdefinierte Funktionen* nur eingeschränkt und die *direkte Eingabe* gar nicht geeignet sind.

Insgesamt lässt sich festhalten, dass probabilistische Verfahren eine Methode in der Gebäudesimulation sind, um Modellunsicherheiten zu quantifizieren oder zu minimieren. Dabei ist aber stets die Datengrundlage ein Problem. Außerdem kann es sehr komplex sein, solche Modelle in eine Gebäudesimulation zu integrieren und die Ergebnisse zu validieren. (Gaetani et al., 2016)

Diese Modellunsicherheiten können als Teil der sogenannten *Norm Gap* zur PG beitragen. Sie abzuschätzen kann als Indikator für den PG dienen (Shi et al., 2019).

Zunächst werden zum besseren Verständnis der in dieser Arbeit verwendeten statistischen Verfahren, einige der wichtigsten Grundbegriffe kurz erklärt.

2.3. Statistische Grundlagen

Mithilfe der deskriptive Statistik, d.h. die beschreibende Statistik, können Variablen dargestellt und Datensätze zusammengefasst werden. Hierfür werden quantitative Maße sowie grafische Darstellungen oder Diagramme genutzt.

Unter Empirischer (oder induktiver) Statistik versteht man das Generieren von neuen Informationen mittels stochastischer Methoden (Cramer & Kamps, 2020).

Im Folgenden werden die wichtigsten kurz eingeleitet und ihre Anwendung beschrieben.

2.3.1. Statistische Kenngrößen

In der Statistik wird eine bestimmte Menge an Objekten, die ein bestimmtes Merkmal tragen, durch mathematische Ausdrucksweisen beschrieben. Die Gesamtheit aller dieser Objekte wird auch Grundgesamtheit genannt. Da man in der Praxis selten alle Objekte betrachten kann (oder möchte), wird nur eine Teilmenge, eine sogenannte Stichprobe betrachtet. Anhang dieser Stichprobe kann mittels probabilistischer (oder stochastischer) Methoden auf die Grundgesamtheit geschlossen werden und so auch die unbekannten oder nicht ermittelten Kenngrößen beschrieben werden.

Stochastische Kenngrößen zeigen die Charakteristika einer Stichprobe auf und machen diese mit anderen Stichproben vergleichbar. Man unterscheidet dabei zwischen Lage- und Streuungsmaßen. Es wird dabei deutlich, ob sich eine Größe auf die Grundgesamtheit oder auf die Stichprobe bezieht (Cramer & Kamps, 2020).

Lagemaße einer Stichprobe sind z.B. der Mittelwert oder der Median. Der Wert der geläufig als *Mittelwert* oder *mean* verstanden wird, ist das arithmetische Mittel (arth. Mittel) \bar{x} . Er berechnet sich nach Gleichung 2.1. Er bezieht jede Variablenausprägung gleich gewichtet in die Ermittlung ein. (Cramer & Kamps, 2020)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2.1)$$

Das wichtigste Lagemaß einer Grundgesamtheit ist der Erwartungswert $E(x)$ oder μ . Er ist der Wert, den eine Zufallsvariable bei unendlicher Wiederholung eines Zufallsexperiments im Mittel annimmt. Er kann damit auch als arth. Mittel der Grundgesamtheit betrachtet werden.

Der *Median* \tilde{x} ist wiederum eine Kenngröße der Stichprobe. Er ist der Wert, der bei Sortierung der Ausprägungen die Stichprobe genau in der Mitte teilt, d.h. die Hälfte der Beobachtungen ist größer und die andere Hälfte kleiner als der Median. Dadurch wird der Einfluss

von Ausreißern auf den ermittelten Kennwert verringert. Er ergibt sich im Allgemeinen nach Gleichung 2.2. (Cramer & Kamps, 2020)

$$\tilde{x} = \begin{cases} x_{m+1} & \text{für ungerades } n = 2m + 1 \\ \frac{1}{2}(x_m + x_{m+1}) & \text{für gerades } n = 2m \end{cases} \quad (2.2)$$

Die Eigenschaften der beiden Größen wird an folgendem Beispiel deutlich:

Sei $T = (21, 22, 28, 21 \text{ und } 20)^\circ\text{C}$ die Stichprobe aus einer Messung der Raumlufttemperatur, deren Mittelwert errechnet werden soll. Das arith. Mittel dieser Stichprobe ist $22,4^\circ\text{C}$, der Median $21,0^\circ\text{C}$. Vier der Fünf Beobachtungen in dieser Stichprobe sind also kleiner als das arith. Mittel, wohingegen der Median zwar genau die Mitte markiert, dabei jedoch 7K kleiner als der größte Wert der Stichprobe ist.

Der Median entspricht dem 0.5 Quantil $Q_{0,5}$. Quantile teilen die Ausprägungen der Variable in Intervalle mit gleichen Wahrscheinlichkeiten. Ein häufig genutztes Quantil ist das Quartil. Quartile teilen die Ausprägung der Variable in vier gleich große Teile: das erste Quartil Q_1 entspricht dem 25. Quantil $Q_{0,25}$ und markiert das Ende des Wertebereichs in welchem sich die kleinsten 25 % der Ausprägungen befinden.

Der Interquartilsabstand (IQR) misst die Differenz zwischen dem ersten Quartil Q_1 und dem dritten Quartil Q_3 , es zeigt somit auch auf, wie breit die Streuung der Ausprägungen ist. (Wooldridge, 2016)

Die Streuung der Daten wird geläufig durch die Varianz σ^2 und ihrer Quadratwurzel, der Standardabweichung σ dargestellt. Die Varianz ist dabei die mittlere quadratische Abweichung einer Zufallsvariable mit ihrem Erwartungswert. Da der wahre Erwartungswert oft unbekannt ist, wird in der Praxis oft die sogenannte Stichprobenvarianz σ^2 verwendet. Sie ergibt sich zu nach Gleichung 2.3

$$\sigma^2 = \frac{1}{n} \sum_{i=0}^n (x_i - \bar{x})^2 \quad (2.3)$$

Die Standardabweichung σ ist die Wurzel der Varianz und hat den Vorteil, dass sie in der gleichen Einheit wie die Variablen ausgedrückt wird und dadurch gut zu veranschaulichen ist. (Cramer & Kamps, 2020)

2.3.2. Darstellungsweisen

Zur grafischen Darstellung der Häufigkeit diskreter Variablen zeigt das Histogramm (vgl. Abbildung 2.1) auf in welchen Intervallen (sog. *bins*) wie viele Beobachtungen gemessen werden. Die Häufigkeit kann sowohl in absoluten als auch in relativen Häufigkeiten (welche sich dann zu 1 bzw. 100 % aufsummieren) dargestellt werden.

Die Ausprägungen der Variable werden in einem ersten Schritt in Intervalle/*bins* eingeteilt. In einem zweiten Schritt wird die Häufigkeit der Ausprägungen in den einzelnen Intervallen errechnet.

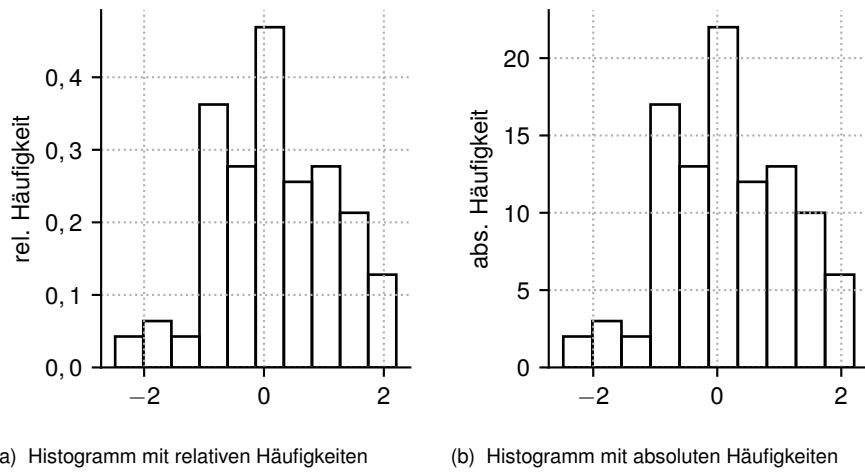


Abbildung 2.1 Histogramme einer Stichprobe ($n=100$) aus einer Normalverteilung ($\mu = 0, \sigma = 1$).

Um sowohl die Lage als auch die Streuung darzustellen, werden *Boxplots* genutzt. Die Streuung der Daten wird anhand der Linie, dem *Whisker* und der Position der Box dargestellt. Die Länge der Box entspricht dem Interquartilsabstand (IQR), in der Box ist in der Regel der Median eingezeichnet. Manchmal kann es sinnvoll sein zusätzlich das arth. Mittel zu markieren. Im Abbildung 2.2 findet sich ein exemplarisches Boxplot. Hier ist der Median als durchgezogene und das arth. Mittel als gestrichelte Linie eingezeichnet. Der Whisker ist eingegrenzt von definierten Minimal- und Maximalwerten: Das Minimum ist üblich definiert als die Differenz des ersten Quartils und des 1,5-fachen des Interquartilsabstands ($Q_1 - 1.5 * IQR$) während das Maximum der Summe des dritten Quartils und des 1,5-fachen des Interquartilsabstands entspricht ($Q_3 + 1.5 * IQR$). Extremwerte werden als Punkte (bzw. +) außerhalb des Whiskers dargestellt¹. (Wooldridge, 2016)

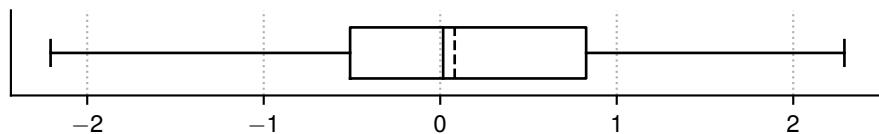


Abbildung 2.2 Boxplot einer Stichprobe ($n=100$) aus einer Normalverteilung ($\mu = 0, \sigma = 1$) mit arth. Mittel (gestrichelte Linie), Median (durchgezogene Linie) und Whisker und Ausreißer (+)

¹ Hinweis: Die grafische Zuordnung wird im Rahmen dieser Arbeit beibehalten.

2.3.3. Funktionen

Die Ausprägungswahrscheinlichkeiten werden über Funktionen dargestellt. Für stetige Variable und diskrete Variable stellt die *Verteilungsfunktion* (*engl. cumulative distribution function, kurz CDF*) Abbildung 2.3 an Stelle x dar, wie groß die Wahrscheinlichkeit ist, dass ein Wert kleiner gleich x erreicht wird (vgl. Abbildung 2.3). Die Wahrscheinlichkeitsfunktion einer diskrete Variable beschreibt die Wahrscheinlichkeit für eine bestimmte Ausprägung, d.h. $P(X = x_i) = p_i$. Das Histogramm (siehe 2.3.2) ist eine Darstellungsweise dieser Wahrscheinlichkeitsfunktion.

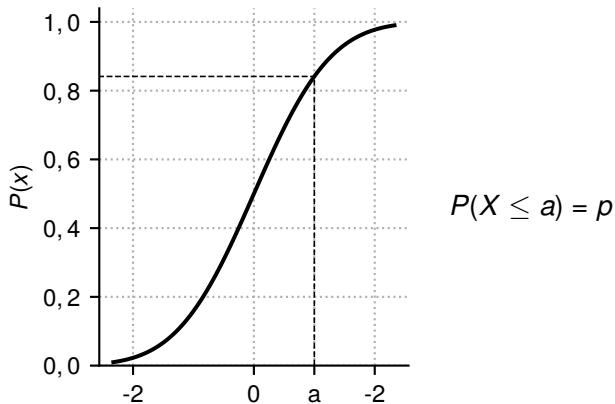


Abbildung 2.3 Verteilungsfunktion (CDF) einer Normalverteilung (Stichprobe n=100, $\mu = 0$, $\sigma = 1$).

Die *Dichtefunktion; probability density function pdf* wiederum zeigt die Wahrscheinlichkeit für stetige Variable an, in einem definierten Intervall $[a,b]$ zu liegen. Diese wird aus der Fläche unter der Dichtefunktion $f(x)$ errechnet. (Stock & Watson, 2012)

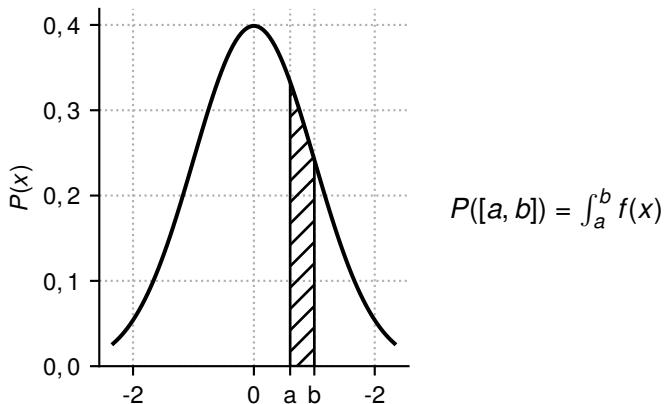


Abbildung 2.4 Dichtefunktion (PDF) einer Normalverteilung (Stichprobe n=100, $\mu = 0$, $\sigma = 1$).

2.3.4. Korrelation

Die Korrelationsanalyse quantifiziert Zusammenhänge von Variablen. Sie zeigt auf, welche Abhängigkeiten bestehen ohne damit kausale Zusammenhänge zu implizieren. Die Korrelation kann über den *Korrelationsindexkoeffizient nach Pearson r* beschrieben werden. Dieser ist ein Grad für den linearen Zusammenhang zweier Variablen. Dabei ist 1 ein *vollständig*

positiver und -1 ein *vollständig negativer* Zusammenhang. Ist $r = 0$ besteht kein linearer Zusammenhang zwischen den Variablen. (Stock & Watson, 2012)

2.3.5. Quantil-Quantil-Plot

Um die statistischen Verteilungen zweier Variablen miteinander zu vergleichen wird der Quantil-Quantil-Plot (Q-Q-Plot) genutzt. Hierzu werden die Quantile errechnet oder geschätzt - falls eine Verteilungsfunktion (CDF) existiert, können die Quantile durch die Umkehrfunktion definiert werden. Für den Fall, dass die Quantile geschätzt werden müssen, existiert eine Vielzahl an Schätzverfahren. Falls die Variablen die gleiche zugrundeliegende Verteilungsfunktion besitzen, liegen die Plots auf der 45° Linie (Identitätslinie). Falls die Plots über der Linie liegen, ist die Verteilung auf der Y-Achse gestreuter und besitzt damit eine größere Varianz als die Verteilung auf der X-Achse. Der Q-Q-Plot hat den Vorteil, dass er unabhängig von der Anzahl der Variablenausprägung ist. (Wooldridge, 2016)

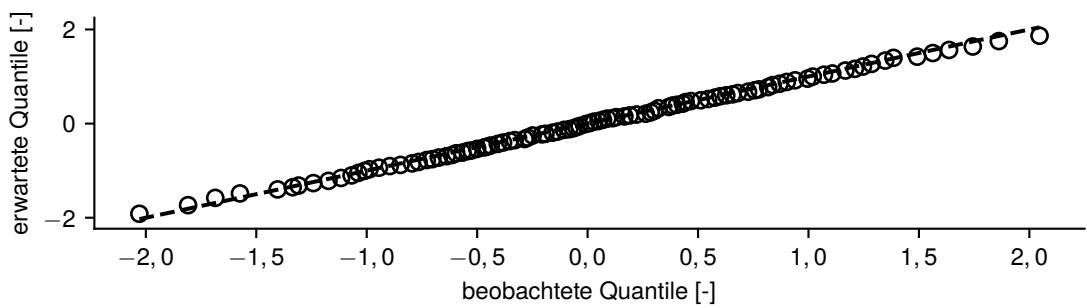


Abbildung 2.5 Beispiel eines Quantil-Quantil-Plots.

3. Methode und Workflow

Im Rahmen dieser Arbeit werden zwei Schwerpunkte bearbeitet. Im ersten Teil werden die Messdaten die im Rahmen des Forschungsprojektes *Einfach Bauen* gesammelt wurden, aufbereitet und ausgewertet. Anhand dieses Datensatzes werden im Anschluss probabilistische Modelle zur Steuerung des Nutzungsverhaltens in einer thermisch dynamischen Gebäude-simulation abgeleitet und in einer Simulation erprobt. Die Verwendung der probabilistischen Modelle sollen dabei gegenüber herkömmlichen, deterministischen Ansätzen eine Bandbreite an Ergebnissen erzeugen. Die Größe dieser Bandbreite soll dann Aufschluss über den mit einer Bauweise verbundenen Performance Gap geben.

3.1. Datenanalyse

Im ersten Schritt wird eine Datenanalyse durchgeführt. Diese basiert auf in situ Messdaten einer noch laufenden Messreihe im Rahmen des Projekts *Einfach Bauen*. Da die Messungen noch nicht abgeschlossen sind, liegt noch kein vollständiger Datensatz vor. Ziel ist es daher eine Auswertungsmethode zu verwenden, die im Laufe der Messung um weitere Beobachtungen erweitert werden kann.

3.1.1. Arbeitsweise

Aufgrund der Menge der erhobenen Daten lässt sich die Auswertung nicht mehr manuell über Tabellenkalkulationsprogramme durchführen. Aus diesem Grund wird für die Auswertung die Programmiersprache Python verwendet. Mithilfe von Paketen für Matrixoperationen wie `numpy` und zur Datenverarbeitung wie `pandas` lassen sich hier einfach und mit vergleichsweise geringer benötigter Rechenleistung komplexe Umformungen und Auswertung durchführen. Zur Arbeit mit Daten in Tabellenform werden dabei sogenannte *Jupyter Notebooks* verwendet. Diese ermöglichen die Unterteilung von Code kurze Blöcke und die Visualisierung von Ausgaben als HTML. Dadurch wird die Arbeit mit Daten, trotz fehlender Benutzeroberfläche sehr einfach. Zur Visualisierung der Daten werden die Pakete `matplotlib` und `seaborn` verwendet. Diese ermöglichen es direkt in Python Grafiken aus Datensätzen zu erstellen.

3.1.2. Aufbereitung und Auswertung der Messdaten

Bei in situ Messungen ist es unvermeidbar, dass es Ausfälle und Fehlfunktionen der Messtechnik gibt. Diese müssen vor der Auswertung bereinigt werden. Dazu werden die Daten z. B. in Form von Zeitreihen, Boxplots oder Histogrammen visualisiert. Fallen dabei ungewöhnliche Daten auf, wird versucht die Ursache zu finden und diese zu beheben. Ist ein Datensatz plausibel, wird er in die neu erstellte Datenbank übernommen. In der neuen Datenbank werden nun alle für die Analyse relevanten Datensätze gesammelt.

Die Auswertung der Datenbank erfolgt anhand der in Unterabschnitt 2.3.1 beschriebenen

statistischen Kenngrößen.

Zur Bewertung des thermischen Komforts werden die beiden adaptive Komfortmodelle nach *DIN EN 16798-1* (2022) verwendet. Die Darstellung erfolgt dabei sowohl als Untertemperaturgradstunden (UTGS) und Übertemperaturgradstunden (ÜTGS), aber auch grafisch, in Form der entsprechenden Graphen. Die Darstellung erfolgt dabei als zwei dimensionale Histogrammen, d. h. die Stärke der Farbe gibt an, wie viele Beobachtungen in einem Bereich liegen. Ein Beispiel der verwendeten Grafiken ist in Abschnitt B.4.

Zusätzlich lässt sich der Datensatz über einen erstellten Übersichtsplot darstellen. Dieser stellt alle relevanten Sensoren einer Wohneinheit in hoher zeitlicher Auflösung an. Ein Beispiel ist in Abschnitt B.2 zu finden.

3.2. Modellierung

Anhand der gewonnenen Messdaten werden im nächsten Schritt Modelle zur Steuerung der Lüftung in der Gebäudesimulation abgeleitet. Dazu wird eine Monte-Carlo-Simulation und eine logistische Regression modelliert.

3.2.1. Monte Carlo Simulation

Mit einer MC-Simulaton lassen sich analytisch nur schwer lösbar Probleme durch wiederholtes Durchführung eines Zufallsexperiments numerisch lösen. Hierzu wird wiederholt eine Stichprobe aus der Grundgesamtheit gezogen und der Parameter aus der Stichprobe geschätzt. Dieser Vorgang kann beliebig oft wiederholt werden bis die Schätzungen des Parameters ausreichend konvergent vorliegen. Als theoretische Grundlage der Methode kann das *Gesetz der großen Zahlen* betrachtet werden. (Cramer & Kamps, 2020)

Im Rahmen dieser Arbeit sollen mittels MC-Simulaton unsichere Randbedingungen abgeschätzt werden. Dazu wurden zwei Verfahren entwickelt: Ein Verfahren zum Sampling konstanter Randbedingungen, die sich während der Simulation nicht mehr ändern sollen (z. B. dem Wetterdatensatz oder einer konstanten Luftwechselrate) und ein Verfahren um Signale oder Parameter für jeden Zeitschritt während einer Simulation zu samplen.

Beide Verfahren folgen dabei dem gleichen Schema, abgeleitet nach Meier (2020), Burhenne (2013) und Cramer und Kamps (2020):

1. Auswahl der zu schätzenden Variable

Im ersten Schritt sollte die Variable definiert, die es zu bestimmen gilt. Dies kann ein einzelner Wert sein (z. B. die Zahl P_i) oder ein komplexes System (wie z. B. das Nutzungsverhalten in der Gebäudesimulation.)

2. Auswahl der beschreibenden Variablen

Die zu schätzende Variable wird durch eine oder mehrere beschreibende Variablen geschätzt. Die Auswahl dieser Variablen hängt dabei stark von der zu schätzenden Variable ab. Möchte man z. B. die Zahl Pi herleiten kann man, als beschreibende Variable ein XY-Koordinatenpaar zwischen 01 wählen. Komplexe Systeme wie das Nutzungsverhalten sind in der Regel von mehreren Variablen abhängig. Hier sind gleich mehrere verschiedene Variablen wie z. B. die eingestellte Heiztemperatur, die mittlere Luftwechselrate oder interne Lasten.

3. Auswahl einer Verteilung für jede beschreibende Variable

Um eine Stichprobe der beschreibenden Variablen ziehen zu können, müssen erst eine Verteilung dieser definiert werden. Diese ist entweder bekannt, kann empirisch bestimmt werden oder eine Stichprobe aus einer Beobachtung gezogen werden. Im Fall der Bestimmung der Zahl Pi wäre die beschreibende Variable zwischen 01 gleich verteilt. Bei komplexeren Variablen kann die Wahl der Verteilung schwieriger sein. Oft kann die Annahme einer Normalverteilung gerechtfertigt sein. Bei Variablen die nicht kleiner als 0 werden können, kann auch eine logarithmische eine sinnvolle Annahme sein.

4. Generation einer Stichprobe aus den beschreibenden Variablen

Zur Bestimmung der zu schätzenden Variable wird nun wiederholt eine Stichprobe aus der gewählten Verteilung der beschreibenden Variablen gezogen.

5. Überführung der Stichprobe in ein Rechenmodell.

Im nächsten Schritt wird die gezogene Stichprobe an ein zu definierendes Rechenmodell übergeben. Im Fall der Zahl Pi muss bestimmt werden, ob die gezogene Zahl zwischen 0 und 1 innerhalb oder außerhalb des Einheitskreises liegt. Dazu kann der *Satz des Pythagoras* $x^2 + y^2 \leq 1$ verwendet werden. Die Zahl Pi ergibt sich schließlich aus der Anzahl der gesampelten Punkte im Kreis geteilt durch die Gesamtanzahl generierter Punkte. Bei der Gebäudesimulation werden die ermittelten Stichproben an das Simulationsmodell übergeben.

6. Validation der Ergebnisse des Rechenmodells.

Im letzten Schritt werden die Ergebnisse überprüft und der Versuch ggf. so lange wiederholt bis das Ergebnis ausreichend konvergent ist.

3.2.2. Logit

Bei der logistischen Regression (Logit) handelt es sich um ein statistisches Verfahren zur Modellierung einer diskreten abhängigen Variable Y (im Folgenden *Kriterium* genannt) durch mehrere Variablen x_k (im Folgenden *Prädiktoren* genannt). Das Kriterium ist eine binäre Variable, die die Werte 0 oder 1 annehmen kann. Die Wahrscheinlichkeit, dass das Kriterium den Zustand 1 annimmt wird durch Gleichung 3.4 beschrieben.

$$P(Y = 1|X = x_i) = \frac{1}{1 + \exp(-\eta_i)} \quad (3.4)$$

mit $\eta_i := \sum_{j=0}^k x_{ij}\beta_j$

wobei $x_{i0} = 1$ Achsenabschnitt

β_{ik} Parameter

x_{ik} Prädiktoren

Um die Wahrscheinlichkeit korrekt zu modellieren, müssen bestimmte Voraussetzungen erfüllt sein. Diese sind in den meisten Fällen erfüllt und sollen hier nicht weiter spezifiziert werden (Wooldridge, 2016). Eine Annahme muss jedoch erfüllt sein: Es darf keine perfekte Multikollinearität in den Prädiktoren vorliegen.

Der Vorteil der logistischen Regression gegenüber einer linearen Wahrscheinlichkeitsfunktion ist durch die Begrenzung des Wertebereichs auf [0,1]. Wahrscheinlichkeiten nähern sich asymptotisch 0 und 1 an, d. h. es können keine Wahrscheinlichkeiten größer als 100% (oder kleiner als 0) modelliert werden. Eine Wahrscheinlichkeit außerhalb dieses Intervalls macht aber im Hinblick auf das binäre Kriterium wenig Sinn. Die lineare Wahrscheinlichkeitsfunktion hat bis auf die oben genannten Randwerte einen ähnlichen Verlauf und bietet den Vorteil, dass die Wahrscheinlichkeiten direkt ausgelesen werden können, d. h. ohne Berechnung des marginalen Effekts wie in 3.4 (Wooldridge, 2016). Angesichts der vorliegenden Daten, die auch eine präzise Modellierung für Extremwerte voraussetzt, wird in dieser Arbeit die logistische Regression verwendet.

Dazu wurde in Anlehnung an Andersen et al., 2013, Calì et al., 2016, Wooldridge, 2016 und Bruce et al., 2021 folgendes Vorgehen entwickelt:

1. Datenaufbereitung

- a) Zu Beginn der Analyse wird eine Vorauswahl von Variablen getroffen, die infrage kommen das Öffnungsverhalten des Fensters zu beeinflussen.
- b) Für die Regression müssen die Variablen stetiger oder binärer Ausprägung sein. Etwaige kategoriale Variablen müssen in binäre, sogenannte *Dummy Variablen* umgeformt werden.
- c) Zur Validierung der Regression muss ein Gütemaß gewählt werden, anhand dessen die Qualität der Prädiktion gemessen werden kann. Gängige Gütekriterien sind die Sensitivität und Spezifität oder die *Grenzwertoptimierungskurve* (Fawcett, 2004).

2. Datenanpassung und -validierung
 - a) In bestimmten Fällen, z.B. wenn die Wertebereiche der gewählten Prädiktoren stark voneinander abweichen, kann es sinnvoll sein, die gewählten Variablen zur besseren Vergleichbarkeit zu Skalieren. Dabei gibt es verschiedene Methoden. Geläufige Skalierungen sind die Skalierung auf Normalverteilung, die logarithmische Skalierung oder die Robuste Skalierung (scikit-learn, 2022).
 - b) Für optimale Ergebnisse sollten die Ausprägungen des Kriteriums annähernd gleich verteilt sein. Ist dies nicht der Fall, kann es die Ergebnisse verbessern, das Kriterium so zu skalieren, dass beide Ausprägungen gleich häufig auftreten (Bruce et al., 2021).
 - c) Ausreiser können die Ergebnisse der Regression verzerrn, daher kann es bei Datensätzen die starke Ausreiser aufweisen, bereinigungen mittels IQR oder Konfidenzintervallen durchzuführen (Bruce et al., 2021).
 - d) Es ist auszuschließen, dass die Prädiktoren eine zu starke gegenseitige lineare Abhängigkeit, die sogenannte *Multikolinearität* aufweisen. Dazu kann der Variance Inflation Factor (VIF) herangezogen werden (Wooldridge, 2016).
3. Auswahl der Prädiktoren

Die Verwendung zu vieler Prädiktoren birgt das Risiko eines Overfitting: Das bedeutet, dass das entwickelte Modell lediglich den Trainingsdatensatz imitiert und vorhersagen über diesen hinaus stark verzerrt sein können (Bruce et al., 2021). Außerdem empfehlen Gaetani et al. (2016) die Komplexität des Modells zu minimieren, um den Rechenaufwand bei der Implementation in die Gebäudesimulation zu minimieren. Dazu werden in dieser Arbeit zwei Methoden verwendet.

 - a) Die einfachste Möglichkeit Prädiktoren zu wählen, ist anhand ihres Regressionskoeffizienten β . Dabei werden die k Prädiktoren mit dem höchsten $|\beta|$ gewählt. Dazu ist es notwendig, dass alle Prädiktoren auf die gleiche Bandbreite (z.B. durch Skalierung auf Normalverteilung) haben. In dieser Arbeit wird für dieses Verfahren das Modul `SelectFromModel` aus dem Softwarepaket `scikit-learn` verwendet (Pedregosa et al., 2011).
 - b) Eine weitere Möglichkeit der zur Auswahl der Prädiktoren ist die Verwendung eines *Selection Algorithmus* wie z.B. der Forward oder der Backward Selection. Bei der Forward Selection werden erst alle zur Auswahlstehenden Prädiktoren einzeln betrachtet. Es wird für jeden Prädikator ein Modell erstellt und das gewählte Gütekriterium errechnet. Der Prädikator, dessen Modell das beste Gütekriterium erreicht hat, wird als erstes ausgewählt. Nun wird jeder, in der ersten Runde nicht ausgewählte Prädikator, in ein Bivariate Modell mit dem in der ersten Runde ausgewählten Prädikator überführt und wiederum das Gütemaß errechnet. Das bivariate Modell mit dem besten Gütemaß wird ausgewählt und der Vorgang mit den übrig gebliebenen Prädiktoren k -mal wiederholt.

Bei der *Backward Selection*, läuft dieser Algorithmus rückwärts ab. D.h. es wird zuerst ein Modell mit allen Variablen aufgestellt und dann so lange Variablen entfernt, bis sich das Modell verschlechtert.

4. Bestimmung der Koeffizienten und Validierung des Models

Nachdem die Prädiktoren ausgewählt wurden, muss nun das eigentliche Modell aufgestellt, die die Koeffizienten β_k errechnet werden.

- a) Zur Bestimmung der Koeffizienten β_k wird eine Kreuzvalidierung durchgeführt. Diese soll ein *overfitting* verhindern und die Qualität der Prognose verbessern. Dazu wird der Datensatz in $n = 10$ Teile unterteilt. Von diesen n Teilen werden $n - 1$ Teile zur Berechnung von β_k verwendet. Mit dem übrig bleibenden Teil n ten Teil der Daten wird das Modell mittels des gewählten Gütemaßes validiert. Dieser Vorgang wird $j = 10$ mal wiederholt.

5. Übergabe an TRNLizard

Die bestimmten und validierten Koeffizienten β_k , sowie die zur Skalierung und Gewichtung verwendeten Parameter werden exportiert und an die Simulationsumgebung übergeben.

3.3. Simulation

Die im vorigen Abschnitt erstellten Modelle werden im Rahmen einer thermisch dynamischen Gebäudesimulation erprobt. Im Rahmen dieser Arbeit wird die TRNLizard Umgebung verwendet. In der aktuellsten Version von TRNLizard [2019] sind die wichtigsten Basisfunktionen, um eine thermisch dynamische Gebäudesimulation mit mehreren Zonen durchzuführen, bereits implementiert. Im Rahmen dieser Arbeit wurde dieses Template um einige Funktionen zur empirischen Arbeit erweitert. Die wichtigsten neuen Funktionen sind dabei:

- Über eine erweiterte CSV-Schnittstelle können Materialien, Wandaufbauten, Schedules und Varianten über externe Editoren (z.B. Excel oder Python) erstellt und bearbeitet werden,
- mit einer neuen *Shoebox*-Komponente lassen sich nun auch Multizone Grundrisse erstellen und deren Geometrie über die *Varianten*-Komponente variieren,
- die bestehende rudimentäre LCA-Funktionalität wurde weiter ausgebaut und lässt sich in die externe Erstellung von Materialen und Bauteilen integrieren,
- über eine neue *Lizard*-Komponente lassen sich Monte-Carlo-Simulationen auch während der *TRNSYS*-Simulation durchführen und
- über eine weitere neue *Lizard*-Komponente lassen sich logistische Wahrscheinlichkeitsmodelle in die *TRNSYS*-Simulation integrieren.

Die Integration der probabilistischen Verfahren zur Beschreibung des Nutzungsverhaltens

erfolgt nach Hong et al. (2018) aus einer Kombination aus *benutzerdefinierten Funktionen* und einer *Parallel Simulation*.

3.3.1. Auswertung

Im Rahmen der Auswertung soll zum einen eine Plausibilitätskontrolle, zum anderen der Nutzen zu Abschätzung des PGs evaluiert werden.

Die Auswertung der Simulationen wird wieder in einem *Jupyter Notebook* mit der Programmiersprache Python durchgeführt. Kenngrößen sind dabei der thermische Komfort nach DIN 16798 sowie der Heizwärmebedarf (ohne Trinkwarmwasser).

Die Abschätzung der Performance Gap soll indirekt über die Abschätzung der Bandbreite der erzeugten Ergebnisse erfolgen. Diese Bandbreite kann als Maß für die Modellunsicherheiten dienen (Shi et al., 2019). Die Modellunsicherheiten als Teil der sogenannten *Norm Gap* tragen wiederum zum PG bei und lassen dabei erste Rückschlüsse auf die mögliche Bandbreite der in Realität möglichen energetischen und thermischen Kenngrößen zu.

4. Auswertung der Messdaten

Im weiteren Verlauf dieser Arbeit wird der, wie im Abschnitt Aufbereitung der Daten beschriebene, vorbereitete Datensatz verwendet. Der Datensatz besteht aus – weitestgehend – minütlichen Messwerten, gruppiert nach Raumebene.

Betrachtet werden dabei die Wohnung Nord (N) und Wohnung Süd (S) im zweiten Obergeschoss der drei Forschungshäuser Leichtbeton (LB), Mauerwerk (MW), Massivholz (MH). Die unbewohnte Referenzwohnung Ost (O) dient als Referenz.

Der Beobachtungszeitraum beginnt mit dem Einzug der Nutzer:innen und endet im Rahmen dieser Arbeit am 02. Juni 2022. In Tabelle A ist eine Übersicht über die Beobachtungszeiträume der einzelnen Wohnungen und den erhobenen Daten zu finden. Darüber hinaus befindet sich im Abschnitt B.1 eine detaillierte grafische Darstellung der Datenlücken. Im Tabelle A ist eine Aufstellung der verbauten Sensoren zu finden und im Abschnitt A.2 ist ein Plan mit allen verbauten Sensoren angehängt.

Tabelle 4.1 Beobachtungszeitraum

Haus	Wohnung	Beginn	Ende	Dauer	fehlende Datensätze
				[Tage]	[Tage]
Leichtbeton	Nord	08.03.2021	02.06.2022	450	79
	Ost	08.03.2021	02.06.2022	450	71
	Süd	08.03.2021	02.06.2022	450	77
Massivholz	Nord	01.05.2021	02.06.2022	397	6
	Ost	09.02.2021	02.06.2022	477	31
	Süd	01.06.2021	02.06.2022	366	6
Mauerwerk	Nord	01.04.2021	02.06.2022	427	34
	Ost	23.02.2021	02.06.2022	463	55
	Süd	01.03.2021	02.06.2022	457	43

4.1. Aufbereitung der Daten

Die Messdaten der TinkerForge Sensoren in den Wohnungen werden in jedem Haus minütlich von einem lokalen Rechner im Haus abgerufen und gespeichert. Es werden tägliche Datensheets erstellt und elektronisch an die TUM übermittelt. In einem ersten Schritt werden

diese Daten in regelmäßigen Abständen zu einer Datenbank zusammengefasst. Dabei werden u. a. doppelte Einträge entfernt, korrekte Indizes sowie Zeitstempel angelegt. Die daraus entstandene (Roh-)Datenbank ist die Grundlage für das weitere Vorgehen in dieser Arbeit.

4.1.1. Datenbereinigung

Im ersten Schritt werden die gesammelten Daten bereinigt. Dabei werden u. a. fehlerhafte Aufzeichnungen korrigiert dann Ausreißer entfernt und schließlich Hilfsgrößen abgeleitet.

Messabweichung der TRH-Sensoren

Durch das Forschungsprojekt hat sich gezeigt, dass die Messwerte des TRH-Sensor teilweise sehr hohe Ausschläge anzeigen. Daher wurden in den drei, jeweils unbewohnten, Einzimerappartements jedes Hauses Vergleichsmessungen durchgeführt.

Dabei wurde nachgewiesen, dass Sensoren der gleichen Bauart einen geringeren Wert für die rel. Luftfeuchte und Lufttemperatur ermitteln, wenn die Sensoren nicht an das verbaute Sensornetzwerk, sondern direkt an einen Rechner angeschlossen werden. Es wurde daher angenommen, dass durch die Hintereinanderschaltung einer größeren Anzahl an Sensoren der Messwert verzerrt wird. Um diesen Fehler zu korrigieren wurden in den Referenzwohnung Vergleichsmessungen mit einem baugleichen TRH-Sensor durchgeführt, der nicht an das Sensornetzwerk angeschlossen wurde. Im gleichen Raum befindet sich ebenfalls ein Sensor, der mit dem Netzwerk verbunden ist. Die mittlere Differenz dieser beiden Messwerte dient als Korrekturwert für die einzelnen Messwerte. Die verwendeten Werte können Tabelle 4.2 entnommen werden. Zusätzlich wird im Rahmen dieser Arbeit eine lineare Korrektur

Tabelle 4.2 Korrekturwerte der TRH-Sensoren

Haus	Messwert rel. Luftfeuchte (rH) [%]	Lufttemperatur (T_{air}) [°C]
Leichtbeton	-4,9	-0,1
Massivholz	-3,7	0,1
Mauerwerk	-12,8	-0,4

untersucht. Dazu wird mittels einer linearen Regression ein Faktor zwischen den Messungen im Netzwerk und der Referenzmessung abgeleitet. In Abbildung 4.1 wird exemplarisch die ermittelte Regressionsgerade für die rel. Luftfeuchte im Massivholz dargestellt. In Tabelle 4.3 sind die ermittelten Faktoren für alle Häuser dargestellt.

Fehlerhafte Aufzeichnung

Neben der Messabweichung kommt es im Messaufbau des TRH-Sensor gelegentlich zu einer Fehlzuordnung zwischen rel. Luftfeuchte und Lufttemperatur. Wenn dieser Fehler bei einem kompletten Tagesdatensatz auftritt, wird er während des Imports des Tagesdatensatz-

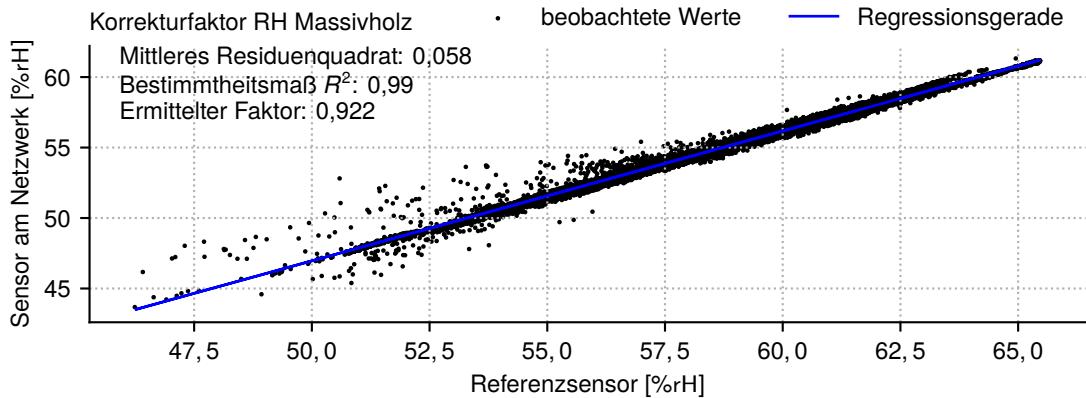


Abbildung 4.1 Ergebnis der linearen Regression eines Korrekturfaktors für die rel. Raumluftfeuchte für das Massivholzhaus.

Tabelle 4.3 Lineare Korrekturfaktoren zur Behebung des Messfehlers der TRH-Sensoren

Messwert	rel. Luftfeuchte (rH) [%]	Lufttemperatur (T_{air}) [°C]
Haus		
Leichtbeton	0,9340	1,0280
Massivholz	0,9220	0,9940
Mauerwerk	0,9620	0,9560

zes automatisch behoben. In einigen wenigen Fällen kommt es jedoch spontan zu Fehlzuordnungen über wenige Stunden, in diesem Fall ist eine automatische Korrektur der Werte nicht möglich. Damit diese Werte nicht die Ergebnisse verzerren, müssen auch diese Werte entfernt werden. Dazu wird für den TRH-Sensor ein gültiger Wertebereich von 0 %rH bis 100 %rH für die relative Feuchte und von –20 °C bis 40 °C festgelegt. Liegt einer der beiden Messwerte außerhalb des jeweiligen Wertebereiches werden beide Messwerte als ungültig betrachtet und entfernt. Des Weiteren lässt sich bei den Temperatursensor vereinzelt beobachten, dass der Messwert spontan in Kelvin statt Celsius aufgezeichnet wird. Durch die hinterlegte Umrechnung des Messwertes um –273,15, springt der Messwert in den dreistellig negativen Bereich. Um diese Werte zu korrigieren werden Werte, die kleiner als 200 sind, mit 273,15 addiert. Da darüber hinaus einzelne Werte größer als 200 aufgezeichnet wurden, wird ebenfalls ein Wertebereich von 0 °C bis 100 °C festgelegt. Werte außerhalb dieses Intervalls werden aussortiert.

Ausfall des Sensors

In bestimmten Fällen kann es vorkommen, dass ein Sensor im Falle eines Fehlers keinen Fehler, sondern einen konstanten – vermeintlichen – Messwert ausgibt. Dieser Fehler wird behoben, indem die rollende Standardabweichung über die letzten 24 h betrachtet wird. Ist dieser Wert für 24 h $< 0,01$ wird angenommen, dass der Wert falsch ist. Die Messungen, seit der letzten und bis zur nächsten Änderung des Sensors werden entfernt. Die Korrektur wird

nur auf Sensoren angewendet die einen kontinuierlichen Wert ausgeben (z. B. TRH-Sensor, Temperatursensor, ...) nicht aber auf binäre Sensoren.

Entferne unbewohnte Zeiten

Einige der Wohneinheiten wurden erst nach Beginn der Messung bezogen. Die Messwerte vor Einzug der Nutzer:innen werden im Rahmen dieser Arbeit nicht betrachtet und werden daher ebenfalls aussortiert. Die genauen Einzugsdaten können in der folgenden Tabelle 4.4 entnommen werden. Als Einzugsdatum wurde immer der Beginn des Mietvertrages angenommen.

Tabelle 4.4 Einzugsdaten der Mieter:innen und Beginn der Messdaten

Haus	Leichtbeton	Massivholz	Mauerwerk
Wohnung Nord	01. Jul '20	01. Mai '21	01. Apr '21
Wohnung Ost	01. Jul '20	01. Okt '20	01. Okt '20
Wohnung Süd	01. Jul '20	01. Jun '21	01. Mrz '21

Klassifikation der Jahreszeiten

Die jahreszeitliche Auswertung der Daten erfolgt nach meteorologischen Jahreszeiten. Diese orientieren sich nach den Kalendermonaten und sind jeweils drei Monate lang. Die Jahreszeiten Frühling und Herbst ähneln sich in ihren meteorologischen Eigenschaften. In Tabelle 4.5 sind exemplarisch die Mittelwerte, Mediane und Standardabweichungen der gemessenen Außenlufttemperatur für Frühling und Herbst sowie beide als Übergang zusammen gefasst dargestellt. Es zeigt sich, dass sich die dargestellten Werte tatsächlich sehr ähneln.

Tabelle 4.5 Vergleich der des Mittelwerts, des Medians und der Standardabweichung der Außenlufttemperatur für die Klassifikation nach Frühling und Herbst sowie der Zusammenfassung als Übergang.

Jahreszeit	Mittelwert	Median	Standardabweichung
Übergang	9,0 °C	8,5 °C	7,3K
Frühling	9,1 °C	8,9 °C	7,4K
Herbst	8,8 °C	7,7 °C	7,1K

Daher werden beide Jahreszeiten im Folgenden zur Jahreszeit Übergang zusammen gefasst. Die daraus resultierende Klassifikation nach Monaten lässt sich Abbildung 4.2 entnehmen.

Zusammenfassung des offenen Grundrisses

Um die Auswertung übersichtlicher zu gestalten werden die offenen Wohnräume (Flur und Wohnzimmer) für die folgende Auswertung zusammengefasst. Dies betrifft im Wesentlichen die Fenster im Flur, die nun dem Wohnzimmer zugerechnet werden.

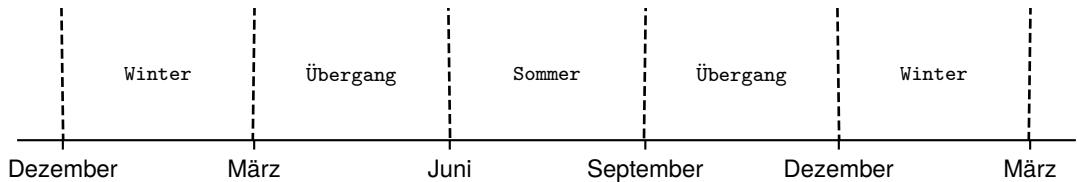


Abbildung 4.2 Klassifikation der Jahreszeiten

4.1.2. Extraktion der Fensteröffnungen- und schließungen

Bevor mit der Analyse begonnen werden kann, werden einige Hilfsgrößen aus den Sensorsordaten erstellt. In einem ersten Schritt werden die Signale der Fensterkontakt-Sensoren ausgewertet. Ziel ist es dabei, zum einen die Zeitpunkte der Interaktion der Nutzer:innen mit den Fenster (sprich: Öffnen und Schließen) zu ermitteln und zum anderen einen Wert für die Gleichzeitigkeit der Fensteröffnung zu erstellen: Der Status der Fenster wird mit 0 für geschlossen und 1 für geöffnet definiert (Variable Fenster (Ausrichtung) ([Größe [S, M, XL]])). Zusätzlich wird für jeden Raum mit Fenstern (Wohnzimmer (mit Flur), Schlafzimmer und Küche) die Summe der Öffnungssignale als Indikator für die Gleichzeitigkeit errechnet (Variable Fenster). Der Zeitpunkt der Öffnung wird mit 1, der Zeitpunkt des Schließens wird –1 unter der Variable Fensteröffnung codiert.

4.1.3. Ermittlung der operativen Raumtemperatur

Die operative Raumtemperatur wird nach *DIN EN ISO 7726, 2021* bestimmt. Dazu wird nach Gleichung 4.5 die *MRT* aus der Schwarzkugel- und der Lufttemperatur berechnet. Die operative Raumtemperatur ergibt sich dann nach Gleichung 4.6 aus dem Mittelwert der *MRT* und der Raumlufttemperatur.

$$MRT_{sk} = \left[(T_g + 273)^4 + \frac{0,25 \cdot 10^8}{\varepsilon_g} \cdot \left(\frac{|T_g - T_a|}{D} \right)^{\frac{1}{4}} \cdot (T_g - T_a) \right]^{\frac{1}{4}} - 273 \quad (4.5)$$

mit MRT_{sk} Mittlere Strahlungstemperatur [°C]

T_g Schwarzkugeltemperatur [°C]

ε_g Emissionsgrad der Schwarzkugelbeschichtung [-]

T_a Temperatur der Umgebungsluft [°C]

D Außendurchmesser der Schwarzkugel [m]

$$T_{op,sk} = \frac{MRT_{sk} + T_{air}}{2} \quad (4.6)$$

mit $T_{op,sk}$ operative Raumtemperatur [°C]

MRT_{sk} Mittlere Strahlungstemperatur [°C]

T_{air} Raumlufttemperatur [°C]

Überschlägige Ermittlung der operativen Raumtemperatur

Da die Schwarzkugeltemperatur in den bewohnten Wohnungen erst seit Spätsommer 2021 aufgezeichnet wird, wird die operative Temperatur im Rahmen dieser Arbeit für die fehlenden Zeiträume näherungsweise bestimmt. Dazu wird ein lineares Regressionsmodell auf Basis der Messwerte aus den unbewohnten Referenzapparments verwendet. In der folgenden 4.3 werden die beobachteten Werte für die gemessenen Werte T_{air} , T_{amb} und die T_{op} in den bewohnten Wohnungen, nach Häusern getrennt, gegeneinander aufgetragen. Die blaue Gerade zeigt die ermittelte lineare Beziehung zwischen beiden Größen an. Die Bestimmung der Regressionskoeffizienten erfolgt mit dem Softwarepaket *Scikit Learn* (Pedregosa et al., 2011).

Die Näherung lässt sich anhand des mittleren Residuenquadrates und des Bestimmtheitsmaßes R^2 bewerten. Dabei wird die - aus den Daten des Referenzappartements (O) - bestimmte Regressionsgerade mit den tatsächlich gemessenen Werten in den bewohnten Wohnungen verglichen. Eine Näherung kann dabei als gut betrachtet werden, wenn das mittlere Residuenquadrat, also die Abweichung der gemessenen zu den errechneten Werten klein ist. Das Bestimmtheitsmaß R^2 gibt an, wie groß der Anteil der Werte ist, die durch das Modell korrekt beschrieben werden können. Die Werte für R^2 liegen in diesem Fall im Bereich zwischen

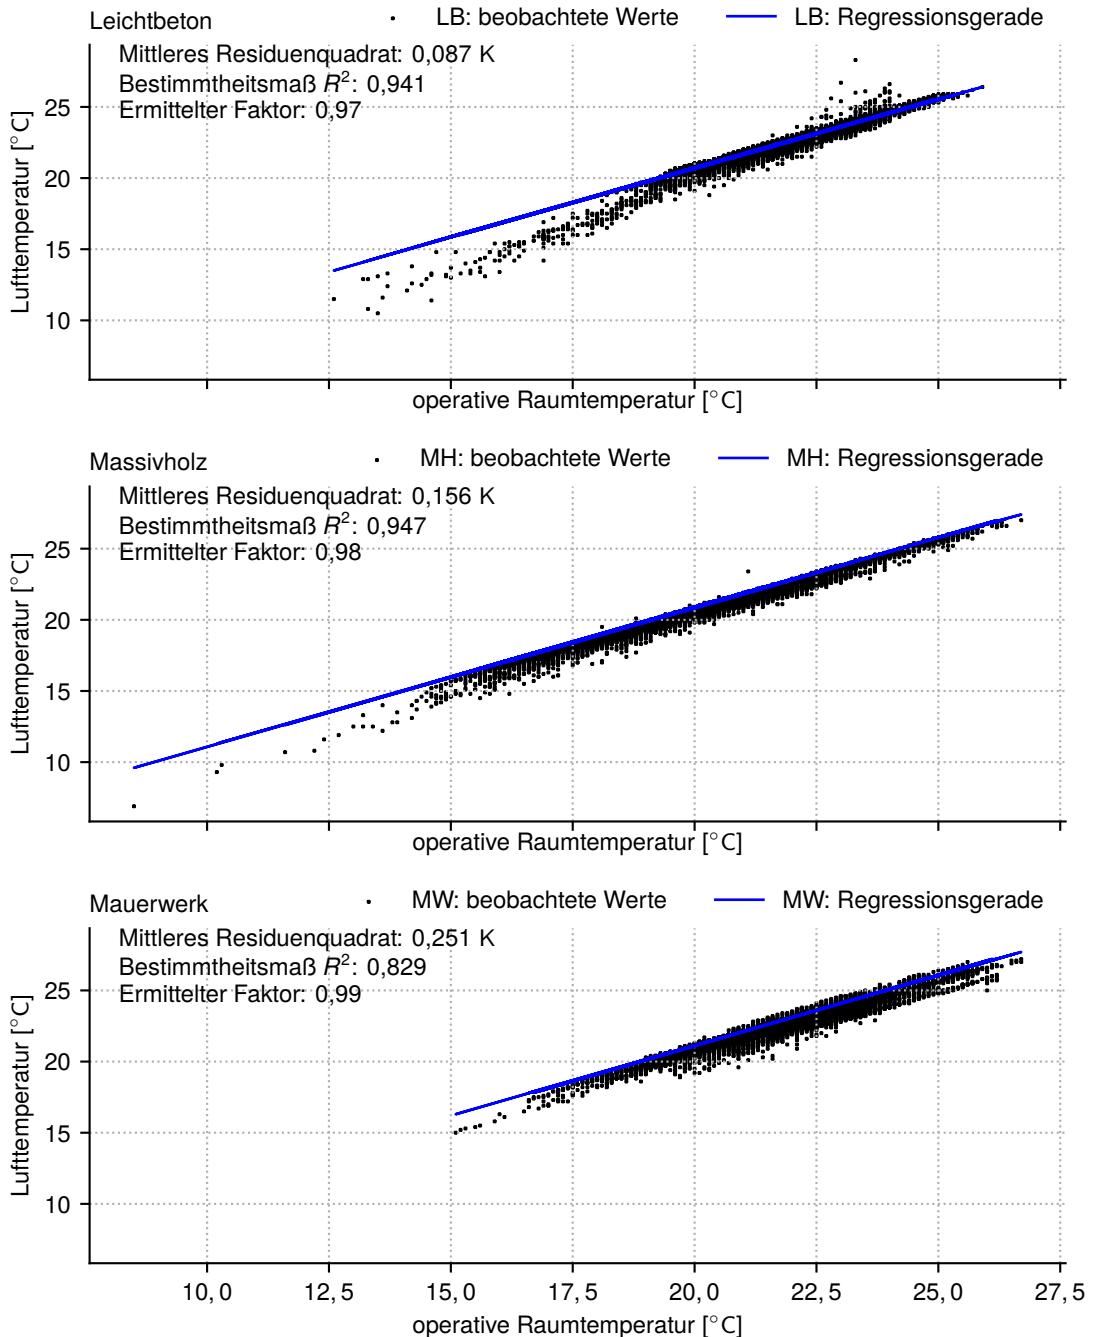


Abbildung 4.3 Ermittlung des Regressionskoeffizienten zur näherungsweisen Bestimmung der operativen Raumtemperatur T_{top} .

0,83 bis 0,95, was eine sehr gute Näherung darstellt. In Verbindung mit einem mittleren Residuenquadrat von 0,09 K bis 0,25 K, welches sich im Bereich der Messungenauigkeit der verbauten Sensoren aufhält (Tinkerforge, 2022), lässt sich festhalten, dass sich die operative Raumtemperatur gut über das entwickelte Modell aus der Raumlufstemperatur approximieren lässt. Für die weiteren Analysen wird daher - sofern kein Messwert vorhanden ist - auf die Näherung nach diesem Modell zurückgegriffen.

4.1.4. Ermittlung der absoluten Luftfeuchte

Die Luftfeuchte in den Wohnungen wird als relative Luftfeuchte über den TRH-Sensor gemessen. Die absolute Luftfeuchte g_{abs} wird nach der Magnusformel 4.7 und der Näherungsformel 4.8 nach DIN EN ISO 7726, 2021 bestimmt.

$$p_{a,max} = 610,5 * e^{\left(\frac{17,27 * T_a}{237,3 + T_a} \right)} \quad (4.7)$$

$$p_a = \frac{p_{a,max} * RH}{100}$$

$$G = 0,622 * \frac{p_a}{p - p_a} \quad (4.8)$$

mit $p_{a,max}$ Sättigungsdampfdruck [kPa]

p_a Partialdruck des Wasserdampfs [kPa]

p atmosphärischer Druck [kPa]

T_a Lufttemperatur [°C]

G abs. Luftfeuchte $\left[\frac{\text{kg}}{\text{kg}} \right]$

Die Gleichungen beschreiben die absolute Luftfeuchte in Abhängigkeit zur relativen Luftfeuchte, der Lufttemperatur und des atmosphärischen Luftdrucks. Da der atmosphärische Luftdruck von der Wetterstation vor Ort nicht gemessen wird, wird der Messwert von der nächsten Wetterstation des DWD in Rosenheim verwendet. Die Bereitstellung der Daten erfolgt dabei über das Python Paket Lamprecht, 2022.

4.1.5. Ermittlung der Heizkörpereinstellung

Der Status der Heizkörper wird über die Messung ihrer Oberflächentemperatur über einen Temperatursensor erfasst. Zur Analyse des Verhaltens der Nutzer:innen ist es vor allem von Interesse wann die Heizung ein- bzw. ausgeschaltet wird und auf welche Einstellung sie eingestellt ist. Da diese beiden Parameter nicht direkt beobachtet werden, wird im Folgenden versucht, beide Größen aus den Messwerten des TRH-Sensors, des Heizkörper-Sensors und der Fensterkontakte abzuleiten. Anhand der folgenden Abbildung 4.4 wird das Vorgehen zur Ermittlung der Heizkörpereinstellung beispielhaft erklärt. Die Heizkörper ($T_{HK,sur}$) weisen bei Aktivierung ein wesentlich höheres Temperaturniveau als die Raumlufttemperatur (T_{air}) auf. Zur Klassifikation werden beide Temperaturen über die Hysterese in 4.9 ins Verhältnis

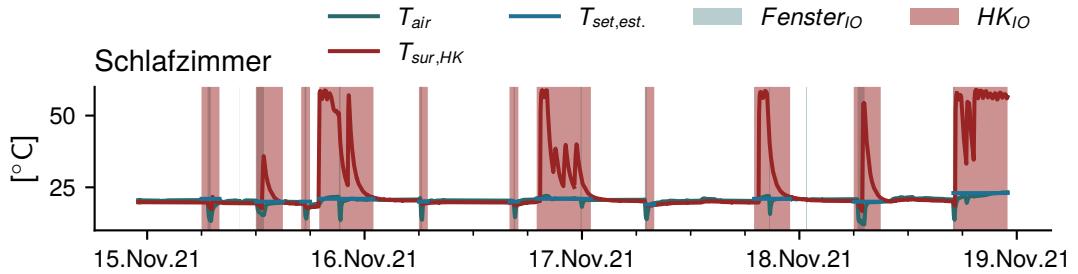


Abbildung 4.4 Beispielhafte Klassifikation der Heizkörperaktivierung. Messwerte der Raumlufttemperatur und Oberflächentemperatur der Heizkörper, sowie Fensteröffnungen. Die Zeiträume in denen die Heizung als an klassifiziert wird, sind rot hinterlegt.

gesetzt.

$$HK_{IO,15 \text{ min}} = \begin{cases} 1, & \text{wenn } T_{HK,15 \text{ min},0,25} > T_{air,15 \text{ min},0,5} \\ 0, & \text{sonst} \end{cases} \quad (4.9)$$

mit $HK_{IO,15 \text{ min}}$ Aktivierungssignal des Heizkörpers über 15 min [1 = An, 0 = Aus]

$T_{air,15min,0,25}$ 25 % Quantil von T_{air} über 15 min [°C]

$T_{air,15min,0,5}$ 50 % Quantil von T_{air} über 15 min [°C]

Die Hysterese wird dabei über die Betrachtung der 15 min Quantile dargestellt. Die Quantile sind dabei so gewählt, dass kleinere Temperaturspitzen auf den Heizkörperoberflächen, die z.B. durch Sonneneinstrahlung entstehen können möglichst nicht als aktivierte Heizung klassifiziert werden. Wenn die Fenster geöffnet sind und dadurch die Raumlufttemperatur stark abfällt, kann die Hystere jedoch Fehler verursachen. Diese sind in 4.4 im Schlafzimmer zu sehen. Hier kommt es durch Lüftungen ($Fenster_{IO}$) gelegentlich wieder zu falschen Klassifikationen. Um diese Fehler zu beheben wird als zusätzliches Kriterium die Maximaltemperatur des Heizkörpers in einem als *An* klassifizierten Zeitraum $T_{HK,I,max,i}$ mit dem Tagesmedian der Raumlufttemperatur $T_{air,24 \text{ h},0,5}$ verglichen. Nur wenn gilt $T_{HK,I,max,i} > T_{air,24 \text{ h},0,5}$, wird ein Zeitraum als *An* klassifiziert. In der Folgenden Abbildung 4.5 ist das Resultat nach der Korrektur dargestellt.

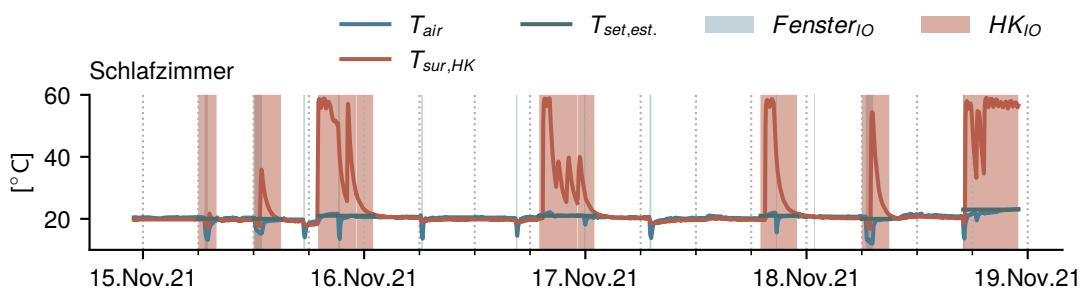


Abbildung 4.5 Korrigierte Heizkörperklassifikation bei Fensteröffnung.

Die Bestimmung der $T_{set,est}$ folgt der Annahme, dass es sich dabei um diejenige Temperatur handelt, bei der das Heizkörperthermostat schließt und damit die Oberflächentemperatur des Heizkörpers zu sinken beginnt. Als Näherung für diese Temperatur wird das 75 % Quantil von T_{HK} im als A_n klassifizierten Zeitraum auf volle Zahlen gerundet, verwendet.

4.1.6. Ermittlung der Präsenzzeiten

Ähnlich wie bei der Heizkörpereinstellung müssen auch die Präsenzzeiten nachträglich als Kombination mehrerer Messwerte bestimmt werden. Der verbaute Bewegungsmelder detektiert lediglich Bewegungen in seinem Sichtfeld, kann aber keine Aussage liefern, ob eine Nutzer:in gerade die Wohnung verlässt oder betritt. Insbesondere um Intervalle herauszufiltern, in denen niemand in der Wohnung ist, wird im Folgenden ein Signal als Kombination aus Bewegungsmelder, Fensterkontakt (auch *reed*), CO₂ sowie der ermittelten absoluten Feuchte g_{abs} generiert. Daraus werden vier Kriterien (MD_{anw} , WIN_{anw} , $CO_{2,anw}$ und G_{anw}) abgeleitet, deren Kombination die Grundlage für das Anwesenheitssignal ergeben.

Präsenz- und Fensterkontakte

Für die Signale MD_{anw} und WIN_{anw} werden die Messdaten der Bewegungsmelder und Fensterkontakt (auch *reed*) verarbeitet. Als sicheren Indikatoren für Anwesenheit werden dabei im ersten Schritt nur die Daten der Bewegungsmelder, sowie die Änderung des Fensterstatus herangezogen. In einer vergleichbaren Studie haben die Autor:innen durch eine begleitende Befragung herausgefunden, dass die Nutzer:innen die Fenster schließen, bevor sie ihre Wohnung verlassen (Andersen et al., 2013). Da in der begleitenden Befragung im vorliegenden Projekt dieses Verhalten jedoch nicht abgefragt wurde, wird im folgenden ausschließlich mit den sicheren Indikatoren gearbeitet. Da es sich bei beiden Indikatoren nur um Momentaufnahmen handelt, wird davon ausgegangen, dass um diese Momentaufnahme in einem Zeitraum von ± 15 min Nutzer:innen in der Wohnung waren. Die daraus resultierende Bedingung ist in den Gleichungen 4.10 und 4.11 dargestellt.

$$MD_{anw} = t_{md} \pm 15 \text{ min} \quad (4.10)$$

$$WIN_{anw} = t_{win} \pm 15 \text{ min} \quad (4.11)$$

mit MD_{anw} Anwesenheitskriterium *Bewegungsmelder*

t_{md} Auslösezeitpunkt des Bewegungsmelders

WIN_{anw} Anwesenheitskriterium *Fensterinteraktion*

t_{win} Zeitpunkt einer Interaktion mit einem Fenster (Öffnen/Schließen)

In Abbildung 4.6 werden die entsprechenden Messwerte für einen beispielhaften Zeitraum dargestellt. Es lassen sich bereits Häufungen morgens und abends erkennen. Insbesondere nachts sind jedoch noch größere Lücken in der Anwesenheit vorhanden. Um ein kontinuierliches Bild über die Anwesenheit zu bekommen wird zusätzlich die CO₂-Konzentration im

Schlafzimmer herangezogen.

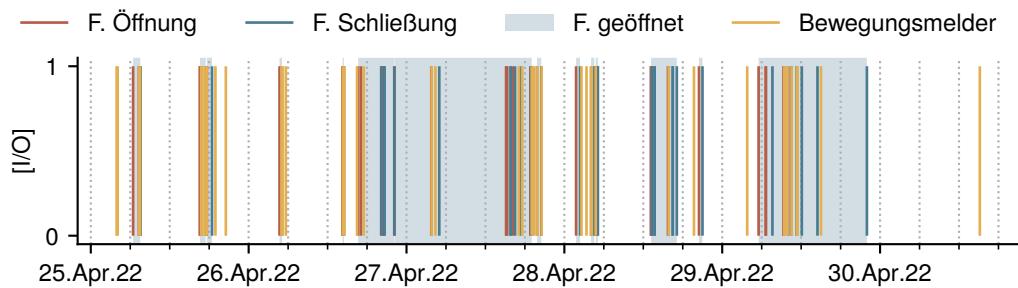


Abbildung 4.6 Beispielhafte Darstellung der detektierten Bewegungen und Fensterinteraktionen zur Ermittlung der Anwesenheit.

CO₂-Anwesenheitskriterium

Da nur im Schlafzimmer ein CO₂-Sensor verbaut ist, wird der Messwert des Schlafzimmers als Indikator für die gesamte Wohneinheit verwendet. Insgesamt wurden vier Teilkriterien entwickelt um anhand des Verlaufes der CO₂-Konzentration auf die Anwesenheit in der Wohnung schließen zu können. Dabei wird stets der gleitende Mittelwert der Messwerte über 15 min betrachtet.

$$CO_{2,app} = CO_{2,SZ,rol.15\text{ min}} \quad (4.12)$$

mit $CO_{2,app}$ CO₂-Indikator für Wohneinheit

$CO_{2,SZ,rol.15\text{ min}}$ Gleitender Mittelwert über 15 min des CO₂-Sensors im Schlafzimmer

Das erste Teilkriterium (CO_2A) beschreibt dabei das Zunehmen der Konzentration. Es wird jeweils ein gleitendes Zeitfenster über 2 h betrachtet. Steigt die Konzentration in diesem Zeitraum, wird von Anwesenheit ausgegangen.

$$CO_2A = \begin{cases} 1 & \text{wenn } CO_{2,app,t=0} < CO_{2,app,t+2\text{ h}}, \\ 0 & \text{sonst} \end{cases} \quad (4.13)$$

mit $CO_{2,app,t}$ CO₂-Konzentration zum Zeitpunkt ($t = 0$)
[1 em]

$CO_{2,app,t+2\text{ h}}$ CO₂-Konzentration zum Zeitpunkt ($t + 2\text{ h}$)

Zusätzlich wird die gemessene CO_2 -Konzentration im unbewohnten 1-Zimmer Appartement der gleichen Bauweise (Referenzwohnung) als Referenzwert für Abwesenheit herangezogen. Zusätzlich zum Zunehmen der Konzentration muss die Konzentration, bei geschlossenen Fenstern, auch über der Konzentration der Referenzwohnung liegen, damit Anwesenheit angenommen werden kann. Es gilt bei geschlossenen Fenstern:

$$CO_2B = \begin{cases} 1 & \text{wenn } CO_{2,app} > 1,1 * CO_{2,ref}, \\ 0 & \text{sonst} \end{cases} \quad (4.14)$$

mit $CO_{2,app}$ aktuelle CO_2 -Konzentration

$CO_{2,ref}$ aktuelle CO_2 -Konzentration in der Referenzwohnung

Sind die Fenster geöffnet sinkt die Konzentration stark ab und gleicht sich der Konzentration in der Außenluft an. Insbesondere wenn Fenster über einen längeren Zeitraum (z.B. über Nacht) geöffnet sind, fallen die CO_2 -Konzentrationsspitzen viel geringer aus. Um auch diesen Fall darzustellen wird bei geöffnetem Fenster die aktuelle Konzentration dem Tagesmittel der Referenzwohnung verglichen. Ist die aktuelle Konzentration größer als das Tagesmittel in der Referenzwohnung, kann ebenfalls von Präsenz ausgegangen werden.

$$CO_2C = \begin{cases} 1 & \text{wenn } CO_{2,app} > CO_{2,ref,24\text{ h}}, \\ 0 & \text{sonst} \end{cases} \quad (4.15)$$

mit $CO_{2,app}$ aktuelle CO_2 -Konzentration

$CO_{2,ref,24\text{ h}}$ Tagesmittel der CO_2 -Konzentration in der Referenzwohnung

Das Kriterium CO_2A wird schließlich mit dem Kriterium CO_2B logisch vereint. Das Kriterium CO_2C gilt davon unabhängig

$$CO_{2,anw} = (CO_2A \wedge CO_2B) \vee CO_2C \quad (4.16)$$

In Abbildung 4.7 ist das CO_2 -Kriterium für den exemplarischen Zeitraum dargestellt. Es lässt sich gut erkennen, dass das abgeleitete Kriterium gut den CO_2 Verlauf widerspiegelt. Am Beispiel des zufällig ausgewählten 29. April 2022 (nachmittags) lässt sich zudem der Wirkmechanismus des Kriteriums CO_2C verdeutlichen. In Abbildung 4.6 ist abzulesen, dass in diesem Zeitraum das Fenster dauerhaft geöffnet ist. Dies führt dazu, die CO_2 -Konzentration nur sehr marginal ansteigt. Die Tatsache, dass sie jedoch über die Referenzkonzentration steigt, lässt darauf schließen, dass sich jemand in der Wohnung befunden haben muss.

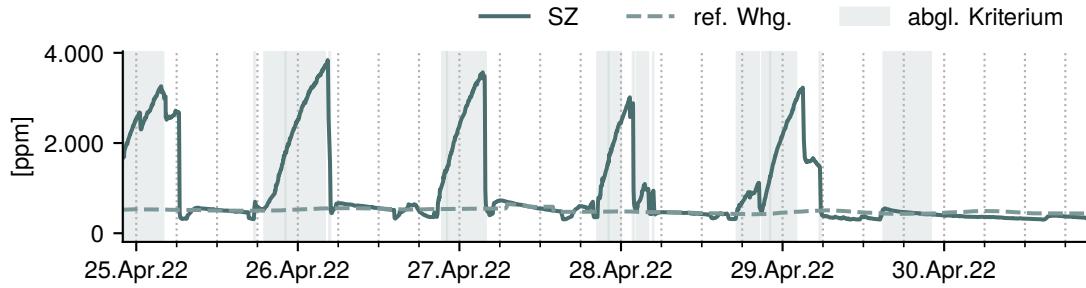


Abbildung 4.7 Beispielhafte Ermittlung des Anwesenheitskriteriums auf Basis der CO_2 -Konzentration. Messwert im Schlafzimmer (SZ) und der Referenzwohnung Ost (O). Grün hinterlegte Zeiträume werden als anwesend klassifiziert.

Feuchte Kriterium

Als letzten Anwesenheitsindikator werden externe Feuchteeinträge über die absolute Luftfeuchte detektiert. Ein externer Feuchteeintrag wird i.d.R. durch Kochen, Duschen aber z.B. auch durch Wäschetrocknen ausgelöst. Da beim Wäschetrocknen nicht unbedingt jemand anwesend sein muss, beim Kochen oder Duschen jedoch schon, werden für dieses Kriterium nur die Messwerte in Bad und Küche herangezogen. Stellen sich in diesen Räumen größere Veränderungen in der Luftfeuchte ein, wird davon ausgegangen, dass entweder ein Feuchteeintag oder -abtrag durch den präsenzgeführten Badablüfter geschehen ist.

Mathematisch wird die Abweichung über das Residuenquadrat dargestellt. Dazu wird die quadrierte Summe aus der Differenz des arithmetischen Mittels des Feuchtegehalts in allen Räumen und dem Feuchtegehalt eines einzelnen Raumes (Küche oder Bad) gebildet. Ist diese größer 0, wird von Präsenz ausgegangen.

$$G_{anw.} = \begin{cases} 1 & \text{für } \sum_{r=0}^{r=n_{rooms}} (\bar{G}_{60\text{ min},r} - \bar{G}_{60\text{ min},rooms})^2 > 0 \\ 0 & \text{sonst} \end{cases} \quad (4.17)$$

Die Darstellung dieses Indikators kann Abbildung 4.8 entnommen werden. Dabei zeigt sich, dass sich die Feuchteveränderungen größtenteils mit den anderen bereits ermittelten Kriterien überschneiden.

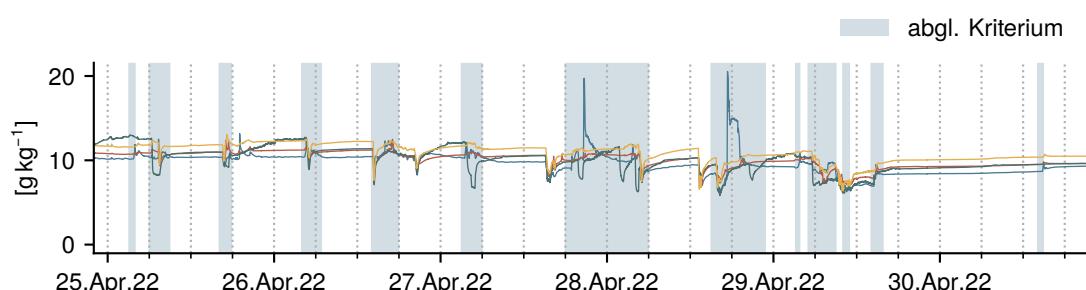


Abbildung 4.8 Beispielhafte Darstellung der Ermittlung des Anwesenheitskriteriums auf Basis der Luftfeuchte [g/kg]. Absolute Luftfeuchte in den Räumen Bad (B), Küche (K), Schlafzimmer (SZ) und Wohnzimmer (WZ). Markierung stellt den Bereich der als Anwesend klassifiziert wurde dar.

Resultierende Anwesenheit

Das Anwesenheitssignal pro Wohneinheit wird schließlich aus der logischen Verbindung der vier ermittelten Indikatoren ($MD_{anw}, WIN_{anw}, CO_2anw und G_{anw}$) gebildet. Sobald eine der vier Bedingungen erfüllt ist, wird für einen Zeitraum Anwesenheit angenommen.

Es gilt:

$$ANW_{\min} = \begin{cases} 1 & \text{für } (MD_{anw} \vee WIN_{anw} \vee CO_2_{anw} \vee G_{anw}) = 1, \\ 0 & \text{sonst} \end{cases} \quad (4.18)$$

$$ANW = \text{median}(ANW_{\min}, 60 \text{ min}) \quad (4.19)$$

Wie in Gleichung 4.19 dargestellt, ergibt sich das verwendete Signal aus dem Median über 60 min der ermittelten Signale. Dadurch wird vermieden, dass das Anwesenheitssignal zu sehr hin und her springt. In Abbildung 4.9 ist das resultierende Anwesenheitssignal für den exemplarischen Zeitraum graphisch dargestellt.

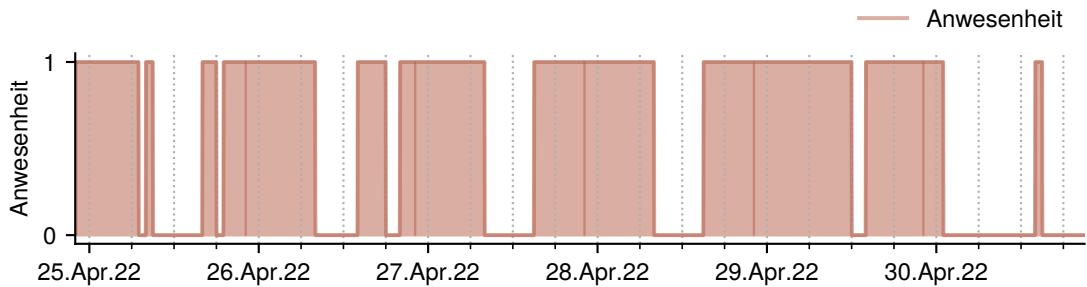


Abbildung 4.9 Resultierendes Anwesenheitssignal aus der beispielhaften Ermittlung.

4.1.7. Thermischer Komfort

Die Ergebnisse dieser Arbeit sollen anhand des thermischen Komforts bewertet werden. Dazu wird im Folgenden beschrieben wie die entsprechenden Größen ermittelt wurden. Als Hauptkriterium werden die adaptiven Komfortmodelle DIN EN 16798 verwendet. Die Auswertung erfolgt dabei über die sogenannten Über- und Untergadstunden. Für die Berechnung der UTGS bzw. ÜTGS gibt die DIN EN 16798-1, 2022 zwei verschiedene Modelle vor. Das Modell aus dem Nationalen Anhang (in dieser Arbeit adaptives Komfortmodell nach DIN EN 16798-1:2022 - NA bezeichnet) gibt einen Komfortbereich für die operative Raumtemperatur in Abhängigkeit des stündlichen Mittelwerts der Außenlufttemperatur an, wenn die Nutzer:innen ihre Bekleidung der Temperatur anpassen können. Das Modell ist vor allem für die Auslegung von Heizungsanlagen gedacht und damit vor allem für die Jahreszeit Winter relevant. Das Modell aus dem Hauptteil der Norm (in dieser Arbeit adaptives Komfortmodell nach DIN EN 16798-1:2022) ist erst ab einer mittleren Außenlufttemperatur von $>10^{\circ}\text{C}$ definiert und damit vor allem für die Jahreszeit Sommer relevant. Die Über- und Untertemperaturgradstunden nach beiden Modellen werden für jeden Zeitschritt errechnet und in der Datenbank

abgespeichert. Zur Berechnung wird dabei - wo kein Messwert des Schwarzkugelthermometer vorhanden ist - die Näherung nach Unterunterabschnitt 4.1.3 verwendet.

4.2. Auswertung der Messdaten

Im Folgenden wird der erstellte Datensatz nun beschrieben und ausgewertet. Dabei liegt der Fokus auf dem Nutzungsverhalten, wobei sich diese Arbeit auf der Beschreibung des Lüftungsverhaltens und dessen Abbildung in der Gebäudesimulation konzentriert. Die vorgestellten Verfahren können jedoch auch auf andere Faktoren wie z.B. das Heizverhalten übertragen und angewendet werden.

4.2.1. Übersicht über den erstellten Datensatz

Der Matrix in Abbildung 4.10 kann entnommen werden, welcher Messwert für welchen Raum und welche Wohnung vorhanden ist. Zusätzlich ist der Zeitschritt, in dem der Messwert erfasst wird, gekennzeichnet. Werte, die als *eigene Berechnung* gekennzeichnet sind, wurden aus den Sensordaten abgeleitet und können abweichende zeitliche Auflösungen haben.

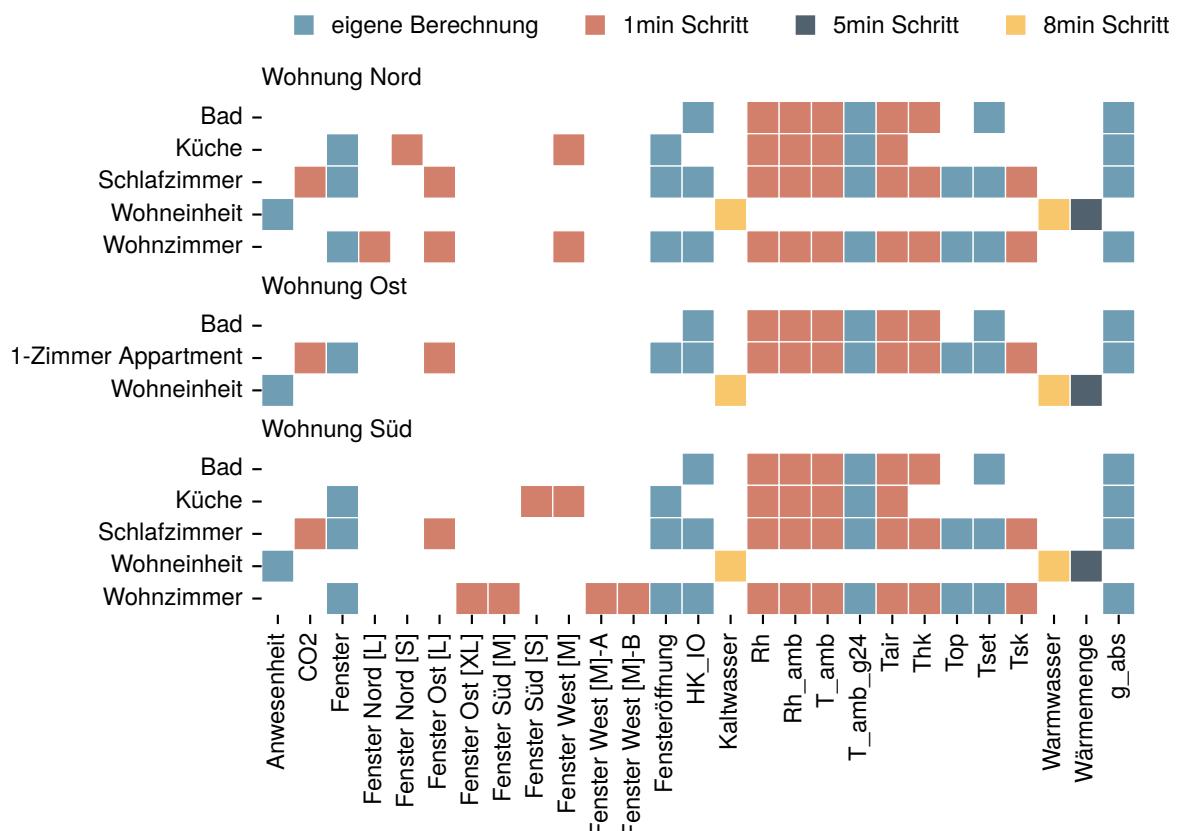


Abbildung 4.10 Übersicht über die verfügbaren Messwerte in den einzelnen Räumen und Wohneinheiten. Die Farbcodierung gibt Auskunft über das Aufzeichnungsintervall des jeweiligen Wertes.

4.2.2. Anwesenheit

Bei den betrachteten Forschungshäusern ist - abgesehen von der mechanischen Abluft im Bad - keine maschinelle Lüftungsanlage verbaut. Das heißt die Nutzer:innen steuern die Lüftung fast vollständig selbst über die Fensteröffnung. Das bedeutet allerdings auch, dass nur gelüftet werden kann, wenn sich Nutzer:innen in einer Wohnung aufhalten. In der folgenden Abbildung 4.11 wird daher dargestellt wie häufig sich im Mittel Personen in einer Wohnung aufgehalten haben. In der oberen Grafik wird dabei der Tagesmittelwert pro Jahreszeit dargestellt. Es zeigt sich, dass hier keine klar erkennbare Saisonalität im Verhalten ablesbar ist. Zwar sind die Nutzer:innen im Leichtbetonhaus im Winter und in den Übergangsphasen mit 12 h bis 16 h beinahe doppelt so lange in der Wohnung wie im Sommer mit 6 h bis 9 h. Jedoch lässt sich im Holzhaus ein gegenteiliger Trend beobachten. Im Mauerwerk ähneln sich alle Mittelwerte dagegen sehr.

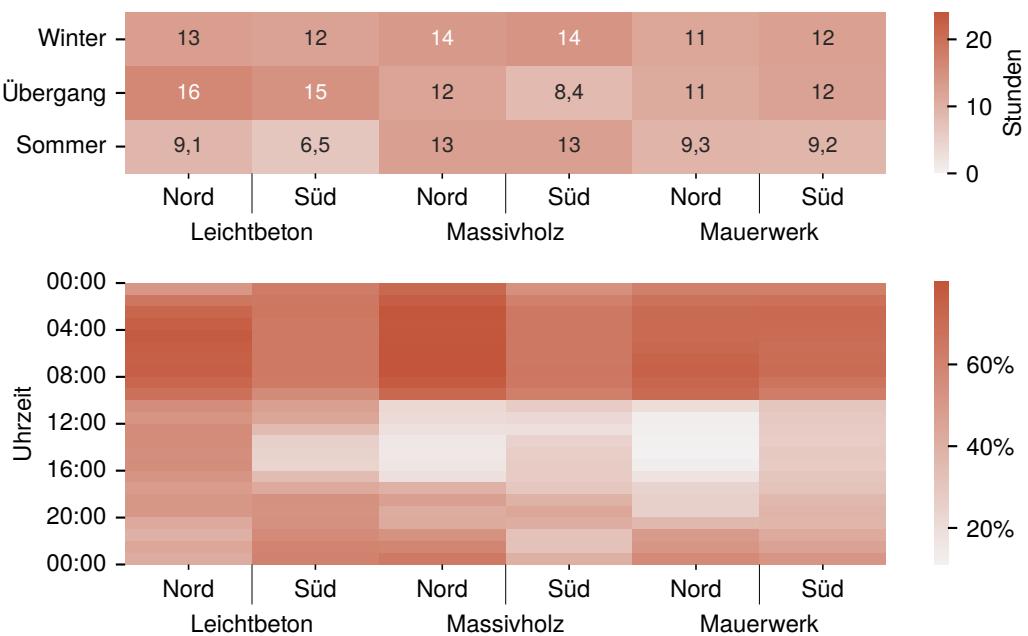


Abbildung 4.11 Mittlere Anwesenheit in Stunden pro Tag, nach Jahreszeiten gemittelt (oben) und Anteil Anwesenheit nach Tageszeit (unten). 50 % bedeutet, dass in 50 % des beobachteten Zeitraums in der betreffenden Stunde Anwesenheit festgestellt wurde.

Betrachtet man nun den Anteil der Stunden mit Anwesenheit im Tagesverlauf (unten) so lassen sich hier etwas deutlichere Trends ablesen. Besonders im Massivholzhaus und im Mauerwerkshaus lässt sich zwischen 08:00 und 10:00 Uhr ein Bruch feststellen. Auch in der südlichen Wohnung im Leichtbetonhaus lässt sich dieser Bruch erkennen, wenn auch etwas später am Tag. Insgesamt spiegelt der tageszeitliche Verlauf tendenziell einen klassischen Arbeitstag mit Arbeitszeiten von 09:00 bis 17:00 Uhr wieder. Dies entspricht annähernd den Annahmen, von denen z.B. in der SIA 2024 ausgegangen wird. Diese wurden in Abschnitt 2.1 beschrieben.

Zusätzlich wurde das ermittelte Anwesenheitssignal mittels KMeans Algorithmus geclustert.

Auf diese Weise sollen aufeinanderfolgende Tage mit außergewöhnlich geringer Anwesenheit ermittelt werden. Dabei wird ein Tag als abwesend deklariert, wenn der Tag davor und der Tag danach ebenfalls geringe Anwesenheiten aufweisen. Für diese Zeiträume wird angenommen, dass die Nutzer:innen verreist bzw. sich länger nicht in der Wohnung aufgehalten haben. Die Ergebnisse sind in Abbildung 4.12 zusammengefasst und in Abschnitt B.6 detailliert dargestellt.

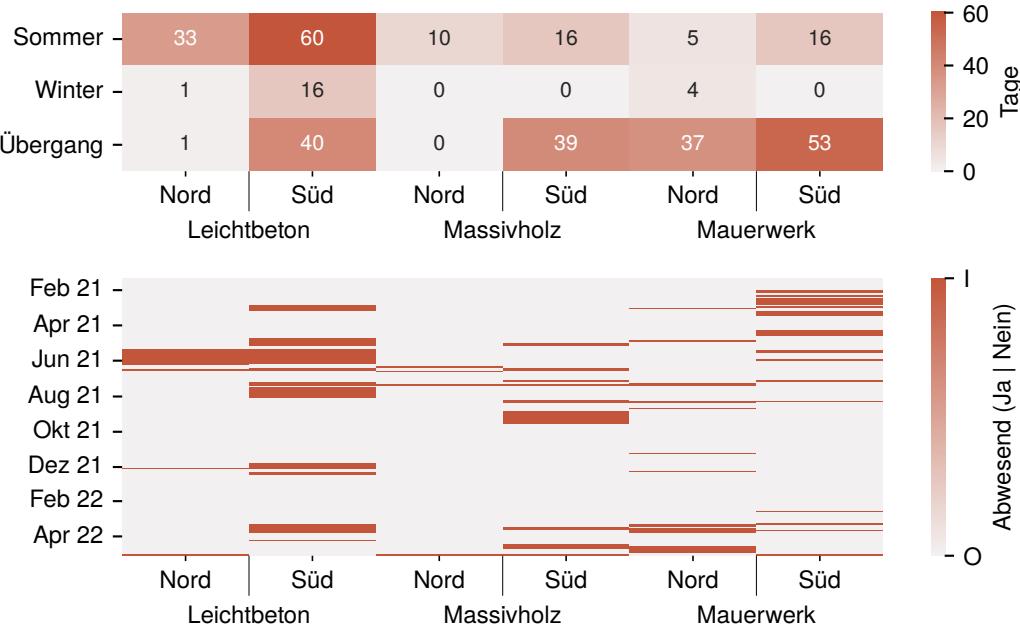


Abbildung 4.12 Durch Clustering ermittelte mittlere Abwesenheit. Anzahl an Tagen, an denen am vorigen und nächsten Tag wenig Anwesenheit detektiert wurde pro Tag und Jahreszeit. Unten zeitlicher Verlauf der geclusterten Abwesenheit.

Aus der Zusammenfassung wird ersichtlich, dass die meisten abwesenden Tage im Sommer festgestellt werden. Es bleibt anzumerken, dass die Messungen während der COVID-19 Pandemie stattgefunden haben und die Ergebnisse - insbesondere bei der Anwesenheit - unter dem Einfluss von zeitweisen Ausgangssperren und Homeoffice-Pflicht stehen.

4.2.3. Raumklima

Neben der Anwesenheit ist vor allem das Raumklima relevant. Im Allgemeinen wird angenommen, dass das Lüftungsverhalten vom Klima im Raum bedingt wird.

Temperatur

In Abbildung 4.13 sind die gemessenen Raumlfttemperaturen in den einzelnen Wohneinheiten inklusive der Referenzappartements dargestellt. Es zeigt sich, dass die Temperaturen in den unterschiedlichen Wohneinheiten relativ konstant sind. Insbesondere in den bewohnten Wohneinheiten Nord (N) und Süd (S) halten sich die Temperaturen alle in ähnlichen Bereichen auf. Im Sommer fällt auf, dass insbesondere die O des Massivholzhaus und des Mauerwerkshaus eine wesentlich höhere Raumlfttemperatur aufweisen als die bewohnten Wohnungen (N und S). Dies könnte auf den fehlenden Luftwechsel durch manuelles Lüften zurückzuführen sein. Dass dieser Effekt im Leichtbetonhaus weniger stark ausgeprägt ist,

könnte mit der Verschattung durch benachbarte Bäume direkt vor dem Fenster des Appartements zusammenhängen.

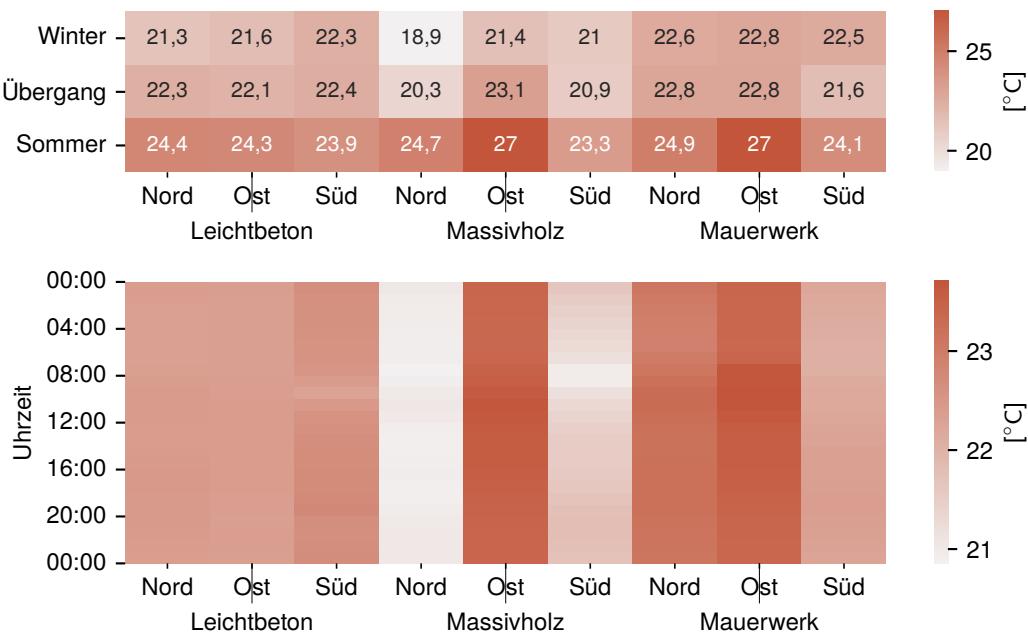
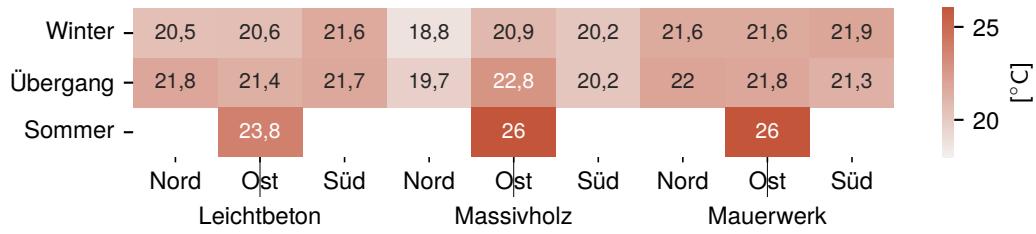


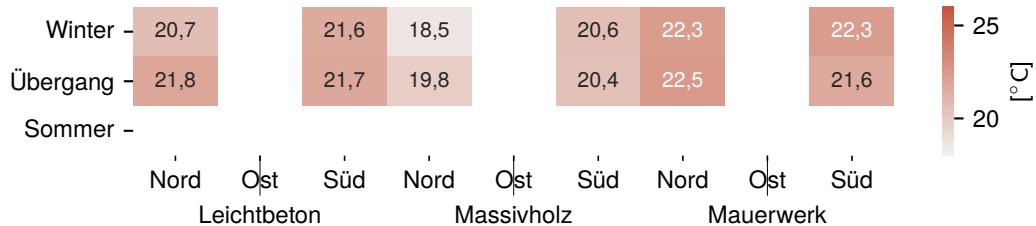
Abbildung 4.13 Mittlere Raumlufttemperatur $\overline{T}_{air,24\text{ h}}$ in $^{\circ}\text{C}$ pro Tag, gemittelt nach Jahreszeit (oben). Mittlere Raumlufttemperatur $\overline{T}_{air,60\text{ min}}$ in $^{\circ}\text{C}$ gemittelt nach Tageszeit (unten)

Zusätzlich zur Raumlufttemperatur sollte im Rahmen einer Komfortbetrachtung immer auch die operative Raumtemperatur mit betrachtet werden. Hier wird im Rahmen dieser Arbeit zwischen der nach Unterabschnitt 4.1.3 aus der Schwarzkugeltemperatur errechneten und der nach Unterunterabschnitt 4.1.3 geschätzten operativen Temperatur unterschieden. In der folgenden Abbildung 4.14 sind die saisonalen Tagesmittelwerte und mittleren Tagesgänge der gemessenen operativen Temperatur dargestellt. Da die Messung erst am 02. September 2021 begann, sind keine Daten für den Sommer vorhanden.

Die operative Raumtemperatur zeigt wie die Raumlufttemperatur keine Auffälligkeiten im Tagesgang. In den Wohnungen mit Ausrichtung gegen Osten lassen sich morgens leichte Spitzen ausmachen, die darauf schließen lassen, dass in diesen Zeiten die Sonne in die Wohnung scheint und es dadurch zu einer Erwärmung kommt. Da vor der Ostfassade des Leichtbetonhauses mehrere altgewachsene Bäume stehen, fällt dieser Effekt hier nicht so stark auf. Vergleicht man die gemessenen operativen Temperaturen mit der Näherung im gleichen Zeitraum, so zeigt sich, dass sich die Werte in einem ähnlichen Bereich aufhalten. Die Abweichung beträgt in den meisten Fällen $<0,5\text{ K}$. Die Qualität der verwendeten Näherung entspricht damit den in Unterunterabschnitt 4.1.3 dargestellten theoretischen Kenngrößen und befindet sich im Bereich der Messtoleranz von $\pm 0,2\text{ K}$. Damit kann sie im Folgenden weiter zur Analyse herangezogen werden.



(a) operative Raumtemperatur bestimmt aus Raumlufstemperatur T_{air} , T_{amb} und Schwarzkugeltemperatur T_{SK} .



(b) operative Raumtemperatur als Näherung aus der Raumlufstemperatur T_{air} , T_{amb} und einem linearen Faktor.

Abbildung 4.14 Mittlere operative Temperatur pro Tag, gemittelt nach Jahreszeit.

Luftfeuchte

Neben der Temperatur bestimmt die Luftfeuchte das Raumklima. Die Luftfeuchte wird als relative Luftfeuchte von den TRH-Sensor aufgezeichnet und anschließend die absolute Feuchte errechnet. Im Rahmen des Forschungsprojektes ist aufgefallen, dass die Messwerte für die relative Luftfeuchte z.T. unplausibel wirken, weswegen die in Unterunterabschnitt 4.1.1 beschriebene Korrektur auf die Messwerte angewendet wird. Die Betrachtung beginnt mit dem Tagesprofil der relativen Luftfeuchte in Abbildung 4.15. Hier zeigt sich, ähnlich wie bei der Temperatur, kein auffälliges Tagesprofil. Etwaige Spitzen durch externe Feuchteinträge wie Duschen oder Kochen lassen sich in dieser Darstellung nicht ausmachen. Anhand der Darstellung kann vielmehr darauf geschlossen werden, dass die Luftfeuchte in den Wohnungen über den Tag verteilt ähnlich ist und sich keine Unterschiede zwischen den Tageszeiten einstellen.

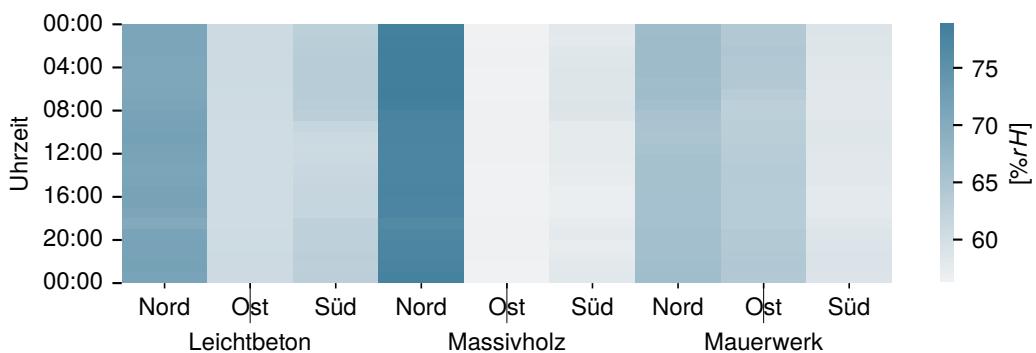


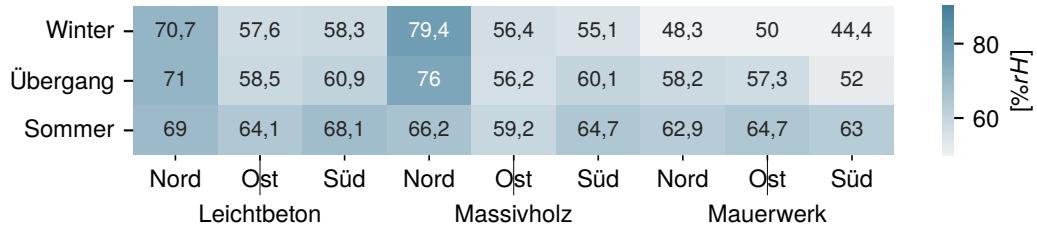
Abbildung 4.15 Tagesprofil der mittleren rel. Luftfeuchte pro Stunde.

Im nächsten Schritt soll die Plausibilität der angewendeten Korrektur überprüft werden. Dazu sind die Tagesmittel nach Jahreszeiten in Abbildung 4.16 nach Korrektur mit einem festen

Wert und einer linearen Korrektur dargestellt. Bei der Betrachtung aller Werte fällt auf, dass die relativen Luftfeuchten auch nach Anwendung der Korrektur noch relativ hoch sind. Be- trachtet man die Werte, die vergleichbare Studien im Vereinigten Königreich (Jones et al., 2017), Dänemark (Andersen et al., 2013) und Deutschland (Calì et al., 2016) ermittelt haben, so werden hier mittlere relative Luftfeuchten im Bereich von 30 %rH bis 50 %rH verzeichnet. Die vorliegenden Werte in diesem Forschungsprojekt bewegen sich - je nach angewandter Korrektur - eher zwischen 50 %rH bis 80 %rH. Aufgrund dieser Feststellung und der ver- gleichend durchgeföhrten Referenzmessungen mit anderen Messsystemen wurde die ein- gangs beschriebene Korrektur entwickelt. Im Rahmen dieser Arbeit wird die Korrektur des Forschungsprojektes noch um eine einfache lineare Korrektur, die jeden Wert mit einem Fak- tor multipliziert, anstatt einen festen Wert zu subtrahieren, erweitert. Die Ergebnisse dieser Korrektur werden zum Vergleich als *lineare Korrektur* dargestellt.



(a) unveränderte Messwerte



(b) Messwerte korrigiert um einen konstanten Wert nach Tabelle 4.2.

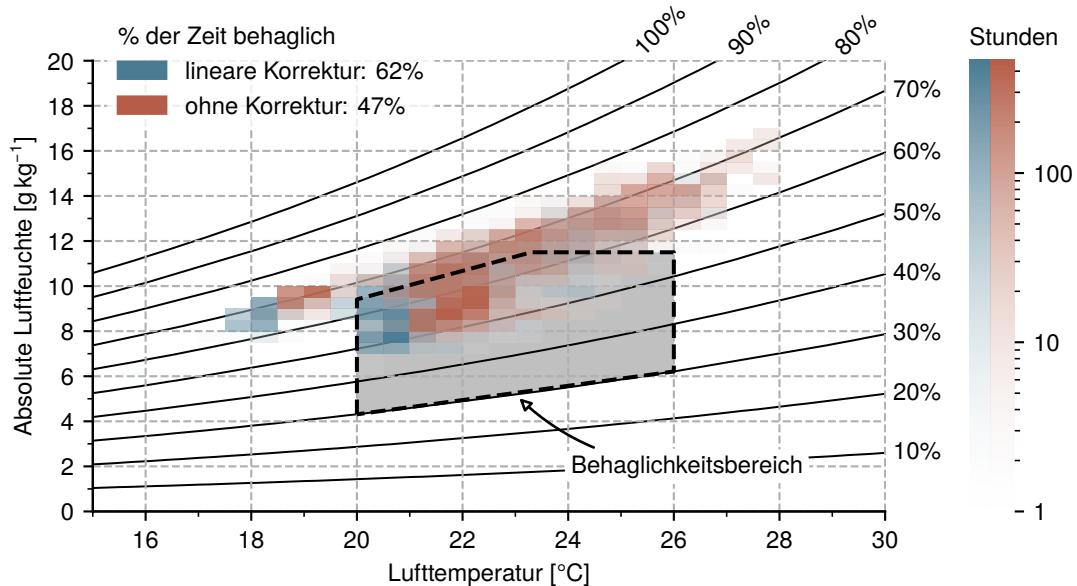


(c) Messwerte korrigiert um einen linearen Faktor

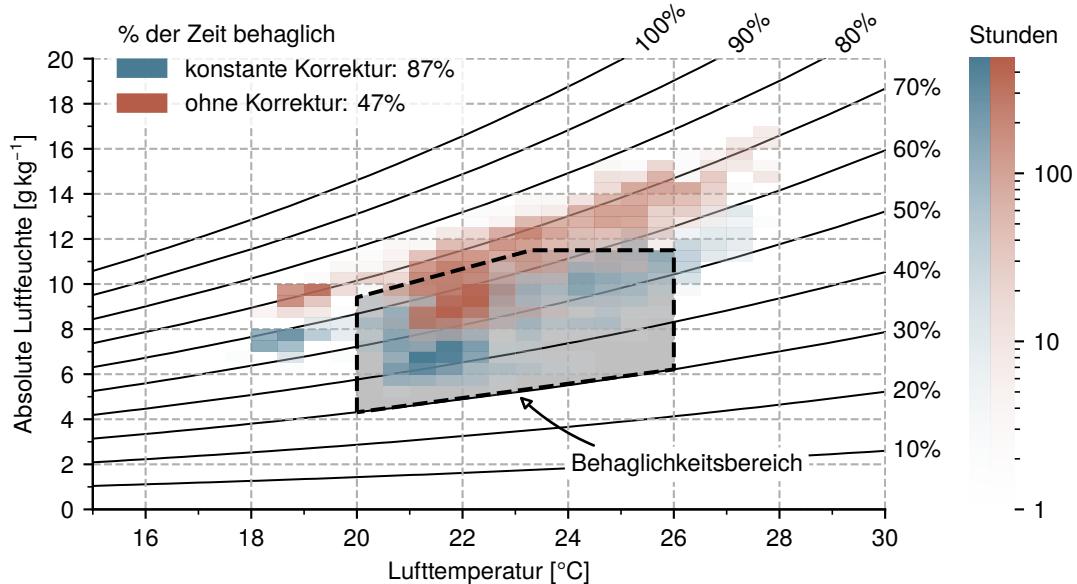
Abbildung 4.16 Vergleich der Korrekturmethoden für die Messwerte der rel. Luftfuchte. Darstellung der mittleren rel. Luftfeuchte in [%rH] nach Jahreszeiten und Wohneinheiten gemittelte Tagesmittelwerte.

Um den Einfluss der Raumtemperatur besser mit einbeziehen zu können, werden die beiden Korrekturen in einem Hx-Diagramm betrachtet. In Abbildung 4.17 sind dazu beispielhaft für zwei Räume Hx-Diagramme einmal mit linearer Korrektur (oben) und mit konstanter Korrektur (unten) dargestellt. Im Vergleich dazu sind jeweils die unkorrigierten Messwerte geplottet. Es zeigt sich der Einfluss der Korrektur noch einmal sehr deutlich. Während die lineare Korrektur mehr eine Verschiebung entlang des relativen Luftfeuchteniveau bewirkt und damit vornehm-

lich die absolute Feuchte korrigiert, führt die konstante Korrektur zu einer Verschiebung in negativer Y-Richtung, wobei durch diese Korrektur am Ende beinahe doppelt so viele Messpunkte im Behaglichkeitsbereich nach DIN EN 16798-1 (2022) liegen.



(a) Lineare Korrektur im Vergleich zum unkorrigierten Messwert.



(b) Konstante Korrektur im Vergleich zum unkorrigierten Messwert.

Abbildung 4.17 Darstellung der Auswirkung der Korrektur der rel. Luftfeuchte anhand eines Hx-Diagrammen am Beispiel des Schlafzimmers der Wohnung Nord im Mauerwerkshaus.

Zusammenfassend lässt sich festhalten, dass die bisher angewendete konstante Korrektur nicht plausibel wirkt. Nicht nur ergibt sie physikalisch wenig Sinn, sie führt auch dazu, dass die Werte v.a. im Mauerwerkshaus im Vergleich zu den anderen Häusern unplausibel wirken. Insgesamt sind die Luftfeuchten jedoch für alle Wohneinheiten relativ hoch. Da sich durch Vergleichsmessungen gezeigt hat, dass die Messungen nicht akkurat sind, ist es rat-

sam eine Korrektur anzuwenden. Im Rahmen dieser Arbeit wird jedoch die vorgestellte lineare Korrektur verwendet. Für die Zukunft könnte es sinnvoll sein, nicht die relative, sondern die absolute Feuchte zu korrigieren. Die errechnete absolute Feuchte nach linearer Korrektur wird - getrennt nach Jahreszeiten - in Abbildung 4.18 dargestellt.

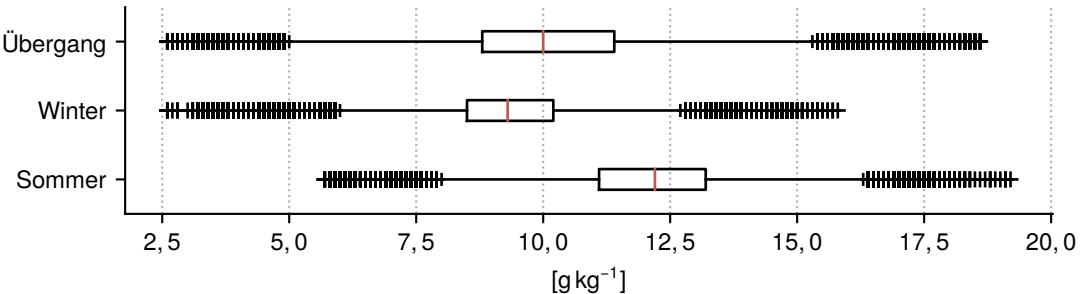


Abbildung 4.18 Wertebereiche der absoluten Luftfeuchte nach Jahreszeiten, dargestellt als Boxplot

CO₂-Konzentration

Die letzte Größe, die im Rahmen dieses Kapitels als Indikator für das Raumklima dienen soll, ist die CO₂-Konzentration in der Luft. Diese wird nur in den Schlafzimmern erfasst, dient falls notwendig jedoch als Referenzwert für die Anwesenheit für der gesamte Wohneinheit. Die Tagesmittelwerte sowie der mittlere Tagesgang wird in Abbildung 4.19 dargestellt.

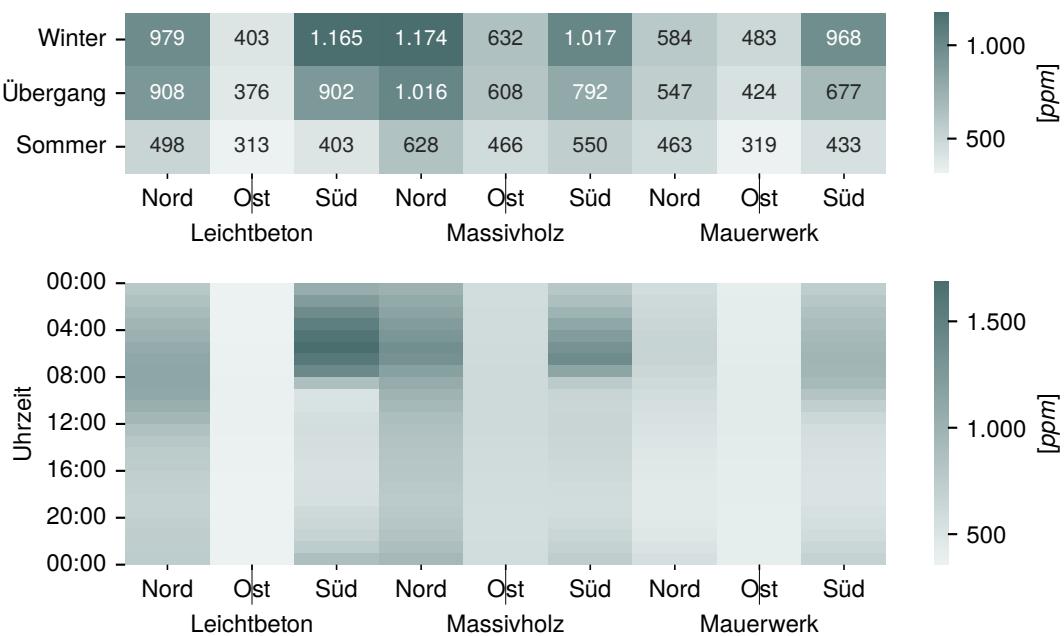


Abbildung 4.19 Mittlere CO₂-Konzentration. Oben Tagesmittelwert, Mittelwerte nach Jahreszeit. Unten stündliche Mittelwerte nach Tageszeit.

Die saisonalen Tagesmittelwerte lassen eine leichte Saisonalität der Messwerte erkennen. Diese ist in den bewohnten Wohnungen ((N) und (S)) stärker ausgeprägt als in den unbewohnten Wohnungen (O). Dennoch sind die Konzentrationen auch in den unbewohnten Wohnungen (Ost) im Sommer zwischen 22 %punkten bis 34 %punkten ausgeprägt. Insbe-

sondere im Winter liegen die Werte in den bewohnten Appartements um ein Vielfaches über den Konzentrationen in den unbewohnten Wohnungen. Betrachtet man die Werte gemeinsam mit den Anwesenheiten in Abbildung 4.11 lässt sich ein Zusammenhang zwischen der mittleren Anwesenheit und der mittleren CO_2 -Konzentration feststellen. In den Tagesprofilen der CO_2 -Konzentration in Abbildung 4.19 lässt sich in unterschiedlicher Ausprägung ein gewisser zeitlicher Zusammenhang zwischen der Uhrzeit und der Höhe der Konzentration ablesen. Am Morgen sind die Konzentrationen meistens am höchsten. Tagsüber nähert sie sich dann auch wieder dem Referenzwert in den Ost-Appartements an. Auch hier lässt sich wieder ein Zusammenhang mit der Anwesenheit feststellen.

Thermischer Komfort

Das ermittelte Raumklima wird im folgenden Abschnitt nach den Komfortparametern der DIN EN 16798-1 (2022) ausgewertet. In Abbildung 4.20 sind die ermittelten Kelvinstunden bei Anwesenheit nach beiden Modellen der DIN EN 16798-1 (2022) dargestellt. Wie in Unterabschnitt 4.1.7 dargestellt, wird das Modell adaptives Komfortmodell nach DIN EN 16798-1:2022 v.a. im Sommer, das Modell adaptives Komfortmodell nach DIN EN 16798-1:2022 - NA v.a. im Winter betrachtet. Dabei fällt auf, dass Überhitzung (ÜTGS) nach beiden Modellen nur relativ selten auftritt. Viel häufiger treten zu niedrige Raumtemperaturen (UTGS) auf.

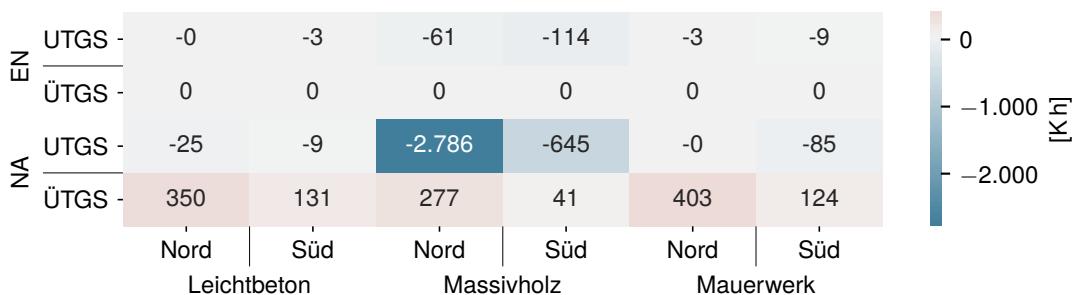


Abbildung 4.20 Summierte Kelvinstunden nach adaptives Komfortmodell nach DIN EN 16798-1:2022 - NA und adaptives Komfortmodell nach DIN EN 16798-1:2022 im Beobachtungszeitraum bei Anwesenheit nach Wohneinheiten und Kategorie. UTGS werden mit negativem Vorzeichen, ÜTGS mit positivem Vorzeichen dargestellt.

Laut Norm dürfen die angegebenen Komfortbänder zu maximal 1 % der Nutzungszeit um mehr als 2 K überschritten werden. Die entsprechenden Werte sind in Abbildung 4.21 dargestellt. Lediglich im Massivholzhaus wurde hier der Grenzwert überschritten.

In den Darstellungen Abbildung 4.22 und Abbildung 4.23 sind die Kelvinstunden für alle Beobachtungen - auch außerhalb der Nutzungszeit - aufgeführt. Betrachtet man nun, wann die Über- bzw. Unterschreitung des Komfortbandes eintritt, zeigt sich, dass dies vor allem im Sommer bzw. in der Übergangszeit und da meistens morgens bzw. nachts der Fall ist. Da dieses Modell erst ab 10 °C Außenlufttemperatur definiert ist, sind im Winter deshalb keine Werte definiert.

Beim Komfortband nach NA (Abbildung 4.23) zeigt sich ein etwas anderes Bild. Während hier im Holz- und Mauerwerkshaus vermehrt ÜTGS auftreten, ist es im Holzhaus, v.a. im

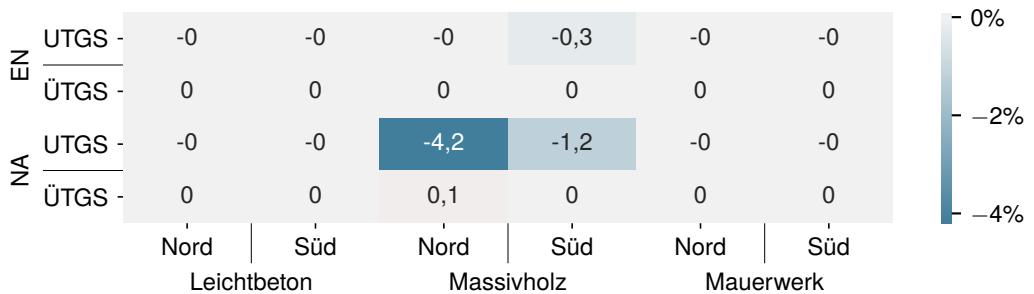


Abbildung 4.21 Zeitlicher Anteil der Abweichung von mehr als 2 K vom entsprechenden Komfortband nach DIN 16798-1 während der Nutzungszeit. UTGS werden mit negativem, ÜTGS mit positivem Vorzeichen dargestellt.

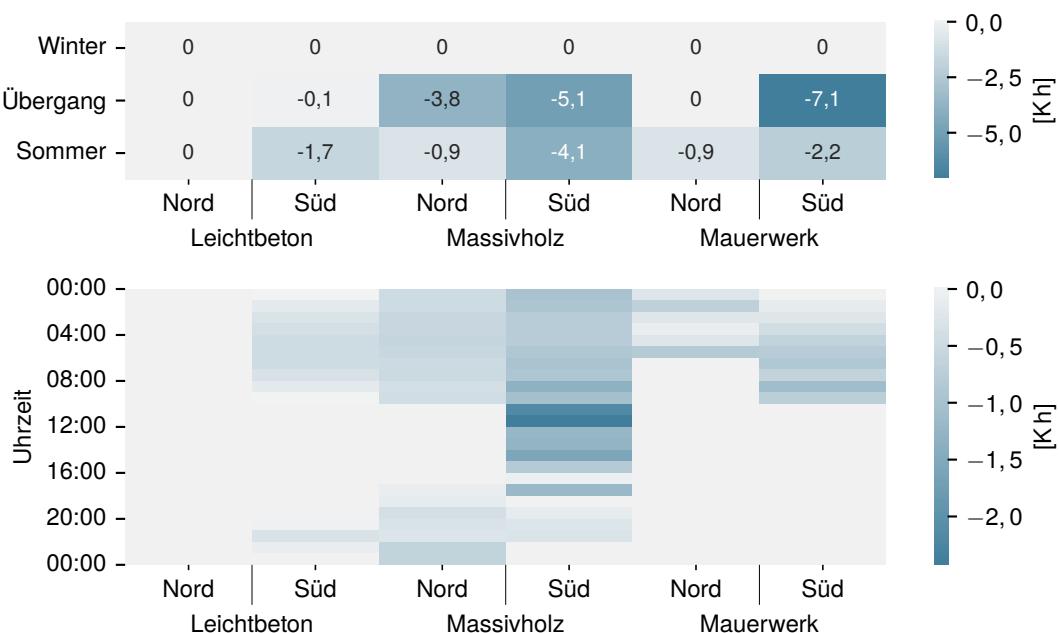


Abbildung 4.22 Mittelwerte der Kelvinstunden (insgesamt, nicht nur bei Anwesenheit!) nach DIN EN 16798-1:2021. ÜTGS werden mit positivem, UTGS mit negativem Vorzeichen dargestellt. Oben: Kelvinstunden pro Tag, gemittelt nach Jahreszeit, Unten: mittlere Kelvinstunden pro Stunde.

Winter oft zu kalt. Dabei treten die meisten UTGS am frühen Abend auf, während die meisten ÜTGS am Vormittag auftreten. Vergleicht man das Profil der UTGS mit dem Heizprofil in Abbildung 4.32 kann man erkennen, dass die sich beide Verläufe gut überlagern lassen. Daraus kann geschlossen werden, dass die zu geringe Temperatur durch die ausgeschaltete Heizung zustande kommt.

4.2.4. Wetter

Das Raumklima ist stets in Zusammenhang mit der Außenklima zu betrachten. In Abbildung 4.24 werden die gemessenen Außenlufttemperaturen der Wetterstation im zeitlichen Verlauf der Tagesmittelwerte und deren Standardabweichung dargestellt. Der Verlauf zeigt die für die Klimaregion zu erwartende Jahreszeitlichkeit der Außenlufttemperatur auf. Trotz einer Datenlücke im Juli 2021 bildet der Datensatz dennoch recht gut einen klimatischen Jahresgang ab. Aus dem Boxplot in Abbildung 4.24 rechts ergibt sich eine Bandbreite der

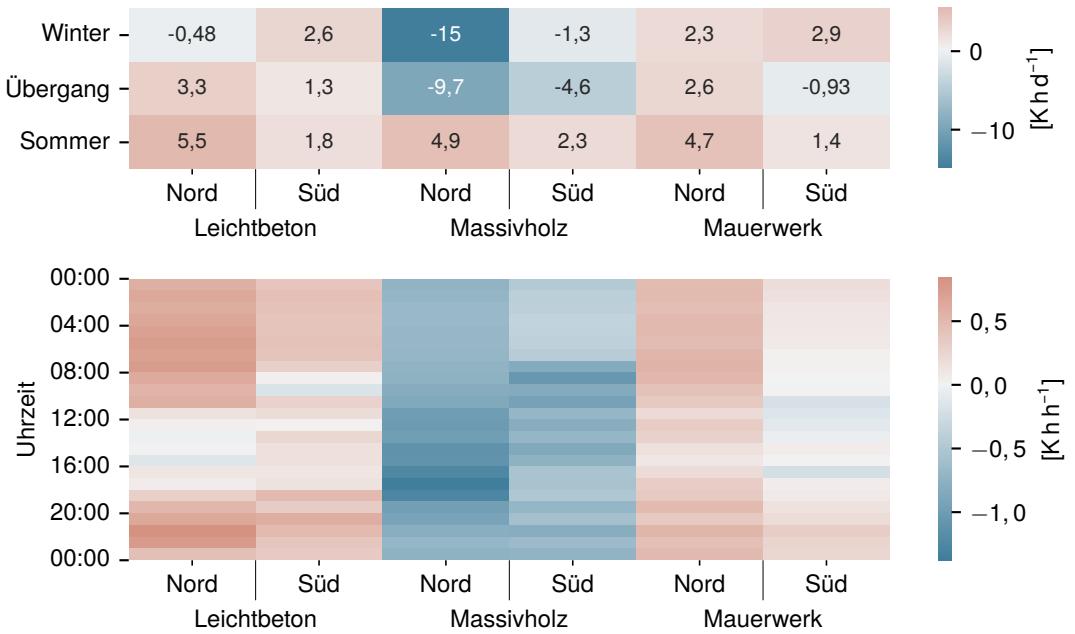


Abbildung 4.23 Mittelwerte der Kelvinstunden (insgesamt, nicht nur bei Anwesenheit!) nach DIN EN 16798-1:2021 (NA). ÜTGS werden mit positivem, UTGS mit negativem Vorzeichen dargestellt. Oben: Kelvinstunden pro Tag, gemittelt nach Jahreszeit, Unten: mittlere Kelvinstunden pro Stunde.

Außenlufttemperatur von etwa -10°C bis 32°C .

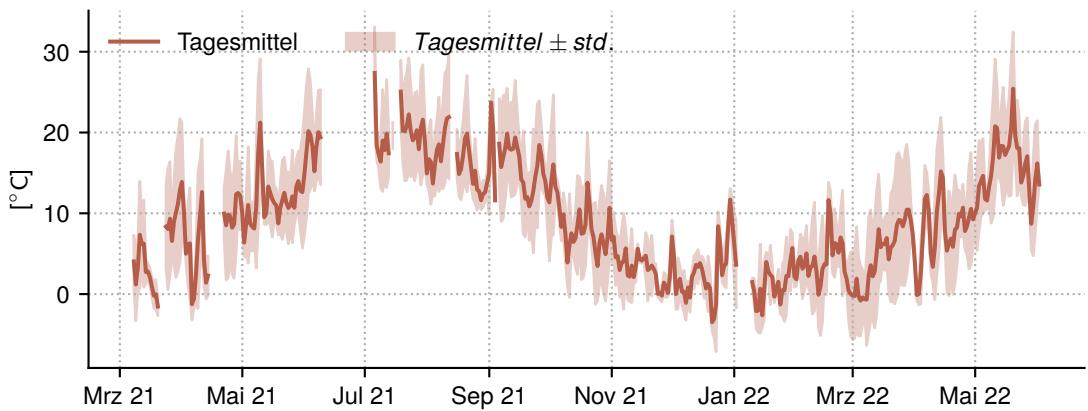


Abbildung 4.24 Profil der Außenlufttemperatur, Tagesmittelwerte mit Bandbreite (\pm Standardabweichung)

Als Plausibilitätskontrolle werden die Messdaten der installierten Wetterstation mit den Daten der nächsten Station des DWD in Rosenheim (**Station 4261**) verglichen. Die Ergebnisse werden in Abbildung 4.25 in Form von Boxplots dargestellt. Man kann erkennen, dass die gemessenen Temperaturen (oben) eine ähnliche Bandbreite wie die Temperaturen der Wetterstation in Rosenheim (unten) haben, wobei die gemessenen Temperaturen in Bad Aibling-Mietraching geringfügig kleiner sind. Dies könnte mit dem Datenausfall im Juli 2021 zusammenhängen, aber auch einfach eine geographische Abweichung aufgrund der unterschiedlichen Standorte sein.

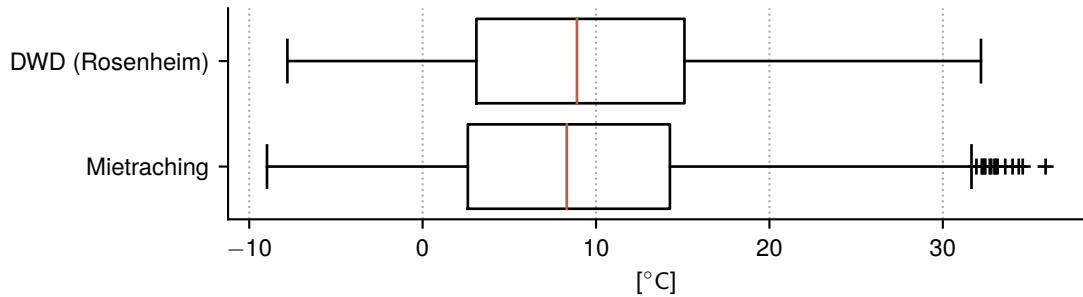


Abbildung 4.25 Vergleich der Messdaten mit den Daten der nächsten DWD-Wetterstation in Rosenheim als Boxplot.

In der folgenden Tabelle 4.6 sind einige klassischen deskriptive Parameter der Außenlufttemperatur, getrennt nach Jahreszeiten, dargestellt. Bei den Minima und Maxima fällt auf, dass der höchste Messwert in den *Übergang* und nicht - wie zu erwarten wäre - in den *Sommer* fällt. Dies könnte ein Indiz sein, dass die Verwendung der meteorologischen Jahreszeiten nicht ideal ist. Da jedoch die Mittelwerte über die Jahreszeiten die zu erwartende aufsteigende Tendenz vom *Winter* über den *Übergang* zum *Sommer* annehmen und zudem im Juli 2021 - einer potentiell sehr warmen Phase im Jahr - ein längerer Messausfall vorliegt, kann davon ausgegangen werden, dass es sich bei den 37,2 °C um einen Ausreißer handelt.

Tabelle 4.6 Desriptive Parameter (min, max, mean, median und std) zum Datensatz T_{amb}

Jahreszeit	min	max	mean	median	std
Winter	-8,8 °C	16,9 °C	2,8°C	2,4°C	4,3K
Übergang	-9,2 °C	37,2 °C	9,0°C	8,5°C	7,3K
Sommer	2,3°C	34,6 °C	17,7 °C	16,2 °C	5,6K

Abschließend werden die Lufttemperaturen in Abbildung 4.26 noch in tageszeitlicher Auflösung dargestellt. Hier zeigt sich eine Abhängigkeit zwischen der Tageszeit und der Lufttemperatur. Diese ist tagsüber stets höher als nachts, was sich durch den Sonnenstand und die damit verbundene Sonneneinstrahlung erklären lässt.

Zum Vergleich ist in Abbildung 4.27 der Messwert der Globalstrahlung im tageszeitlichen Mittel nach Jahreszeiten abgebildet. Diesen beiden Grafiken lässt sich klar der Zusammenhang zwischen Außenlufttemperatur und Globalstrahlung entnehmen. In Abbildung 4.27 ist auffällig, dass die Strahlungsintensität in der Übergangsphase höher zu sein scheint als im Sommer. Hierzu ist zur Veranschaulichung noch der Jahresgang der aufgezeichneten Stahlungen in Abbildung 4.28 abgebildet. Es ist zu sehen, dass im potentiell relativ stahlungsreichen Zeitraum von April 2021 bis Juli 2021 keine Aufzeichnungen vorhanden sind. Zwar fällt dieser Zeitraum auch in die Übergangsperiode, da jedoch für diese viel mehr Messdaten als für die Sommerperiode vorhanden sind, könnte dies die Abweichung erklären.

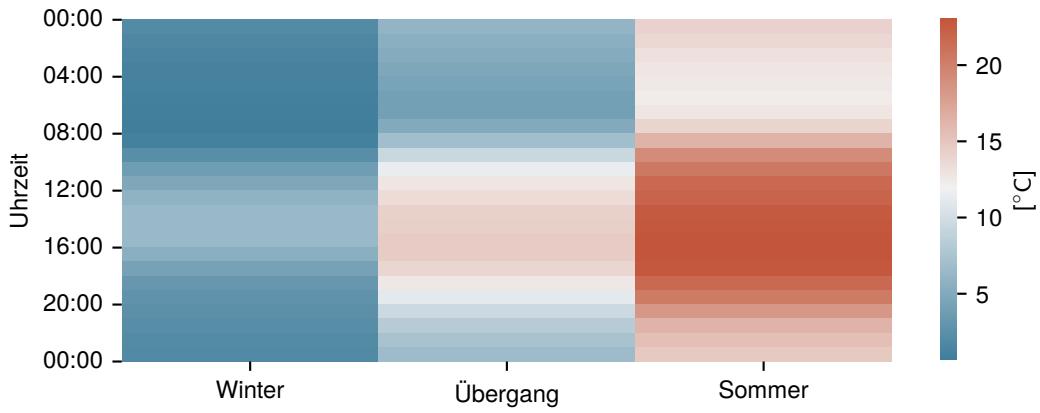


Abbildung 4.26 Stündliche Mittelwerte der Außenlufttemperatur nach Tages- und Jahreszeiten.

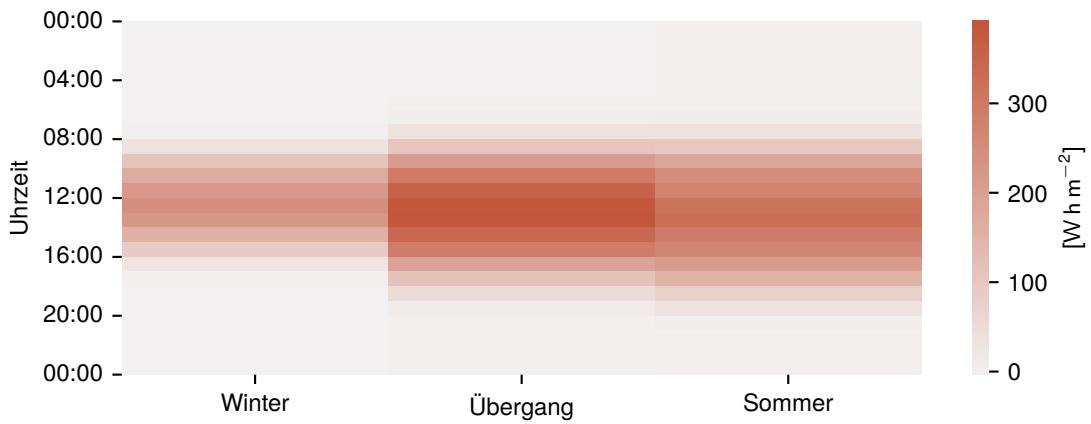


Abbildung 4.27 Stündliche Mittelwerte der Globalstrahlung nach Tages- und Jahreszeiten.

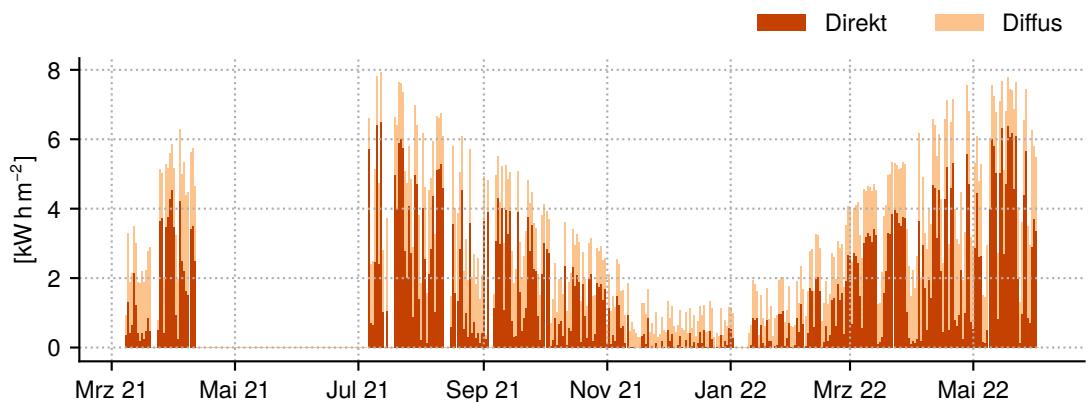


Abbildung 4.28 Jahresgang der gemessenen Strahlungsintensität, getrennt nach Diffus- und Direktstrahlung. Die Globalstrahlung ergibt sich aus der Summe beiden Werte.

Als weitere relevante Größe zur Beschreibung des Außenklimas wird die relative Außenluftfeuchte untersucht. Hier findet sich in Abbildung 4.29 der Jahresgang der aufgezeichneten Tagesmittelwerte mit der zugehörigen Standardabweichung. Bis auf den Ausfall im Juni / Juli 2021 der bereits in den anderen Wetterdaten aufgefallen ist, gibt es hier keine Auffälligkeiten.

ten.

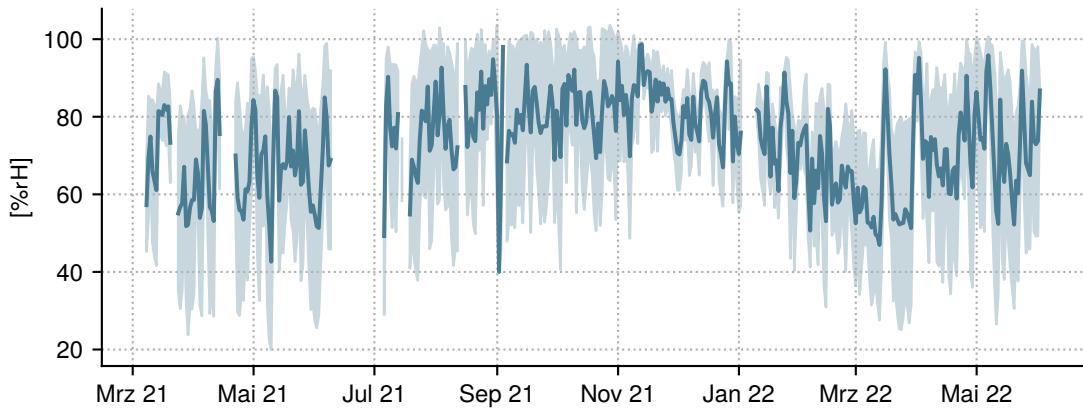


Abbildung 4.29 Profil der relativen Außenluftfeuchte, Tagesmittelwerte mit Bandbreite ($\pm \text{std.}$).

4.2.5. Nutzungsverhalten

Im Kontext des gezeigten Raum- und Außenklimas lässt sich nun das Nutzungsverhalten analysieren. Dabei liegt der Fokus auf der Fensterlüftung und auf dem Heizverhalten.

Heizung

Das Heizverhalten wird über die ermittelten Größen HK_{IO} und T_{set} dargestellt. Zusätzlich werden sogenannte Heiztage ermittelt. Diese werden im Rahmen dieser Arbeit als Tage definiert, in denen vorwiegend geheizt wurde: Tage an denen nur punktuell (z.B. nur im Bad o.ä.) geheizt wurde, werden so aus dieser Betrachtung heraus genommen. Zur Klassifikation der Heiztage wurde dabei ein KMeans Algorithmus verwendet, der die Tagesmittelwerte des Heizungssignals HK_{IO} in zwei Cluster, Heiztag und kein Heiztag, trennt. In Abbildung 4.30 wird die Anzahl der ermittelten Heiztage pro Jahreszeit und Wohneinheit dargestellt. Eine detaillierte Darstellung der Klassifikation im zeitlichen Verlauf kann Abschnitt B.5 entnommen werden.

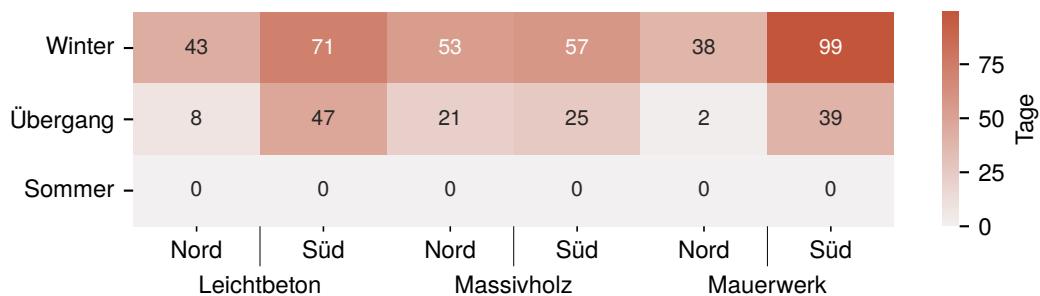


Abbildung 4.30 Darstellung der ermittelten Heiztage im Beobachtungszeitraum

Die Analyse des Heizverhaltens auf Tagesebene erfolgt nun ausschließlich für die ermittelten Heiztage. Im ersten Schritt wird untersucht, wie viele Stunden an einem Heiztag geheizt wird. Die Ergebnisse werden in Abbildung 4.31 dargestellt. Es zeigt sich, dass erwartungsgemäß im Sommer in der Regel nicht geheizt wird. Lediglich in der Südwohnung des Mauerwerkha-

es wurde punktuell geheizt. Es ist auffällig, dass in den Wohnungen LB-N und MW-N auch im Winter nur relativ wenige Heiztage detektiert wurden. Das liegt daran, dass in diesem Leichtbetonhaus zusätzlich zu den Radiatoren Heizpanele an der Decke vorhanden sind. Diese werden im Rahmen des Messkonzeptes nicht erfasst. Aus der Befragung der Nutzer:innen im Rahmen des Forschungsprojektes *Einfach Bauen 3* wurde herausgefunden, dass die Nutzer:innen hier vornehmlich mit der Deckenheizung heizen und die Radiatoren nicht verwendet werden. Dies verzerrt die Klassifikation der Heizkörper in diesem Haus. Im Mauerwerks haus fällt bei Betrachtung der Sensorausfälle im Abschnitt B.1 auf, dass der TRH-Sensor im Schlafzimmer erst seit Januar 2022 wieder Daten liefert. Aus diesem Grund ist hier die Heizkörperklassifikation lückenhaft.

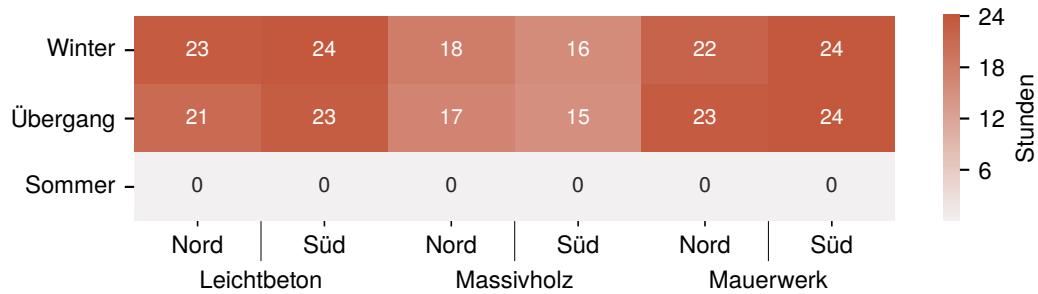


Abbildung 4.31 Kummulierte Auswertung des ermittelten Heizungssignals HK_{IO} für Heiztage. Nach Uhrzeit gemittelte Stundenwerte.

Ebenso wird ersichtlich, dass vier von sechs Nutzer:innen, wenn sie heizen, i.d.R. den ganzen Tag heizen. Das spiegelt sich auch im in dem in Abbildung 4.32 dargestellten Tagesprofil wieder. Hier zeigt sich nochmal, dass v.a. im Massivholzhaus tagsüber die Heizung abgeschaltet wird, wohingegen die Heiung in den anderen beiden Häusern vorwiegend eingeschaltet bleibt. Hier muss jedoch in dieser Darstellungsform die Relation betrachtet werden. Z.B. wird in der N im Mauerwerkshaus nur an relativ wenig Tagen überhaupt geheizt. An den Tagen an denen dann geheizt wird, ist die Heizung dann aber meistens durchgehend an.

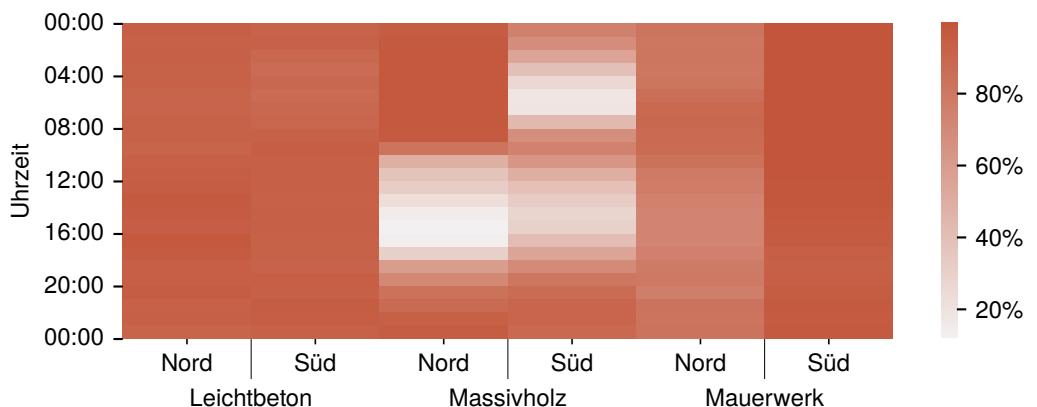


Abbildung 4.32 Kummulierte Auswertung des ermittelten Heizungssignals HK_{IO} für Heiztage in nach Uhrzeit gemittelte Stundenwerte.

Zusätzlich zum Heizzeitraum wurde näherungsweise eine Heizkörpereinstellung ermittelt.

Dazu wurde wie in Abschnitt 4.1 beschrieben, die Raumlufttemperatur als Referenz herangezogen. Die ermittelten Werte können Abbildung 4.33 entnommen werden. Es zeigt sich ein recht homogenes Bild, wobei dies im Mauerwerkshaus einen Ausreißer darstellt. Hier sind die Temperaturen bis zu 6 K höher als z.B. im Holzhaus. Dies kann zum einen am Heizverhalten der Nutzer:innen liegen - kann jedoch auch ein technischer Defekt sein. Z.B. kommt es hin und wieder vor, dass die Sonne direkt auf einen Heizkörper scheint und diesen so stark erwärmt, dass der verwendete Algorithmus den Heizkörper als *an* klassifiziert obwohl dies nicht so ist.



Abbildung 4.33 Ermittelte Heizkörpereinstellung T_{set} in [°C]. Median nach Jahreszeiten und Wohneinheiten

Neben der Heizkörpereinstellung wurde untersucht ab welcher mittleren Außenlufttemperatur vornehmlich geheizt wird. Dazu wurde eine univariate logistische Regression durchgeführt. Dabei wurde als abhängige Variable die mittlere Außenlufttemperatur gewählt. Über die Regression wurde nun für jede Außenlufttemperatur die Wahrscheinlichkeit, dass die Heizung aktiviert ist, bestimmt. Die Ergebnisse sind in Abbildung 4.34 dargestellt. Es zeigt sich, dass ab einer Außenlufttemperatur von weniger als 5 °C die Wahrscheinlichkeit, dass die Heizung an ist, höher als die Gegenwahrscheinlichkeit ist. Damit kann anhand dieses Modells von einer Grenztemperatur von 5 °C ausgegangen werden.

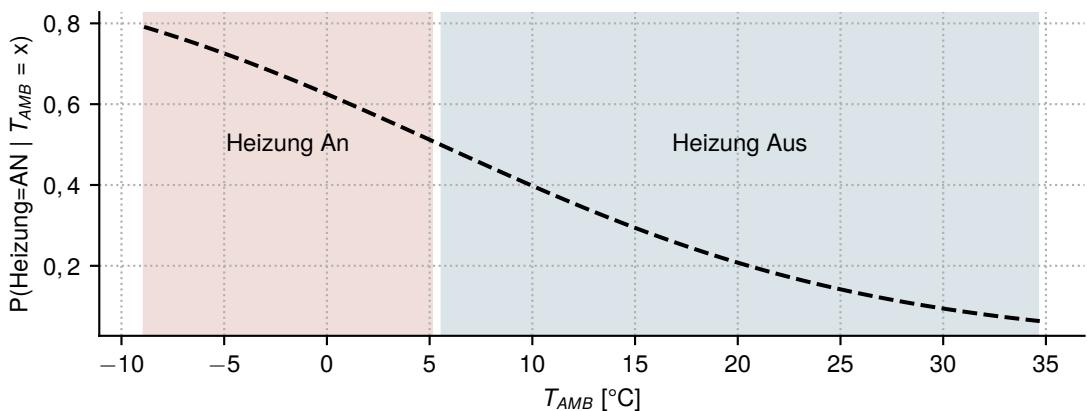


Abbildung 4.34 Durch eine univariate logistische Regression bestimmte Heizgrenztemperatur in [°C].

Eng mit dem Heizverhalten verknüpft ist der Wärmeenergieverbrauch. Dieser wird im Rahmen des Forschungsprojektes über Wärmemengenzähler auf Wohnungsebene ermittelt. Diese können jedoch nicht zwischen Wärme zur Trinkwarmwasserbereitung und zur Heizung

trennen. Außerdem beginnt die Aufzeichnung der Daten hier erst im September 2021. Daher sind die ermittelten Werte nur bedingt aussagekräftig. Basierend auf den vorhandenen Daten wurde wieder der Mittelwert nach Tag und Jahreszeit getrennt nach Wohneinheit ermittelt. Bei den gezeigten Werten handelt es sich um Kilowattstunden pro Tag. Zu beachten ist, dass bedingt durch den Aufzeichnungsbeginn im September nur sehr wenige Datensätze für den Sommer vorhanden sind. Die erhobenen Daten werden dennoch in Abbildung 4.35 dargestellt. Dabei werden sie auf Grundfläche der Wohnungen und pro Tage skaliert. Damit ergibt sich ein spezifischer Wärmeenergieverbrauch in Kilowattstunden pro Quadratmeter und Tag. Bei Betrachtung der ermittelten Werte fällt auf, dass im Massivhaus - wo auch besonders wenige Heiztage ermittelt wurden - auch der geringste spezifische Wärmeenergieverbrauch ermittelt wurde.



Abbildung 4.35 Mittlerer Wärmeenergieverbrauch pro Wohneinheit in [$\text{kW h}/(\text{m}^2 \text{ d})$]. Mittlere Tagessummen nach Jahreszeit. Keine Unterscheidung nach Heiztag oder kein Heiztag.

Um den Verbrauch der Heizung vom Energieverbrauch zur Trinkwarmwasserbereitung zu trennen wurde das Clustering nach Heiztagen auf die aufgezeichneten Verbrauchswerte angewandt. Die Ergebnisse des Wärmeenergieverbrauchs, an Tagen die nicht als Heiztag klassifiziert wurden, werden in Abbildung 4.36 dargestellt. Zuerst fällt auf, dass in der N des Leichtbetonhauses an "nichtHeiztagen sogar mehr verbraucht wird als im Mittel (Abbildung 4.35). Dies liegt wiederum an der weiter oben beschriebenen fehlerhaften Klassifikation im Leichtbetonhaus durch die nicht erfassten Deckenpanele. Auch der Wert in der N des Mauerwerkhauses ist hier wieder durch den Ausfall des TRH-Sensor verzerrt. Beide Werte sollte daher in weiteren Analysen bis auf weiteres nicht verwendet werden.

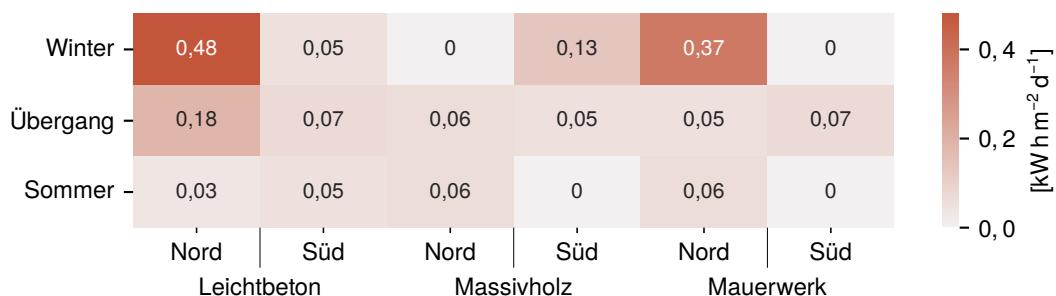


Abbildung 4.36 Mittlerer Wärmeenergieverbrauch pro Wohneinheit in [$\text{kW h}/(\text{m}^2 \text{ d})$]. Mittlere Tagessummen nach Jahreszeit. Nur für Tage, die als nicht Heiztag klassifiziert wurden.

Bei Betrachtung der übrigen Wohneinheiten zeigt sich ein relativ ähnliches Bild: Der Wärmeenergieverbrauch ohne die Heizung beläuft sich auf etwa $0,05 \text{ kWh}/(\text{m}^2 \text{ d})$ bis $0,07 \text{ kWh}/(\text{m}^2 \text{ d})$. Gehen wir davon aus, dass der Großteil dieser Energie in die Bereitstellung des Trinkwarmwassers zum Waschen und Kochen fließt, so käme man aufs Jahr gerechnet auf einen spez. Energieverbrauch für Trinkwarmwasser zwischen $18 \text{ kWh}/(\text{m}^2 \text{ a})$ bis $25 \text{ kWh}/(\text{m}^2 \text{ a})$.

Dieser Wert ist dennoch mit Vorsicht zu betrachten, da der gemessene Zeitraum vorwiegend auf die Heizperiode gefallen ist. Die Vermutung liegt daher nahe, dass die ermittelten Werte den Energieverbrauch eher überschätzen. Auf eine Bestimmung des Wärmeenergieverbrauch wurde daher verzichtet.

Lüftungen

Im Folgenden wird das Fensteröffnungsverhalten der Nutzer:innen untersucht. Abbildung 4.37 stellt oben die absolute Anzahl an beobachteten Lüftungsvorgängen pro Jahreszeit und Wohneinheit dar. Unten ist die prozentuale Verteilung der beobachteten Lüftungen pro Wohneinheit über den Tag dargestellt. Da es sich bei der oberen Darstellung um absolute Zahlen handelt, ist zu beachten, dass in der Kategorie Übergang zwei Jahreszeiten zusammen gefasst sind und damit Kategorie damit doppelt so lange ist. Betrachtet man die Beobachtungen und beurteilt diese bereinigt von der unterschiedlichen Länge, fällt auf, dass die absolute Anzahl an beobachteten Lüftungen zwischen den einzelnen Jahreszeiten nicht bei allen Nutzer:innen stark zu schwanken scheint.

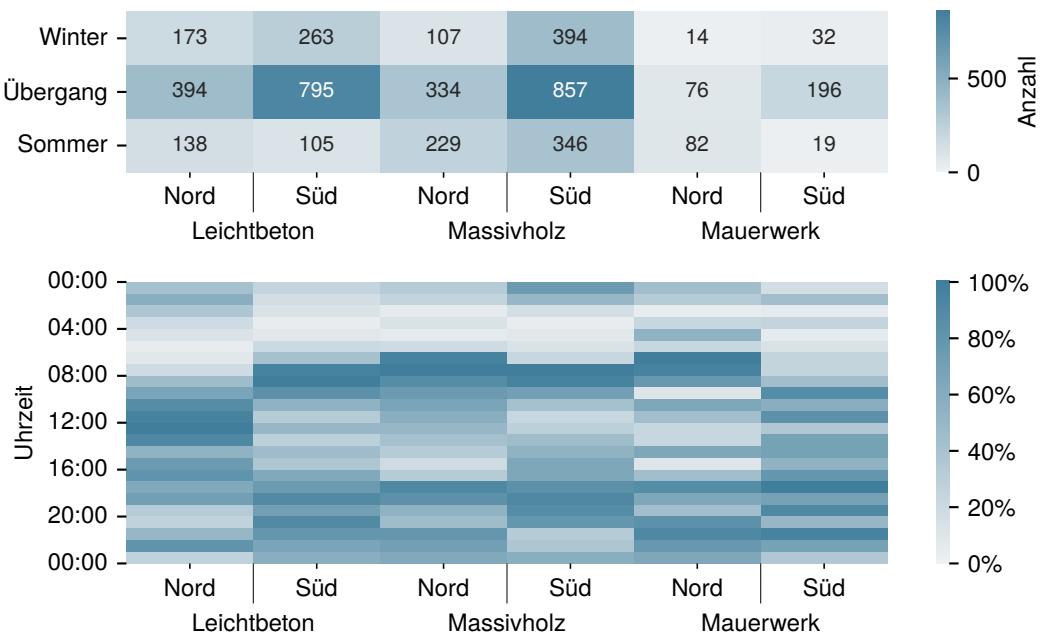


Abbildung 4.37 Absolute Häufigkeit der beobachteten Lüftungsvorgänge nach Wohnungen und Jahreszeit (oben), Verteilung der beobachteten Lüftungen pro Wohneinheit über den Tag in Prozent.

Im Tagesverlauf wird erkennbar, dass es bei den meisten betrachteten Wohnungen eine starke Häufung von Fensteröffnungen am Morgen und eine etwas kleinere Häufung am Abend zu geben scheint. Das spiegelt sich auch in der Betrachtung der absoluten Häufigkeit von

beobachteten Lüftungen im Tagesverlauf wider. Diese sind in Abbildung 4.38 abgebildet. Es lässt sich eine deutliche Häufung an Beobachtungen zwischen 06:00 und 09:00 Uhr sowie zwischen 17:00 und 20:00 Uhr erkennen.

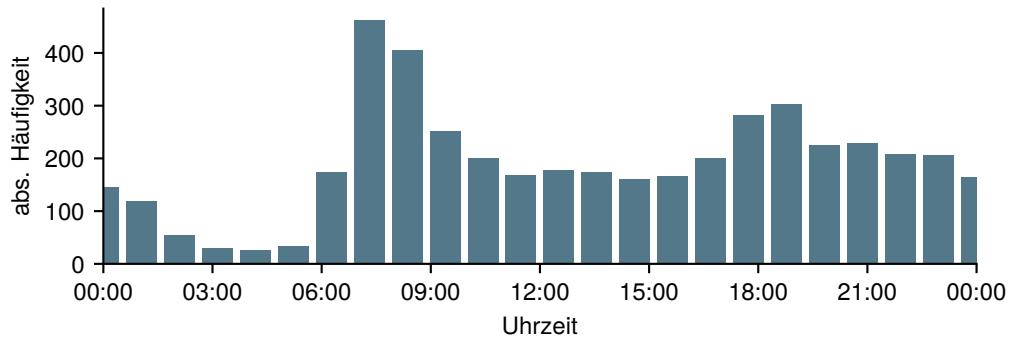


Abbildung 4.38 Absolute Häufigkeit der beobachteten Lüftungsvorgänge nach Tageszeit.

Im nächsten Schritt wird die Dauer der Lüftungsvorgänge betrachtet. In Abbildung 4.39 ist die mittlere Dauer pro Tag, mit mindestens einer Fensteröffnung pro Wohnung, dargestellt. Hier lässt sich wiederum eine stärkere Saisonalität als bei der Anzahl der Lüftungsvorgänge ablesen. Während im Winter die Fenster im Mittel zwischen 0,4 h bis 2,5 h geöffnet sind, sind es im Sommer zwischen 5,9 h bis 14,9 h.



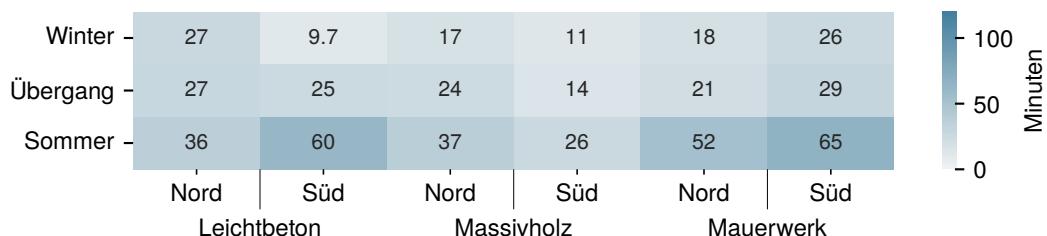
Abbildung 4.39 Mittlere Dauer eines Lüftungsvorgangs im Schlafzimmer.

Die Fensterlüftung pro Tag wird nun nochmal in die mittlere Dauer eines Lüftungsvorgangs herunter gebrochen. Diese lässt sich Abbildung 4.40, getrennt nach Wohn- und Schlafzimmer entnehmen. Aus dieser Darstellung kann man entnehmen, dass sich die mittlere Dauer zwischen den Nutzer:innen und auch zwischen Wohn- und Schlafzimmer unterscheiden. Beispielsweise kann man im Schlafzimmer der S im LB und MW zwischen den Jahreszeiten keinen nennenswerten Unterschied feststellen, während dieser bei anderen Wohnungen deutlicher (LB N) bis stark (MW N und S) erkennbar ist.

Wie in Abschnitt 2.1 dargestellt, werden in der Gebäudesimulation oft deterministische Kriterien verwendet, um die Wohnungslüftung darzustellen. Exemplarisch wird hier die voreingestellte Hystere des TRNLizard-Templates betrachtet. Diese greift ab einer mittleren Außenlufttemperatur von 6 °C und bestimmt, dass die Fenster geöffnet werden, sobald die Raumlufttemperatur (T_{air}) über 25 °C steigt, sofern die Außenlufttemperatur (T_{amb}) höchstens 3 K über T_{air} liegt. Die Fenster werden dann wieder geschlossen, sobald die Raumlufttempera-



(a) Schlafzimmer



(b) Wohnzimmer

Abbildung 4.40 Mittlere Dauer eines Lüftungsvorgangs in Minuten

tur unter 22 °C fällt oder die Außenlufttemperatur mehr als 3 K über die Raumlufttemperatur steigt. Anhand des vorliegenden Datensatzes wurde betrachtet, wie oft dieses Verhalten tatsächlich eintrifft. In der folgenden Abbildung 4.41 wird der Anteil der Stunden dargestellt, auf die das Kriterium zutrifft und tatsächlich ein Fenster geöffnet ist. Es zeigt sich, dass bei den beobachteten Nutzer:innen dieses Kriterium nur in 20 % bis 30 % der Fälle zu einer Lüftung der Wohnung führt.

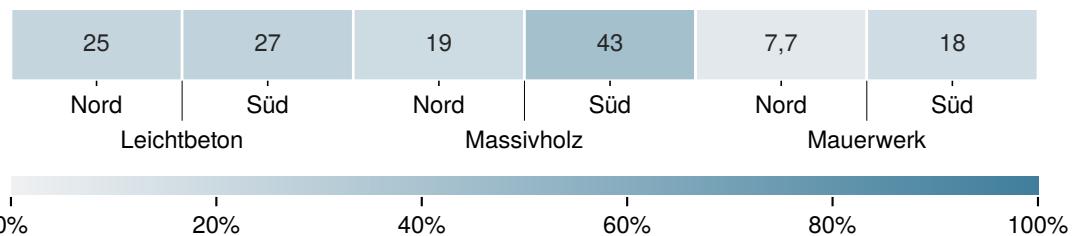


Abbildung 4.41 Anteil der Stunden, auf die das Lüftungskriterium nach XY zutrifft und tatsächlich ein Fenster geöffnet ist.

Zusammenfassend lässt sich feststellen, dass das Lüftungsverhalten zwischen den Nutzer:innen variiert. Es zeigt sich, dass die Nutzer:innen unterschiedliche Ansprüche an das Raumklima zu haben scheinen und ihr Heiz- und Lüftungsverhalten daran anpassen. Es hat sich v. a. ein saisonales und tageszeitliches Verhalten gezeigt. Auf Basis der in diesem Kapitel hergestellten Datengrundlage werden im Folgenden probabilistische Modelle zur Modellierung des Nutzungsverhaltens in einer thermisch dynamischen Gebäudesimulation hergeleitet.

5. Entwicklung probabilistischer Steuerungsmodelle

Aus den im vorangegangen dargestellten Daten, sollen nun weitere Rückschlüsse auf das Nutzungsverhalten gezogen werden. Im Rahmen dieser Arbeit soll es dabei vor allem um das Lüftungsverhalten gehen. An diesem Beispiel sollen Modelle zur Abschätzung der Modellunsicherheiten in der Gebäudesimulation hergeleitet werden.

5.1. Empirische Analyse der Fensteröffnung

Der vorherige Abschnitt hat gezeigt, dass das Lüftungsverhalten stark von den Nutzer:innen einer Wohneinheit abhängt. Es hat sich jedoch eine gewisse Abhängigkeit von der Tageszeit bzw. dem Tagesablauf der Bewohner:innen beobachten lassen. Um diese anfängliche Beobachtung weiter zu vertiefen, werden im Folgenden weitere Analysen durchgeführt.

5.1.1. Korrelationsanalyse

Im folgenden Abschnitt werden die beobachteten Fensteröffnungen betrachtet. Dabei wird nach anderen Variablen gesucht, die die Fensteröffnung erklären. Dazu wird im ersten Schritt eine Korrelationsanalyse durchgeführt. Dafür wird für alle Variablenkombinationen der Korrelationskoeffizient nach Pearson berechnet (siehe auch 2.3.1). Dieser beschreibt den linearen Zusammenhang beider Variablen auf einer Skala zwischen –1 bis 1 wobei -1 einen entgegengesetzten und 1 ein perfekten linearen Zusammenhang beschrieben. Die Ergebnisse sind in Abbildung 5.1 dargestellt.

Diese Analyse funktioniert nur mit numerischen oder binären Datensätzen. Die kategorischen Variablen Tages- und Jahreszeit wurden daher in binäre – sogenannte Dummy-Variablen – überführt. Die Zeitpunkte der Fensteröffnung und -schließung wurden getrennt betrachtet.

Für die Analyse werden für die numerischen Variablen jeweils 15 min Mittelwerte herangezogen, binäre Variablen werden summiert. Auf diese Weise lässt sich die Seltenheit der Fensteröffnung (bzw. Schließung) im Gegensatz zu den anderen Beobachtungen kompensieren.

Es zeigt sich, dass keine der untersuchten Variablen eindeutig mit der Fensteröffnung oder -schließung korreliert. Alle Korrelationskoeffizienten liegen im Bereich zwischen –0,2 bis 0,2 was für keinen starken linearen Zusammenhang spricht.

Betrachtet man den aktuellen Zustand des Fensters (Variable Fenster) zeigt sich eine etwas stärker ausgeprägte lineare Abhängigkeit. Die ermittelten Koeffizienten liegen aber immer noch in einem niedrigen Bereich, der für keinen starken linearen Zusammenhang spricht.

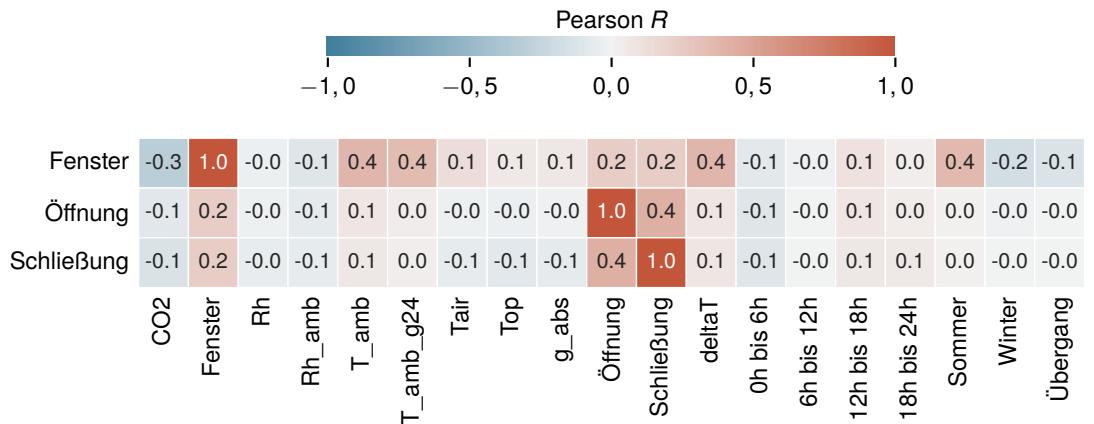
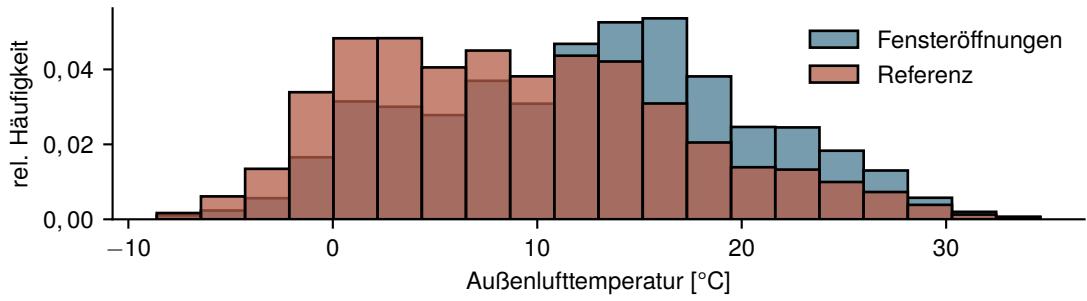


Abbildung 5.1 Korrelationskoeffizienten nach Pearson für die Kriterien Fenster, Fensteröffnung und Fensterschließung mit ausgewählten erklärenden Variablen.

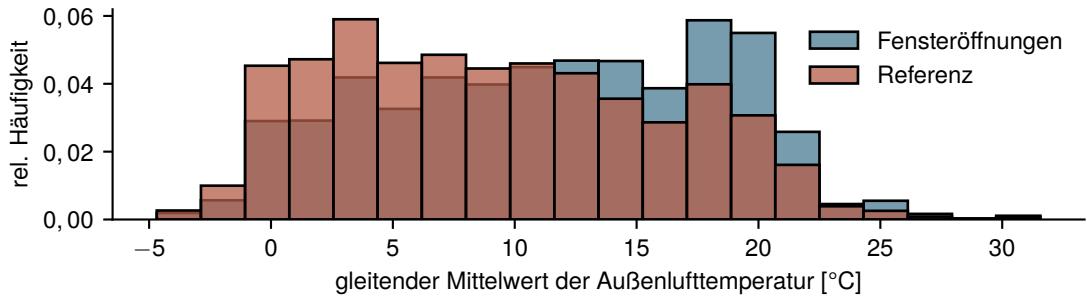
5.1.2. Histogrammanalyse

In einem nächsten Schritt wird eine Histogrammanalyse durchgeführt. Dabei werden die relativen Häufigkeiten einer *erklärenden* Variable zum Zeitpunkt der Fensteröffnung (*zu erklärende Variable*) mit deren relativen Häufigkeit in der Gesamtbeobachtung verglichen. Tritt ein bestimmter Wert einer erklärenden Variablen häufiger zum Zeitpunkt einer Fensteröffnung auf, kann dies ein Indiz dafür sein, dass dieser Wert ein Indikator der Nutzer:innen zur Fensteröffnung ist.

Im Folgenden werden für die Variablen aktuelle Außenlufttemperatur, gleitender Mittelwert über 24h der Außenlufttemperatur, Raumlufttemperatur, CO_2 -Konzentration und der absoluten Luftfeuchte, Histogramme zum Zeitpunkt einer Fensteröffnung und der Gesamtbeobachtung gegenüber gestellt.



(a) Aktuelle Außenlufttemperatur



(b) Gleitenden Mittelwerts der Außenlufttemperatur.

Abbildung 5.2 Gegenüberstellung der rel. Häufigkeiten der Außenlufttemperatur bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).

Bei den beiden Variablen in Bezug zur Außenlufttemperatur (Abbildung 5.2) zeigt sich eine leichte Häufung von Werten im höheren Temperaturspektrum. Dies lässt darauf schließen, dass eine hohe Außenlufttemperatur eine Fensteröffnung begünstigt. Diese Beobachtung deckt sich mit der beobachteten Saisonalität der Fensteröffnung aus dem vorherigen Abschnitt. Dies könnte ein Indiz für eine leichte Abhängigkeit sein.

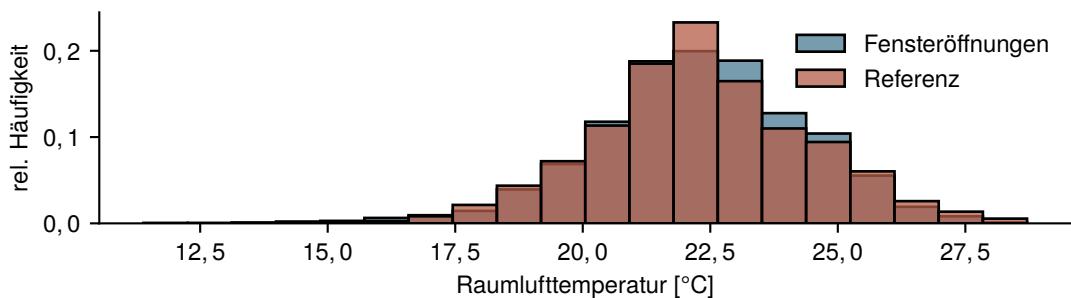


Abbildung 5.3 Gegenüberstellung der rel. Häufigkeiten der Raumlufttemperatur bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).

Bei der Raumlufttemperatur (Abbildung 5.3) ist lediglich eine sehr geringe Häufung von Fensteröffnungen zwischen 22 °C bis 24 °C erkennbar. Ansonsten ist das Histogramm sehr überlagert, weswegen sich auch hier kein Indiz auf eine Abhängigkeit ableiten lässt.

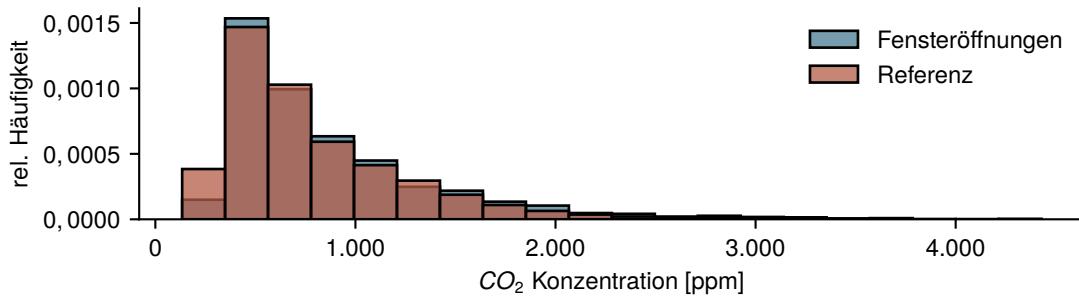


Abbildung 5.4 Gegenüberstellung der rel. Häufigkeiten der CO_2 -Konzentration bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).

Für die CO_2 -Konzentration (Abbildung 5.4) ist ebenfalls keine besondere Häufung zu erkennen. Es fällt lediglich auf, dass im niedrigen Konzentrationsbereich (<500 ppm) sehr selten ein Fenster geöffnet wird.

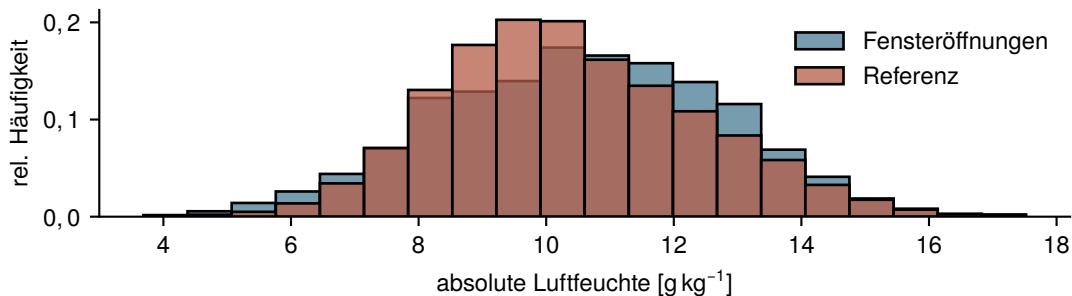


Abbildung 5.5 Gegenüberstellung der rel. Häufigkeiten der absoluten Luftfeuchte bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).

Die Histogramme zur absoluten Luftfeuchte zeigen wiederum eine leichte Häufung im oberen Mittelfeld des Wertebereichs (11 g/kg bis 13 g/kg). Vergleicht man diese Werte mit den saisonalen Wertebereichen, welche in Abbildung 4.18 dargestellt sind, fällt auf, dass dieser Wertebereich vor allem im Sommer häufig auftritt. In diesem Zusammenhang könnte das bedeuten, dass die häufigere Beobachtung von Fensteröffnungen in diesem Luftfeuchtespektrum, vor allem durch die häufigere Lüftung im Sommer getrieben ist und nicht durch eine Reaktion der Nutzer:innen auf die hohe Luftfeuchtigkeit zustande kommt.

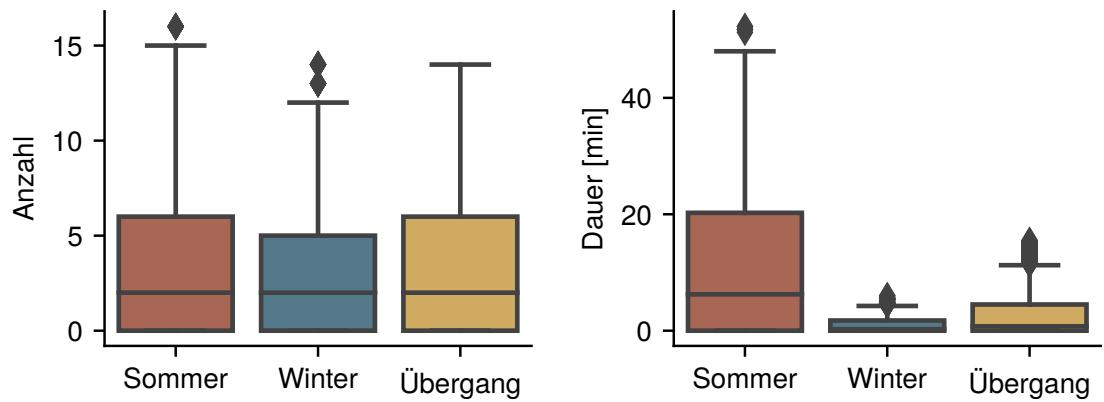
Am Ende dieser Analyse kann zusammenfassend festgestellt werden, dass auch hier kein Parameter neben Saisonalität und der Tageszeit heraussticht, der die Fensterinteraktion zu beschreiben scheint. Daher wird als erstes Steuerungsmodell ein Modell abgeleitet, welches als Hauptkriterien die Saisonalität und die Tageszeit hat. Auf diesen Kriterien aufbauend wird eine Monte-Carlo-Simulation durchgeführt, aus welcher die Signale für die Fensteröffnung hervorgehen sollen.

5.2. Monte-Carlo-Simulation

Die MC-Simulaton basiert auf der wiederholten Durchführung von Zufallsexperimenten. In diesem Fall soll durch ein Zufallsexperiment über den Fensteröffnungszeitpunkt und -dauer definiert werden. Die Simulation läuft analog zu den Zeitschritten der Gebäudesimulation. Ziel ist es für jeden Zeitschritt ein Signal zu erstellen, welches angibt, ob ein Fenster geöffnet oder geschlossen ist. Dabei dienen die Beobachtungen der Forschungshäuser als Grundgesamtheit.

5.2.1. Vorbereitung des Datensatzes

Die Grundgesamtheit wird in drei Teilmengen für die Jahreszeiten Sommer, Übergang und Winter unterteilt. In 5.6a sind die Anzahl der beobachteten Lüftungsvorgänge pro Tag, aufgelöst nach Jahreszeiten dargestellt. In Abbildung 5.6b ist analog die mittlere Dauer eines Lüftungsvorgangs dargestellt. Es wird deutlich, dass die Anzahl der Lüftungen pro Tag über das Jahr hinweg relativ konstant sind. Die Lüftungen unterscheiden sich jedoch stark in der Länge.



(a) Anzahl der Lüftungsvorgänge pro Tag nach Jahreszeiten. Bereinigt um IQR.
(b) Dauer der Lüftungsvorgänge pro Tag nach Jahreszeiten. Bereinigt um IQR.

Im ersten Schritt der Monte-Carlo-Simulation werden die Zeitpunkte der Fensteröffnung bestimmt. Aus der Annahme, dass sich das Lüftungsverhalten hauptsächlich nach den Gewohnheiten und dem Tagesablauf der Nutzer:innen richtet, wird ein Wahrscheinlichkeitsprofil für die Fensteröffnung aus den beobachteten Daten abgeleitet. Dieses besteht aus den, um Ausreißer bereinigten, relativen Häufigkeiten der Beobachtung *Fensteröffnung* zum Zeitpunkt t . Der Verlauf der Dichtefunktion (PDF) für die drei Jahreszeiten ist in Abbildung 5.7 dargestellt. Diese Funktion gibt für jede Uhrzeit t die Wahrscheinlichkeit an, dass genau zu diesem Zeitpunkt ein Fenster geöffnet wird. Es fällt auf, dass sich der Verlauf für alle Jahreszeit relativ ähnelt. Es gibt i.d.R. einen Peak am Morgen und eine kleinere Spitze am Abend.

Die ermittelte Dichtefunktion dient nun als Referenzgröße $P_{OPENING}(t, S)$ für das Zufallsexperiment.

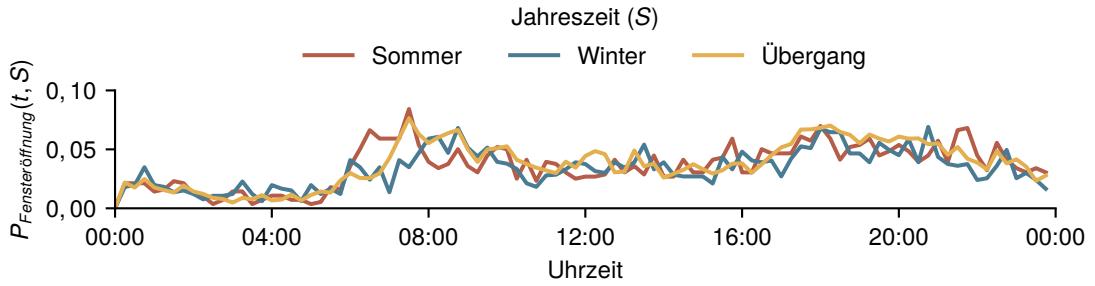


Abbildung 5.7 Dichtefunktion (PDF) $P_{\text{OPENING}}(t, S)$ der Fensteröffnung zum Zeitpunkt t im Tagesverlauf, 15 min-Schritte, getrennt nach Jahreszeiten.

5.2.2. Durchführung der Simulation

Dazu wird für jeden Zeitschritt t zur Jahreszeit S eine zufällige Zahl x zwischen 0 bis 1 generiert. Ist die generierte Zahl x kleiner als die $P_{\text{OPENING}}(t, S)$ wird das Fenster als geöffnet klassifiziert. Ist x größer als $P_{\text{OPENING}}(t, S)$ ist das Fenster geschlossen. Dieses Vorgehen wird für jeden Tag n , der in der Gebäudesimulation simuliert werden soll, wiederholt.

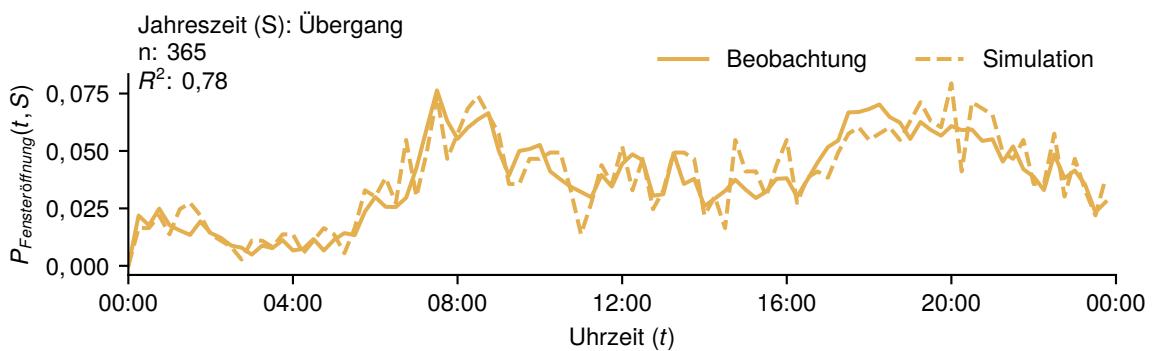


Abbildung 5.8 Beispielhafte Dichtefunktion (PDF) $P_{\text{OPENING}}(t, S)$ für einen Tag in der Übergangsperiode. Anzahl simulierte Tage $n = 365$

Wird für eine Uhrzeit t eine Fensteröffnung definiert, wird für diese Uhrzeit in einem zweiten Zufallsexperiment die Dauer der Lüftung bestimmt. Dazu wird aus der Grundgesamtheit der Lüftungsdauern der entsprechenden Jahreszeit zum Zeitpunkt t eine zufällige Dauer ausgewählt. Das Fenster wird nun, vom Zeitpunkt der Fensteröffnung an, für die ermittelte Dauer als *geöffnet* klassifiziert. Etwaige Überschneidungen werden ignoriert. Abbildung 5.9 zeigt beispielhaft die resultierende Fensteröffnungsdauer pro Tag einer MC-Simulation für ein gesamtes Jahr mit Simulationsschritt 15 min. Am Jahresgang lässt sich deutlich die Saisonalität ablesen: In den Wintermonaten sind die Fenster weniger lang geöffnet als in den Sommermonaten. Trotzdem gibt es aber in allen Jahreszeiten Ausreißer, die ein etwaiges Fehlverhalten der Nutzer:innen abbilden.

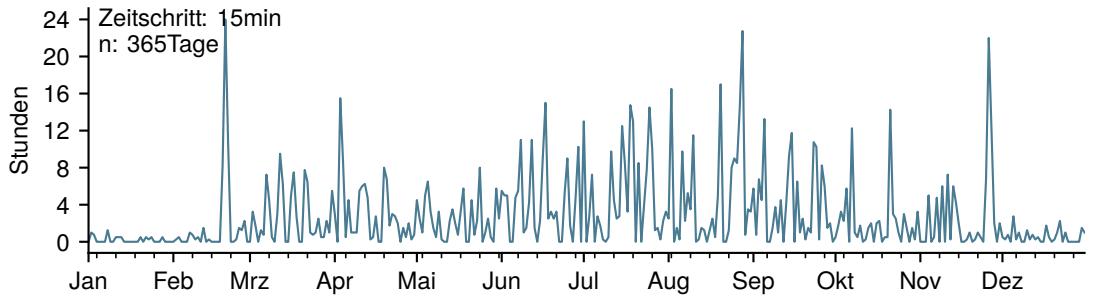


Abbildung 5.9 Beispielhaftes Resultat einer Monte-Carlo-Simulation des Lüftungssignals im Jahresgang. Auf der Y-Achse sind die Stunden pro Tag mit als *offen* klassifiziertem Fenster aufgetragen.

5.2.3. Schnittstelle zu TRNLizard

Die Monte-Carlo-Simulation wird zum größten Teil vor der Simulation durchgeführt und die Ergebnisse als Steuerungssignal über eine CSV-Schnittstelle in die Simulation übertragen. Tabelle 5.1 enthält einen Ausschnitt der übergebenen Datei. Sie enthält für den Simulations-

Tabelle 5.1 Beispiel eines CSV-Exports für die Übergabe des Monte-Carlo-Models an TRNLizard.

HoY	season	HoD	$P_{OPENING}(t, S)$	x	Fenster	duration
0.25	Winter	0	0.00	0.73	False	False
...
12.25	Winter	12	0.29	0.23	True	True
...
8759.75	Winter	23	0.03	0.33	False	False

zeitpunkt HoY die beiden Testgrößen $P_{OPENING}(t, S)$ und x, den ermittelten Öffnungszeitpunkt Fenster sowie das Signal für die Öffnungsduer duration. Letztere dient der Simulation als eigentliches Signal, welches die Fensterlüftung über die Stack Ventilation-Komponente auslöst.

5.2.4. Validation des Modells

Vergleicht man nun die mittels Monte-Carlo-Simulation erzeugte Stichprobe mit der Grundgesamtheit, lässt sich eine ausreichend gute Überschneidung feststellen. In Abbildung 5.10 sind beide Verteilungen als Quantil-Quantil-Plot dargestellt. Diesem lässt sich entnehmen, dass beide Verteilungen, abgesehen von einigen Ausreißern am oberen Ende der Bandbreite, gut übereinstimmen.

Die Aussage der Grafik ist gleichzeitig eine Einschränkung dieses Modells. Es bildet zwar das Nutzungsverhalten der beobachteten Grundgesamtheit sehr gut nach, ist dadurch allerdings auch abhängig von den Rahmenbedingungen der Beobachtung. Es basiert auf dem Verhalten, welches die Nutzer:innen zum beobachteten Zeitpunkt gezeigt haben. Es kann nicht auf

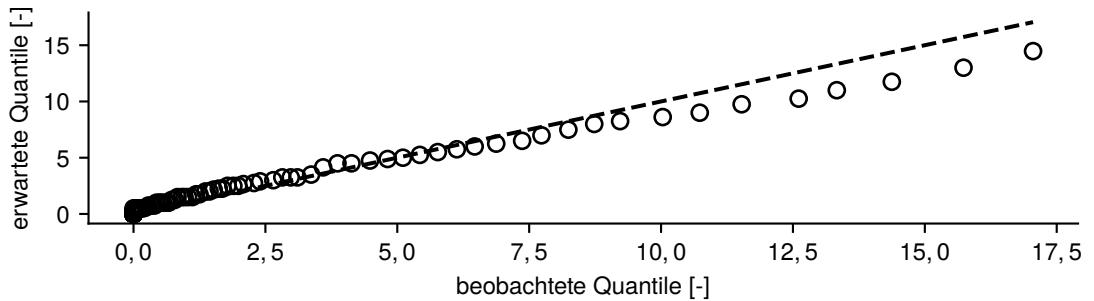


Abbildung 5.10 Quantil-Quantil-Plot zum Vergleich der Verteilung der Fensteröffnungsduer pro Tag der Grundgesamtheit (erwartete Quantile) mit dem Ergebnis der Monte-Carlo-Simulation (beobachtete Quantile).

etwaige klimatische Veränderungen reagieren. Angesichts des voranschreitenden Klimawandels wäre jedoch gerade diese Klimaadaptivität eine nützliche Eigenschaft des Modells. Aus diesem Grund wird das beschriebene Modell um weitere Parameter erweitert. Dazu wird eine logistische Regression durchgeführt.

5.3. Logistische Regression

Mit der logistischen Regression (auch Logit genannt) kann, wie im Unterabschnitt 3.2.2 dargestellt, die Eintrittswahrscheinlichkeit eines Kriteriums Y mithilfe von k unabhängigen Variablen x beschrieben werden. In diesem Fall soll dabei die Wahrscheinlichkeit der Fensteröffnung zum Zeitpunkt t abgebildet werden. Es gilt also die Wahrscheinlichkeit $P(Y = \text{open}|X = x_t)$ zu bestimmen. Das im Unterabschnitt 3.2.2 beschriebene Vorgehen wird nun angewendet, um ein Modell für das Kriterium Fensteröffnung zu erstellen.

5.3.1. Datenaufbereitung

Dazu wird der – in Abschnitt 4.2 beschriebe – Datensatz verwendet. Auf Basis der Datenauswertung in Abschnitt 4.2 und den in Abschnitt 2.2 beschriebenen Erkenntnissen aus der Literatur werden folgende Variablen in der Analyse berücksichtigt:

- das Raumklima (T_{air} , rH , CO_2 , g_{abs}),
- das Außenklima (T_{amb} , rH_{amb} , $T_{amb,g24}$),
- das Temperaturdelta zwischen Innen und Außen ($\Delta T_{I,A}$) sowie
- die Tageszeit und die Jahreszeit.

Als Kriterium wird die Variable Fenster verwendet.

Der Datensatz wird auf die gewünschte Simulationsauflösung von 15 min skaliert. Dabei wird bei allen Größen der Median der Zwischenwerte verwendet. Da nur in den Schlafzimmern ein CO_2 -Sensor verbaut ist, wird dessen Messwert auch für die anderen Räume verwendet.

Die kategorischen Variablen Tageszeit und Jahreszeit werden in Dummy-Variablen überführt. Für die Tageszeit wird dabei eine Gruppierung in 6 h-Schritten vorgenommen, für die Jahreszeit werden die drei bereits verwendeten Klassen Sommer, Übergang und Winter verwendet.

Als Gütemaß wird die Grenzwertoptimierungskurve (ROC) und die Fläche unter dieser Kurve (AUC) verwendet. Die Grenzwertoptimierungskurve beschreibt dabei das Verhältnis zwischen korrekt Positiven und falsch Positiven Prädikationen. Die Fläche unter der Kurve ist dabei 0, wenn alle positiven Prädikationen falsch Positiv sind und 1, wenn alle positiven Prädikationen korrekt Positiv sind. Es wird daher ein Wert möglichst nah an 1 angestrebt. Eine Übersicht der verwendeten Variablen und den Datensatz kann Tabelle 5.2 entnommen werden.

Tabelle 5.2 Beschreibung des Datensatzes zur Durchführung der logistischen Regression mit Stichprobenumfang, arth. Mittel Mittel, Standardabweichung, Minimum, 1-3 Quartil und Maximum.

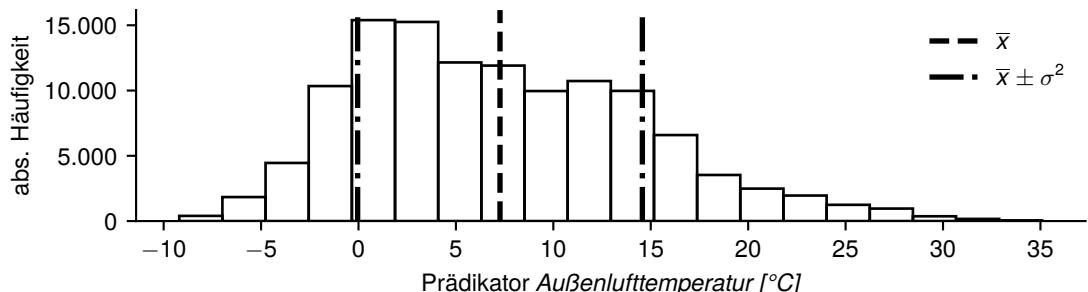
	count	mean	std	min	25 %	50 %	75 %	max
Prädiktoren								
Kriterium								
Fenster	119 727,0	0,3	0,5	0,0	0,0	0,0	1,0	1,0
Prädikatoren								
CO_2	119 727,0	959,6	547,7	97,7	557,1	812,2	1221,1	4483,3
rH	119 727,0	61,4	9,0	30,0	54,6	61,5	68,2	92,2
rH_{amb}	119 727,0	78,3	18,2	13,2	67,6	82,0	93,0	99,0
T_{amb}	119 727,0	7,3	7,3	-9,2	1,5	6,4	12,4	35,1
$T_{amb,g24}$	119 727,0	8,4	6,5	-4,7	3,1	7,5	13,3	31,8
T_{air}	119 727,0	21,8	1,6	11,2	20,8	21,9	22,8	28,0
$gabs$	119 727,0	10,1	1,8	3,8	8,9	10,1	11,4	17,1
$\Delta T_{Innen,Auen}$	119 727,0	-14,5	6,7	-31,4	-19,8	-15,0	-10,0	12,5
windspeed	119 727,0	1,2	1,7	0,0	0,0	0,6	1,7	16,6
global	119 727,0	71,6	169,5	-14,9	-3,5	-0,6	44,3	1200,0
Dummy Variablen								
0:00 bis 6:00h	119 727,0	0,3	0,5	0,0	0,0	0,0	1,0	1,0
6:01 bis 12:00h	119 727,0	0,3	0,5	0,0	0,0	0,0	1,0	1,0
12:01 bis 18:00h	119 727,0	0,1	0,4	0,0	0,0	0,0	0,0	1,0
18:00 bis 24:00h	119 727,0	0,2	0,4	0,0	0,0	0,0	0,0	1,0
Sommer	119 727,0	0,1	0,3	0,0	0,0	0,0	0,0	1,0
Winter	119 727,0	0,3	0,4	0,0	0,0	0,0	1,0	1,0
Übergang	119 727,0	0,6	0,5	0,0	0,0	1,0	1,0	1,0

5.3.2. Analyse des Datensatzes

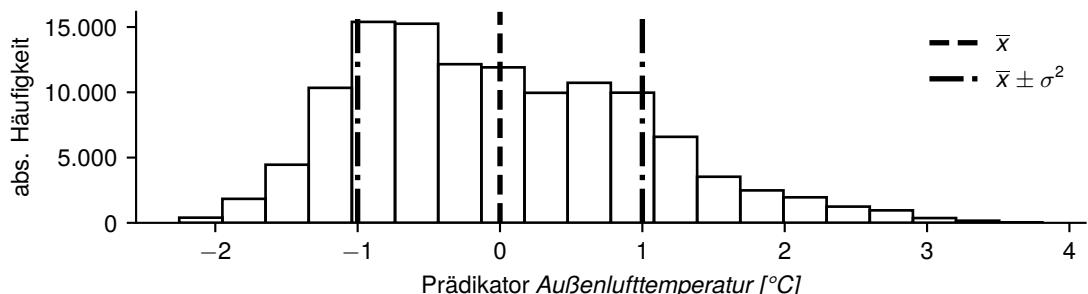
In Tabelle 5.2 ist zu sehen, dass die Prädiktoren alle sehr verschiedene Bandbreiten aufweisen. Während die CO_2 -Konzentration einen IQR von etwa 600 ppm aufweist, liegt der IQR der absoluten Feuchte g_{abs} bei 3 g/kg. Um die Variablen vergleichbarer zu machen, wird daher eine Skalierung auf eine Standardnormalverteilung ($\mu = 0, \sigma^2 = 1$) angewendet. Dabei werden alle Beobachtungen i eines Prädiktoren k nach Gleichung 5.20 transformiert.

$$x_{i,k} = \frac{x_{i,k} - \bar{x}_k}{\sigma_k^2} \quad (5.20)$$

Abbildung 5.11 zeigt die Funktionsweise der Transformation am Beispiel der Außenlufttemperatur T_{amb} . Bei der Erstellung des Modells wird dabei die Funktion `StandardScaler()` aus dem Paket `scikit-learn` verwendet.



(a) Histogramm der untransformierten Außenlufttemperatur [°C] mit Mittelwert \bar{x} und Standardabweichung σ^2 .



(b) Histogramm der nach Gleichung 5.20 transformierten Außenlufttemperatur [°C] mit Mittelwert \bar{x} und Standardabweichung σ^2 .

Abbildung 5.11 Demonstration der Skalierung auf Normalverteilung am Beispiel der Außenlufttemperatur.

Bei Betrachtung der in Abbildung 5.12 dargestellten Ausprägungshäufigkeiten des Kriteriums Y , wird deutlich, dass dieses nicht gleichverteilt ist. Daher werden die Datensätze mit der Inversen der Häufigkeit nach Gleichung 5.21 gewichtet.

$$w(Y = 1) = \frac{n_{gesamt}}{n_{Y=1}} \quad (5.21)$$

Die Variablen werden nun auf Multikollinearität überprüft. Dazu wird der Variance Inflation

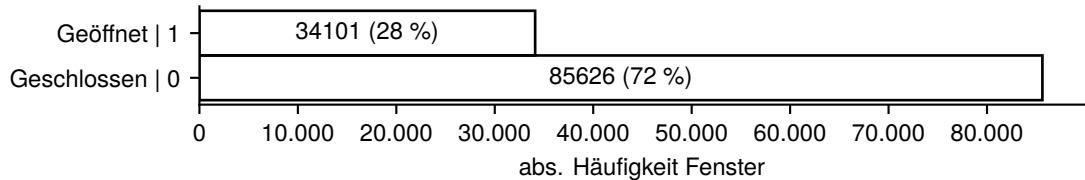


Abbildung 5.12 Verteilung des Kriteriums *Fenster*. Absolute und relative Häufigkeiten in Klammern.

Factor (VIF) verwendet. Dieser ist ein Index, der angibt wie stark die Varianz eines bestimmten Regressionskoeffizienten durch Multikollinearität beeinflusst wird. Dabei gibt es keinen festen Grenzwert, ab dem eine Variable als Prädiktor ungeeignet wäre. Verschiedene Quellen empfehlen Werte zwischen 2 bis 10 (Wooldridge, 2016). In dieser Arbeit wird als Grenzwert der Wert 5 gewählt. In Abbildung 5.13 wird der Grad der Multikollinearität anhand des Variance Inflation Factor (VIF) ermittelt und dargestellt. Es zeigt sich, dass die Außenlufttemperatur T_{amb} eine starke Multikollinearität zur mittleren Außenlufttemperatur $T_{amb,g24}$ und der Temperaturdifferenz ΔT aufweist. Ebenso die absolute Luftfeuchte g_{abs} zur relativen Luftfeuchte rH . Die genannten Variablen sollten daher nicht zusammen in einem Modell als Prädiktoren verwendet werden.

5.3.3. Auswahl der Prädiktoren

Im nächsten Schritt wird nun nach einer optimalen Kombination von Prädiktoren gesucht. In einem ersten Schritt werden dabei drei Prädiktoren nach der Methode der besten Koeffizienten gewählt. In Abbildung 5.14 werden die ermittelten Koeffizienten aller untersuchten Variablen, geordnet nach deren Betrag, dargestellt. Am Vorzeichen des Koeffizienten kann man den Beitrag zur Wahrscheinlichkeit ablesen. Hat ein Prädiktor ein negatives Vorzeichen, so führt eine Steigerung des Wertes dieser Variablen zu einer Abnahme der Eintrittswahrscheinlichkeit $P(Y = 1|X = x_t)$. Aus diesen Koeffizienten sucht nun ein Algorithmus unter Berücksichtigung deren Multikollinearität die Kombination aus drei Prädiktoren mit der höchsten Signifikanz aus. Dazu wird die Funktion `SelectFromModel` aus dem Paket `scikit-learn` verwendet. Die gewählten Parameter sind in Abbildung 5.14 grün hinterlegt. Die Validation des Modells erfolgt über die eingangs beschriebene Kreuzvalidierung. Dieses Ergebnis ist in der nachfolgenden Abbildung 5.15 dargestellt. Es wird sichtbar, dass sich die Qualität der Prädiktion in allen $n = 10$ Durchgängen unterscheidet. Dabei liegt die AUC im Bereich zwischen 0,62 bis 0,98 bei einem Mittelwert von $0,82 \pm 0,1$, was in der Theorie bereits eine sehr gute Prädiktion darstellt.

Dennoch wird die Prädiktorenauswahl nun noch einmal mittels Forward- und Backward-Selection wiederholt. Die Ergebnisse dieser erneuten Anpassungen werden in Abbildung 5.16 dargestellt. Die Backward-Selection wählt die Prädiktoren CO_2 , $T_{amb,g24}$ und ΔT aus (mit einer mittleren ROC/AUC von 0,81) während die Forward-Selection die Prädiktoren CO_2 , rH_{amb} und ΔT bei einem mittleren ROC/AUC von 0,82 auswählt.

Es zeigt sich also, dass alle drei Algorithmen zu unterschiedlichen Ergebnissen mit ähnlichen

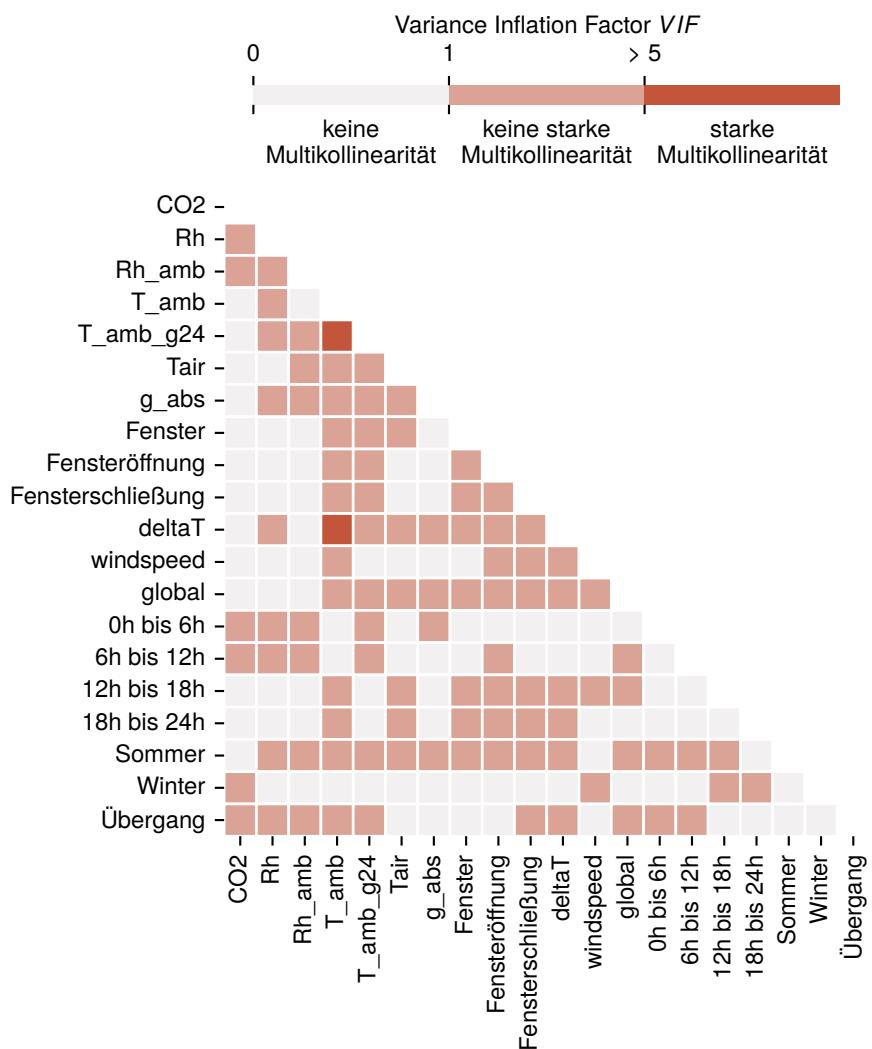


Abbildung 5.13 Multikollinearität der Variablen des Regressionsdatensatzes anhand des *Variance Inflation Factors* (VIF).

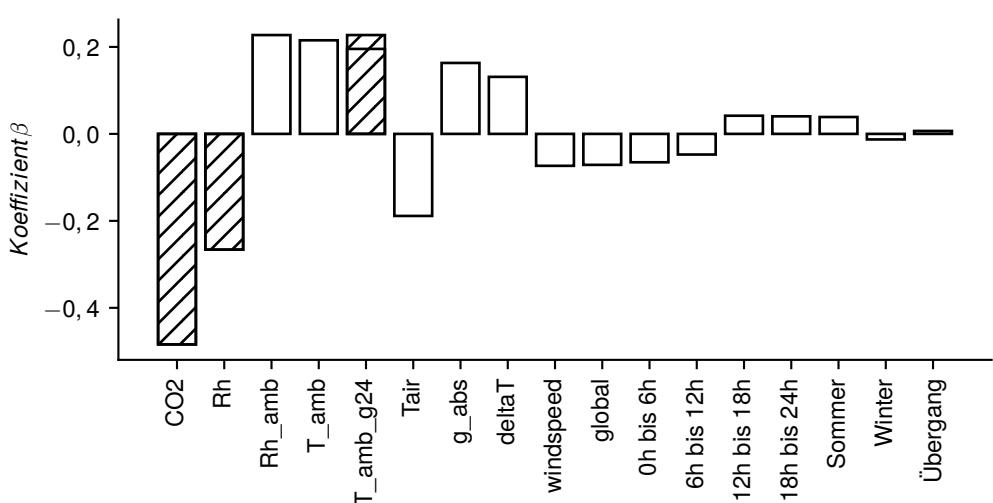


Abbildung 5.14 Prädiktoren x_k für $Y_{Fenster} = 1$, sortiert nach dem Betrag ihres Koeffizienten $|\beta_k|$

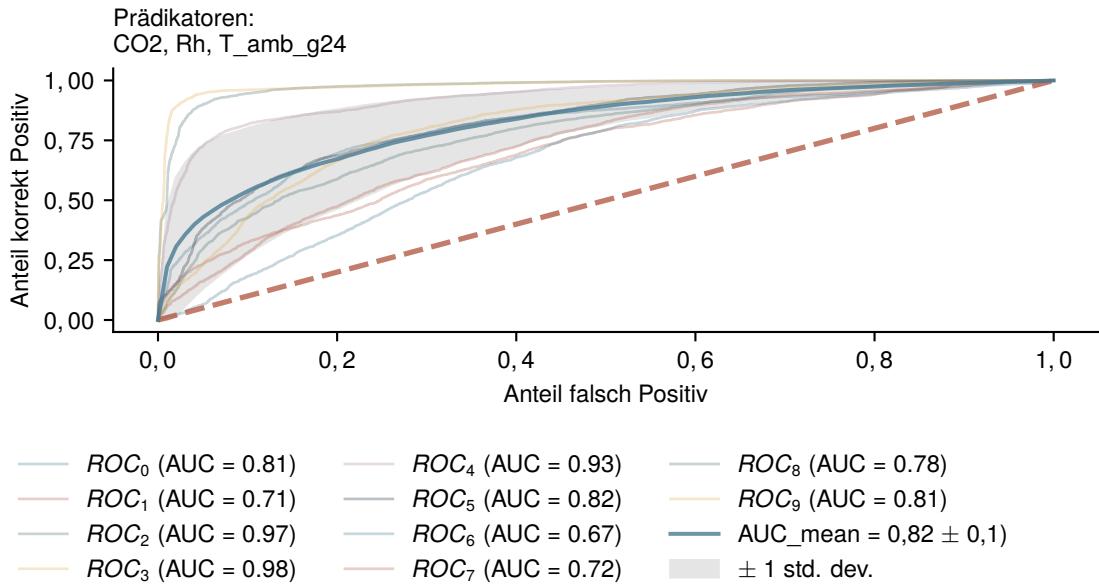


Abbildung 5.15 Grenzwertoptimierungskurven *ROC* für das Logistische Regressionsmodell mit Prädiktorenwahl nach Koeffizienten.

Güteparametern kommen. Auffällig ist, dass die CO_2 -Konzentration in jeder Anpassung ausgewählt wird. Aus den drei Modellen wird für die weitere Analyse das Modell nach Backward Selection mit den Parametern CO_2 , $T_{amb,g24}$ und ΔT weiter verwendet, da diese Parameter in der praktischen Anwendung der Gebäudesimulation am plausibelsten scheinen. Die resultierenden Parameter zur Übergabe an die Simulationsumgebung sind in Tabelle 5.3 dargestellt.

Tabelle 5.3 Bestimmte Regressionskoeffizienten β_k , β_0 sowie die Skalierungsfaktoren \bar{x}_k und σ_k für die ausgewählten Prädiktoren

	$\Delta T_{Innen,Auen}$	CO_2	$T_{amb,g24}$
\bar{x}_k	-14,5	959,6	8,4
σ_k	6,7	547,7	6,5
β_k	0,3	-1,0	0,3
β_0	-0,3	nan	nan

5.3.4. Integration in die Simulation

Im Gegensatz zur Monte-Carlo-Simulation findet die logistische Regression als parallele Berechnung während der Simulation statt. Das Modell wird, wie im Abschnitt 5.3 beschrieben, aufgestellt und die Regressionskoeffizienten β_k , der Achsenabschnitt β_0 sowie die Parameter zur Transformation \bar{x} und σ werden via CSV-Schnittstelle an TRNLizard übergeben. Zusätzlich wird eine Zeitreihe mit einer gleich verteilten Zufallsvariable x_t für jeden Simulations-

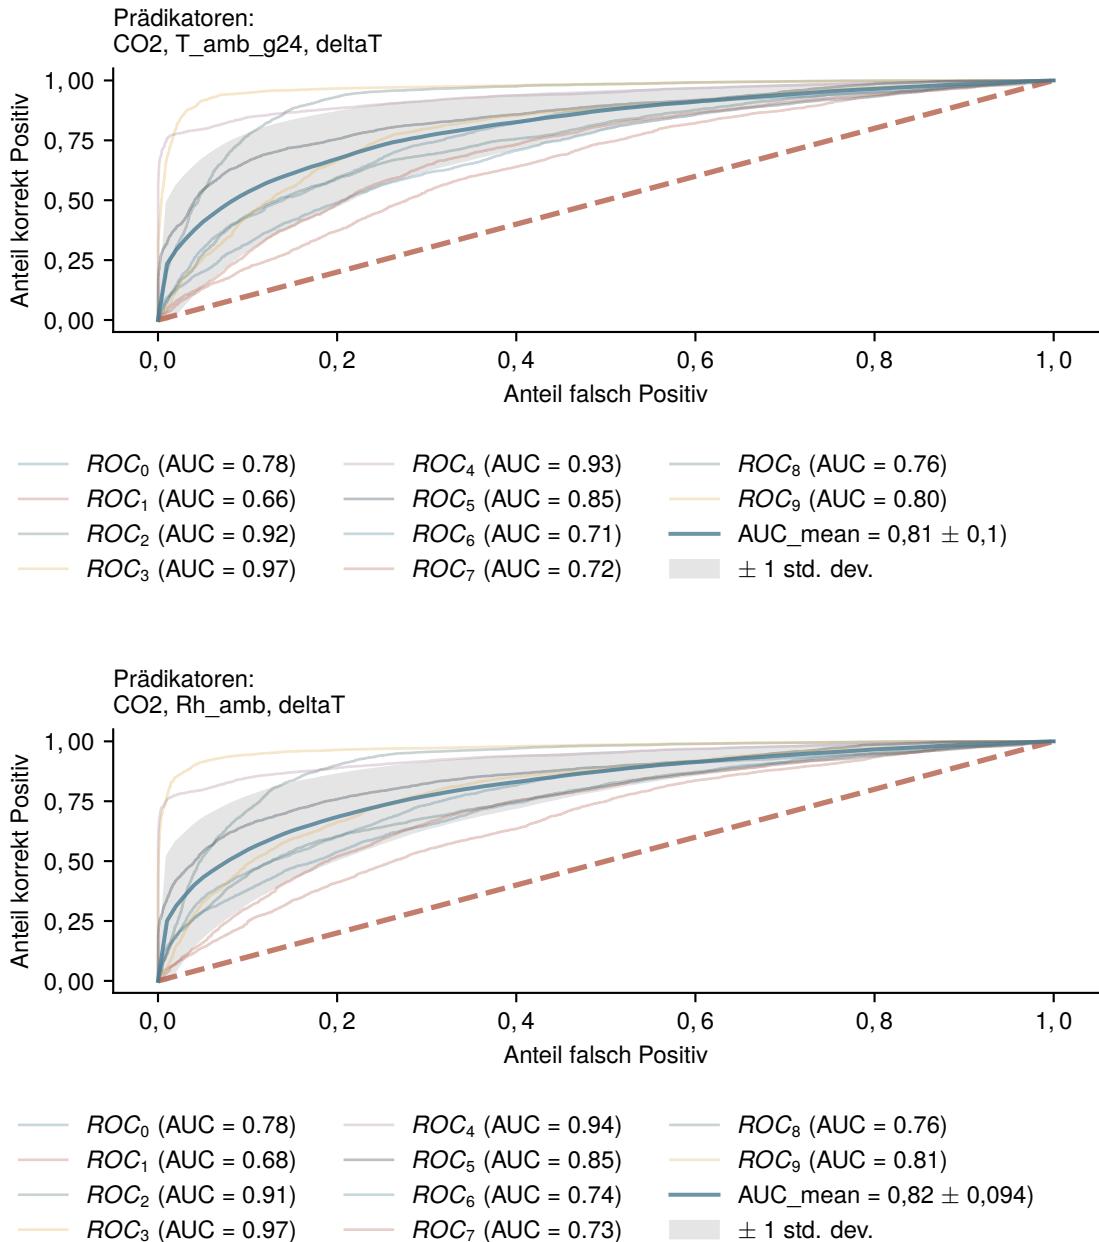


Abbildung 5.16 Grenzwertoptimierungskurven ROC für das Logistische Regressionsmodell mit Prädiktorenauswahl nach Koeffizienten.

schritt erzeugt und ebenfalls mittels CSV-Schnittstelle übergeben. Aus den übergebenen Koeffizienten und Transformationsparametern errechnet eine eigens dafür erstellte TRNLizard Komponente über Gleichung 3.4 die Wahrscheinlichkeit der Fensteröffnung zum Zeitpunkt t $P_{opening}(t)$. Diese errechnete Wahrscheinlichkeit wird dann mit der entsprechenden Zufallsvariablen x_t verglichen. Ist die Zufallsvariable x_t kleiner als $P_{opening}(t)$ wird das Fenster als geöffnet klassifiziert. Ist sie größer, bleibt das Fenster geschlossen. Das aus der Klassifikation resultierende Steuerungssignal wird wiederum an die Stack Ventilation-Komponente weiter gegeben und damit die Lüftung ausgelöst.

5.3.5. Erstellung der Simulationsvarianten

Zur Erstellung der Simulationsvarianten wurde ein automatisierter Prozess entwickelt. Dabei wird zwischen *sicheren Randbedingungen*, *unsicheren Randbedingungen* und *Varianten* unterschieden. Als *Varianten* werden dabei die Parameter zusammengefasst, die eine eindeutige technische Einheit definieren, die es zu evaluieren gilt. Eine Variante hat *sichere und unsichere Randbedingungen*, dabei sind *sichere Randbedingungen* Simulationsparameter, die für jede untersuchte Variante gleich bleiben. Für jede Variante werden n -Durchläufe mit jeweils unterschiedlichen *unsicheren Randbedingungen* errechnet. Dadurch soll eine Streuung der Ergebnisse zur Schätzung der PG erreicht werden. Als mögliche Varianten wurden dabei Bauweisen oder Nutzungsprofile implementiert, wobei unsichere Randbedingungen u. a. die Raumgeometrie, die Heizkörpereinstellung, die Lüftungsregelung oder Wetterdatensätze sein können.

5.3.6. Untersuchte Varianten

Die entwickelte Steuerung wird an einem - den Abmessungen des Ein-Zimmer Appartements der Forschungshäuser nachempfundenen – drei Zonen-Modell erprobt. Der gewählte Grundriss kann Abbildung 5.17 entnommen werden.

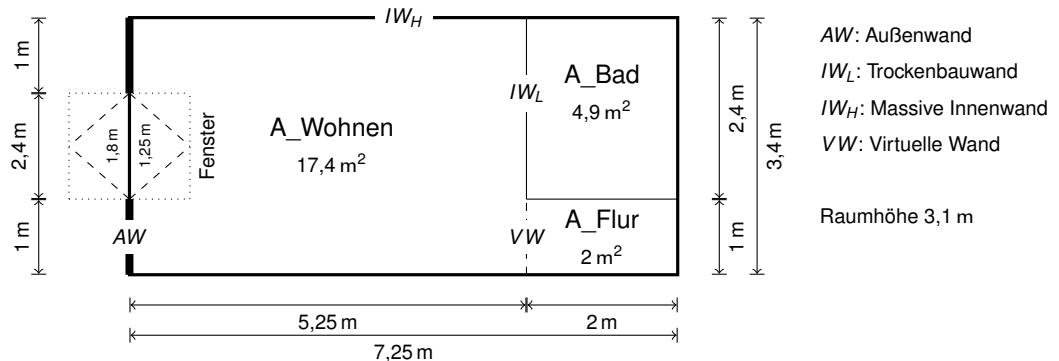


Abbildung 5.17 Grundriss des verwendeten Simulationsmodells

Die Simulation wird dabei in fünf unterschiedlichen Bauweisen: Leichtbeton (Einfach Bauen), Mauerwerk (Einfach Bauen), Massivholz (Einfach Bauen) und Mauerwerk (nach GEG) durchgeführt. Die U-Werte sowie die Massen und Bauteilstärken der verwendeten Wandaufbauten, Bauteile und Materialien sind im Anhang C dargestellt. Das Nutzungsmodell aller Varianten ist – abgesehen von der implementierten Steuerung der Fensterlüftung - an die SIA 2024 angelehnt. Als Wetterdatensatz dient der TRY2020 Datensatz des DWD für München. Ein Übersichtsplot über den Wetterdatensatz ist im Anhang zu finden. Zur Schätzung der PG sollen für jede Bauweise mehrere Simulationen mit unterschiedlichen Zufallsvariablen als Input für die Steuerungsmodelle durchgeführt werden. Auf diese Weise soll eine probabilistische Streuung der Ergebnisse erzeugt und mit den daraus resultierenden Ergebnissen der PG abgeschätzt werden. Zur Plausibilitätskontrolle wird zu jeder Bauweise eine Referenzvariante mit identischen Randbedingungen nach SIA 2024, 2021 und einer deterministischen Lüftungssteuerung nach Tabelle 2.1 gerechnet mit zusätzlich zwei 15 minütige Lüftungen

(einmal morgens einmal abends). Eine Übersicht über die durchgeführten Simulationen ist in Tabelle 5.4 dargestellt.

Tabelle 5.4 Übersicht über die durchgeführten Simulationen

Bauweise	Monte-Carlo	Logit	Referenz	Summe
Leichtbeton	20	20	1	41
Mauerwerk	20	20	1	41
Massivholz	20	20	1	41
GEG	20	20	1	41
Gesamtanzahl Simulationen				164

5.4. Ergebnisse

Im nächsten Abschnitt wird das durchgeführte Simulationsprogramm ausgewertet. Dabei wird im ersten Schritt die Plausibilität kontrolliert. Im nächsten Schritt werden die Ergebnisse der drei untersuchten Modelle verglichen und bewertet.

Im ersten Schritt wird der ermittelte Heizwärmebedarf betrachtet. Dieser ist in Abbildung 5.18 dargestellt.¹ Es zeigt sich eine starke Varianz in den errechneten Heizwärmebedarfen für die drei untersuchten Varianten auf. Während die deterministische Referenzvariante Werte zwischen 15 kW h/(m² a) bis 19 kW h/(m² a) ausgibt, kommen die Varianten der Monte-Carlo-Simulation auf Werte zwischen 17 kW h/(m² a) bis 25 kW h/(m² a) und die logistische Regression sogar auf Werte zwischen 29 kW h/(m² a) bis 33 kW h/(m² a).

Betrachtet man im Vergleich dazu die erzielten mittleren Luftwechselraten pro Tag (Abbildung 5.19), wird deutlich, dass hier die Abweichungen nur marginal sind. Das bedeutet, dass die Steuerung der Fensteröffnung unabhängig von der Bauweise arbeitet. Das liegt bei der Monte-Carlo-Simulation nahe, die beiden anderen Modelle sind jedoch – wenn auch in unterschiedlich starker Ausprägung – vom Raumklima und damit indirekt von der Bauweise abhängig.

Was deutlich wird ist, dass die drei Strategien zu sehr unterschiedlichen Lüftungsregimen führen. Die logistische Regression führt zu einem vielfachen Luftwechsel gegenüber der Referenz und der MC-Simulaton. Die MC-Simulaton führt immer noch zu einem guten Drittel mehr Luftwechsel als die Referenz. Bei zusätzlicher Betrachtung, der in Abbildung 5.20 dargestellten Streuung der Öffnungsduer, wird deutlich, dass die Referenz zwar im Mittel zu etwa 7 h Fensteröffnung pro Tag führt, der Median liegt jedoch bei etwa 2,5, d.h. an min-

¹ Hinweis: Im verwendeten Simulationsprogramm wurde keine Heißwassernutzung implementiert. Der ermittelte Heizwärmebedarf bezieht sich damit nur auf die Bereitstellung der Raumwärme.

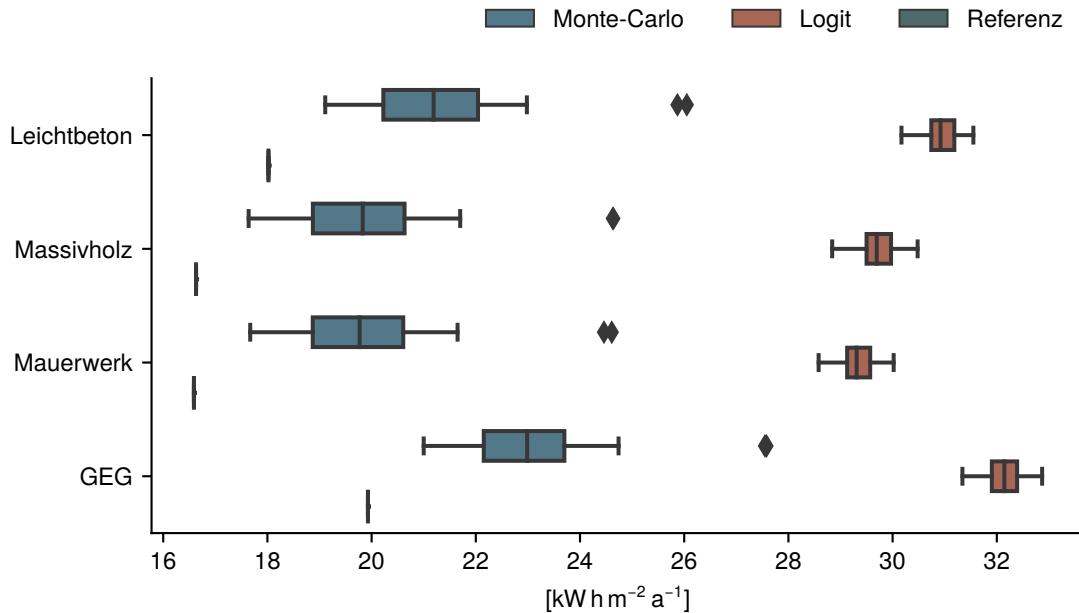


Abbildung 5.18 Ergebnisse für den Heizwärmebedarf (ohne Trinkwarmwasser) in [$\text{kWh}/(\text{m}^2 \text{a})$] des Simulationsprogramms für die zwei untersuchten Steuerungsmodelle durch Monte-Carlo-Simulation und logistischer Regression sowie eine Referenzgröße mit deterministischer Lüftungssteuerung.

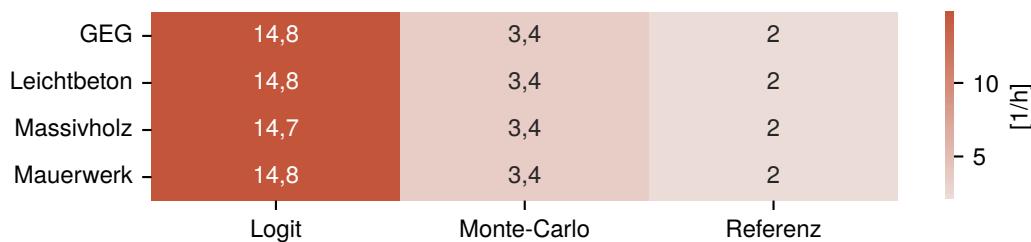


Abbildung 5.19 Mittlere Luftwechselrate [$1/\text{h}$] nach Steuerungsmodell und Bauweise.

destens 50 % der Tage war das Fenster überhaupt nicht geöffnet. Die MC-Simulaton führt dagegen immerhin zu einem Median von etwa 2,5 h bei einigen Ausreißern im Bereich >12 h. Bei der logistischen Regression sieht das wiederum genau anders aus. Es ergibt sich ein Median von 15 h. Der untere Whisker geht bis etwa 3 h mit einigen wenigen Ausreißern nach unten. Insgesamt kann man daher festhalten, dass das Logit Modell über das ganze Jahr verteilt zu viel mehr Lüftungsvorgängen als die anderen beiden Modelle führt. Das spiegelt sich auch am entsprechenden Heizwärmebedarf wider.

Stellt man den Heizwärmebedarf dem mittleren Luftwechsel gegenüber, ergibt sich ein recht klares Bild. Das Logit-Modell ermittelt hier nur sehr wenig Varianz. Man kann sehen, dass sich dabei die einzelnen Bauweisen auch relativ ähnlich verhalten. Es sind keine größeren Ausreißer erkennbar. Das spiegelt sich so auch in den Boxplots in Abbildung 5.18 wider. Die Boxen sind hier alle symmetrisch, Ausreißer gibt es keine.

Bei der MC-Simulaton sieht das Bild hier etwas anders aus. Dort zeigt sich eine etwas breitere

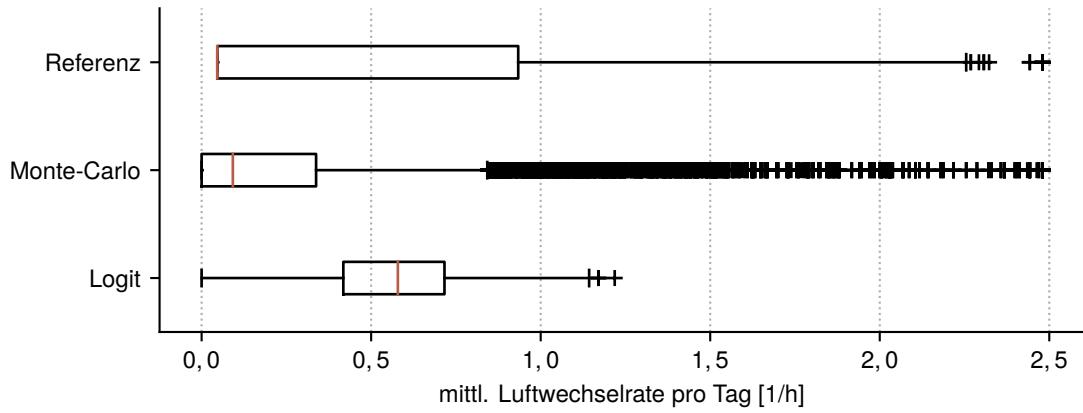


Abbildung 5.20 Simulierte mittlere Fensteröffnungsduer in Stunden pro Tag für die drei untersuchten Varianten.

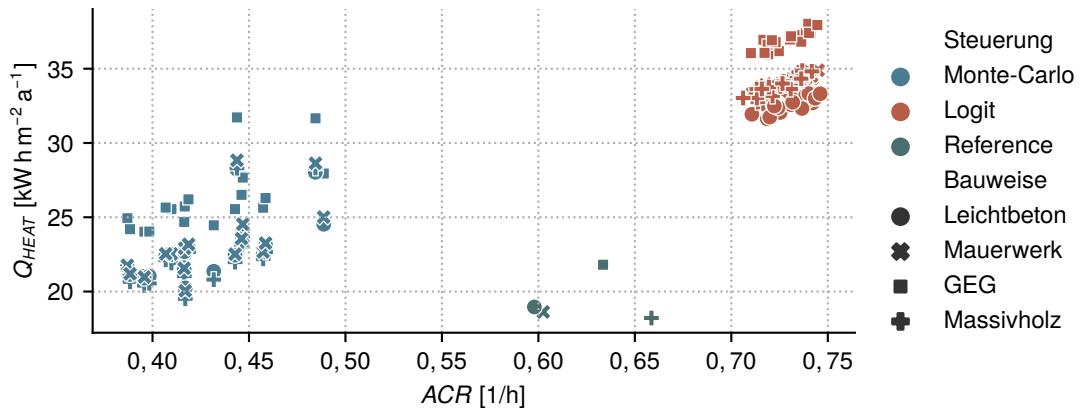


Abbildung 5.21 Gegenüberstellung der simulierten Luftwechselrate (ACR [1/h]) und des spez. Heizwärmebedarfs (Q_{HEAT} [$\text{kWh}/(\text{m}^2 \text{ a})$])

Streuung der Ergebnisse. Zwar lässt sich wieder ein pos. linearer Zusammenhang erkennen, es gib jedoch auch mehr Ausreißer. Insbesondere bei den GEG Varianten (Quadrat) fällt auf, dass es Varianten gibt, die bei gleicher Luftwechselrate mehr als $5 \text{ kWh}/(\text{m}^2 \text{ a})$ mehr Energie verbrauchen. Betrachtet man in Relation zu den beiden entwickelten Modellen die Referenzvariante, wird deutlich, dass sich diese trotz wesentlich höheren mittleren Luftwechselraten als die MC-Simulaton, eher im unteren Spektrum des Energiebedarfs aufhalten. Es scheint also kein direkter linearer Zusammenhang zwischen der Luftwechselrate und dem Energieverbrauch ersichtlich (zumindest nicht unabhängig von der Lüftungsstrategie).

Betrachtet man in diesem Kontext die in Abbildung 5.22 dargestellten Parameter des thermischen Komforts ² wird deutlich, dass die relativ hohen Luftwechselraten beim Logit Modell auch zu sehr vielen UTGS nach adaptives Komfortmodell nach DIN EN 16798-1:2022 - NA führen. Diese weisen auf eine Unterkühlung - vor allem im Winter und damit in der Heizperiode – hin. Im Sommer treten weniger Kelvinstunden auf. Dies deutet darauf hin, dass durch die hohen Luftwechselraten auch eine sommerliche Überhitzung verhindert wird.

² Hinweis: Zur Berechnung der Kelvinstunden wurde abweichend von der SIA 2024 (2021) mit einem Nutzungs-

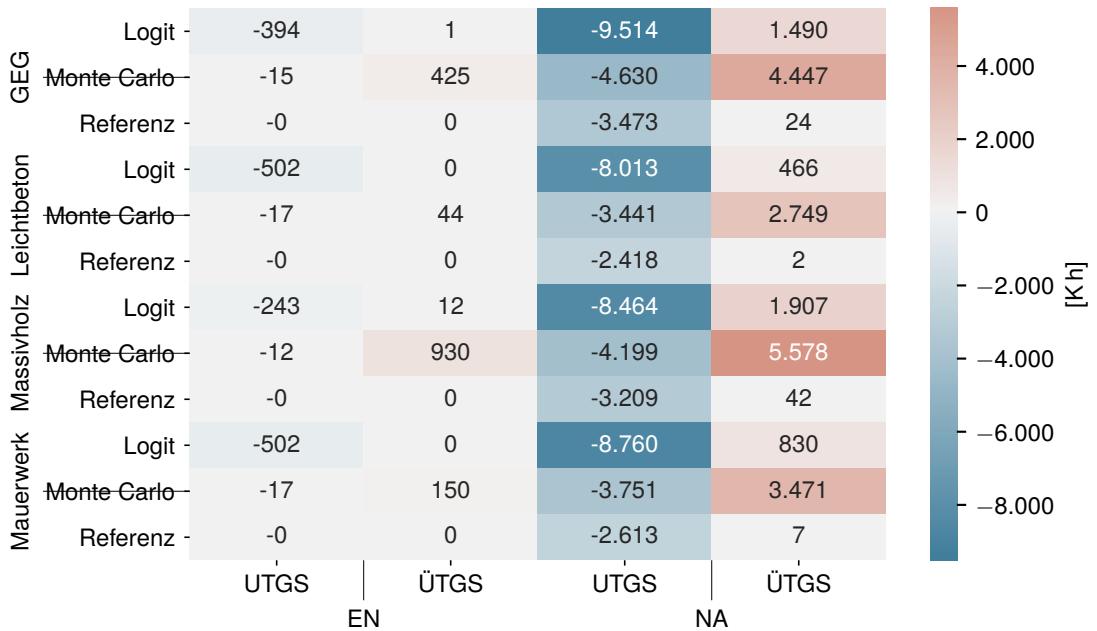


Abbildung 5.22 Thermische Komfortparameter nach den adaptiven Komfortmodellen der DIN EN 16798-1. UTGS werden mit neg., ÜTGS mit pos. Vorzeichen dargestellt. Mittelwerte nach Steuerungsmodell und Bauweisen.

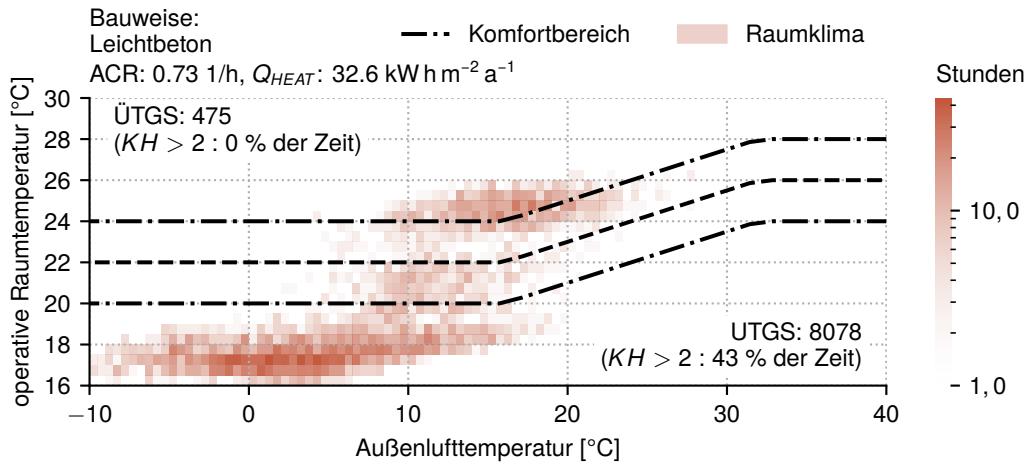
In Abbildung 5.23 sind die Simulationsergebnisse exemplarisch für eine Variante im adaptiven Komfortband nach *DIN EN 16798-1 (2022)-NA* dargestellt.

Bei Betrachtung des Anteils der Nutzungszeit, in dem das Komfortkriterium von max. 2 K Über- bzw. Unterschreitung des Komfortbandes nicht eingehalten wird, zeigt sich, dass der thermische Komfort bei beiden entwickelten Modellen nicht gegeben ist.

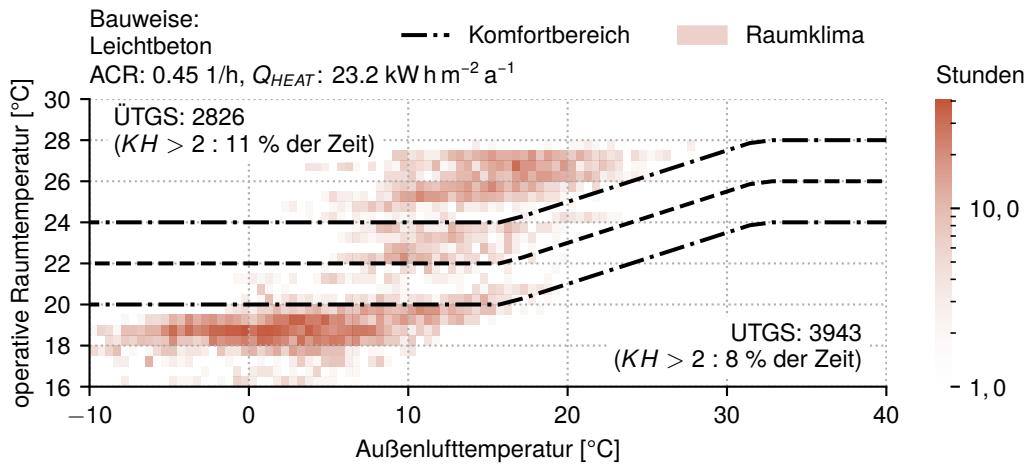
Es zeigt sich, dass die logistische Regression gerade in der Heizperiode viele UTGS produziert. Mit einem zeitlichen Anteil von 43 % bei mehr als 2 K Abweichung vom Komfortband ist hier der lt. Norm einzuhaltende Toleranzbereich von maximal 1 % der Nutzungszeit weit überschritten. Ähnlich verhält es sich bei der MC-Simulaton - wenn auch weniger stark ausgeprägt. Dafür treten hier auch bei relativ geringen Außenlufttemperaturen von <20 °C ÜTGS auf. Dieses Bild spiegelt sich auch beim errechneten Energieverbrauch wider. Die Referenzsimulation kommt hier auf 19 kWh/(m² a) wohingegen das Logit-Modell auf 32,6 kWh/(m² a) kommt.

Die Ergebnisse lassen darauf schließen, dass die beiden entwickelten Modelle zu einem relativ hohen Luftwechsel im Winter führen. Dies ist dann mit einem hohen Energieverbrauch verbunden, um die angestrebte Raumtemperatur wieder zu erreichen. Betrachtet man den Luftwechsel im Jahresgang (Abbildung 5.24) bestätigt sich diese Vermutung. Während das Referenzmodell im Winter nur die vorgegebenen zwei 15 min Lüftung pro Tag durchführt und nur im Sommer mehr Luftwechsel veranlasst, führt das MC-Simulaton auch im Winter zu

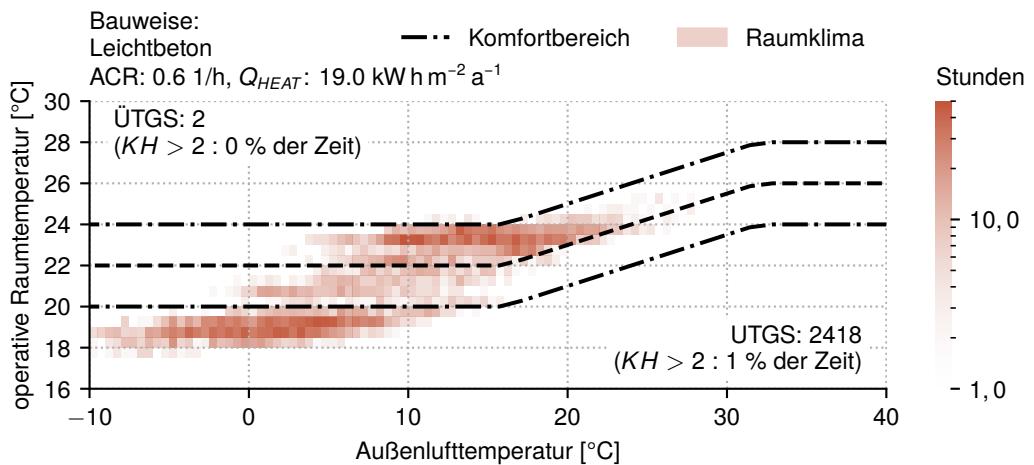
Zeitraum von 18:00 bis 08:00 Uhr gerechnet.



(a) Adaptives Komfortband für eine Simulation mit logistischer Lüftungssteuerung.



(b) Adaptives Komfortband für eine Simulation mit Monte-Carlo Lüftungssteuerung



(c) Adaptives Komfortband für die Referenzsimulation

Abbildung 5.23 Adaptives Komfortband nach DIN EN 16798-1 - NA.

einem erhöhten Luftwechsel. Hier lässt sich dennoch ein saisonaler Unterschied zwischen Sommer und Winter ausmachen. Anders sieht das beim Logit-Modell aus. Hier sieht man über den gesamten Jahresverlauf einen relativ konstanten Luftwechsel. Die Saisonalität ist

nur minimal ausgeprägt.

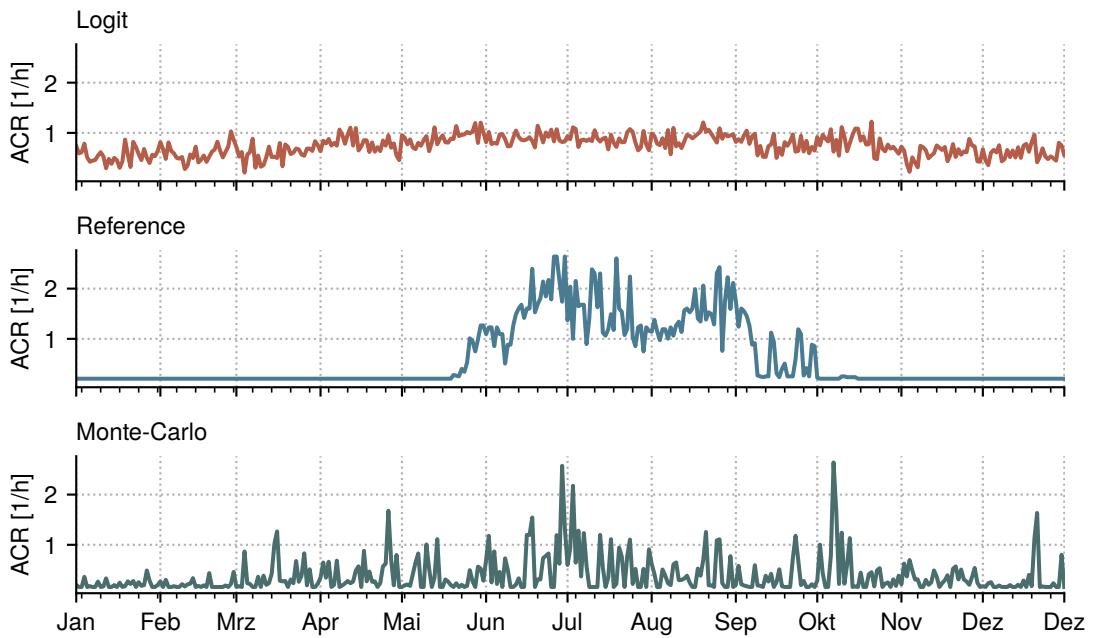


Abbildung 5.24 Gegenüberstellung der mittleren Luftwechselraten für die drei untersuchten Steuerungsmodelle in [1/h] pro Tag im Jahresgang.

Bei Betrachtung der Prädiktoren im Logit-Modell wird deutlich warum: Während der gleitende Mittelwert der Außenlufttemperatur noch einen saisonalen Effekt erkennen lässt, sieht dies bei ΔT und der CO_2 -Konzentration schon anders aus. Hier lässt sich eher eine gegenläufige Saisonalität feststellen.

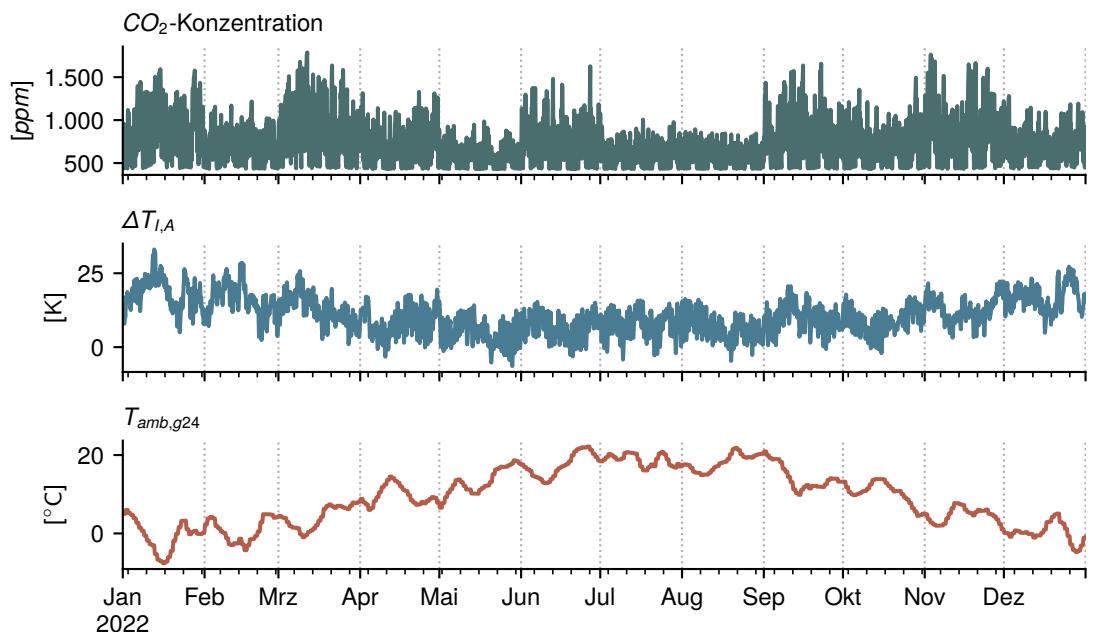


Abbildung 5.25 Gegenüberstellung des Jahresgangs der Simulationsergebnisse für die drei gewählten Prädiktoren CO_2 -Konzentration, Temperaturdifferenz ($\Delta T_{I,A}$ [K]) und gleitender Mittelwert der Außenlufttemperatur ($T_{amb,g24}$ [°C])

Zusammenfassend lässt sich festhalten, dass die Steuerungsmodelle zwar funktionieren, die erzielten Ergebnisse jedoch nur wenig überzeugend sind. Das Logit-Modell liefert viel zu wenig Varianz in den Ergebnissen. Die Aussagekraft ist dadurch gering, da sich zwischen den untersuchten Modellen keine Unterschiede ergeben. Dass die Steuerung so wenig zufriedenstellend funktioniert, kann mit fehlender Varianz der Prädiktoren zusammenhängen. Insbesondere die CO_2 -Konzentration hat im entwickelten Modell einen starken Einfluss auf die Fensteröffnung. Die Abbildung dieser in der Simulation folgt jedoch einer relativ rudimentären Implementation. Wie schon Kargruber (2022) festgestellt hat, weichen die simulierten CO_2 -Konzentrationen stark von den *in situ* gemessenen Werten ab.

Die Ergebnisse der MC-Simulaton erzielen eher das gewünschte Ergebnis. Hier lässt sich über das ganze Jahr hinweg eine relativ hohe Varianz der Ergebnisse erzielen. Zwar führt auch dieses Modell zu vielen – verglichen mit den *in situ* beobachteten (siehe Abbildung 4.20), UTGS und ÜTGS. Das kann allerdings auch mit Unterschieden in der Modellierung zusammenhängen. So wird z. B. die Anwesenheit in der Simulation nur rudimentär abgebildet. Die Schedules der *SIA 2024* (2021) geben Gewichtungsfaktoren für die Anwesenheit vor. Das reduziert zwar die entsprechenden Eingangsparameter, die Simulation klassifiziert allerdings nur Zeiträume in denen der entsprechende Schedule Null wird als abwesend. Aus diesem Grund wurde für die relevanten Analysen ein Anwesenheitszeitraum von 18:00 bis 08:00 Uhr angenommen. In der Messung sind diese Profile natürlich viel exakter. Hinzu kommen Abweichung im Wetter. Vergleicht man die in Abschnitt B.3 und Abschnitt C.4 dargestellten Wetterdaten, kann man erkennen, dass der verwendete TRY Datensatz im Winter wesentlich geringere Temperaturen ansetzt als in Realität beobachtet wurden.

6. Einordnung der Ergebnisse

Im ersten Teil dieser Arbeit wurden die im Rahmen des Forschungsprojektes *Einfach Bauen* erhobenen Messdaten statistisch aufbereitet und empirisch ausgewertet. Die gesammelten Daten beinhalten raumklimatische und energetische Daten sowie Wetterdaten. Im Gegensatz zu vergleichbaren Forschungsprojekten wie Andersen et al. (2013) oder Calì et al. (2016) handelt es sich hier um Neubauten mit einem besonders geringen Grad an technischer Gebäudeausrüstung. Abgesehen von einer Abluftanlage im Bad muss der Luftwechsel zum Temperieren der Wohnung im Sommer manuell von den Nutzer:innen hergestellt werden. Dies macht diesen Datensatz besonders geeignet zur Analyse des Lüftungsverhaltens. Das detaillierte Messkonzept bietet gegenüber einzelnen Messpunkten wie sie Andersen et al. (2013) oder Calì et al. (2016) verwenden den Vorteil einer Auflösung auf Raumbene. Insbesondere der thermische Komfort lässt sich dadurch sehr gut auswerten.

Im Rahmen dieser Arbeit wurden die gesammelten Messdaten noch einmal restrukturiert und bereinigt. Dabei konnten einige Fehler in den Daten behoben werden. Darüber hinaus wurde das Pre-Processing der Daten weiter entwickelt, sodass nun mehr Fehler wie z.B. ausgefallene Sensoren und Ausreißer automatisiert entfernt werden.

Eine wichtige Erweiterung der gesammelten Messdaten ist deren Synthese zu einem Anwesenheitssignal und einem Signal für die Heizungsaktivierung. Beide Parameter wurden vorher nur indirekt beobachtet und können nun detaillierter analysiert werden.

Außerdem konnte durch die Restrukturierung des Datensatzes der Zugriff auf die Datensätze und deren Lesbar- und Verständlichkeit verbessert werden.

Die Auswertung der aufbereiteten Daten hat gezeigt, dass sich die Nutzer:innen im wesentlichen erwartbar verhalten. Das Anwesenheitsprofil Abbildung 4.11 zeigt bei den meisten Nutzer:innen einen typischen *nine to five* Tagesablauf, wie ihn im wesentlichen auch die SIA 2024 (2021) annimmt. Abweichend von der SIA kann jedoch kein erneuter Peak um die Mittagszeit festgestellt werden. Diese Annahme der Norm könnte für zukünftige Modellierungen überdacht werden.

Das beobachtete Raumklima liegt weitestgehend im thermischen Komfortbereich. Die Raumtemperaturen liegen weitestgehend im Komfortbereich beider adaptiver Komfortbänder nach (DIN EN 16798-1, 2022). Selbst im Massivholzhaus treten im beobachteten Zeitraum keine größeren Überhitzungen auf. Zu beachten ist jedoch, dass es im betrachteten Zeitraum auch keine längere Hitzeperiode gab. Auffällig ist, dass die Häuser nach Komfortbetrachtung eher zur Unterkühlung neigen. Insbesondere im Massivholzhaus kommt es vermehrt zu UTGS. Es fällt jedoch auf, dass diese Wohnungen auch die mit dem geringsten Wärmeenergieverbrauch und der kürzesten Heizdauer sind. Es liegt daher nahe, dass die Nutzer:innen ganz

bewusst niedrige Temperaturen herbeiführen und auf eine Nutzung der Heizung verzichten. Dies spiegelt sich so auch in der ermittelten Heizgrenztemperatur wider. Mit 5 °C ist diese vergleichsweise gering. Gängige Normwerke zur Heizungsauslegung gehen hier eher von 10 °C bis 17 °C aus (Bundesministerium für Wohnen, Stadtentwicklung und Bauwesen, 2020; DIN V 18599-1, 2018).

Im Sommer zeigt der Vergleich mit der unbewohnten O eines jeden Hauses, dass die Nutzer:innen durch Fensterlüftung die Lufttemperatur gut regulieren können. Während in der O im Mittel teilweise 27 °C herrschen, sind die restlichen Wohnungen im Mittel 2 K bis 3 K kühler. Beim Lüftungsverhalten selbst ist aufgefallen, dass sich das Lüftungsverhalten zwischen den Nutzer:innen im Wesentlichen nicht sehr stark unterscheidet. Es gibt zwar eine starke Schwankung in der Dauer der Fensteröffnung, das tages- und jahreszeitliche Profil ähnelt sich jedoch sehr. Was bei der empirischen Analyse allerdings auffällt ist, dass es kein eindeutiges Kriterium erkennen lässt, dass die Nutzer:innen zum Lüften bewegt. Es wurden keine linearen Zusammenhänge gefunden. Auch bei der Histogrammanalyse ist kein Parameter ausgeprägt, der eine starke Abhängigkeit induzieren könnte. Die festgestellte Häufung der absoluten Feuchte und Außenlufttemperatur lässt eher auf einen saisonalen Effekt, als einen direkten Zusammenhang schließen.

Vor diesem Hintergrund wurden Modelle zur Lüftungssteuerung für eine thermische Gebäudesimulation abgeleitet. Dabei wurde im ersten Schritt eine MC-Simulation durchgeführt. Diese wird in der jüngeren Forschung immer wieder zur Abbildung von Modellunsicherheiten in der Gebäudesimulation verwendet (Meier, 2020; T. Auer et al., 2021). Dabei gibt es jedoch stets das Problem der Datenverfügbarkeit zur Modellierung. Die im Rahmen von *Einfach Bauen* erhobenen Messdaten eignen sich hierfür hingegen gut. Daher konnte auf dieser Basis ein probabilistisches Modell erstellt werden, dass das beobachtete Nutzungsverhalten mit einer guten theoretischen Genauigkeit approximiert.

In der praktischen Erprobung des Modells hat sich gezeigt, dass es sich gut eignet, um eine probabilistische Streuung von Randbedingungen zu ermöglichen. Problematisch ist bei diesem Modell die Festlegung einer geeigneten Verteilung der Eingangsparameter. Da diese aus einer bekannten Verteilung gesampelt werden müssen, bildet jede MC-Simulation mit zunehmender Stichprobengröße lediglich die gewählte Verteilung ab. Es ist daher entscheidend, eine passende Verteilung als Eingangsgröße zu wählen. Im Rahmen dieser Arbeit wurde hierfür eine tages- und jahreszeitliche Verteilung gewählt, da sich in der empirischen Untersuchung vor allem hier Zusammenhänge gezeigt haben. Damit ergibt sich jedoch eine starke Verknüpfung mit dem während der Beobachtung vorherrschenden Wetter. Das daraus resultierende Modell konnte nicht auf andere klimatische Randbedingungen reagieren. Dies hat sich auch im durchgeföhrten Simulationsprogramm gezeigt. Hier konnte die MC-Simulation nicht auf den - im Vergleich zu den in situ Bedingungen - geringfügig kühleren Wetterdatensatz reagieren. Um dieses bereits bei der Modellierung absehbare Problem zu umgehen, wurde eine logistische Regression durchgeführt.

Logistische Regressionsmodelle sind z.B. in der Ökonomie ein gängiges Modell zur Approximation abhängiger diskreter Variablen durch mehrere unabhängige (erklärender) Variablen. Auch in der Forschung zur Gebäudeperformance finden solche Modelle gelegentlich, insbesondere zur Modellierung des Nutzungsverhaltens, Anwendung. In der Vergangenheit wurden dabei zwar bereits häufiger Modelle zur Fensteröffnung in Wohngebäuden erstellt, die Implementation in eine Gebäudesimulation wurde jedoch nur sehr selten durchgeführt (Gae-tani et al., 2016; Fabi et al., 2012). Zur Modellierung wurde für diese Arbeit ein Ansatz aus der von Andersen et al. (2013) postulierten Methode abgeleitet. Dabei konnten - trotz der unterschiedlichen Datensätze - vergleichbare Ergebnisse erzielt werden. Auch in dieser Arbeit wurde die CO_2 -Konzentration als mathematisch gewichtigster Faktor zur Prädiktion der Fensteröffnung identifiziert werden. Zusätzlich wurden die mittlere Außenlufttemperatur und die Differenz zwischen Innen- und Außenlufttemperatur als signifikante Einflussfaktoren ermittelt. Dabei handelt es sich um ähnliche Variablen, wie sie von Andersen et al. (2013) oder Hong et al. (2018) verwendet wurden.

Das im Rahmen dieser Arbeit entwickelte Modell ist sehr gut darin, anhand der Messdaten Fensteröffnungen zu erkennen. Die als Gütekriterium verwendete Grenzwertoptimierungskurve hat gezeigt, dass etwa 80 % der vorhergesagten Fensteröffnungen korrekt waren. Bei der Anwendung des Modells in der Gebäudesimulation hat sich jedoch offenbart, dass es nicht sehr zufriedenstellend arbeitet. Das resultierende Steuerungssignal weist nur eine sehr geringe Varianz auf. Es ist im Tages- und Jahresverlauf nahezu konstant und führt damit zu einem viel zu hohen Luftwechsel.

Bei der Validierung des Steuerungsmodells wurde aufgezeigt, dass die Ermittlung der CO_2 -Konzentration im Simulationsmodell, nicht mit den in situ Messungen übereinstimmt. Außerdem ist es problematisch, dass die Fensteröffnung die Prädiktoren stark beeinflusst. Durch das Öffnen der Fenster sinkt die CO_2 -Konzentration relativ schnell ab, ebenso verhält es sich mit dem Temperaturdelta, welches sich durch die Fensteröffnung verändert. In der Signalverarbeitung wird dieser Effekt auch *Autokorrelation* genannt. Der Einfluss dieses Effektes hat sich in der Simulation als stärker erwiesen, als eingangs vermutet wurde.

Insgesamt lässt sich über das Fensterlüftungsverhalten festhalten, dass sich auch in dieser Arbeit kein eindeutiger Parameter finden ließ, der als guter Indikator für die Fensteröffnung dient. Ähnlich wie in den Arbeiten von (Buso et al., 2015) und (Andersen et al., 2013) haben sich eine Vielzahl möglicher Einflussgrößen ergeben, von denen allerdings keine besonders prägnant gewesen ist. Die CO_2 -Konzentration hat sich in der logistischen Regression, wie auch bei (Buso et al., 2015) und (Andersen et al., 2013), als signifikanter Prädiktor erwiesen. Der Einfluss der CO_2 -Konzentration auf die Fensteröffnung erscheint jedoch in der Realität eher fragwürdig: CO_2 ist farb- und geruchslos und hat in Konzentrationen von <5000 ppm weder wahrnehmbar noch hat es physiologische Auswirkungen auf das Wohlbefinden der Nutzer:innen (P. D. I. T. Auer, SoSe 2020). Es dient lediglich als Indikatorgas für Raumluftqualität. Das in Abbildung 5.4 dargestellte Histogramm zeigt, dass bei hohen CO_2 -Konzentrationen

nicht häufiger das Fenster geöffnet wird als bei geringer Konzentration.

Insgesamt lässt sich festhalten, dass die untersuchten probabilistischen Modelle einen nur eingeschränkten Nutzen aufzeigen. Es konnte zwar gezeigt werden, dass sich probabilistische Modelle prinzipiell auch tiefer in die Gebäudesimulation integrieren lassen. Insbesondere die MC-Simulaton hat dabei das Potenzial gezeigt auch zur Abschätzung der PG hilfreich zu sein. Mit seiner Hilfe lassen sich, vorausgesetzt man verwendet passende Eingangsverteilungen, schon mit relativ wenigen Simulation eine Bandbreite an Ergebnisse erzielen. Anhand dieser Bandbreite lassen sich die Modellunsicherheiten, bezogen den modellierten Parameter quantifizieren und damit auch der potenziell daraus resultierende Anteil am PG.

Die Verwendung von logistischen Modellen kann Helfen, Zusammenhänge zwischen Variablen aufzuzeigen. Anhand dieser Zusammenhänge lassen sich Daten gut beschreiben und auswerten. Die Verwendung als Steuerungsmodell konnte in dieser Arbeit nicht zielführend angewendet werden.

7. Ausblick

Im Rahmen dieser Arbeit wurde eine Methode entwickelt, um probabilistische Modelle aus in situ Messdaten abzuleiten und diese in einer thermisch dynamischen Gebäudesimulation zur Abbildung des Nutzungsverhaltens zu verwenden. Mit dieser Methode sollten die daraus resultierenden Modellunsicherheiten abgeschätzt und damit Rückschlüsse auf den PG möglich werden. Die entwickelten Modelle waren dazu nur bedingt in der Lage. Es hat sich gezeigt, dass sich durch stochastische Methoden keine plausiblen Parameter identifizieren lassen, die das Lüftungsverhalten signifikant erklären können. Es konnte dargestellt werden, dass in den vorliegenden Beobachtungen vor allem die Tages- und Jahreszeit einen entscheidenden Einfluss auf das Lüftungsverhalten hatten.

Das zur Steuerung der Lüftung in der Simulation verwendete logistische Regressionsmodell, hat in der Simulation aufgrund der Autokorrelation der Fensterlüftung mit ihren Prädiktoren nur bedingt brauchbare Ergebnisse geliefert. Bei der zukünftigen Verwendung eines solchen Modells, sollte die Autokorrelation bei der Modellierung berücksichtigt werden, um verwertbare Ergebnisse zu erzielen.

Zur Abbildung von Modellunsicherheiten hat sich jedoch die Monte-Carlo-Simulation als sehr nützlich gezeigt. Im Rahmen dieser Arbeit konnte diese in den Simulationsablauf integriert werden. Abhängig von der gewählten Verteilung der gewählten Parameter lassen sich hier mit relativ wenigen Simulationen eine solide Bandbreite an Ergebnissen erzielen, die dazu geeignet sind, Abschätzungen der Modellunsicherheiten (PG) zu integrieren.

Des Weiteren konnte durch diese Arbeit eine Grundlage für weitere Analyse gelegt werden: Durch die Aufbereitung der im Rahmen des Projekts *Einfach Bauen* erhobenen Variablen, wurde ein Datensatz von raumklimatischen und energetischen Messungen gebildet, mit welchem diverse weitere statistische Analysen durchgeführt werden können.

Mithilfe der, in das TRNLizard Template implementierten, Erweiterungen lassen sich neue probabilistische Erkenntnisse und Thesen nun auch schnell in einer thermisch dynamischen Simulation anwenden.

Literaturverzeichnis

- Andersen, R., Fabi, V., Toftum, J., Cognati, S. P., & Olesen, B. W. (2013). Window opening behaviour modelled from measurements in Danish dwellings. *Building and Environment*, 69, 101–113. <https://doi.org/10.1016/j.buildenv.2013.07.005>
- Andersen, R., Olesen, B., & Toftum, J. (2007). Simulation of the Effects of Occupant Behaviour on Indoor Climate and Energy Consumption.
- ASHRAE 55: Thermal Environmental Conditions for Human Occupancy*. (2010). American Society of Heating, Refrigerating and Air-Conditioning Engineers, Inc.
- Auer, P. D. I. T. (SoSe 2020). *Hygiene Comfort Basics* (Vorlesung). München.
- Auer, T., Lauss, L., Meier, A., Rink, A., & Granmayeh, A. (2021, 30. November). *Robuste, Nutzerfreundliche Und Kostengünstige TGA in Gebäuden* (Forschungsbericht Nr. 10.08.17.7-19.42). Forschungsinitiative ZukunftBAU.
- Bruce, P., Bruce, A., Gedeck, P., O'Reilly for Higher Education (Firm) & Safari, a. O. M. C. (2021). *Praktische Statistik für Data Scientists, 2nd Edition*. Verfügbar 16. Juli 2022 unter <https://ezproxy.torontopubliclibrary.ca/login?url=https://learning.oreilly.com/library/view/-/9781098129224/?ar>
OCLC: 1258251667
- Gesetz Zur Vereinheitlichung Des Energieeinsparrechts Für Gebäude Und Zur Änderung Weiterer Gesetze (2020, 13. August). Verfügbar 10. Juli 2022 unter http://www.bgbler.de/xaver/bgbler/start.xav?startbk=Bundesanzeiger_BGBI&jumpTo=bgbler120s1728.pdf
- Burhenne, S. (2013, 13. November). *Monte Carlo Based Uncertainty and Sensitivity Analysis for Building Performance Simulation* (Diss.). Karlsruher Institut für Technologie. Karlsruhe.
- Burhenne, S., Jacob, D., & Henze, G. P. (14–2011, 16. November). Sampling based on Sobol' Sequences Monte Carlo Techniques applied to building simulations. *Proceedings of Building Simulation 2011*: 8.
- Buso, T., Fabi, V., Andersen, R. K., & Cognati, S. P. (2015). Occupant Behaviour and Robustness of Building Design. <https://doi.org/10.1016/j.buildenv.2015.11.003>
- Calì, D., Andersen, R. K., Müller, D., & Olesen, B. W. (2016). Analysis of occupants' behavior related to the use of windows in German households. *Building and Environment*, 103, 54–69. <https://doi.org/10.1016/j.buildenv.2016.03.024>
- Carlucci, S., De Simone, M., Firth, S. K., Kjærgaard, M. B., Markovic, R., Rahaman, M. S., Annaqeeb, M. K., Biandrate, S., Das, A., Dziedzic, J. W., Fajilla, G., Favero, M., Ferrando, M., Hahn, J., Han, M., Peng, Y., Salim, F., Schlüter, A., & van Treeck, C. (2020). Modeling occupant behavior in buildings. *Building and Environment*, 174, 106768. <https://doi.org/10.1016/j.buildenv.2020.106768>
- Cramer, E., & Kamps, U. (2020). *Grundlagen der Wahrscheinlichkeitsrechnung und Statistik: Eine Einführung für Studierende der Informatik, der Ingenieur- und Wirtschaftswissenschaften*. Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-662-60552-3>

- Deutsche Energie-Agentur GmbH. (2021, Mai). *dena-Gebäudereport Fokusthemen zum Klimaschutz im Gebäudebereich*. Deutsche Energie-Agentur GmbH. Berlin. Verfügbar 29. Juni 2022 unter https://www.dena.de/fileadmin/dena/Publikationen/PDFs/2021/dena-Gebäudereport_2021_-_Fokusthema_Zahlen__Daten__Fakten.pdf
- Deutscher Wetterdienst. (n. d.). *Testreferenzjahre (TRY)*. Verfügbar 7. Juni 2022 unter <https://www.dwd.de/DE/leistungen/testreferenzjahre/testreferenzjahre.html>
- de Wilde, P. (2014). The gap between predicted and measured energy performance of buildings: A framework for investigation. *Automation in Construction*, 41, 40–49. <https://doi.org/10.1016/j.autcon.2014.02.009>
- DIN EN 16798-1:2022-03, Energetische Bewertung von Gebäuden - Lüftung von Gebäuden - Teil 1: Eingangsparameter Für Das Innenraumklima Zur Auslegung Und Bewertung Der Energieeffizienz von Gebäuden Bezuglich Raumluftqualität, Temperatur, Licht Und Akustik.* (2022, März). Beuth Verlag GmbH. <https://doi.org/10.31030/3327351>
- DIN EN ISO 7726:2021-03, Umgebungsklima - Instrumente Zur Messung Physikalischer Größen.* (2021, März). Beuth Verlag GmbH. <https://doi.org/10.31030/3123890>
- DIN V 18599-1:2018-09, Energetische Bewertung von Gebäuden - Berechnung Des Nutz-, End- Und Primärenergiebedarfs Für Heizung, Kühlung, Lüftung, Trinkwarmwasser Und Beleuchtung - Teil 1: Allgemeine Bilanzierungsverfahren, Begriffe, Zonierung Und Bewertung Der Energieträger.* (2018, September). Beuth Verlag GmbH. <https://doi.org/10.31030/2874317>
- Fabi, V., Andersen, R., & Cognati, S. (2012). Window Opening Behaviour: Simulations of Occupant Behaviour in Residential Buildings Using Models Based on a Field Survey.
- Fawcett, T. (2004). ROC Graphs: Notes and Practical Considerations for Researchers. *Machine Learning*, 31, 1–38.
- Frenzel, C., & Hiller, M. (2014). TRNSYSLIZARD - Open Source Tool für Rhinoceros /Grasshopper zur einfachen, schnellen und sicheren Simulation einer Gebäudezone unter Ankoppelung von TRNSYS und DAYSIM. *German-Austrian IBPSA Conference*, 7.
- Frenzel, C. (2019, Juni). *TRNLizard*. Food4Rhino. Verfügbar 8. Juli 2022 unter <https://www.food4rhino.com/en/app/trnlizard>
- Gaetani, I., Hoes, P.-J., & Hensen, J. L. (2016). Occupant behavior in building energy simulation: Towards a fit-for-purpose modeling strategy. *Energy and Buildings*, 121, 188–204. <https://doi.org/10.1016/j.enbuild.2016.03.038>
- Hájek, A. (2019). Interpretations of Probability. In E. N. Zalta (Hrsg.), *The Stanford Encyclopedia of Philosophy* (Fall 2019). Metaphysics Research Lab, Stanford University. Verfügbar 10. Juli 2022 unter <https://plato.stanford.edu/archives/fall2019/entries/probability-interpret/>
- Hong, T., Chen, Y., Belafi, Z., & D’Oca, S. (2018). Occupant behavior models: A critical review of implementation and representation approaches in building performance simulation programs. *Build. Simul.*, 11(1), 1–14. <https://doi.org/10.1007/s12273-017-0396-6>
- Ioannou, A., & Itard, L. C. M. (2015). Energy performance and comfort in residential buildings: Sensitivity for building parameters and occupancy. *Energy and Buildings*, 92, 216–233. <https://doi.org/10.1016/j.enbuild.2015.01.055>

- Jones, R. V., Fuertes, A., Gregori, E., & Giretti, A. (2017). Stochastic behavioural models of occupants' main bedroom window operation for UK residential buildings. *Building and Environment*, 118, 144–158. <https://doi.org/10.1016/j.buildenv.2017.03.033>
- Kargruber, J. (2022, 1. März). *Validierung Des Thermisch-Dynamischen Simulationsmodells Aus Dem Forschungsprojekt Einfach Bauen 3 Der TUM Anhand von Messdaten* (Magisterarb.). Technische Universität München. München.
- Lamprecht, C. (2022). *Meteostat: Access and Analyze Historical Weather and Climate Data with Python*. (Version 1.6.2). Verfügbar 18. Juni 2022 unter <https://github.com/meteostat/meteostat-python>
- Macdonald, I. (2002, 1. Juli). *Quantifying the Effects of Uncertainty in Building Simulation* (Diss.). University of Strathclyde. Strathclyde.
- Maderspacher, J. (2017). *Robuste Optimierung in Der Gebäudesimulation* (Diss.). Technische Universität München. Verfügbar 10. November 2021 unter <https://mediatum.ub.tum.de/1356587>
- Meier, A. (2020, 28. Februar). *Monte-Carlo basierte Unsicherheits- und Sensitivitätsanalyse der Gebäudeperformance zur Bewertung von Betriebsfehlern in der technischen Gebäudeausrüstung* (Magisterarb.). Technische Universität München. München.
- Mojic, I., Luzzatto, M., Haller, M., Lehmann, M., Benz, M., & van Velsen, S. (2018, 31. August). *ImmoGap: Einfluss Der Kombination Aus Nutzerverhalten Und Gebäudetechnik Auf Den Performance Gap Bei Mehrfamilienhäusern*. Bundesamt für Energie BFE. Rapperswil. Verfügbar 29. Juni 2022 unter https://www.minergie.ch/media/501469_haller_sb_immogap.pdf
- Nagler, F., Jarmer, T., & Niemann, A. (2018, 1. Oktober). *Einfach Bauen - Ganzheitliche Strategien Für Energieeffizientes, Einfaches Bauen – Untersuchung Der Wechselwirkung von Raum, Technik, Material Und Konstruktion* (Abschlussbericht Nr. 1). Technische Universität. München. <https://www.einfach-bauen.net/wp-content/uploads/2019/04/einfach-bauen-schlussbericht.pdf>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-Learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12(85), 2825–2830. Verfügbar 2. Mai 2022 unter <http://jmlr.org/papers/v12/pedregosa11a.html>
- Rhein, B. (2014). *Robuste Optimierung mit Quantilmaßen auf globalen Metamodellen* (Diss.). Logos-Verlag, Berlin. Verfügbar 11. November 2021 unter <http://www.uni-koeln.de/>
- Schmidt, J. (2016, 4. November). *Sensitivitätsanalyse wesentlicher Einflussfaktoren auf den Energiebedarf von Wohngebäuden* (Magisterarb.). Technische Universität München. München.
- scikit-learn. (2022). *Preprocessing data*. scikit-learn. Verfügbar 11. Juli 2022 unter <https://scikit-learn/stable/modules/preprocessing.html>
- Shi, X., Si, B., Zhao, J., Tian, Z., Wang, C., Jin, X., & Zhou, X. (2019). Magnitude, Causes, and Solutions of the Performance Gap of Buildings: A Review. *Sustainability*, 11(3), 937. <https://doi.org/10.3390/su11030937>

- SIA 2024 Raumnutzungsdaten Für Die Energie- Und Gebäudetechnik. (2021).
- Stock, J. H., & Watson, M. W. (2012). *Introduction to econometrics* (3. ed., global ed., internat. ed). Pearson.
- Tinkerforge. (2022). *Humidity Bricklet 2.0*. Verfügbar 1. Juli 2022 unter https://www.tinkerforge.com/de/doc/Hardware/Bricklets/Humidity_V2.html
- Wooldridge, J. M. (2016). *Introductory econometrics: A modern approach* (Sixth edition, student edition). Cengage Learning.

Abbildungsverzeichnis

Abbildung 2.1 Histogramme einer Stichprobe ($n=100$) aus einer Normalverteilung ($\mu = 0, \sigma = 1$).....	11
Abbildung 2.2 Boxplot einer Stichprobe ($n=100$) aus einer Normalverteilung ($\mu = 0, \sigma = 1$) mit arth. Mittel (gestrichelte Linie), Median (durchgezogene Linie) und Whisker und Ausreißer (+)	11
Abbildung 2.3 Verteilungsfunktion (CDF) einer Normalverteilung (Stichprobe $n=100$, $\mu = 0, \sigma = 1$).....	12
Abbildung 2.4 Dichtefunktion (PDF) einer Normalverteilung (Stichprobe $n=100$, $\mu = 0, \sigma = 1$).....	12
Abbildung 2.5 Beispiel eines Quantil-Quantil-Plots.....	13
Abbildung 4.1 Ergebnis der linearen Regression eines Korrekturfaktors für die rel. Raumluftfeuchte für das Massivholzhaus.....	23
Abbildung 4.2 Klassifikation der Jahreszeiten.....	25
Abbildung 4.3 Ermittlung des Regressionskoeffizienten zur näherungsweisen Bestimmung der operativen Raumtemperatur T_{op}	27
Abbildung 4.4 Beispielhafte Klassifikation der Heizkörperaktivierung. Messwerte der Raumlufttemperatur und Oberflächentemperatur der Heizkörper, sowie Fensteröffnungen. Die Zeiträume in denen die Heizung als an klassifiziert wird, sind rot hinterlegt.....	29
Abbildung 4.5 Korrigierte Heizkörperklassifikation bei Fensteröffnung.....	29
Abbildung 4.6 Beispielhafte Darstellung der detektierten Bewegungen und Fensterinteraktionen zur Ermittlung der Anwesenheit.....	31
Abbildung 4.7 Beispielhafte Ermittlung des Anwesenheitskriteriums auf Basis der CO_2 -Konzentration. Messwert im Schlafzimmer (SZ) und der Referenzwohnung Ost (O). Grün hinterlegte Zeiträume werden als anwesend klassifiziert.....	33
Abbildung 4.8 Beispielhafte Darstellung der Ermittlung des Anwesenheitskriteriums auf Basis der Luftfeuchte [g/kg]. Absolute Luftfeuchte in den Räumen Bad (B), Küche (K), Schlafzimmer (SZ) und Wohnzimmer (WZ). Markierung stellt den Bereich der als Anwesend klassifiziert wurde dar	33

Abbildung 4.9 Resultierendes Anwesenheitssignal aus der beispielhaften Ermittlung....	34
Abbildung 4.10 Übersicht über die verfügbaren Messwerte in den einzelnen Räumen und Wohneinheiten. Die Farbcodierung gibt Auskunft über das Aufzeichnungsintervall des jeweiligen Wertes.....	35
Abbildung 4.11 Mittlere Anwesenheit in Stunden pro Tag, nach Jahreszeiten gemittelt (oben) und Anteil Anwesenheit nach Tageszeit (unten). 50 % bedeutet, dass in 50 % des beobachteten Zeitraums in der betreffenden Stunde Anwesenheit festgestellt wurde.....	36
Abbildung 4.12 Durch Clustering ermittelte mittlere Abwesenheit. Anzahl an Tagen, an denen am vorigen und nächsten Tag wenig Anwesenheit detektiert wurde pro Tag und Jahreszeit. Unten zeitlicher Verlauf der geclusterten Abwesenheit.....	37
Abbildung 4.13 Mittlere Raumlufttemperatur $\overline{T_{air,24\text{ h}}}$ in [°C] pro Tag, gemittelt nach Jahreszeit (oben). Mittlere Raumlufttemperatur $\overline{T_{air,60\text{ min}}}$ in [°C] gemittelt nach Tageszeit (unten)	38
Abbildung 4.14 Mittlere operative Temperatur pro Tag, gemittelt nach Jahreszeit.....	39
Abbildung 4.15 Tagesprofil der mittleren rel. Luftfeuchte pro Stunde.	39
Abbildung 4.16 Vergleich der Korrekturmethoden für die Messwerte der rel. Luftfuchte. Darstellung der mittleren rel. Luftfeuchte in [%rH] nach Jahreszeiten und Wohneinheiten gemittelte Tagesmittelwerte.....	40
Abbildung 4.17 Darstellung der Auswirkung der Korrektur der rel. Luftfeuchte anhand eines Hx-Diagrammen am Beispiel des Schlafzimmers der Wohnung Nord im Mauerwerkhaus.	41
Abbildung 4.18 Wertebereiche der absoluten Luftfeuchte nach Jahreszeiten, dargestellt als Boxplot.....	42
Abbildung 4.19 Mittlere CO_2 -Konzentration. Oben Tagesmittelwert, Mittelwerte nach Jahreszeit. Unten stündliche Mittelwerte nach Tageszeit.	42
Abbildung 4.20 Summierte Kelvinstunden nach adaptives Komfortmodell nach DIN EN 16798-1:2022 - NA und adaptives Komfortmodell nach DIN EN 16798-1:2022 im Beobachtungszeitraum bei Anwesenheit nach Wohneinheiten und Kategorie. UTGS werden mit negativem Vorzeichen, ÜTGS mit positivem Vorzeichen dargestellt.	43

Abbildung 4.21 Zeitlicher Anteil der Abweichung von mehr als 2K vom entsprechenden Komfortband nach DIN 16798-1 während der Nutzungszeit. UTGS werden mit negativem, ÜTGS mit positivem Vorzeichen dargestellt.	44
Abbildung 4.22 Mittelwerte der Kelvinstunden (insgesamt, nicht nur bei Anwesenheit!) nach DIN EN 16798-1:2021. ÜTGS werden mit positivem, UTGS mit negativem Vorzeichen dargestellt. Oben: Kelvinstunden pro Tag, gemittelt nach Jahreszeit, Unten: mittlere Kelvinstunden pro Stunde.	44
Abbildung 4.23 Mittelwerte der Kelvinstunden (insgesamt, nicht nur bei Anwesenheit!) nach DIN EN 16798-1:2021 (NA). ÜTGS werden mit positivem, UTGS mit negativem Vorzeichen dargestellt. Oben: Kelvinstunden pro Tag, gemittelt nach Jahreszeit, Unten: mittlere Kelvinstunden pro Stunde.....	45
Abbildung 4.24 Profil der Außenlufttemperatur, Tagesmittelwerte mit Bandbreite (\pm Standardabweichung)	
Abbildung 4.25 Vergleich der Messdaten mit den Daten der nächsten DWD-Wetterstation in Rosenheim als Boxplot.....	46
Abbildung 4.26 Stündliche Mittelwerte der Außenlufttemperatur nach Tages- und Jahreszeiten.....	47
Abbildung 4.27 Stündliche Mittelwerte der Globalstrahlung nach Tages- und Jahreszeiten.	47
Abbildung 4.28 Jahresgang der gemessenen Strahlungsintensität, getrennt nach Diffus- und Direktstrahlung. Die Globalstrahlung ergibt sich aus der Summe beiden Werte.....	47
Abbildung 4.29 Profil der relativen Außenluftfeuchte, Tagesmittelwerte mit Bandbreite ($\pm std.$).	48
Abbildung 4.30 Darstellung der ermittelten Heiztage im Beobachtungszeitraum	48
Abbildung 4.31 Kummulierte Auswertung des ermittelten Heizungssignals HK_{IO} für Heiztage. Nach Uhrzeit gemittelte Stundenwerte.	49
Abbildung 4.32 Kummulierte Auswertung des ermittelten Heizungssignals HK_{IO} für Heiztage in nach Uhrzeit gemittelte Stundenwerte.	49
Abbildung 4.33 Ermittelte Heizkörpereinteilung T_{set} in [°C]. Median nach Jahreszeiten und Wohneinheiten	50
Abbildung 4.34 Durch eine univariate logistischer Regression bestimmte Heizgrenztemperatur in [°C].....	50

Abbildung 4.35 Mittlerer Wärmeenergieverbauch pro Wohneinheit in [kW h/(m ² d)]. Mittlere Tagessummen nach Jahreszeit. Keine Unterscheidung nach Heiztag oder kein Heiztag.....	51
Abbildung 4.36 Mittlerer Wärmeenergieverbauch pro Wohneinheit in [kW h/(m ² d)]. Mittlere Tagessummen nach Jahreszeit. Nur für Tage, die als nicht Heiztag klassifiziert wurden.....	51
Abbildung 4.37 Absolute Häufigkeit der beobachteten Lüftungsvorgänge nach Wohnungen und Jahreszeit (oben), Verteilung der beobachteten Lüftungen pro Wohneinheit über den Tag in Prozent.....	52
Abbildung 4.38 Absolute Häufigkeit der beobachteten Lüftungsvorgänge nach Tageszeit.	53
Abbildung 4.39 Mittlere Dauer eines Lüftungsvorgangs im Schlafzimmer.....	53
Abbildung 4.40 Mittlere Dauer eines Lüftungsvorgangs in Minuten	54
Abbildung 4.41 Anteil der Stunden, auf die das Lüftungskriterium nach XY zutrifft und tatsächlich ein Fenster geöffnet ist.	54
Abbildung 5.1 Korrelationskoeffizienten nach Pearson für die Kriterien Fenster, Fensteröffnung und Fensterschließung mit ausgewählten erklärenden Variablen.	56
Abbildung 5.2 Gegenüberstellung der rel. Häufigkeiten der Außenlufttemperatur bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).	57
Abbildung 5.3 Gegenüberstellung der rel. Häufigkeiten der Raumlufttemperatur bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).	57
Abbildung 5.4 Gegenüberstellung der rel. Häufigkeiten der CO ₂ -Konzentration bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).	58
Abbildung 5.5 Gegenüberstellung der rel. Häufigkeiten der absoluten Luftfeuchte bei Fensteröffnung (Blau), mit der Grundgesamtheit (Rot).	58
Abbildung 5.7 Dichtefunktion (PDF) $P_{OPENING}(t, S)$ der Fensteröffnung zum Zeitpunkt t im Tagesverlauf, 15 min-Schritte, getrennt nach Jahreszeiten.	60
Abbildung 5.8 Beispielhafte Dichtefunktion (PDF) $P_{OPENING}(t, S)$ für einen Tag in der Übergangsperiode. Anzahl simulierten Tage $n = 365$	60
Abbildung 5.9 Beispielhaftes Resultat einer Monte-Carlo-Simulation des Lüftungssignals im Jahresgang. Auf der Y-Achse sind die Stunden pro Tag mit als offen klassifiziertem Fenster aufgetragen.	61

Abbildung 5.10 Quantil-Quantil-Plot zum Vergleich der Verteilung der Fensteröffnungs- dauer pro Tag der Grundgesamtheit (erwartete Quantile) mit dem Er- gebnis der Monte-Carlo-Simulation (beobachtete Quantile).	62
Abbildung 5.11 Demonstration der Skalierung auf Normalverteilung am Beispiel der Außenlufttemperatur.	64
Abbildung 5.12 Verteilung des Kriteriums <i>Fenster</i> . Absolute und relative Häufigkeiten in Klammern.	65
Abbildung 5.13 Multikollinearität der Variablen des Regressionsdatensatzes anhand des <i>Variance Inflation Factors</i> (VIF).	66
Abbildung 5.14 Prädiktoren x_k für $Y_{Fenster} = 1$, sortiert nach dem Betrag ihres Koeffizi- enten $ \beta_k $	66
Abbildung 5.15 Grenzwertoptimierungskurven <i>ROC</i> für das Logistische Regressions- modell mit Prädiktorenwahl nach Koeffizienten.	67
Abbildung 5.16 Grenzwertoptimierungskurven <i>ROC</i> für das Logistische Regressions- modell mit Prädiktorenauswahl nach Koeffizienten.	68
Abbildung 5.17 Grundriss des verwendeten Simulationsmodells	69
Abbildung 5.18 Ergebnisse für den Heizwärmebedarf (ohne Trinkwarmwasser) in [$\text{kW h}/(\text{m}^2 \text{ a})$] des Simulationsprogramms für die zwei untersuchten Steuerungs- modelle durch Monte-Carlo-Simulation und logistischer Regression sowie eine Referenzgröße mit deterministischer Lüftungssteuerung.	71
Abbildung 5.19 Mittlere Luftwechselrate [1/h] nach Steuerungsmodell und Bauweise.....	71
Abbildung 5.20 Simulierte mittlere Fensteröffnungsdauer in Stunden pro Tag für die drei untersuchten Varianten.....	72
Abbildung 5.21 Gegenüberstellung der simulierten Luftwechselrate (ACR [1/h]) und des spez. Heizwärmebedarfs (Q_{HEAT} [$\text{kW h}/(\text{m}^2 \text{ a})$])	72
Abbildung 5.22 Thermische Komfortparameter nach den adaptiven Komfortmodellen der DIN EN 16798-1. UTGS werden mit neg., ÜTGS mit pos. Vorzei- chen dargestellt. Mittelwerte nach Steuerungsmodell und Bauweisen....	73
Abbildung 5.23 Adaptives Komfortband nach DIN EN 16798-1 - NA.	74
Abbildung 5.24 Gegenüberstellung der mittleren Luftwechselraten für die drei unter- suchten Steuerungsmodelle in [1/h] pro Tag im Jahresgang.	75

Abbildung 5.25 Gegenüberstellung des Jahresgangs der Simulationsergebnisse für die
drei gewählten Prädiktoren CO_2 -Konzentration, Temperaturdifferenz ($\Delta T_{I,A}[K]$)
und gleitender Mittelwert der Außenlufttemperatur ($T_{amb,g24}[^{\circ}C]$)..... 75

Tabellenverzeichnis

Tabelle 2.1 Parameter der Hysteresen zur Steuerung der natürlichen Lüftung. Voreinstellung des Templates von Frenzel (2019)	6
Tabelle 4.1 Beobachtungszeitraum	21
Tabelle 4.2 Korrekturwerte der TRH-Sensoren	22
Tabelle 4.3 Lineare Korrekturfaktoren zur behebung des Messfehlers der TRH-Sensoren	23
Tabelle 4.4 Einzugsdaten der Mieter:innen und Beginn der Messdaten.....	24
Tabelle 4.5 Vergleich der des Mittelwerts, des Medians und der Standardabweichung der Außenlufttemperatur für die Klassifikation nach Frühling und Herbst sowie der Zusammenfassung als Übergang.	24
Tabelle 4.6 Descriptive Parameter (min, max, mean, median und std) zum Datensatz T_{amb}	46
Tabelle 5.1 Beispiel eines CSV-Exports für die Übergabe des Monte-Carlo-Models an TRNLizard.	61
Tabelle 5.2 Beschreibung des Datensatzes zur Durchführung der logistischen Regression mit Stichprobenumfang, arth. Mittel Mittel, Standardabweichung, Minimum, 1-3 Quartil und Maximum.	63
Tabelle 5.3 Bestimmte Regressionskoeffizienten β_k , β_0 sowie die Skalierungsfaktoren \bar{x}_k und σ_k für die ausgewählten Prädiktoren	67
Tabelle 5.4 Übersicht über die durchgeführten Simulationen	70
Tabelle C.1 Thermisch dynamische Kenngrößen der simulierten Bauweisen. Dicke in [m], U-Werte in [W/(m ² K)], Masse in [kg/m ²], Wärmebrückenzuschlag (THB) in [W/(m ² K)]	114
Tabelle C.2 In der Simulation verwendete Materialien.	115
Tabelle C.3 In der Simulation verwendete Wandaufbauten.....	116

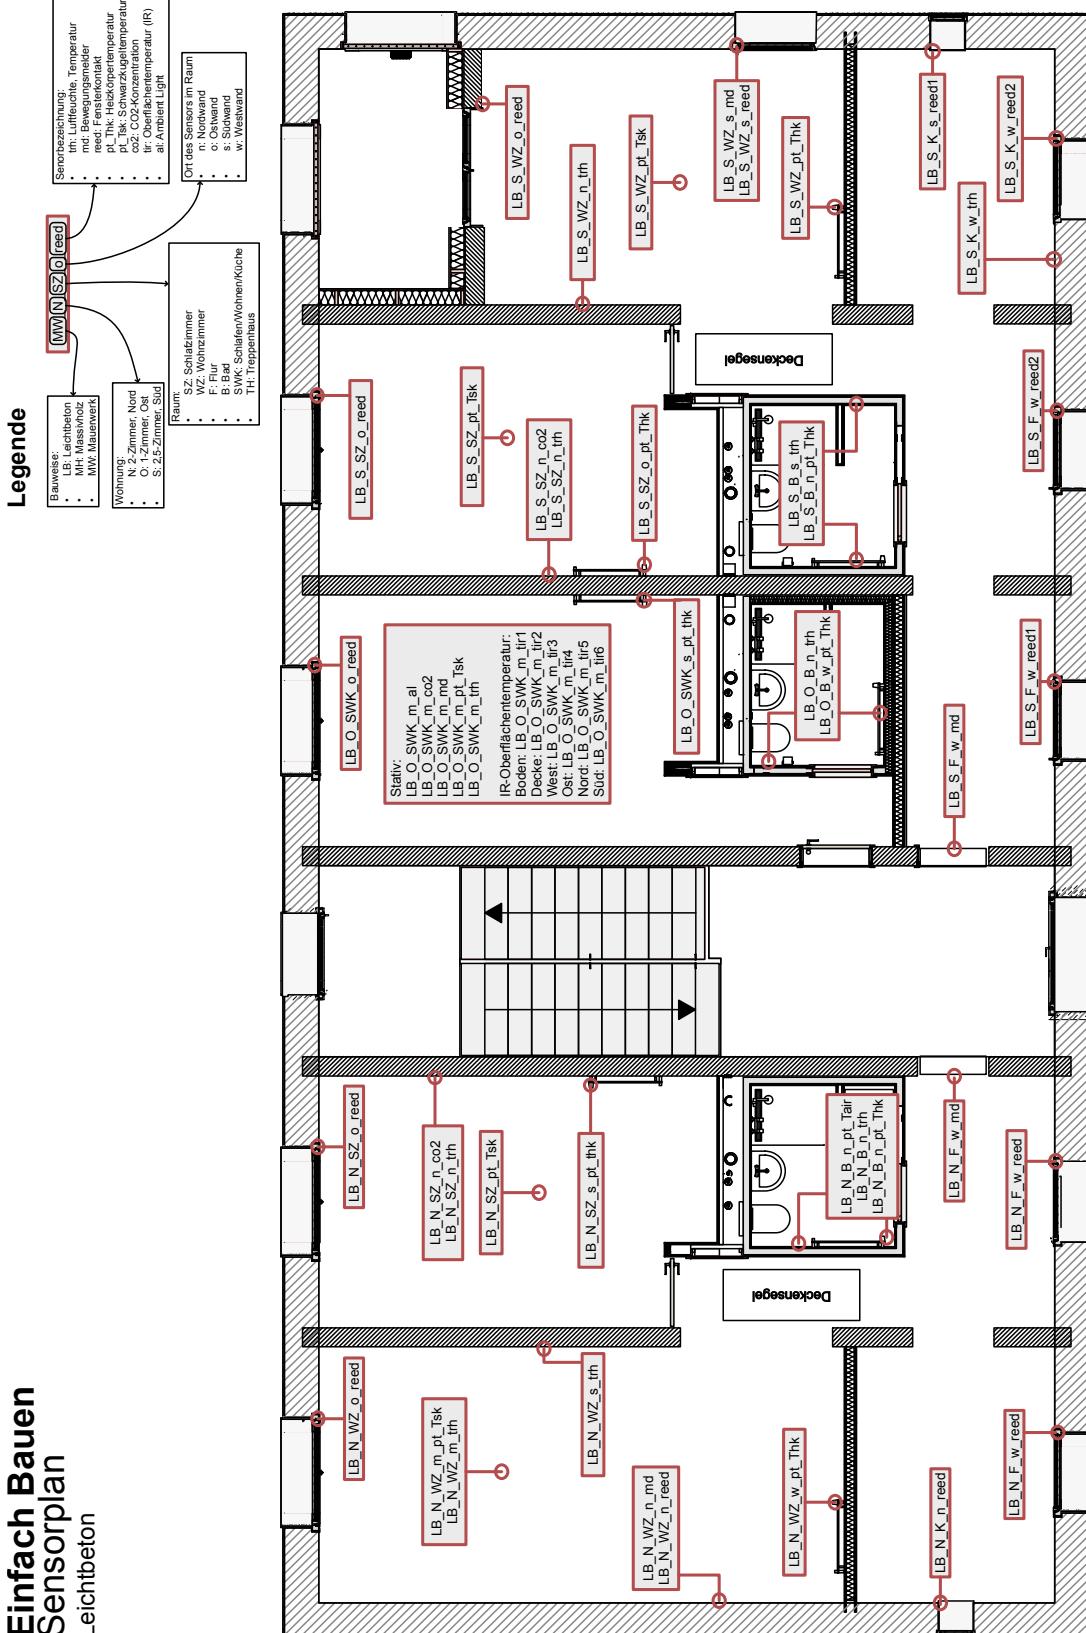
Anhang A. Messkonzept

A.1. Sensorverzeichnis

Bezeichnung	Beschreibung	Messwerte
CO2	Misst die CO_2 -Konzentration in der Luft	ppm, °C, %rH
Bewegungsmelder	Stellt Bewegungen in einem bestimmten Sichtfeld fest.	0,1
Temperatursensor	Sensor zur Messung der Umgebungstemperatur	°C
Heizkörpersensor	pt Sensor zur Messung der Oberflächentemperatur der Heizkörper	°C
Schwarzkugelthermometer	Sensor zur Messung der Schwarzkugeltemperatur	°C
Fensterkontakt (auch <i>reed</i>)	Stellt fest, ob ein Fenster geöffnet oder geschlossen ist.	0,1
TRH-Sensor	Sensor zur Messung der Lufttemperatur und rel. Feuchte.	°C, %–rH

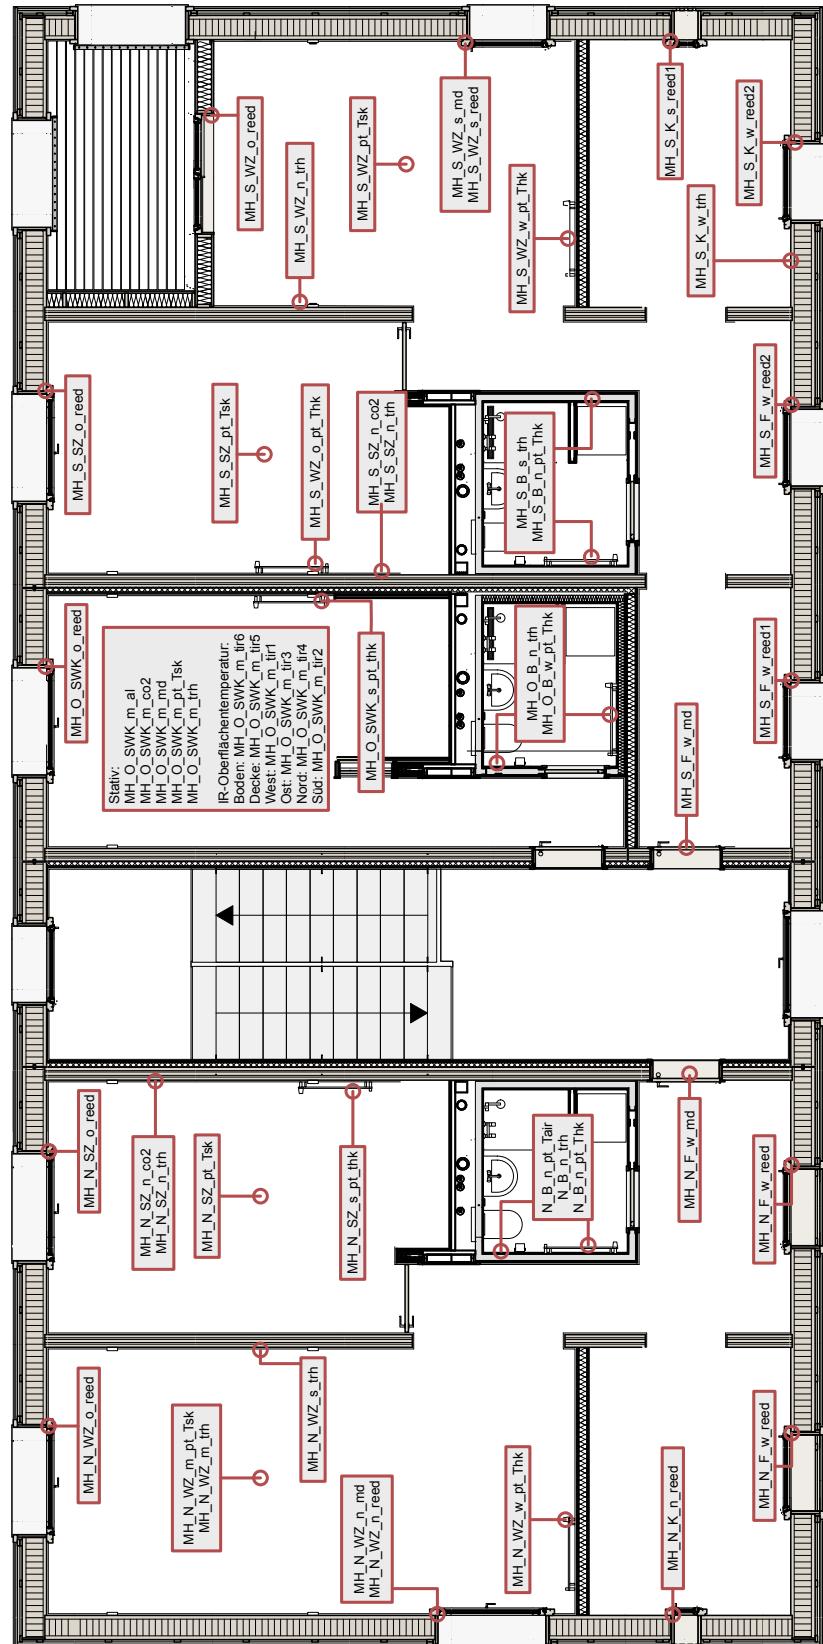
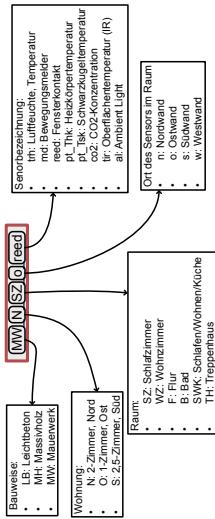
Hinweis: Das Verzeichnis enthält nur die für diese Arbeit relevanten Sensoren.

A.2. Sensorplan

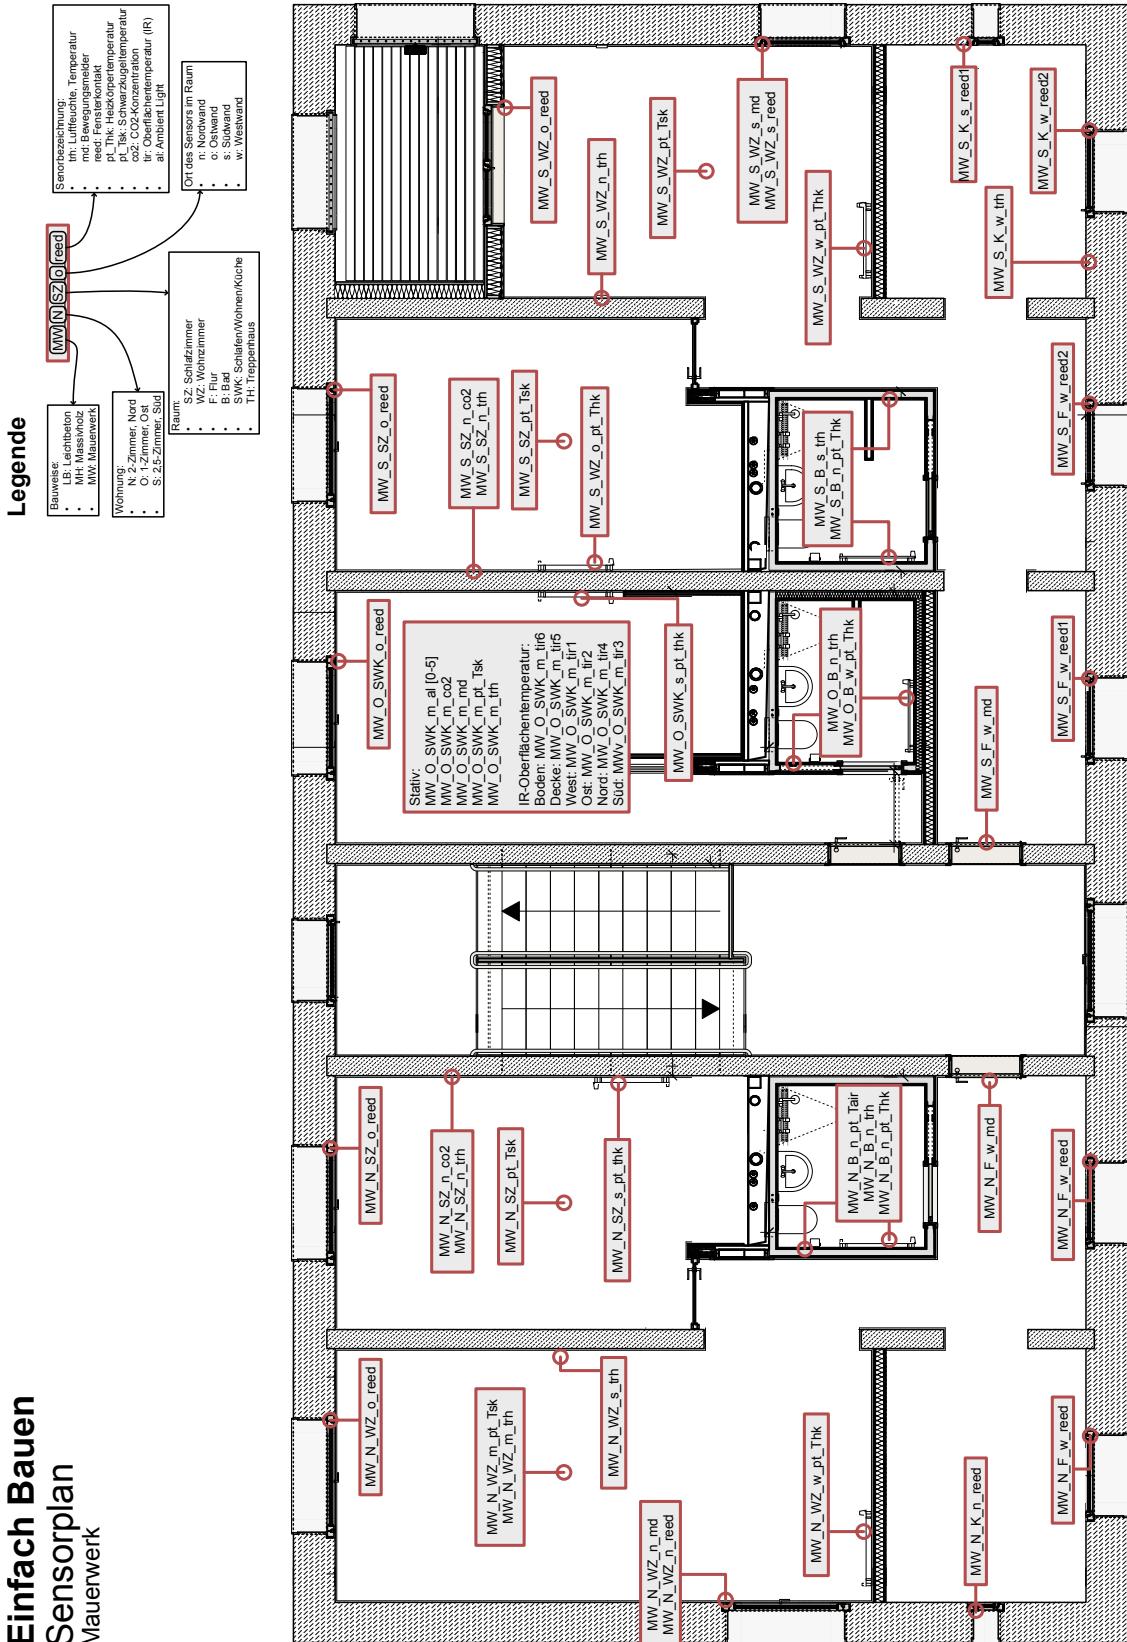


Einfach Bauen Sensorplan Massivholz

Legende

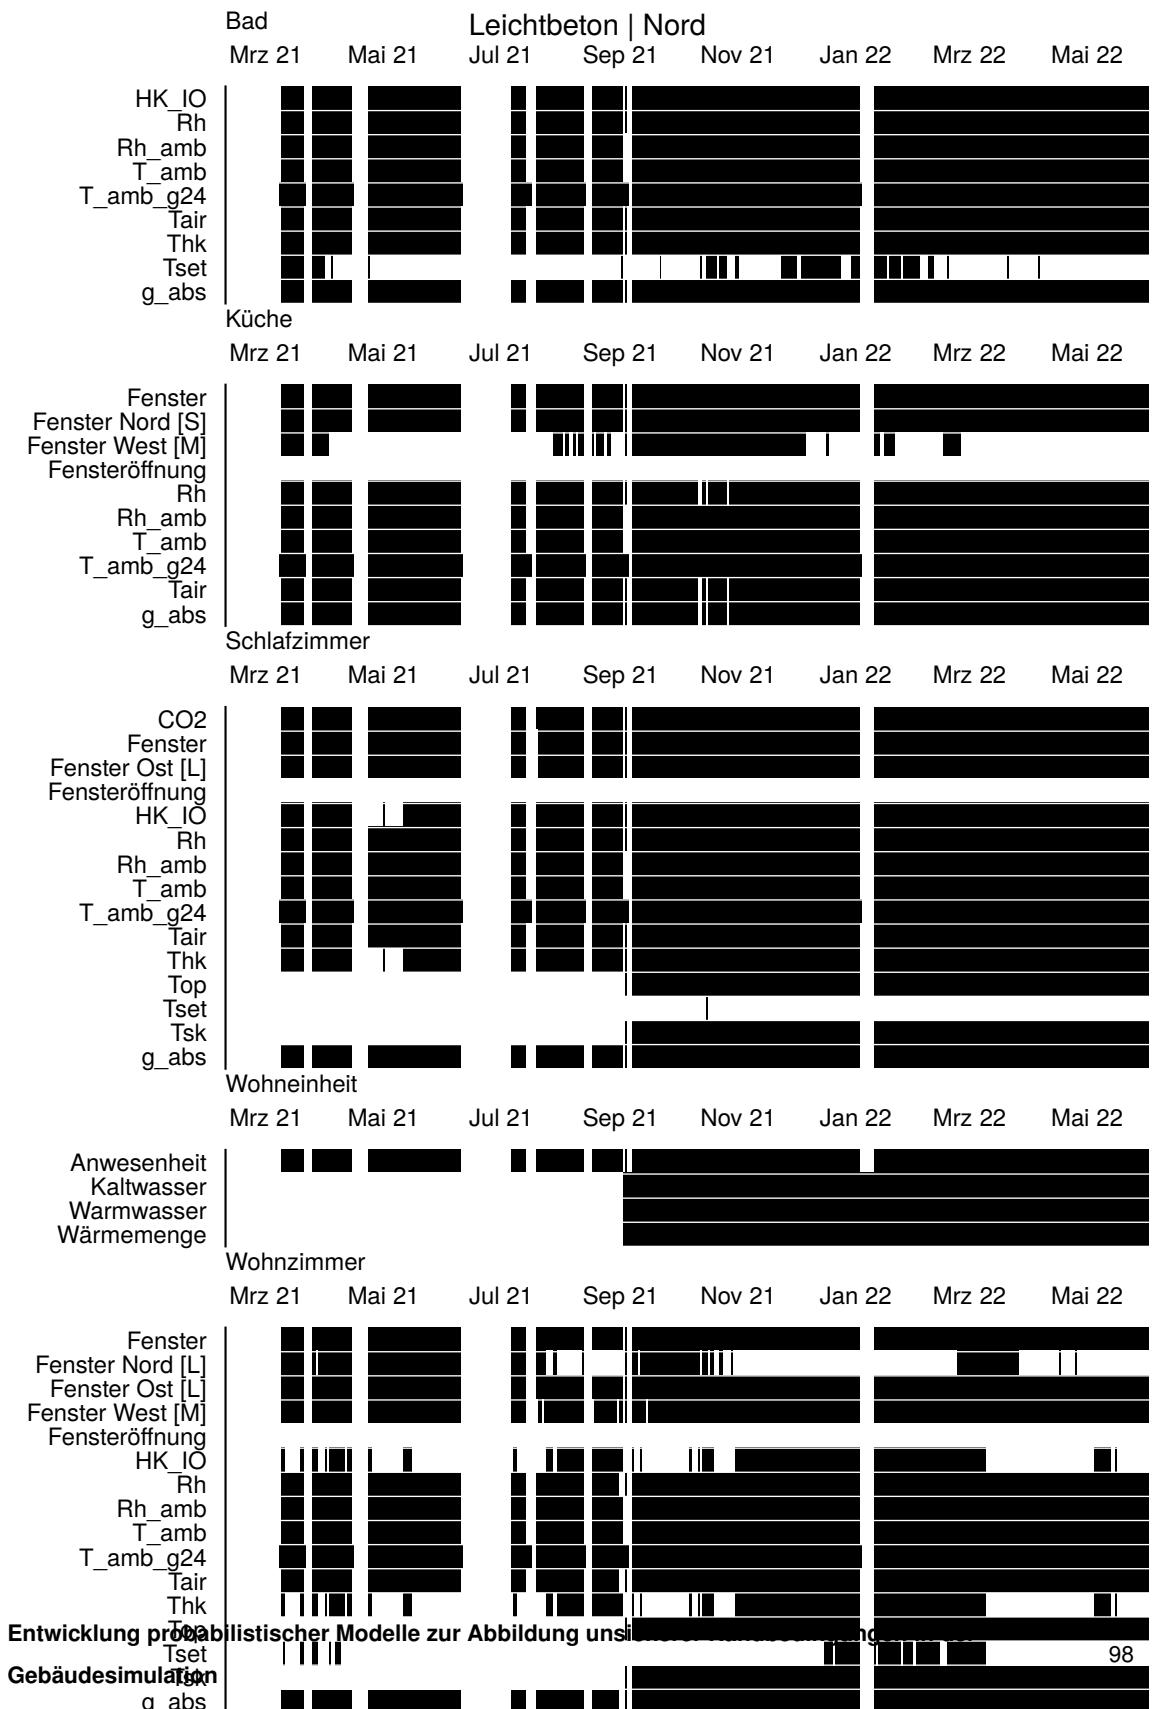


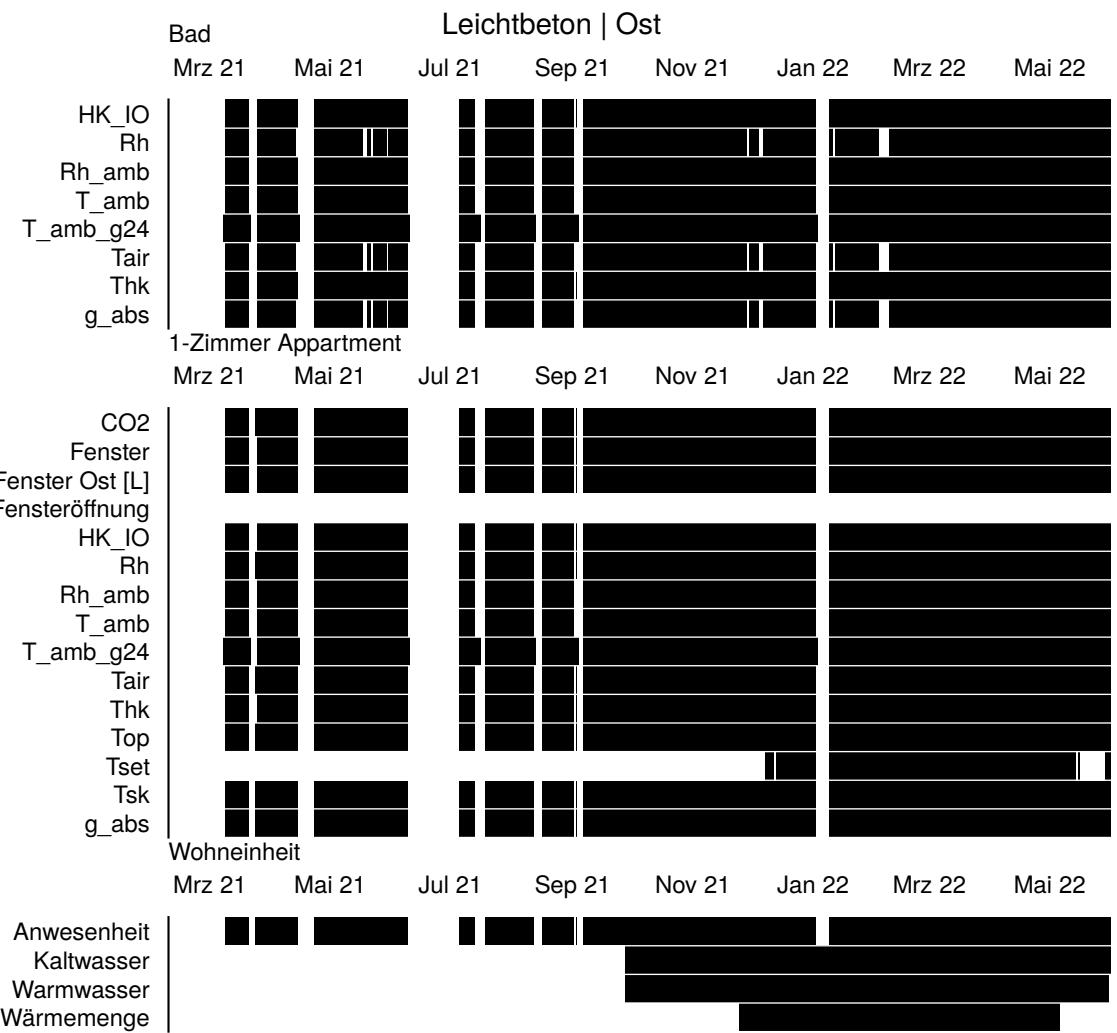
Einfach Bauen
Sensorplan
Mauerwerk

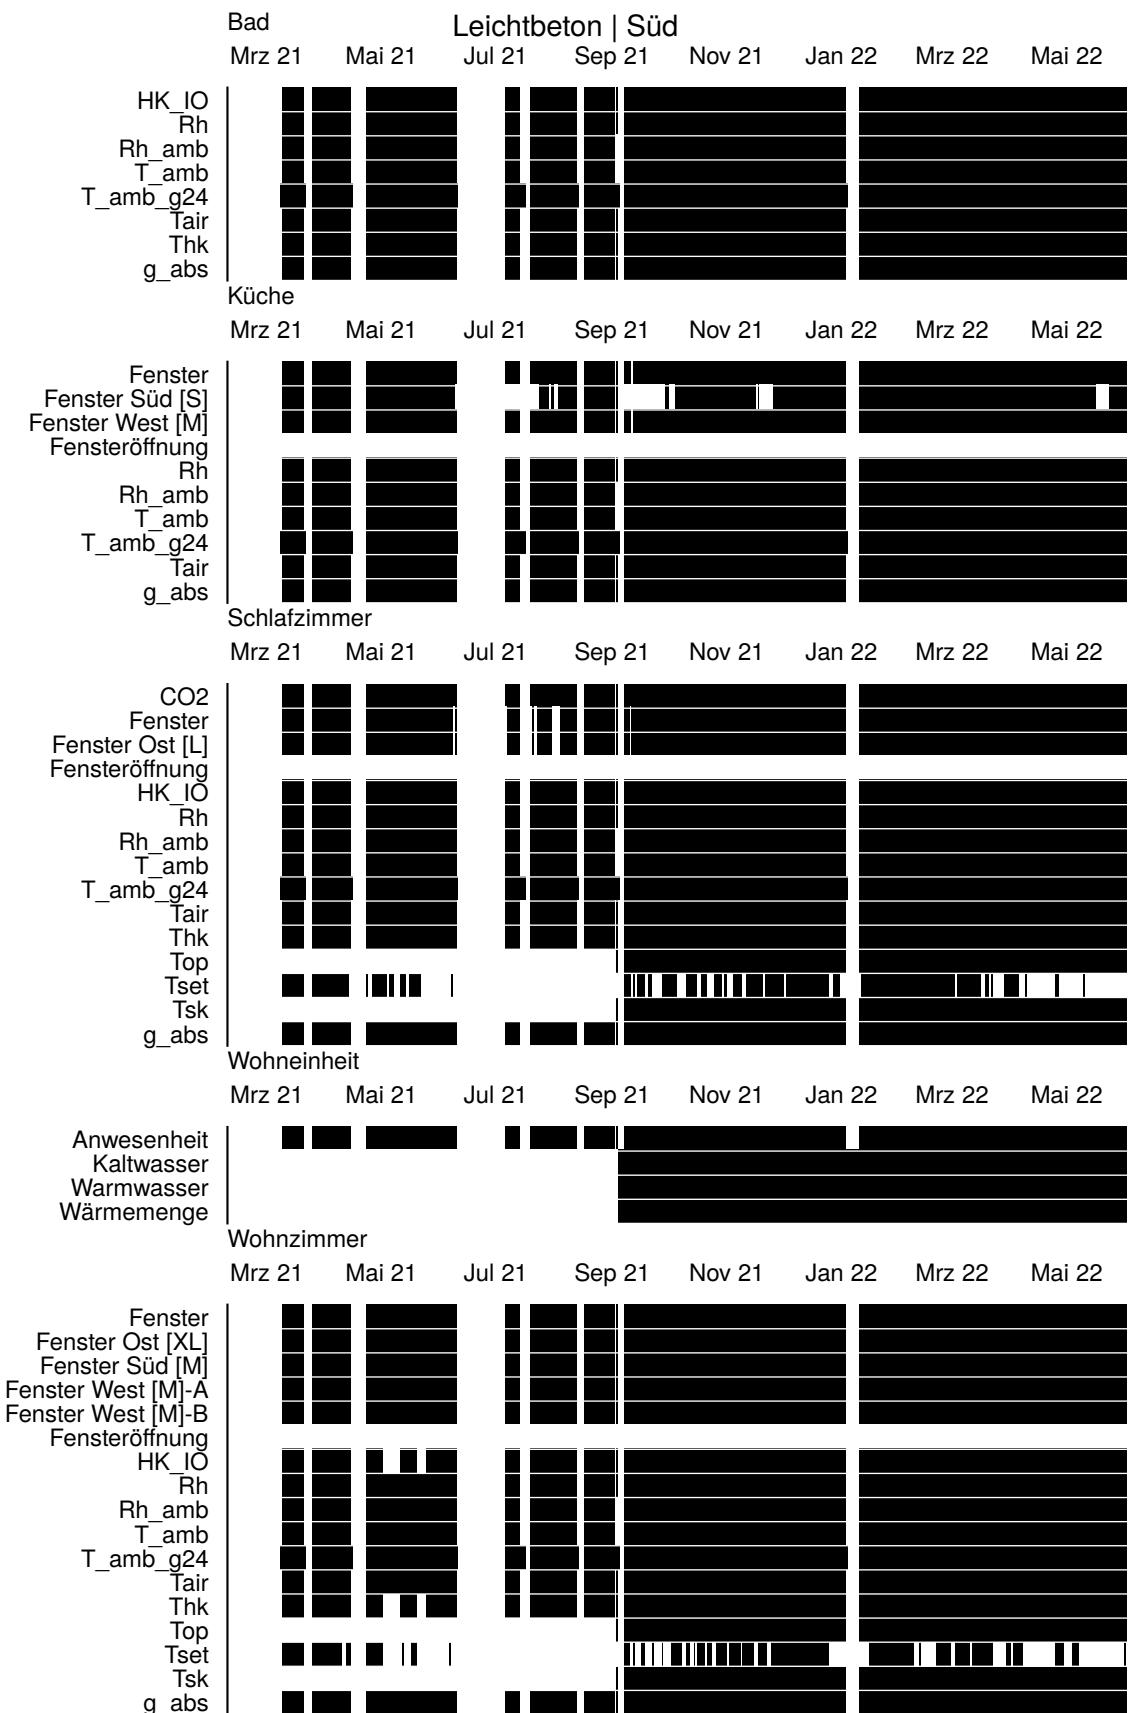


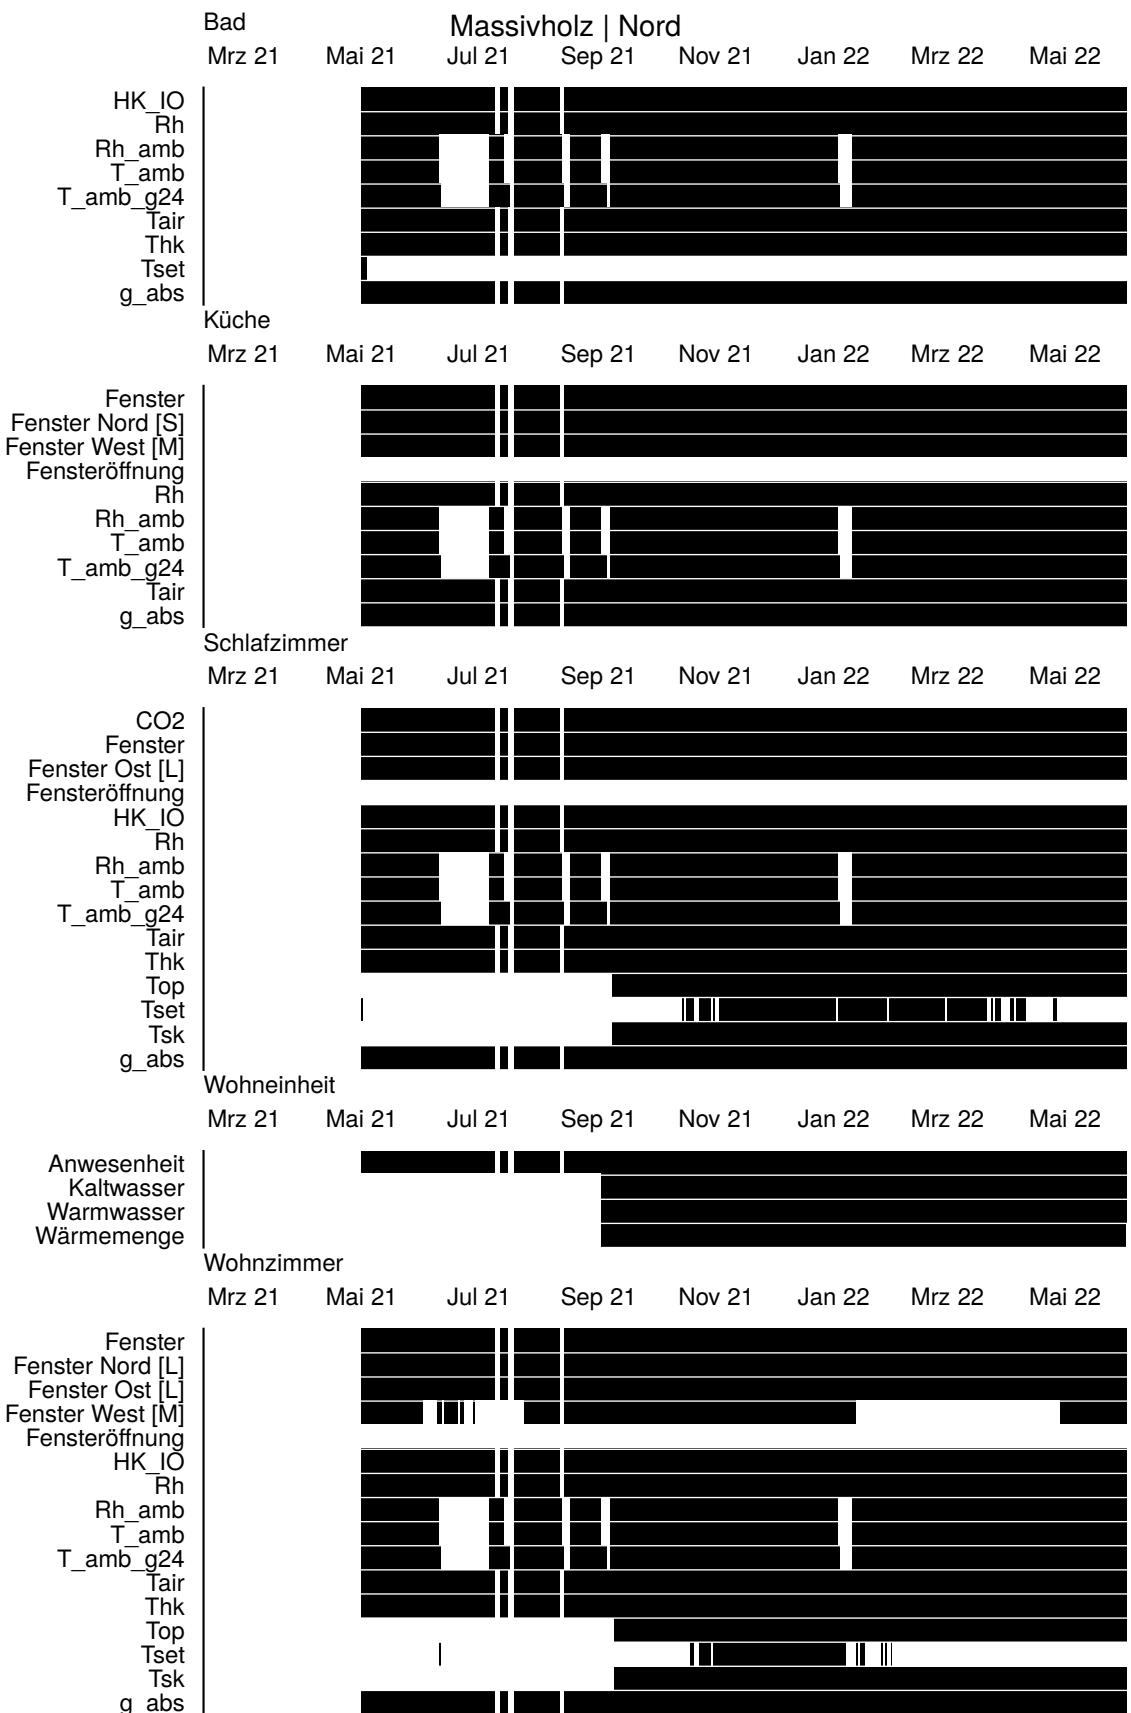
Anhang B. Zusätzliche Auswertungen des Datensatzes

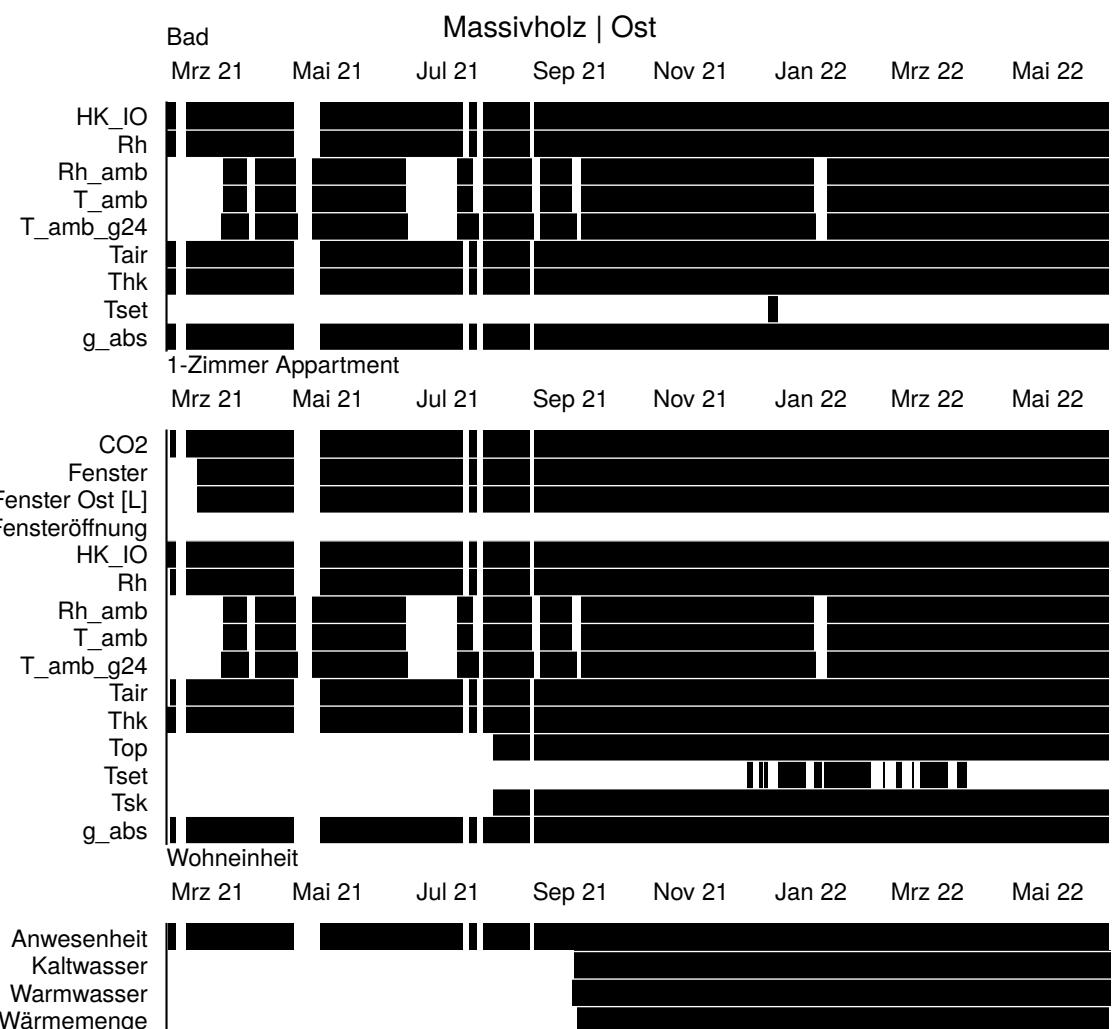
B.1. Missing Data

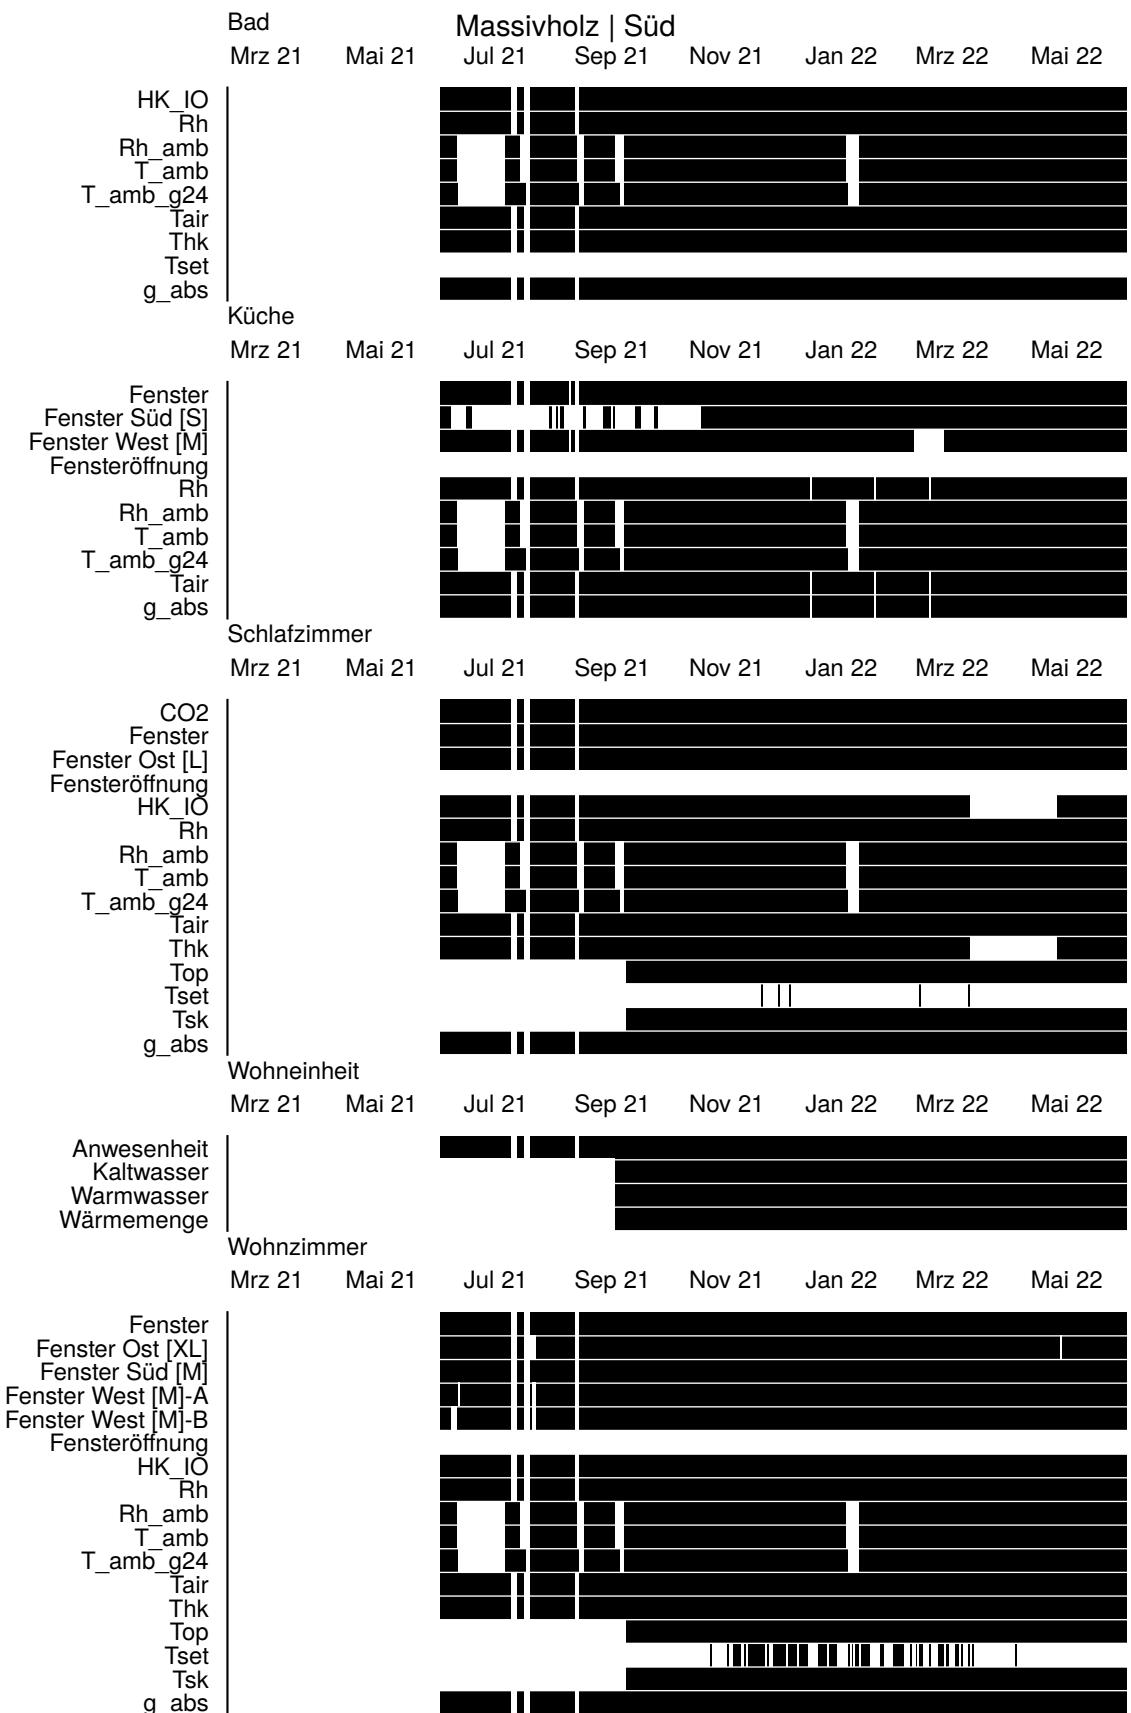


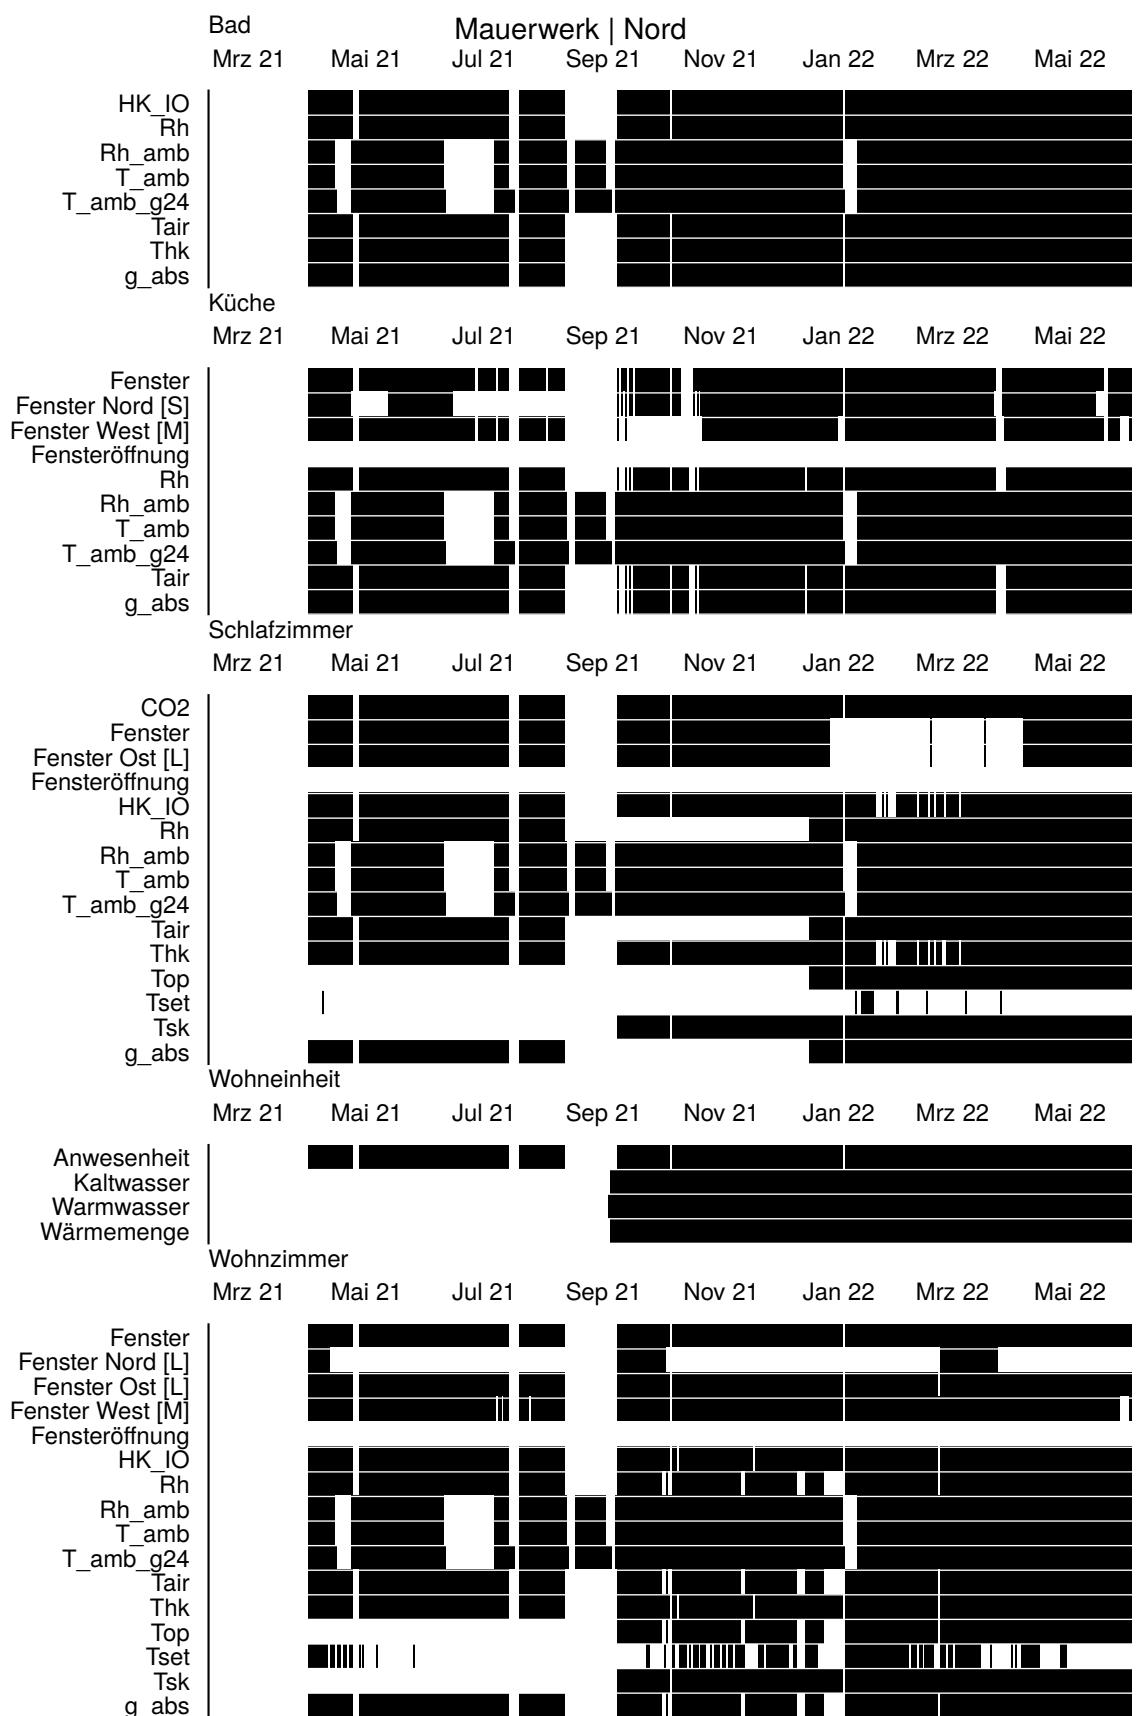


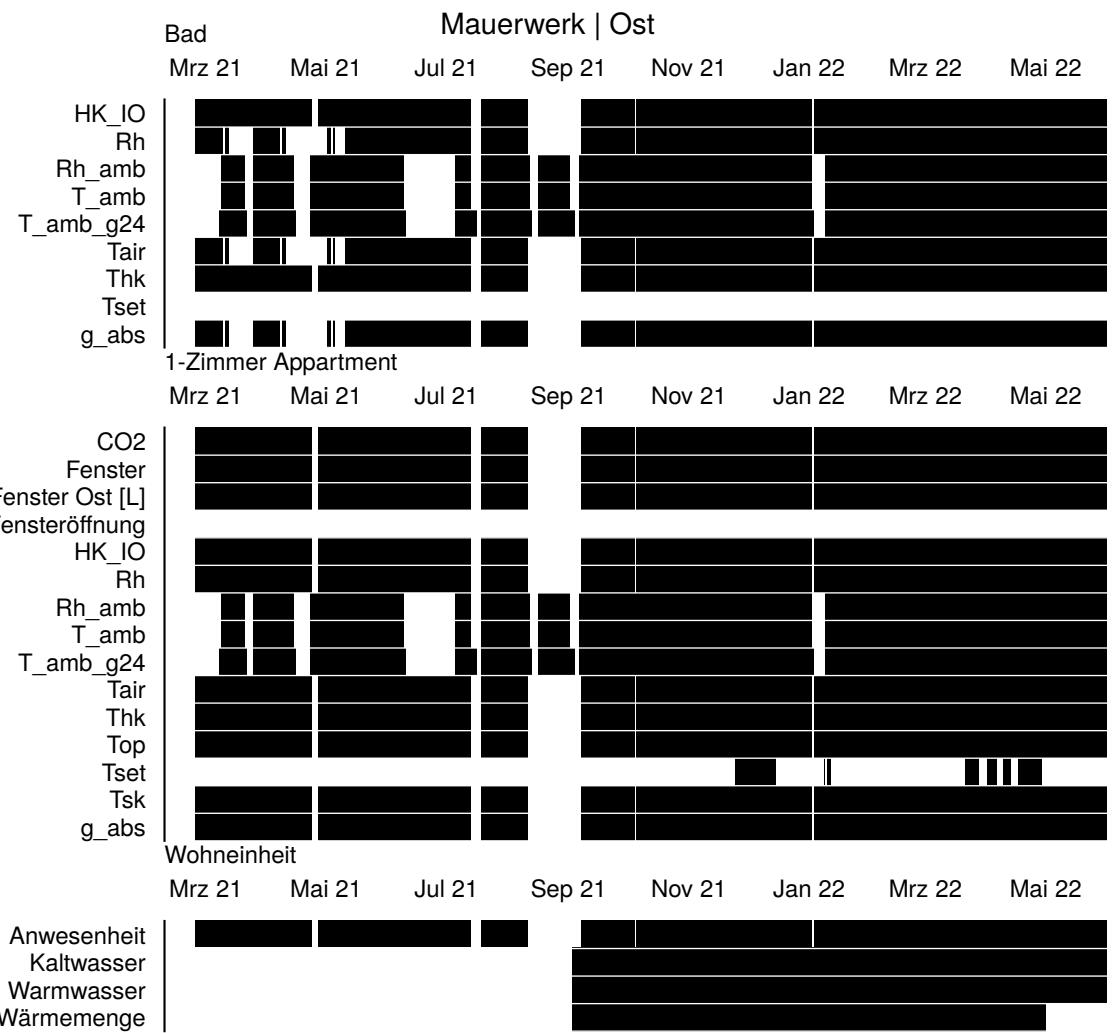


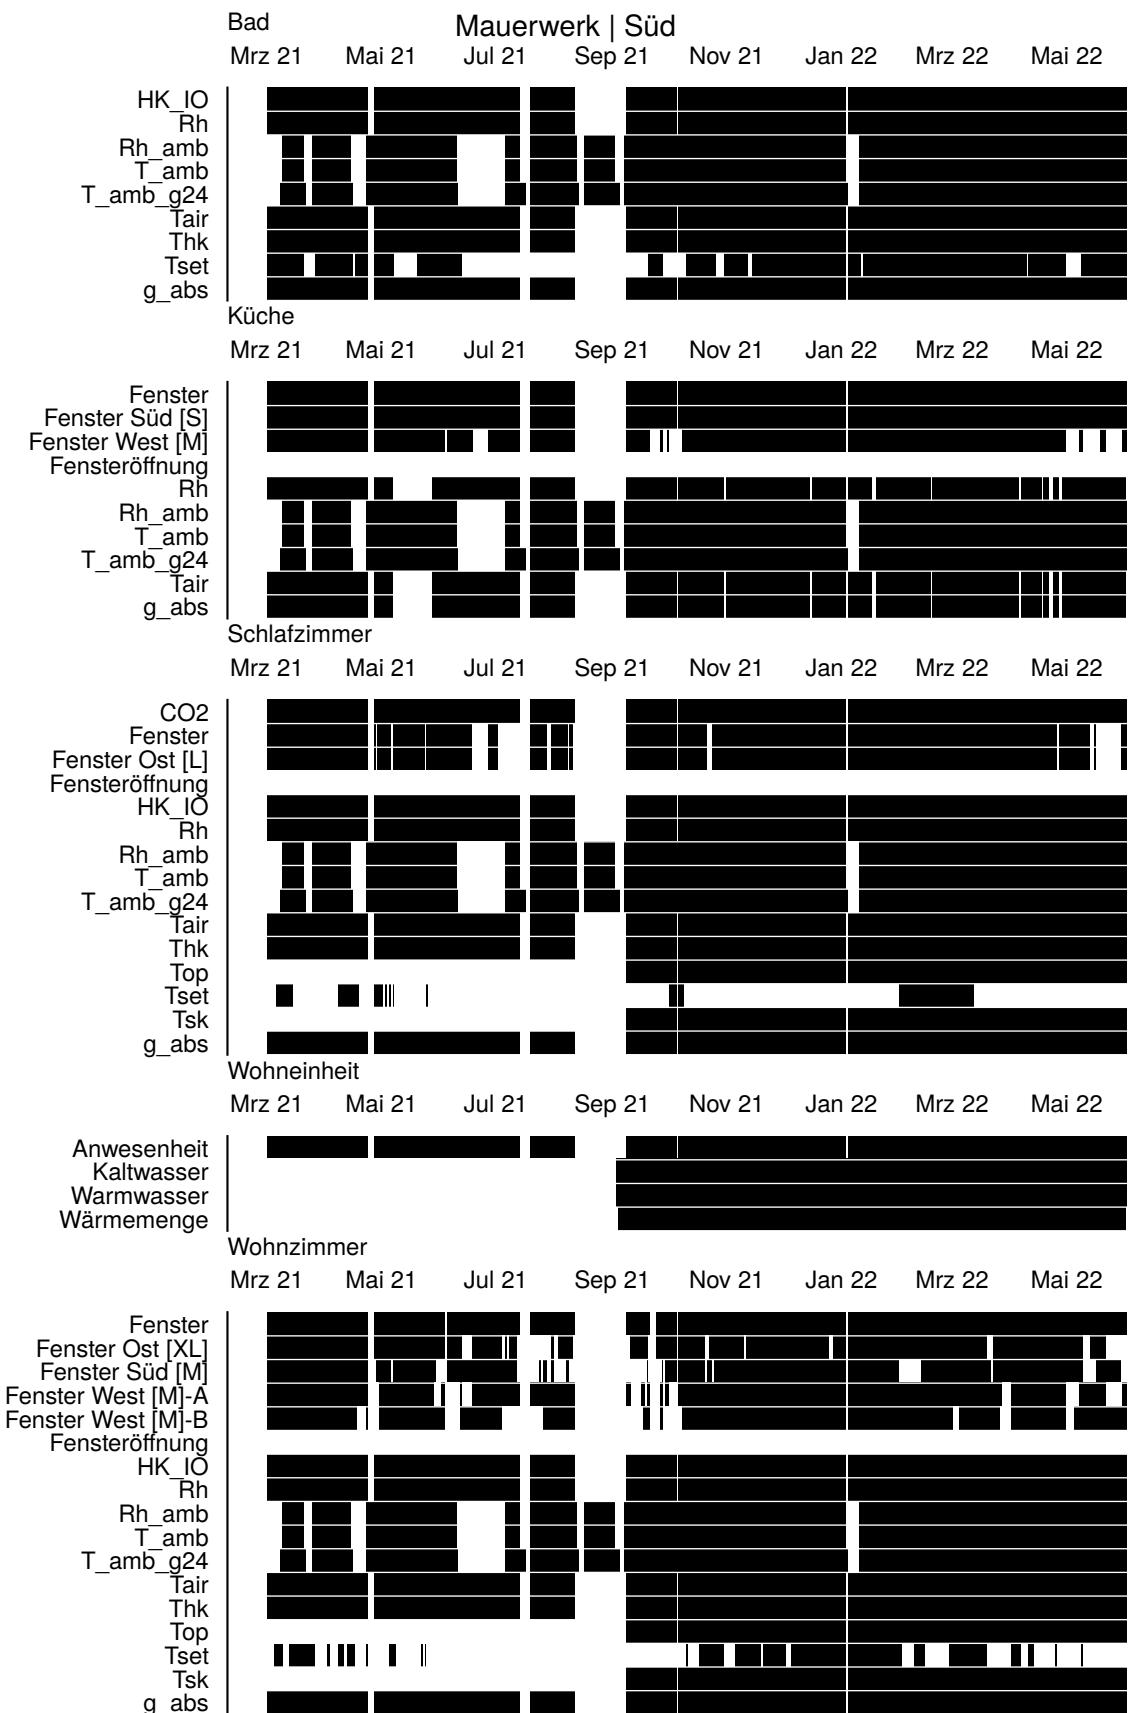




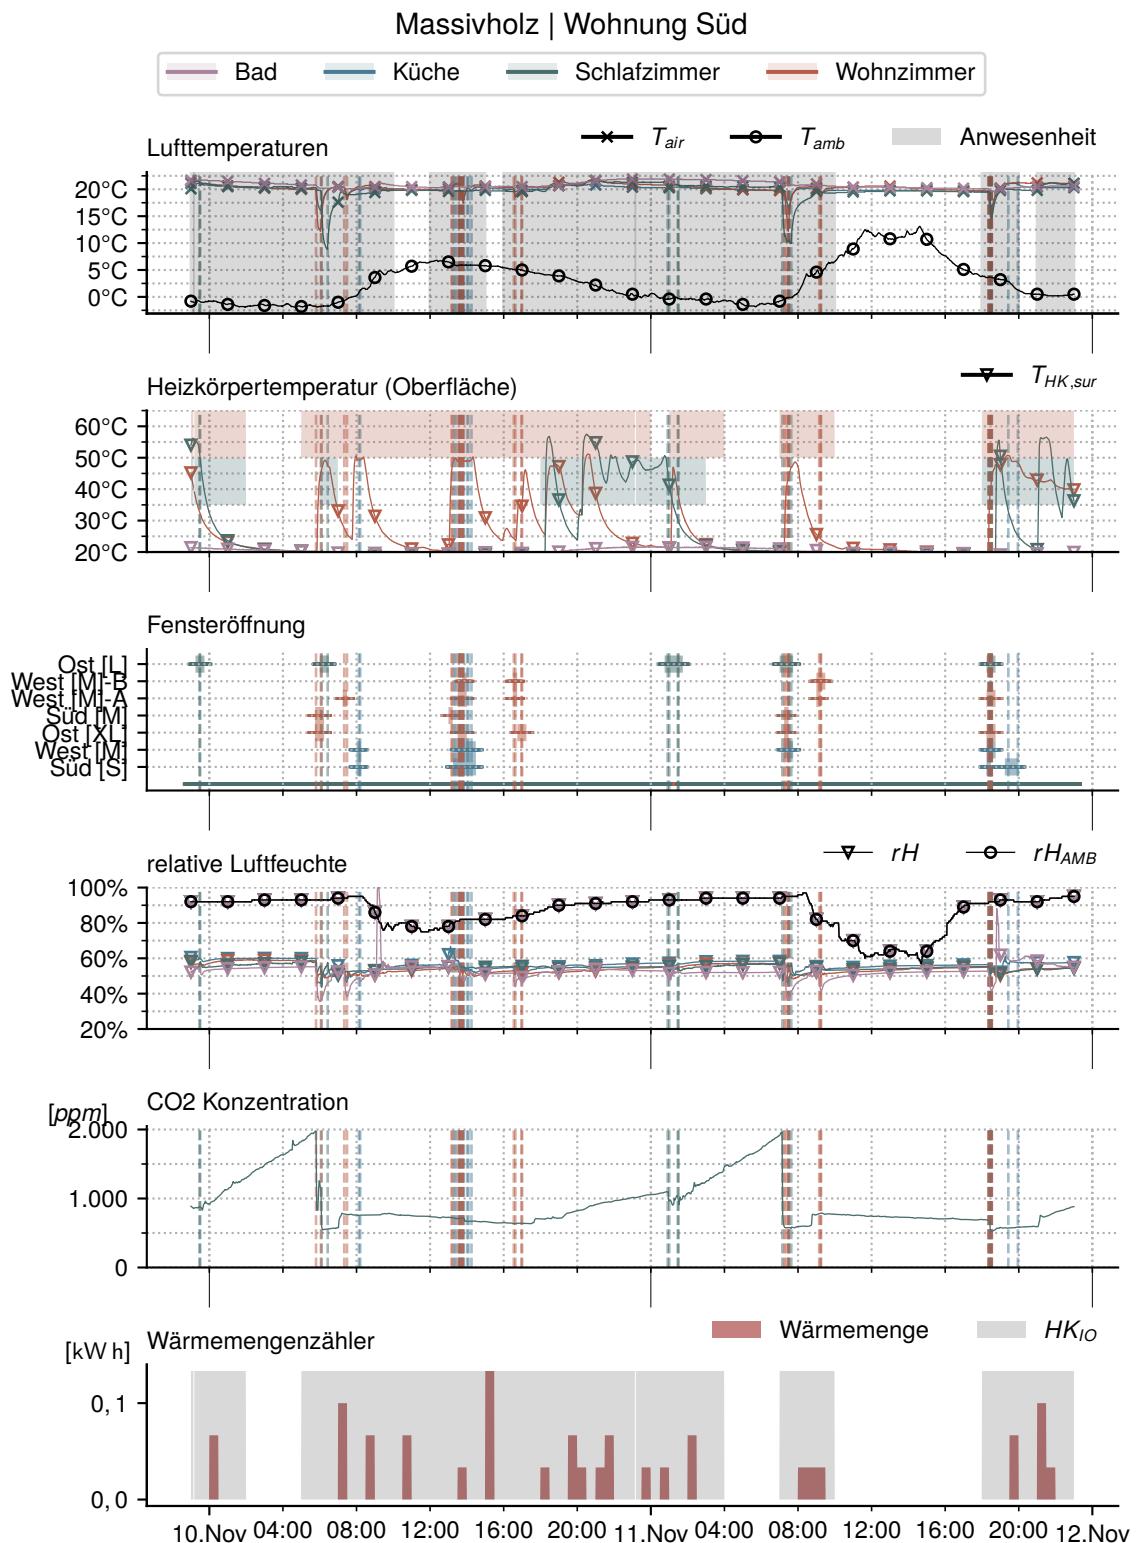






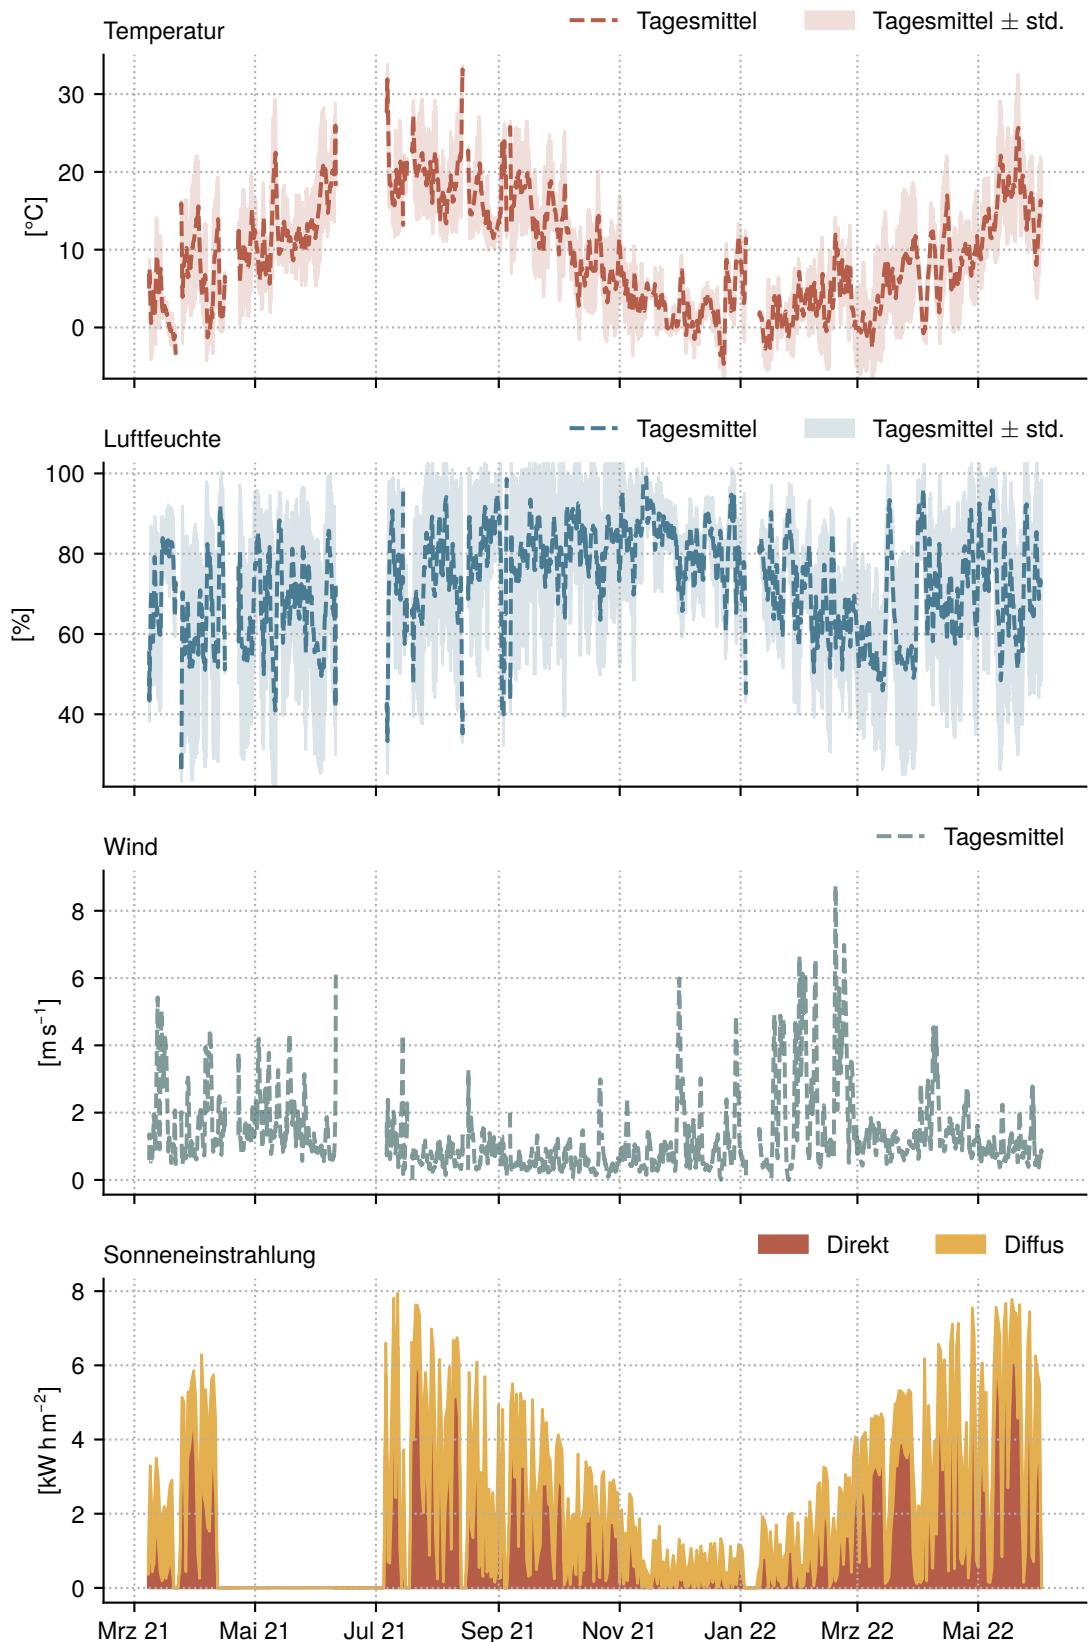


B.2. Übersicht der Messungen in einer Wohnung

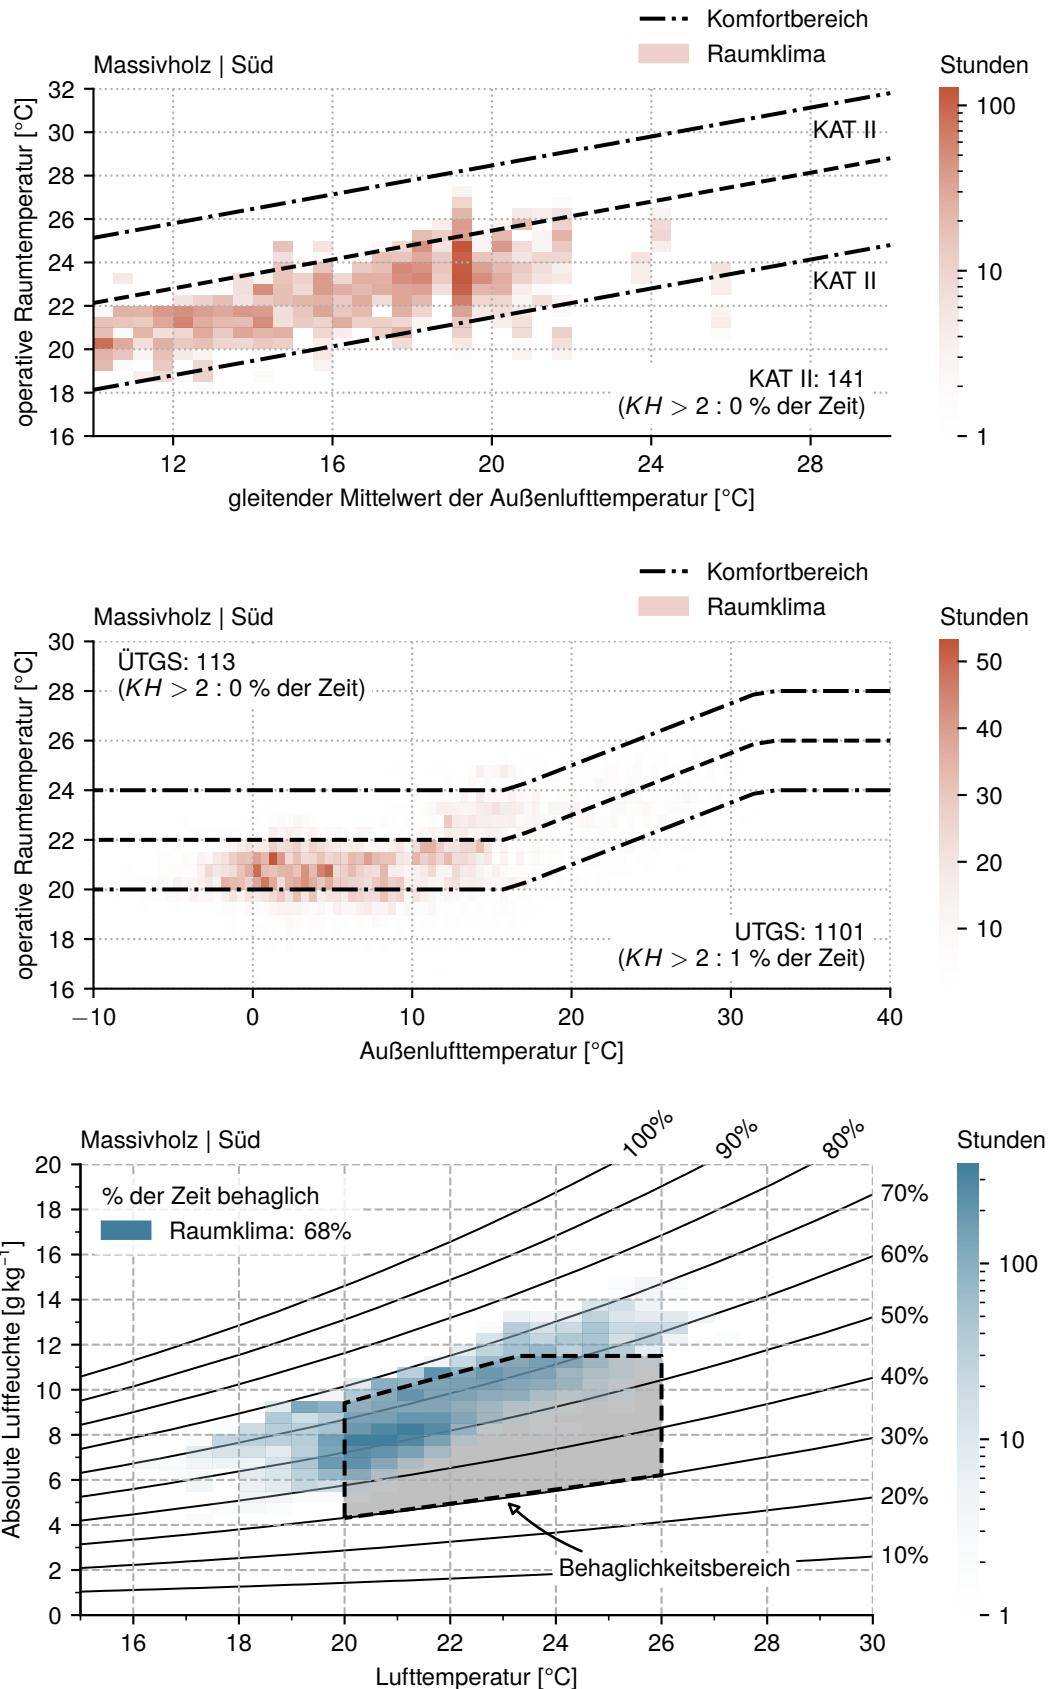


Hinweis: Dieser Plot lässt sich über das im digitalen Anhang enthaltene Datei `Übersichtsplot.ipynb` für eine beliebige Wohnung für einen beliebigen Zeitraum erstellen.

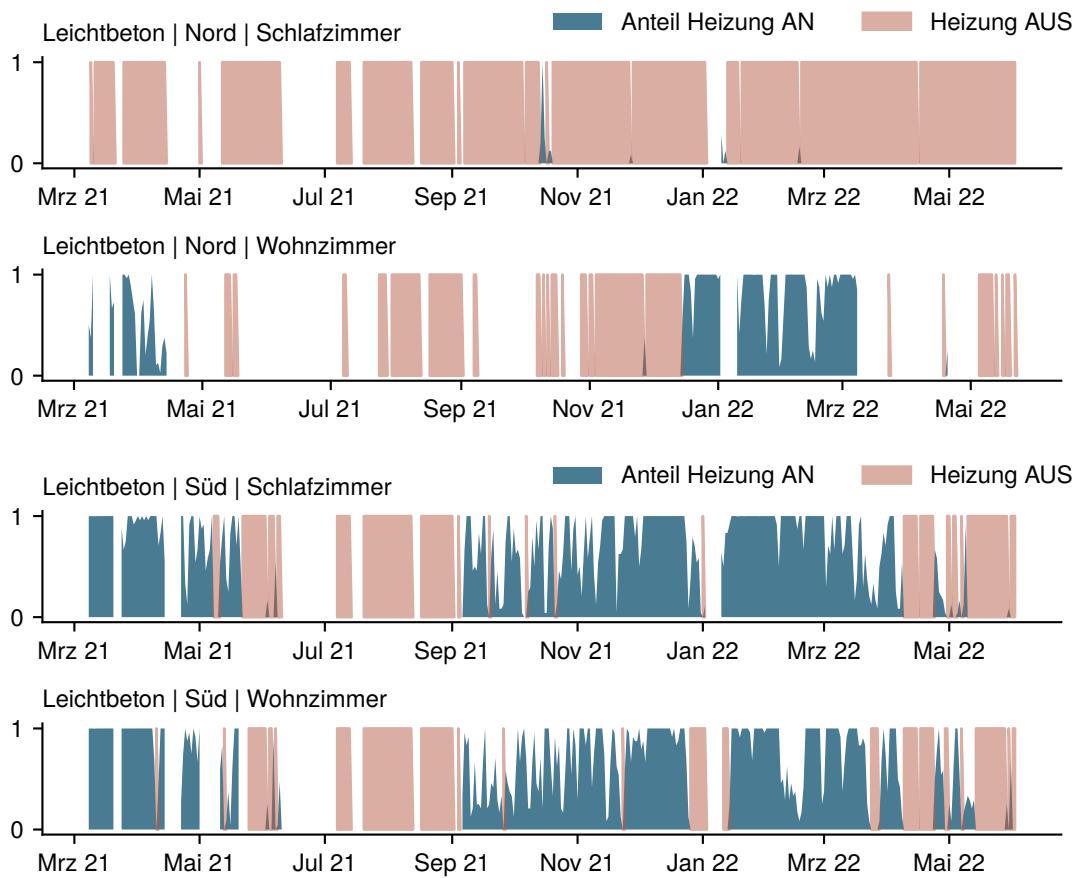
B.3. Übersicht Wetterdaten

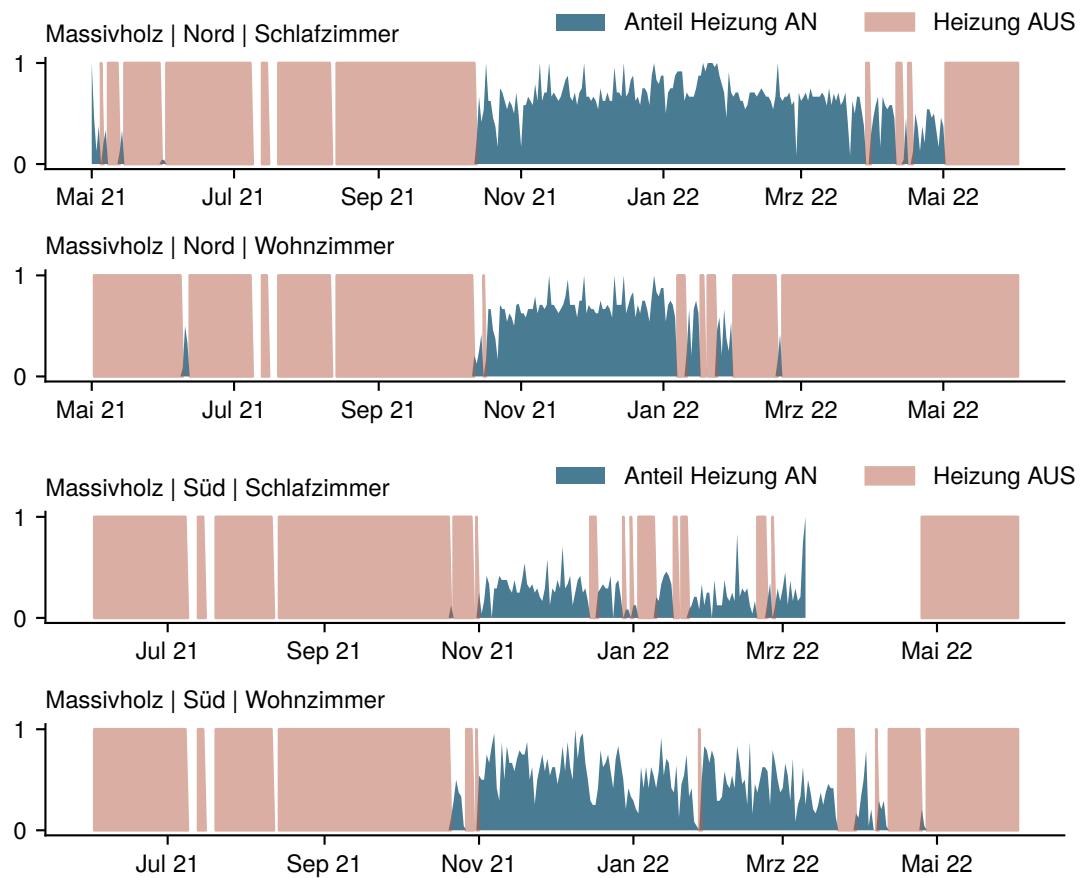


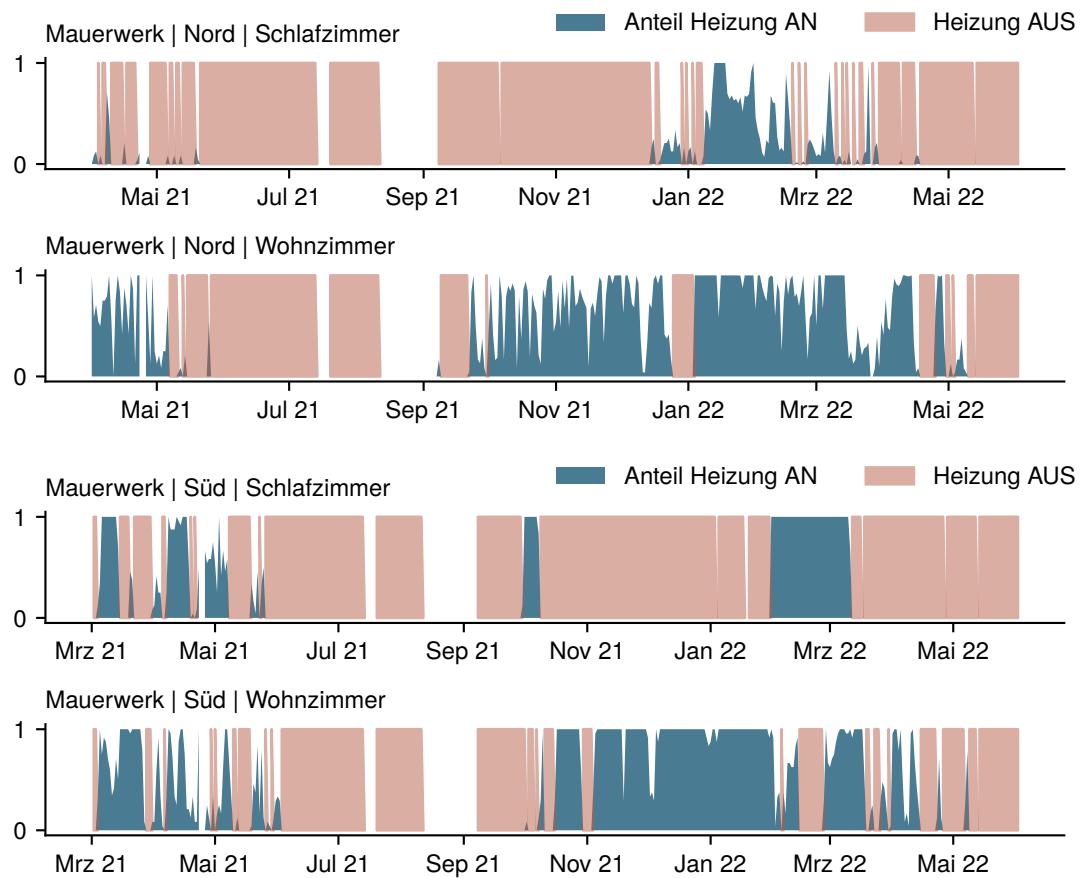
B.4. Beispiel der verwendeten adaptiven Komfortgraphen



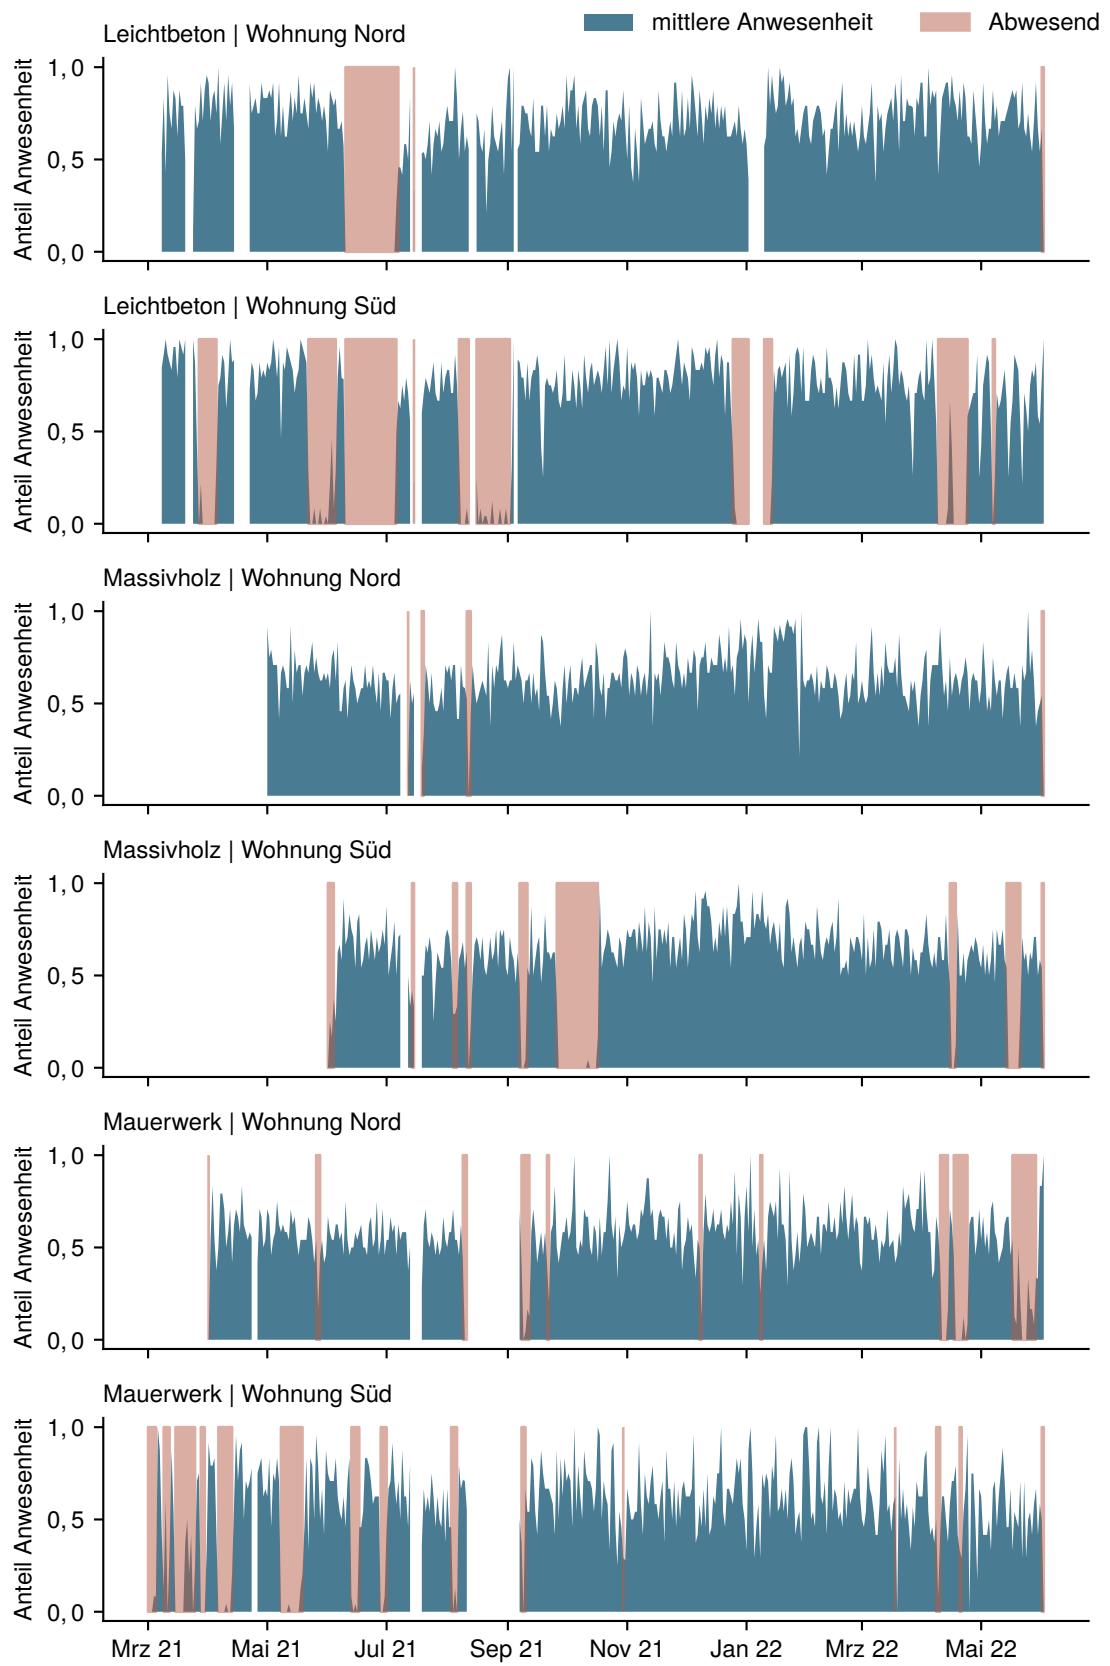
B.5. Clustering der Heizkörperaktivierung zur Ermittlung von Heiztagen







B.6. Clustering des Anwesenheitssignals zur Ermittlung von längerer Nichtnutzung.



Anhang C. Simulation

C.1. Bauweisen

Tabelle C.1 Thermisch dynamische Kenngrößen der simulierten Bauweisen. Dicke in [m], U-Werte in [W/(m² K)], Masse in [kg/m²], Wärmebrückenzuschlag (THB) in [W/(m² K)]

Variante	Bezeichnung	Dicke	U-Wert	Masse	THB
		[m]	[W/(m ² K)]	[kg/m ²]	W K/m ²
Leichtbeton	LB_AW	0,5	0,357	160	0,018
	LB_IW_L	0,24	3,45	576	0,018
	LB_IW_H	0,24	3,45	576	0,018
	DA	0,45	0,161	12,5	0,018
	BO	0,3	3,45	720	0,018
Massivholz	MH_AW	0,3	0,224	150	0,024
	MH_IW_L	0,16	0,665	65,6	0,024
	MH_IW_H	0,2275	0,318	32,8	0,024
	DA	0,45	0,161	12,5	0,024
	BO	0,3	3,45	720	0,024
Mauerwerk	MW_AW	0,445	0,249	30	0,023
	MW_IW_L	0,13	0,366	15	0,023
	MW_IW_H	0,25	3,32	9	0,023
	DA	0,45	0,161	12,5	0,023
	BO	0,3	3,45	720	0,023
GEG	GEG_AW	0,36	0,202	7,5	0,05
	GEG_IW_L	0,16	0,257	9	0,05
	GEG_IW_H	0,205	2,62	27	0,05
	GEG_DA	0,47	0,205	120	0,05
	GEG_BO	0,35	0,687	600	0,05

C.2. Materialien

Tabelle C.2 In der Simulation verwendete Materialien.

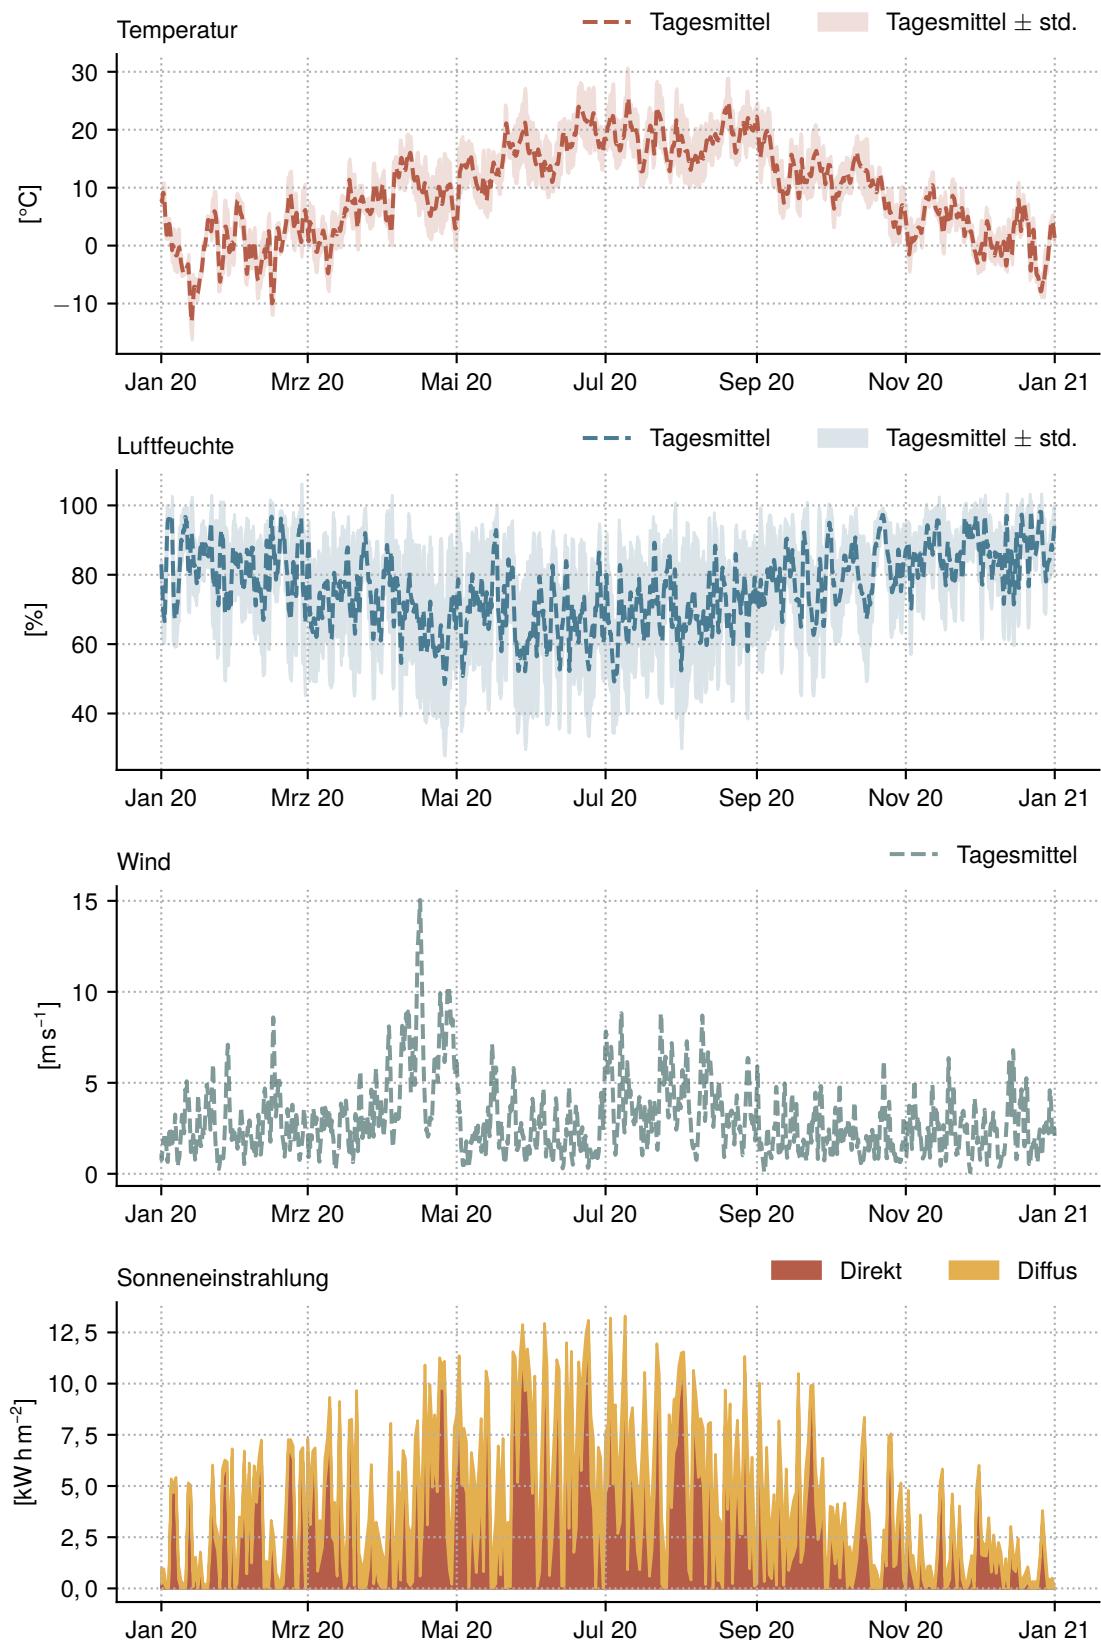
Name	Conductivity [kJ/(h m K)]	Resistance [K m ² h/kJ]	Capacity [kJ/(kg K)]	Density [kg/m ³]
SICHTBETONDECKE	9.00		1.00	2400
DIRECT		0		
HOLZFASER	0.15		2.10	50
SCREED	5.04		1.00	2000
SUBSONIC	0.16		1.00	96
KALKZEMENTPUTZ	3.13		1.00	1800
MAUERWERK	3.56		0.94	2000
AUSSENPUTZ_KALK	3.24		1.00	1500
MINERALWOLLE	0.13		0.60	100
ZEMENTESTRICH	5.04		1.00	2000
LEICHTBAUPLATTE	0.65		1.00	600
LEICHTBETON_NEU	0.68		0.95	800
NORMALBETON	7.20		1.00	2400
HOLZ	0.25		1.60	500
BS_HOLZ	0.43		1.60	410
GELOCHTER_ZIEGEL	0.40		0.94	600
HOCHLOCHZIEGEL	7.20		0.92	2000

C.3. Wandaufbauten

Tabelle C.3 In der Simulation verwendete Wandaufbauten.

Name	Layer	Thickness [m]	Name	Layer	Thickness [m]
BO	SICHTBETONDECKE	0.3		LEICHTBETON_NEU	0.3
	SICHTBETONDECKE	0.2	LB_AW	DIRECT	0.0
DA	DIRECT	0.0		LEICHTBETON_NEU	0.2
	HOLZFASER	0.25	LB_IW_H	NORMALBETON	0.24
	KALKZEMENTPUTZ	0.005	LB_IW_L	NORMALBETON	0.24
	MAUERWERK	0.175	MH_AW	HOLZ	0.3
GEG_AW	AUSSENPUTZ_KALK	0.015		LEICHTBAUPLATTE	0.0125
	MINERALWOLLE	0.16		BS_HOLZ	0.08
	AUSSENPUTZ_KALK	0.005	MH_IW_H	MINERALWOLLE	0.055
	ZEMENTESTRICH	0.06		BS_HOLZ	0.08
GEG_BO	MINERALWOLLE	0.04	MH_IW_L	BS_HOLZ	0.16
	SICHTBETONDECKE	0.25		KALKZEMENTPUTZ	0.005
	SICHTBETONDECKE	0.25		GELOCHTER_ZIEGEL	0.22
GEG_DA	MINERALWOLLE	0.16	MW_AW	DIRECT	0.0
	ZEMENTESTRICH	0.06		GELOCHTER_ZIEGEL	0.2
	KALKZEMENTPUTZ	0.015		AUSSENPUTZ_KALK	0.02
GEG_IW_H	MAUERWERK	0.175		KALKZEMENTPUTZ	0.005
	KALKZEMENTPUTZ	0.015	MW_IW_H	HOCHLOCHZIEGEL	0.24
	KALKZEMENTPUTZ	0.005		KALKZEMENTPUTZ	0.005
	LEICHTBAUPLATTE	0.0125		LEICHTBAUPLATTE	0.025
GEG_IW_L	MINERALWOLLE	0.125	MW_IW_L	MINERALWOLLE	0.08
	LEICHTBAUPLATTE	0.0125		LEICHTBAUPLATTE	0.025
	KALKZEMENTPUTZ	0.005		SICHTBETONDECKE	0.3
	V_WALL			DIRECT	0.0

C.4. Wetterdatensatz



Anhang D. Digitaler Anhang

Die im Rahmen dieser Arbeit erstellten Analysen, Auswertungen und Vorlagen können über den folgenden Link heruntergeladen werden.

<https://github.com/Ramonfi/ModellingOccupantBehavior>

